PROSAFEPRUNE：PROJECTED SAFETY PRUNING FOR MITIGATING OVER-REFUSAL IN LLMS

陈子君 [1,2], 胡文博 [1,*], 李娅 [2], 苗磊 [2], 胡国平 [2], and 洪日昌 [1]

[1] 合肥工业大学，chenzijun@mail.hfut.edu.cn, hongrc.hfut@gmail.com

[2] 科大讯飞研究院，中国合肥，{ 亚丽、雷谋、国平胡} @iflytek.com *通讯作者：wenbohu@hfut.edu.cn

摘要

大型语言模型（LLMs）在多个领域表现出色，但其安全部署面临平衡安全性与实用性的挑战。现有的对齐策略通常会强化拒绝机制以减少有害输出，但带有表面风险词汇的无害指令会被错误拒绝，这被称为*过度拒绝*。本工作首次揭示，过度拒绝源于模型内部表示空间中的*认知偏差*：LLMs 会自然地在隐藏状态中编码安全属性，而伪有害指令与有害特征重叠，导致过度有害编码。为解决这一问题，我们提出了 ProSafePrune，这是一种用于缓解过度拒绝的子空间投影低秩参数剪枝框架。通过将伪有害特征投影到子空间，并移除最具判别性的层中对应有害成分的低秩方向，我们显著降低了过度拒绝，同时保持了模型拒绝真正有害请求的能力，提升了通用任务的表现。在实验中，针对不同模型，我们的方法显著降低了平均误拒率，同时略微提升了通用任务的性能。代码：https://github.com/hfutml/PROSAFEPRUNE。

1 引言

大型语言模型（LLMs）在多个领域表现出色，但其安全部署取决于在安全性与实用性之间取得平衡（Bai 等，2022；Bianchi 等人，2024；Dai 等人，2024；Huang 等人，2024；Zou 等人，2024；Wang 等人，2026；Gou 等人，2025）。当前的对齐实践通常会强化拒绝机制以抑制有害输出，但这往往导致过度拒绝（R¨ottger 等，2024；Zhang 等，2025a）——不仅拒绝真正有害的请求，也拒绝那些仅包含表面风险提示的无害请求。这损害了可用性，长期以来一直被视为过于保守对齐的副作用。

基于这一观察，先前的研究已探索了两种主要的缓解方法。基于训练的方法（Zhang 等，2025b；Dabas 等，2025；Wu 等，2025）虽然有效，但需要额外的数据和计算资源，限制了其实用性。无训练方法（Cao 等，2025；Shi 等，2024）提供了更大的灵活性，但通常无法解决根本性的偏见问题，且经常引入额外的推理时间开销。这些局限性凸显了开发一种既轻量又能够直接针对过度拒绝根源的必要性。

相比之下，我们首先揭示，过度拒绝不仅仅是现有对齐流程的失败，而是模型内部表示空间中一种固有*认知偏差*的表现。先前的研究表明，大语言模型的隐藏状态自然地编码了输入指令的安全属性(Li 等, 2025; Zhao 等, 2025)。然而，伪有害指令通常同时投射到有害子空间和无害子空间上。在过度的安全性微调下，这种自然重叠会被扭曲：有害投影被不成比例地放大，而无害投影则被抑制。结果，良性指令被过度编码了有害特征，导致内部决策边界发生偏移，最终引发误拒。

有趣的是，这种现象——我们称之为*过度有害编码*——也揭示了对齐税(Huang 等人，2025)的来源，即模型被推向一种过于谨慎的状态，从而进一步限制了其通用任务的表现。

在本工作中，我们提出了一种新的视角来缓解过度拒绝问题，即直接作用于模型的参数空间，而非仅依赖激活层面的干预或代价高昂的再训练。我们的核心见解是，过度拒绝源于模型参数中包含过多的低秩成分，这些成分不成比例地编码了有害性，从而导致伪有害指令被错误分类。与基于训练的方法不同，我们的方法仅需少量辅助数据，且避免了昂贵的微调；与现有的无训练方法相比，它不依赖于重复的推理时调整，从而避免引入额外开销，同时能够解决根本的认知偏差。相反，我们构建子空间投影以解耦伪有害特征和有害特征，并采用低秩剪枝策略，从最具判别力的层中选择性地移除有害组件。由于这些方向仅占据参数空间的一小部分，剪枝它们可在最小程度影响模型整体行为的同时缓解过度拒绝问题，从而在安全性和实用性之间取得更好的平衡。

总之，我们的贡献如下：

- 我们发现，大语言模型中的过度拒绝现象是由内部表示中的认知偏差引起的，这是由于无害指令被过度编码了有害特征所致。
- 为解决这一问题，我们提出了 ProSafePrune，该方法从模型参数中剪除低秩有害成分，在不增加推理时开销的情况下减少过度拒绝。
- 我们发现模型内部的过度有害编码与对齐税密切相关，这限制了通用性能。我们的方法有效纠正了这一问题，从而提升了通用任务上的表现。

2 相关工作

2.1 过度-拒绝现象

大型语言模型的安全对齐技术对于减轻恶意指令带来的风险至关重要。主流方法包括监督微调（SFT）和基于人类反馈的强化学习（RLHF），其目标是防止模型生成有害内容或响应恶意请求(Bai 等, 2022; Bianchi 等, 2024)。然而，现有的安全对齐解决方案通常存在过度防御问题：模型会不必要地拒绝伪有害提示——这些输入在语义上无害，但包含表面上具有风险的词汇。学术界将这一现象定义为过度拒绝或夸大安全性（Röttger 等人，2024；Varshney 等人，2024）。例如，大语言模型仅因“kill”一词便错误地拒绝诸如“如何关闭房间的灯”这类无害请求（Cao 等人，2025）。此类行为严重削弱了模型的实用性，并凸显了无害性与有用性之间难以调和的权衡关系。

从根本上说，过度拒绝源于模型对安全信号的泛化偏差：在安全对齐过程中，模型倾向于强行将危险词汇与拒绝行为关联起来，而忽略了上下文语义上的差异。早期研究已证实，这种偏差在主流大语言模型中普遍存在，并且与模型的越狱抵抗能力呈正相关——模型越倾向于防御恶意指令，就越容易对良性提示产生过度拒绝（黄等，2024）。这一发现推动了对过度拒绝现象的系统性学术研究，涵盖评估基准构建和缓解方法设计等多个领域。尽管这些发现通常被解释为外部对齐策略的局限性，但我们认为，过度拒绝反映了模型内部表征空间中更深层次的认知偏差。换句话说，问题不仅在于对齐如何在输出层面实施，还在于安全属性如何在隐藏状态内部被编码和扭曲，从而导致伪有害指令被过度有害地编码。

2.2 过拒绝缓解

现有的缓解方法可分为两类：基于训练的和无需训练的。

基于训练的。这些方法通过调整模型参数来纠正过度拒绝问题，利用伪有害数据重新校准安全决策边界。安全修补（Zhao 等，2024）生成基于梯度的修补——增强对有害提示的拒绝能力，同时抑制对伪有害提示的拒绝——并将其整合到特定层中。Zeng 等表明，在成对的伪有害数据上进行监督微调（SFT）可减少过度拒绝。Dabas 等（2025）进一步识别出安全关键层，提取拒绝方向向量，并仅通过专用拒绝损失对这些层进行微调。

无需训练。这些方法避免参数更新，并在推理阶段进行干预。Ray & Bhalani (2024) 提出了一种基于提示的策略。Shi 等人 (2024)（Self-CD）对提示进行两次解码——一次带安全提示，一次不带，并通过概率比较抑制拒绝标记。早期工作(Zou 等人, 2023a) 识别出与拒绝相关的激活方向，该方向可被操纵以改变模型行为。在此基础上，Cao 等人 (2025) 从有害与良性激活中提取拒绝引导向量，通过词汇投影定位安全关键层，并设计了一个余弦相似性分类器以实现自适应调整。Wang 等人 (2025) 通过正交化分离真实与虚假拒绝向量，仅消融虚假向量以保留真正的安全性。

虽然有效，但基于训练的方法需要昂贵的重新训练，而无需训练的方法则在推理时增加开销，且未解决根本问题。相比之下，我们的剪枝方法在数据上高效，推理时无成本，并能直接纠正导致过度拒绝的内部认知偏差。

3 方法学

我们通过直接解决模型内部的过度有害编码来应对过度拒绝问题。首先，我们分析各层激活情况，揭示伪有害指令如何与有害特征重叠。随后，我们采用基于子空间的低秩剪枝方法，仅移除伪有害方向中的有害成分，从而在保留真实拒绝能力的同时减少过度拒绝。剪枝操作应用于特征可分性最强的层，以确保对整体效用的影响最小。

3.1 模型各层的过度有害性编码

大量研究已表明，大语言模型的隐藏状态包含丰富信息(Chen 等, 2026; Burns 等, 2023; Chen 等, 2025; Skean 等, 2025），其中包括对指令有害性的表征。这种有害性编码可能会影响模型的最终输出决策，过度的有害性编码可能是导致过度拒绝现象的一个促成因素。为探究该现象的内在机制，我们分析了大语言模型在不同层面对伪有害指令的激活分布，旨在揭示模型内部各层中有害性表征的演化过程。

为了分析指令的有害性编码，我们使用探针（Alain & Bengio，2016），这些探针通过基于模型各层提取的激活向量来预测指令的有害性。具体而言，对于模型第l层的每个权重矩阵$W_{l,m}$，我们提取输入指令x,的激活输出，然后通过均值池化将其压缩为一个向量。对安全指令和有害指令训练一个逻辑回归分类器，该分类器用于预测伪有害指令的有害性。更多细节见附录 A.1。

如 1 所示，伪有害指令在 LLaMA-2-7 B 和 LLaMA-3-8 B 中的逐层有害性编码。我们观察到，LLaMA-2 在深层中表现出更强的有害性信号，这与其相比 LLaMA-3 更高的误拒率相关。

3.2 基于子空间的参数剪枝

探测实验表明，在严重过度拒绝的模型中，伪有害指令在其高层隐藏表示中保留了过多的有害成分，与真正有害的特征重叠。尽管该模型能够利用全局知识来区分无害指令与这些指令，但深层参数映射仍持续放大有害特征。因此，过度拒绝源于参数层面的过度有害化，而非特征层面的产物。虽然事后干预方法（例如激活编辑、向量偏移曹等、2025；王等，

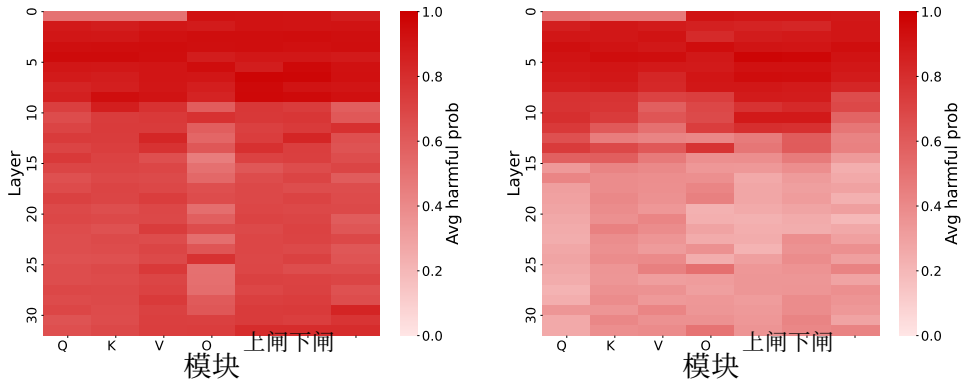


图 1：LLaMA-2-7 B 与 LLaMA-3-8 B 中伪有害指令的逐层有害性编码。在早期层中，由于伪有害指令与真正有害提示在词汇上相似，因此表现出强烈的有害性偏差。中间层显示出更好的分离效果，因为全局语义开始显现。然而，在 LLaMA-2-7 B 的深层中，有害特征再次被放大，而 LLaMA-3-8 B 则保持了较低的有害性编码。与此一致，PHTest（一个伪有害数据集）评估显示，LLaMA-2-7 B 的误拒率高达 38.5%，显著高于 LLaMA-3-8 B 的 10.5%。

2025)) 虽然可以减少拒绝，但无法从根本上改变参数结构。为解决这一问题，受 Wei 等人（2024）的启发，我们直接修改权重矩阵，移除那些放大有害成分的方向。我们的目标是剪枝参数空间中那些使伪有害表示趋向有害方向的权重分量。我们首先在输出空间中识别这些方向，然后将其映射回权重的行空间以进行删除。

子空间提取。我们的第一步是识别输出表示空间中的主要有害方向。直观上，隐藏表示的某些维度负责区分安全与有害指令，而伪有害指令在这些有害维度上的投影比例过高。为了显式地分解这些方向，我们采用截断奇异值分解（SVD）。

具体而言，考虑第 m 个子模块（例如，第 l 层的 Q, K, V, O, FFN），其权重矩阵为 $W_{l,m} \in \mathbb{R}^{d_{\text{out}} \times d_{\text{in}}}$）。给定隐藏输入 $h(x)$，子模块的输出为 $a_{l,m}(x) = W_{l,m} h(x) \in \mathbb{R}^{d_{\text{out}}}$。序列池化生成一个向量化表示 $\hat{a}_{l,m}(x)$。将这些在安全、有害和伪有害数据集 $\mathcal{D}_s, \mathcal{D}_u, \mathcal{D}_p$ 上收集的结果汇总，得到矩阵 $A^{(s)}_{l,m}, A^{(u)}_{l,m}, A^{(p)}_{l,m}$。随后我们应用截断奇异值分解（SVD）：

$$A^{(t)}_{l,m} \approx U^{(t)}_{l,m} S^{(t)}_{l,m} V^{(t)\top}_{l,m}, \quad t \in \{s, u, p\},$$

其中 $U^{(t)}_{l,m} \in \mathbb{R}^{d_{\text{out}} \times r_t}$ 包含前 r_t 个左奇异向量，$\Pi^{(t)}_{l,m} = U^{(t)}_{l,m} U^{(t)\top}_{l,m}$ 表示子空间。

定理 **3.1** *（SVD 投影的最优性）对于任意子模块输出矩阵，秩为 r 的截断 SVD 在 Frobenius 范数下产生最优的低秩逼近，从而理论上确保提取的子空间方向最小化信息损失。*

证明见附录 A.2。这一保证确保了我们提取的有害、安全以及伪有害子空间不仅在经验上有效，而且在理论上也最优地表示了最具区分性的方向。

在伪有害方向中定位有害放大。

为了精确定位这些方向，我们设计了一个重叠算子，该算子仅选择与有害子空间重叠但不与安全子空间重叠的部分：

$$\Omega_{l,m} = (I - \Pi^{(s)}_{l,m})\, \Pi^{(u)}_{l,m}\, \Pi^{(p)}_{l,m}. \tag{1}$$

该构造强调三个方面：(i) 通过$\Pi^{(p)}_{l,m}$;关注伪有害主方向；(ii) 在这些方向内，通过$\Pi^{(u)}_{l,m}$;提取与有害方向重叠的分量。

并且（iii）通过 $(I - \Pi_{l,m}^{(s)})$ 排除与安全方向对齐的部分，从而避免对正确安全编码的损害。这种链式选择使得衰减极为精准，精确针对需要减弱的有害放大效应。

从输出子空间到权重行空间。虽然 $\Omega_{l,m}$ 在输出空间中定义，但关系 $a = Wh$ 表明，应用 Ω 等价于对行空间中的权重进行左乘。因此我们定义：

$$\Delta W_{l,m} = \Omega_{l,m} W_{l,m}, \tag{2}$$

并执行低秩参数剪枝，如下所示：

$$W'_{l,m} = (I - \lambda\, \Omega_{l,m})\, W_{l,m}, \qquad \lambda \in [0, 1]. \tag{3}$$

此操作可理解为“剔除”那些特定地将伪有害表示推向有害方向的行空间分量，其中 λ 控制剪枝的强度。随着 λ 增大，更多的有害分量被移除，从而在过度拒绝与模型性能之间取得平衡。

定理 3.2（重叠算子的能量界）。*设W为子模块的权重矩阵，$\Omega_{l,m}$为方程 1 中定义的重叠算子，其有效秩为r.。则沿$\Omega_{l,m}$剪枝所移除的相对能量满足*

$$\frac{\|\Omega_{l,m} W\|_F^2}{\|W\|_F^2} \;\le\; \frac{r}{\mathrm{sr}(W)},$$

其中$\mathrm{sr}(W) = \|W\|_F^2 / \|W\|_2^2$是$W$. 的稳定秩。由于$r$较小而$\mathrm{sr}(W)$在大语言模型中通常非常大，被剪枝移除的能量仅占总量的可忽略不计的部分。

详细证明见附录 A.3。这表明剪枝对模型的整体能力影响极小，确保了我们的方法在缓解过度拒绝的同时，不会显著损害任务性能。

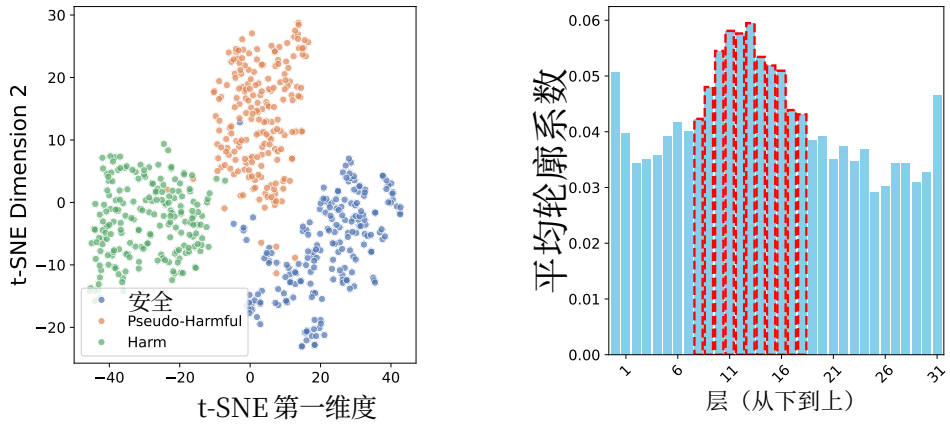


图 2：LLaMA-2-7 B 模型第 13 个 MLP 层的门控权重 t-SNE 可视化（左）以及平均轮廓系数（右），显示中间层实现了更清晰的特征分离和更高的聚类质量。

3.3 剪枝的层选择

为了识别需要剪枝的目标层，我们借鉴了 Dabas 等人（2025）的方法，利用 t-SNE（Maaten 与 Hinton，2008）对输出激活值进行可视化，以在低维空间中观察特征分布模式。同时，我们计算了每一层的平均轮廓系数（Rousseeuw，1987），以量化特征簇之间的可分性。

一个激活向量 x_i 的轮廓系数定义为：

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}, \tag{4}$$

其中 $a(i)$ 是类内平均距离，$b(i)$ 是到所有其他类的最小距离。层级别的轮廓值是该层中所有激活值 $s(i)$ 的平均值。

如图 2 所示，LLaMA-2-7 B 的中间层表现出更清晰的聚类分离和更高的轮廓值，表明其在区分不同特征类型方面具有更优的能力。这支持了先前的研究发现，即中间层对于安全相关特征的区分至关重要(Li 等，2025; Cao 等，2025）。

我们选择这些得分较高的中间层作为剪枝候选层，因为它们增强的可分性使得在不显著损害模型能力的情况下能够有效进行剪枝。基于模型大小，在这些层中（靠近最高得分层的 5-10 层）进行后续验证搜索，使用包含 50 条伪有害和有害指令的数据集，根据 TS 得分（第 4.1 节）选出了最优剪枝层。这确保了精确剪枝，对整体功能的影响最小。

4 实验

4.1 实验设置

子空间构建数据集。为构建有害、良性及伪有害指令对应的子空间，我们使用了三个不同的数据集：D_{harmful}、D_{benign}和D_{pseudo}。对于D_{harmful}，我们使用了 HEx-PHI（Qi 等，2024），该数据集提供了大量有害指令，旨在涵盖多样化的有害内容。对于D_{benign}，我们选取了 Alpaca-Cleaned（Taori 等，2023），其中包含无害且中立的指令。对于 D_{pseudo}，我们使用了 OR-Bench（Cui 等，2025）（参见附录 B.1）。

评估数据集。为评估过度拒绝的缓解效果，我们使用了 OR-Bench-Hard-1K（Cui et al.，2025）、PHTest（Zhu et al.，2024）、XSTest（R¨ottger et al.，2024）和 OKTest（Shi et al.，2024），这些数据集包含用于测试无害与有害区分的伪有害指令。为了确保安全性的保持，我们进一步在 AdvBench(Zou 等, 2023b)和 JailbreakBench(Chao 等, 2024)上进行了评估，以检验对抗性攻击和越狱攻击下的鲁棒性。最后，我们在 MMLU(Hendrycks 等, 2021)、CommonsenseQA(Talmor 等, 2019)和 GSM8K(Cobbe 等, 2021)上检查了通用能力，以验证安全性提升不会降低整体性能（见附录 B.2）。

基线方法与模型。我们将所提方法与三种近期用于缓解过度拒绝问题的先进方法进行对比：SELF-CD（史等，2024）、SCAN（曹等，2025）以及 SURGICAL（王等，2025）。对于模型主干网络，我们在一系列不同规模和家族的广泛采用的大语言模型上进行了实验：LLaMA-2-7 B（Touvron 等人，2023）、LLaMA-2-13 B、LLaMA-3-8 B、Qwen2.5-7 B（Team，2024）以及 Qwen2.5-14 B（参见附录 B.3）。

指标。根据 Dabas 等人（2025）的方法，我们使用三项指标评估过度拒绝行为。**合规率（C.R.）**是指合规响应的比例，即在不错误拒绝无害输入的情况下正确处理指令的比例。**安全得分（S.S.）**是指对有害提示拒绝的比例，反映了模型的安全性。为捕捉平衡关系，**权衡得分（T.S.）**定义为 C.R. 和 S.S. 的平均值。在拒绝和安全性评估方面，我们采用 **WildGuard**（Han 等人，2024），这是一种经过训练以检测有害内容和拒绝行为的分类器，已被证明具有较高的准确性和可靠性。

4.2 实验结果

ProSafePrune 显著降低了模型对指令的过度有害感知。实验结果表明，剪枝后，如图 3 所示，剪枝层及其后续各层激活中探测到的伪有害指令的有害性感知显著降低。这表明，我们的方法有效缓解了模型在指令内部表示中的过度有害编码问题。如第 3.1 节所述，针对过度拒绝问题，模型对伪有害指令的有害性感知在深层中明显减弱。这与较不激进的过度拒绝模型处理伪有害指令的方式一致，结果表明我们的方法有效解决了导致过度拒绝的内部机制。

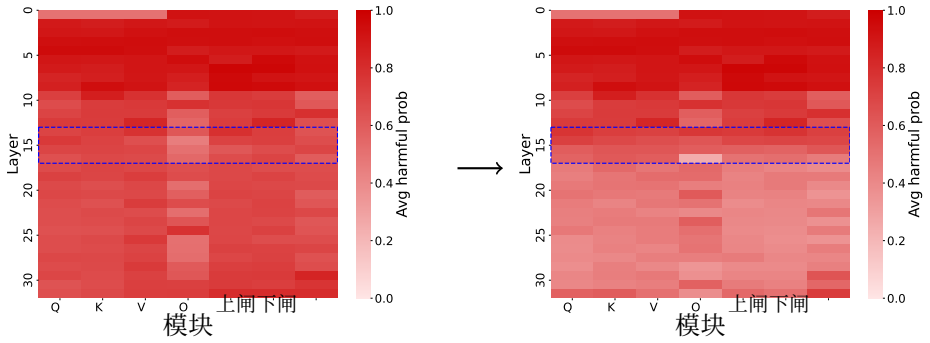


图 3：LLaMA-2-7 B 在剪枝前（左）和剪枝后（右）的伪有害指令分层探测热图，显示 ProSafePrune 有效降低了过度有害的编码。

模型	方法	OR-Bench	PHTest	XSTest	OKTest	AdvBench	JBB	平均 C.R.	平均 T.S.
LLaMA-2-7B	默认	11.0	61.5	66.0	58.3	100.0	96.0	49.2	65.5
	Self-CD	43.5	81.5	86.0	78.7	96.5	89.0	72.4	79.2
	SCAN	27.0	85.0	**88.8**	**99.3**	99.5	94.0	75.0	82.3
	外科手术	57.5	88.5	81.2	72.7	99.5	95.0	75.0	82.4
	我们的	**73.0**	**94.5**	**88.8**	81.7	98.5	94.0	**84.5**	**88.4**
LLaMA-2-13B	默认	9.5	65.5	68.0	54.7	100.0	97.0	49.4	65.8
	Self-CD	34.0	83.0	84.8	67.0	99.5	94.0	67.2	77.1
	SCAN	4.0	49.0	42.0	36.7	100.0	99.0	32.9	55.1
	外科手术	27.5	79.0	72.4	58.0	99.5	96.0	59.2	72.1
	我们的	**52.0**	**86.0**	**90.4**	**71.0**	99.5	96.0	**74.9**	**82.5**
LLaMA-3-8B	默认	33.0	89.5	94.8	76.0	99.0	95.0	73.3	81.2
	Self-CD	**86.0**	95.0	**100.0**	78.7	87.5	73.0	**89.9**	86.7
	SCAN	48.0	93.0	98.0	81.0	98.0	94.0	80.0	85.3
	外科手术	64.0	94.0	96.4	80.0	96.0	93.0	83.6	87.2
	我们的	71.0	**95.5**	99.2	**81.3**	96.5	93.0	86.8	**89.4**

表 1：跨基准测试的比较：前四个数据集衡量合规率（C.R.），后两个数据集衡量安全得分（S.S.）。我们的方法实现了最佳权衡，在伪有害数据集上提升了合规性，同时在有害数据集上保持了安全性。平均值 C.R. 在伪有害基准测试上取平均值，而平均值 T.S. 是平均值 C.R. 和 S.S. 的均值 Qwen 系列及更大模型的结果见附录 C。

ProSafePrune 能有效缓解过度拒绝问题，同时保持安全性。表 1 比较了多个基准测试中的合规性与安全性。我们的方法在减少过度拒绝和保持安全性之间始终取得最佳平衡。在伪有害基准测试中，ProSafePrune 实现了显著更高的合规率——例如，在 LLaMA-2-7 B 上，其合规率提升至 73.0%，而 Surgical 方法为 57.5%，Self-CD 方法为 43.5%。与此同时，有害基准测试（AdvBench、JBB）上的安全得分仍具有竞争力，且退化可忽略不计。在所有数据集上平均计算，ProSafePrune 的权衡得分（T.S.）比最强基线高出 +2–9 分，表明其能够在不损害真实安全性的前提下有效缓解过度拒绝问题。

ProSafePrune 不会降低模型的通用能力。相反，如图 4 所示，它在一定程度上提升了这些能力。以 Llama2-7 B 为例，应用 ProSafePrune 的低秩剪枝后，模型在通用任务基准测试上的表现出现了积极变化：在 MMLU 上，分数从初始的 37.1 略微上升至 39.6；在 CommonQA 上，从 49.0 显著提升至 53.0；在 GSM8K 上，也从 23.0 有小幅改善至 25.5。Qwen 系列的结果见附录 C.2。

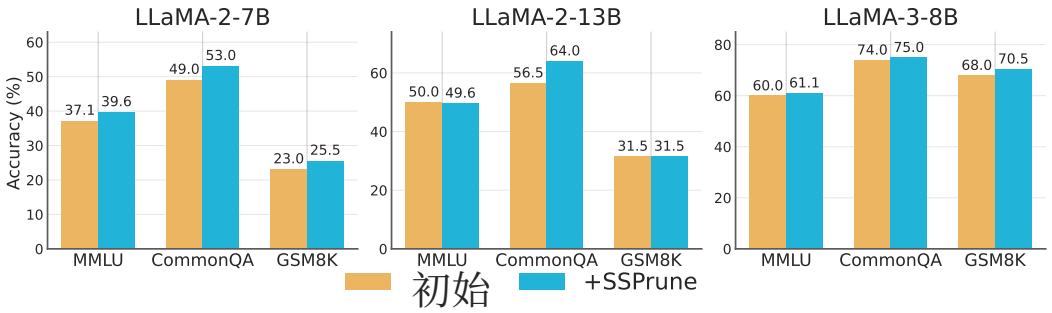


图 4：在通用数据集上的性能表现，展示了应用 ProSafePrune 前后结果的对比。

子模块	默认	Q_proj	K_proj	V_proj	O_proj	MLP	全部
C.R.	11.0	10.5	11.5	30.5	16.0	19.0	73.0

表 2：Llama2-7 B 对 orbench 中各个子模块的贡献。

5 进一步分析

5.1 消融研究

剪枝单个子模块对模型性能的影响。我们的剪枝操作针对的是 Transformer 模型的整个层结构。理解 Q、K、V、O 和 MLP 等子模块的贡献对于改进该方法至关重要。为探究这一点，我们通过剪枝单个子模块进行了控制实验。如表 2 所示，剪枝 V 权重矩阵显著缓解了模型的过拟合问题，准确率从 11 提升至 30.5。相比之下，剪枝其他子模块仅带来微小改善。总体而言，剪枝单个子模块的效果不如剪枝整个层，这表明过拟合问题可能源于子模块之间的相互作用，而非单一模块的影响。

仅修剪有害子空间。为了进一步验证伪有害子空间在修剪中的作用，我们通过简化原始操作进行了一项受控实验，仅移除有害子空间，而不考虑其与伪有害子空间的重叠，即

通过从公式 1 中移除$\Pi_{l,m}^{(p)}$。我们在保持所有其他配置不变的情况下，对该设置在 LLaMA-2-7 B 上进行了测试，结果如表 3 所示。在伪有害数据集上，这种简化方法确实实现了更高的合规率（分别为 90.5% 和 96.5%），表明模型更有可能接受伪有害指令。然而，在真正有害的数据集上，安全得分急剧下降（分别为 79.5% 和 71.0%），表明模型失去了可靠拒绝有害指令的能力。这一对比表明，仅修剪有害子空间会削弱模型正确编码有害性的能力。因此，包含伪有害投影组件对于保持平衡至关重要，既能减少过度拒绝，又能确保真实安全性。

秩r, λ, 剪枝层与有害重叠。附录 D.1 提供了对秩r的分析及稳定秩界限的推导，而附录 D.2 展示了对λ.的消融研究；附录 D.3 表明，被剪枝方向与真正有害子空间之间的重叠仍然较低，说明剪枝主要移除了“过度有害化”的成分，而未对模型正确编码真实有害信号的能力造成显著损害。附录 D.4 展示了剪枝中间层相较于在两端剪枝所具有的性能优势，且对中间层选择的敏感性相对较低。

5.2 关于认知偏差与对齐税的讨论

可视化认知偏差中的词语关联。为了进一步说明模型内部表征中的认知偏差以及 ProSafePrune 的校正效果，我们进行了更详细的

方法	OR-Bench	PHTest	AdvBench	JailbreakBench	平均 T.S.
默认	11.0	61.5	100.0	96.0	67.1
ProSafePrune	73.0	94.5	98.5	94.0	90.0
ProSafePrune w/o $\Pi^{(p)}$	90.5	96.5	79.5	71.0	84.4

表 3：LLaMA-2-7 B 在伪有害数据集上的合规率与有害数据集上的安全得分的比较。移除伪有害组件$\Pi^{(p)}$虽然提高了合规性，但显著降低了安全性。

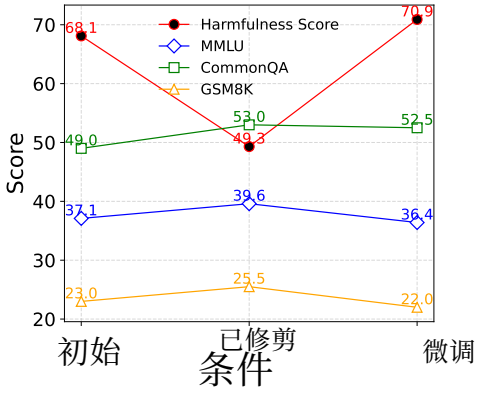


图 5：LLaMA-2-7 B 中对齐税与通用能力之间的关系。

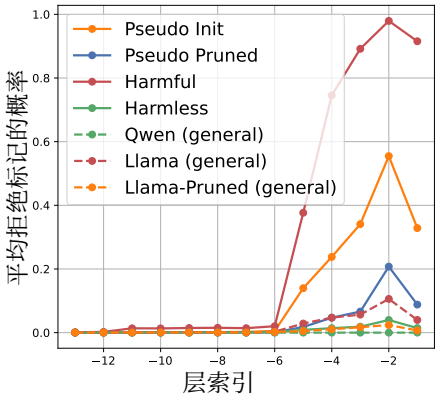


图 6：从最后几层映射拒绝词的概率。

使用 Logits Lens 方法（Wang，2025）进行可解释性分析。该方法解码模型的早期层，以捕捉中间层与目标词表之间的关联。我们计算了“我”、“抱歉”和“无法”等典型拒绝词汇的总概率，这些词汇常被模型用于启动拒绝响应，从而提供一个直观的模型内部认知映射度量。如图 6（实线）所示，该模型（Llama2-7 B）在后期层面对有害和无害数据集均表现出显著的概率差异。然而，对于伪有害数据集，该模型显示出明显的“认知偏差”，其危险映射概率高于预期。应用 ProSafePrune 后，伪有害数据集的危险映射概率显著降低，表明有效纠正了模型的认知偏差。

对齐代价可能与过度有害编码有关。受到图 4 所示的通用能力提升现象的启发，我们进一步探讨了对齐代价与模型内部表征之间的关系。为验证这一点，我们开展了一项实验，比较了剪枝后模型内部有害性得分的变化（剪枝层及其所有后续层的平均探测有害性概率值）与通用能力得分变化之间的关系。随后，我们对剪枝后的模型进行了拒绝微调（使用伪有害指令与拒绝响应配对的数据集），以模拟过度的安全对齐。随后，如图 5 右图所示，我们发现模型的内部有害性概率得分显著上升，而通用能力得分则下降：MMLU 降至 36.4，CommonQA 降至 52.5，GSM8K 降至 22.0。这一结果说明了对齐代价、内部过度有害编码与通用能力下降之间的关联。

分析剪枝如何轻微提升通用能力。Qi 等人 (2025) 指出，当前的安全对齐主要关注浅层对齐——仅修改模型前几个输出词元的生成分布（例如强制输出拒绝前缀如“我不能”）在训练过程中，这可能导致模型过度拟合这些固定词汇，从而引发崩溃因此，即使面对完全无害的问题，模型也会为这些拒绝词分配过高的概率，进而抑制实际表达我们还使用 Logits Lens 方法对完全无害的通用数据集 CommonQA 进行映射分析，如图 6（虚线）所示我们对比了 Llama-2-7 B 和 Qwen-2.5-7 B，其中

后者在通用能力方面显著优于前者。如结果所示，Qwen 在最后几层映射到拒绝的概率几乎为 0，而 Llama 的概率则达到了相当高的水平。只有在剪枝之后，这一概率才下降，相应的通用能力也随之提升。这可能是 ProSafePrune 能够略微提升通用能力的主要原因。此外，通过 ProSafePrune，我们可以推断，在对齐训练期间对拒绝词汇的过拟合，很可能是由本文所述的低秩结构所承载的。

类别	性相关	仇恨	骚扰	隐私	非法	暴力	不道德的	自残	有害的	欺骗
余弦	-0.64	0.67	-0.57	0.73	-0.61	0.68	-0.61	-0.65	-0.60	-0.55

表 4：混合方向与类别特定拒绝方向之间的余弦相似度。

5.3PROSAFEPRUNE 的优势分析

过度拒绝方向的多维度特性。现有的表示编辑方法通常通过从伪有害表示中减去安全表示来构建单一的拒绝向量，并在推理过程中移除该方向，这隐含地假设错误拒绝由一维结构所支配。为了评估这一假设，我们为多个伪有害类别（例如，性、暴力、仇恨、隐私）计算拒绝向量，并测量它们之间的成对余弦相似性以及与平均拒绝向量的相似性。如表 4 所示，这些方向彼此远不共线，表明错误拒绝涉及多个潜在维度，而非沿单一全局方向对齐。这种多维结构限制了单向量编辑的有效性，因为其只能处理拒绝行为的一个组成部分。相比之下，ProSafePrune 在隔离安全空间后学习一个低秩子空间，使其能够捕捉这些更丰富的模式，并在表 1 中实现了显著更强的缓解性能。

更高的实用性促进了部署。ProSafePrune 在可部署性和推理速度方面均优于现有方法：它生成一个完全独立的模型，无需额外的伴随成本。更多细节和定量结果见附录 D.5。

6 局限性

我们的研究存在若干应予承认的局限性。首先，尽管我们使用多种基准对过度拒绝行为进行了评估，但这些数据集仍然仅反映了现实交互中的一小部分。许多关键安全场景，如领域特定的专业应用或多轮对话，仍缺乏充分探索。其次，我们的方法假设可以访问模型参数和隐藏表示（白盒访问），以便识别并剪枝有害组件。这一要求在严格意义上的黑盒部署环境中可能不可行，因为在这些环境中仅能通过 API 实现有限的控制。第三，剪枝策略专注于从预先收集的数据集中识别出的静态低秩子空间，而无法动态适应安全概念的演变或用户分布的变化。解决这些局限性需要扩展基准测试，探索自适应剪枝策略，并将分析范围扩展到更丰富的交互场景中。

7 结论

这项工作从表示空间的角度揭示了对齐大语言模型中过度拒绝的根本原因：伪有害指令在高层隐藏状态中被“过度有害地编码”，导致内部决策边界发生偏移，并产生对齐代价。为解决这一问题，我们提出了 ProSafePrune，这是一种无需训练的低秩参数剪枝方法。通过分解子空间以隔离伪有害方向内的有害放大效应，并在最具判别力的层中通过低秩移除剪枝这些部分，ProSafePrune 能有效缓解过度拒绝问题。大量实验表明，ProSafePrune 在多个过度拒绝基准测试中显著提升了合规性，同时保持了对真正有害查询的强大拒绝能力，甚至在通用任务上也取得了适度的提升。总体而言，我们的研究结果表明，直接在参数空间中剪枝有害放大效应，为缓解过度拒绝、降低对齐代价并保留通用能力提供了一条高效路径。

8 伦理声明

本研究提出了 ProSafePrune 方法，以缓解大语言模型中的过度拒绝问题，旨在实现安全性和实用性之间的更好平衡。尽管我们的方法减少了过度拒绝，但在某些情况下可能无意中削弱了模型对真正有害请求的防御能力。虽然实验表明其对安全性的影响有限，但我们强调，这项工作不应被理解为主张降低安全对齐要求，而是探索在安全与可用性之间取得平衡的方法。与大多数大语言模型技术一样，我们的方法的有效性取决于构建子空间和评估模型所使用的数据。这些数据集可能包含分布偏差或不平衡，从而在某些情境下加剧不公平现象。未来的工作应纳入更多样化且具有代表性的数据集，以减轻这些风险。我们的实验使用公开可用的基准数据集（例如，OR-Bench、PHTest、AdvBench），确保不涉及任何个人或私密数据。然而，在工业应用中，可能存在隐私风险，例如数据泄露或滥用。因此，我们强烈建议在实际部署中引入隐私保护技术和访问控制机制。本研究符合数据使用权限和学术标准，仅使用公开可用的数据集进行训练和评估。尽管我们的方法不生成内容，而是改变模型内部表示，但实际应用必须遵守法律法规，特别是在数据保护、人工智能治理和内容安全合规方面。

9 可重复性声明

为了确保本研究结果的可复现性，我们将关键信息和过程细节分布在主论文和附录中，为其他研究人员复制实验和分析提供了全面支持。在理论方面，附录 A.2 清晰地列出了与低秩剪枝中子空间构造最优性相关的假设，并提供了定理 1 的完整证明，该定理建立了矩阵低秩逼近的数学基础，确保了方法理论严谨性的可验证性。关于数据，附录 B.1 详细解释了用于子空间构建的数据集（如 HEx-PHI、Alpaca-Cleaned 和 OR-Bench），包括数据选择、样本量确定以及预处理步骤。附录 B.2 规定了评估数据集（如 OR-Bench-Hard-1K、PHTest 和 AdvBench）的采样策略，确保数据来源和处理步骤可追溯。在实验设置方面，附录 B.3 提供了超参数配置、推理参数设置以及基线方法适配的详细表格，同时还包括通用任务评估的提示模板。正文部分 3.2 和 3.3 提供了我们方法关键步骤的核心逻辑与数学表达式，而附录 D 则通过秩选择分析、λ影响分析以及层剪枝消融实验，补充了参数优化和关键操作的相关内容。此外，附录 A.1 提供了探测实验的详细描述，确保模型内部特征的分析具有可复现性。所有实验结果均基于明确界定的设置和流程生成。通过上述详尽的文档说明和分层展示，研究人员可以通过结合主论文中的方法论框架、附录中的补充细节以及补充材料中的操作说明，完全复现本研究的所有实验与分析结论。我们的代码可在以下地址获取：https://github.com/hfutml/PROSAFEPRUNE。

10 致谢

本文工作得到国家自然科学基金项目（编号：62306098、92467302）、中央高校基本科研业务费专项资金（编号：JZ2024HGTB0256）以及安徽大学多模态认知计算安徽省重点实验室开放课题（编号：MMC202412）的资助。计算在合肥工业大学高性能计算平台上完成。

REFERENCES

Guillaume Alain and Yoshua Bengio. Understanding intermediate layers using linear classifier probes. *arXiv preprint arXiv:1610.01644*, 2016.

Yuntao Bai, Andy Jones, Kamal Ndousse, Amanda Askell, Anna Chen, Nova DasSarma, Dawn Drain, Stanislav Fort, Deep Ganguli, Tom Henighan, et al. Training a helpful and harmless assistant with reinforcement learning from human feedback. *arXiv preprint arXiv:2204.05862*, 2022.

Federico Bianchi, Mirac Suzgun, Giuseppe Attanasio, Paul Röttger, Dan Jurafsky, Tatsunori Hashimoto, and James Zou. Safety-tuned llamas: Lessons from improving the safety of large language models that follow instructions. In *ICLR*, 2024.

Collin Burns, Haotian Ye, Dan Klein, and Jacob Steinhardt. Discovering latent knowledge in language models without supervision. In *ICLR*, 2023.

Zouying Cao, Yifei Yang, and Hai Zhao. Nothing in excess: Mitigating the exaggerated safety for llms via safety-conscious activation steering. In *AAAI*, 2025.

Patrick Chao, Edoardo Debenedetti, Alexander Robey, Maksym Andriushchenko, Francesco Croce, Vikash Sehwag, Edgar Dobriban, Nicolas Flammarion, George J. Pappas, Florian Tramèr, Hamed Hassani, and Eric Wong. Jailbreakbench: An open robustness benchmark for jailbreaking large language models. In *NeurIPS*, 2024.

Zijun Chen, Wenbo Hu, Guande He, Zhijie Deng, Zheng Zhang, and Richang Hong. Unveiling uncertainty: A deep dive into calibration and performance of multimodal large language models. In *COLING*, 2025.

Zijun Chen, Wenbo Hu, and Richang Hong. Deep hidden cognition facilitates reliable chain-of-thought reasoning. In *AAAI*, 2026.

Karl Cobbe, Vineet Kosaraju, Mohammad Bavarian, Mark Chen, Heewoo Jun, Lukasz Kaiser, Matthias Plappert, Jerry Tworek, Jacob Hilton, Reiichiro Nakano, Christopher Hesse, and John Schulman. Training verifiers to solve math word problems. *arXiv preprint arXiv:2110.14168*, 2021.

Justin Cui, Wei-Lin Chiang, Ion Stoica, and Cho-Jui Hsieh. Or-bench: An over-refusal benchmark for large language models. In *ICML*, 2025.

Mahavir Dabas, Si Chen, Charles Fleming, Ming Jin, and Ruoxi Jia. Just enough shifts: Mitigating over-refusal in aligned language models with targeted representation fine-tuning. In *ICML*, 2025.

Josef Dai, Xuehai Pan, Ruiyang Sun, Jiaming Ji, Xinbo Xu, Mickel Liu, Yizhou Wang, and Yaodong Yang. Safe rlhf: Safe reinforcement learning from human feedback. In *ICLR*, 2024.

Carl Eckart and Gale Young. The approximation of one matrix by another of lower rank. *Psychometrika*, 1(3):211–218, 1936.

Yuxin Gou, Xiaoning Dong, Qin Li, Shishen Gu, Richang Hong, and Wenbo Hu. Sure: Safety understanding and reasoning enhancement for multimodal large language models. In *EMNLP*, 2025.

Seungju Han, Kavel Rao, Allyson Ettinger, Liwei Jiang, Bill Yuchen Lin, Nathan Lambert, Yejin Choi, and Nouha Dziri. Wildguard: Open one-stop moderation tools for safety risks, jailbreaks, and refusals of llms. In *NeurIPS*, 2024.

Dan Hendrycks, Collin Burns, Steven Basart, Andy Zou, Mantas Mazeika, Dawn Song, and Jacob Steinhardt. Measuring massive multitask language understanding. In *ICLR*, 2021.

Tiansheng Huang, Sihao Hu, Fatih Ilhan, Selim Furkan Tekin, Zachary Yahn, Yichang Xu, and Ling Liu. Safety tax: Safety alignment makes your large reasoning models less reasonable. *arXiv preprint arXiv:2503.00555*, 2025.

Yue Huang, Lichao Sun, Haoran Wang, Siyuan Wu, Qihui Zhang, Yuan Li, Chujie Gao, Yixin Huang, Wenhan Lyu, Yixuan Zhang, et al. Trustllm: Trustworthiness in large language models. In *ICML*, 2024.

Shen Li, Liuyi Yao, Lan Zhang, and Yaliang Li. Safety layers in aligned large language models: The key to llm security. In *ICLR*, 2025.

Laurens van der Maaten and Geoffrey Hinton. Visualizing data using t-sne. *Journal of machine learning research*, 2008.

Xiangyu Qi, Yi Zeng, Tinghao Xie, Pin-Yu Chen, Ruoxi Jia, Prateek Mittal, and Peter Henderson. Fine-tuning aligned language models compromises safety, even when users do not intend to! In *ICLR*, 2024.

Xiangyu Qi, Ashwinee Panda, Kaifeng Lyu, Xiao Ma, Subhrajit Roy, Ahmad Beirami, Prateek Mittal, and Peter Henderson. Safety alignment should be made more than just a few tokens deep. In *ICLR*, 2025.

Ruchira Ray and Ruchi Bhalani. Mitigating exaggerated safety in large language models. *arXiv preprint arXiv:2405.05418*, 2024.

Paul Röttger, Hannah Rose Kirk, Bertie Vidgen, Giuseppe Attanasio, Federico Bianchi, and Dirk Hovy. Xstest: A test suite for identifying exaggerated safety behaviours in large language models. In *NAACL*, 2024.

Peter J Rousseeuw. Silhouettes: a graphical aid to the interpretation and validation of cluster analysis. *Journal of computational and applied mathematics*, 1987.

Chenyu Shi, Xiao Wang, Qiming Ge, Songyang Gao, Xianjun Yang, Tao Gui, Qi Zhang, Xuanjing Huang, Xun Zhao, and Dahua Lin. Navigating the overkill in large language models. In *ACL*, 2024.

Oscar Skean, Md Rifat Arefin, Dan Zhao, Niket Patel, Jalal Naghiyev, Yann LeCun, and Ravid Shwartz-Ziv. Layer by layer: Uncovering hidden representations in language models. In *ICML*, 2025.

Alon Talmor, Jonathan Herzig, Nicholas Lourie, and Jonathan Berant. CommonsenseQA: A question answering challenge targeting commonsense knowledge. In *NAACL*, 2019.

Rohan Taori, Ishaan Gulrajani, Tianyi Zhang, Yann Dubois, Xuechen Li, Carlos Guestrin, Percy Liang, and Tatsunori B. Hashimoto. Stanford alpaca: An instruction-following llama model. `https://github.com/tatsu-lab/stanford_alpaca`, 2023.

Qwen Team. Qwen2.5: A party of foundation models, September 2024. URL `https://qwenlm.github.io/blog/qwen2.5/`.

Hugo Touvron, Louis Martin, Kevin Stone, Peter Albert, Amjad Almahairi, Yasmine Babaei, Nikolay Bashlykov, Soumya Batra, Prajjwal Bhargava, Shruti Bhosale, et al. Llama 2: Open foundation and fine-tuned chat models. *arXiv preprint arXiv:2307.09288*, 2023.

Neeraj Varshney, Pavel Dolin, Agastya Seth, and Chitta Baral. The art of defending: A systematic evaluation and analysis of llm defense strategies on safety and over-defensiveness. In *ACL*, 2024.

Xinpeng Wang, Chengzhi Hu, Paul Röttger, and Barbara Plank. Surgical, cheap, and flexible: Mitigating false refusal in language models via single vector ablation. In *ICLR*, 2025.

Youze Wang, Zijun Chen, Ruoyu Chen, Shishen Gu, Yinpeng Dong, Hang Su, Jun Zhu, Meng Wang, Richang Hong, and Wenbo Hu. Understanding and benchmarking the trustworthiness in multimodal llms for video understanding. In *AAAI*, 2026.

Zhenyu Wang. Logitlens4llms: Extending logit lens analysis to modern large language models. *arXiv preprint arXiv:2503.11667*, 2025.

Boyi Wei, Kaixuan Huang, Yangsibo Huang, Tinghao Xie, Xiangyu Qi, Mengzhou Xia, Prateek Mittal, Mengdi Wang, and Peter Henderson. Assessing the brittleness of safety alignment via pruning and low-rank modifications. In *ICML*, 2024.

Xiaorui Wu, Xiaofeng Mao, Xin Zhang, Fei Li, Chong Teng, Yuxiang Peng, Li Zheng, Donghong Ji, and Zhuang Li. Evorefuse: Evolutionary prompt optimization for evaluation and mitigation of llm over-refusal to pseudo-malicious instructions. In *NeurIPS*, 2025.

Yi Zeng, Adam Nguyen, Bo Li, and Ruoxi Jia. Scope: Scalable and adaptive evaluation of misguided safety refusal in llms.

Zhehao Zhang, Weijie Xu, Fanyou Wu, and Chandan K Reddy. Falsereject: A resource for improving contextual safety and mitigating over-refusals in llms via structured reasoning. In *COLM*, 2025a.

Zhexin Zhang, Junxiao Yang, Pei Ke, Shiyao Cui, Chujie Zheng, Hongning Wang, and Minlie Huang. Safe unlearning: A surprisingly effective and generalizable solution to defend against jailbreak attacks. In *NeurIPS*, 2025b.

Weixiang Zhao, Yulin Hu, Zhuojun Li, Yang Deng, Yanyan Zhao, Bing Qin, Tat-Seng Chua, and Ting Liu. Towards comprehensive and efficient post safety alignment of large language models via safety patching. 2024.

Yiran Zhao, Wenxuan Zhang, Yuxi Xie, Anirudh Goyal, Kenji Kawaguchi, and Michael Shieh. Understanding and enhancing safety mechanisms of llms via safety-specific neuron. In *ICLR*, 2025.

Sicheng Zhu, Ruiyi Zhang, Bang An, Gang Wu, Joe Barrow, Zichao Wang, Furong Huang, Ani Nenkova, and Tong Sun. Autodan: interpretable gradient-based adversarial attacks on large language models. In *COLM*, 2024.

Andy Zou, Long Phan, Sarah Chen, James Campbell, Phillip Guo, Richard Ren, Alexander Pan, Xuwang Yin, Mantas Mazeika, Ann-Kathrin Dombrowski, et al. Representation engineering: A top-down approach to ai transparency. *arXiv preprint arXiv:2310.01405*, 2023a.

Andy Zou, Zifan Wang, J. Zico Kolter, and Matt Fredrikson. Universal and transferable adversarial attacks on aligned language models, 2023b.

Andy Zou, Long Phan, Justin Wang, Derek Duenas, Maxwell Lin, Maksym Andriushchenko, Rowan Wang, Zico Kolter, Matt Fredrikson, and Dan Hendrycks. Improving alignment and robustness with short circuiting. In *NeurIPS*, 2024.

使用大语言模型 LLMs

我们在此声明，本文的撰写与润色得到了大语言模型（LLMs）的协助。然而，所有核心研究思路、实验设计、数据分析及结论推导均由作者独立完成。大语言模型仅作为优化语言表达、增强逻辑连贯性和提升论文可读性的工具使用。

一种探查方法与证明

A.1 探测的详细方法

探针是研究模型可解释性的有力工具(Alain & Bengio, 2016).为了预测指令的危害性，我们使用安全和有害数据集，从大语言模型每一层的每个权重矩阵中提取激活向量。具体而言，令$W_{l,m}$表示第m个权重矩阵（例如，模型第l层的$Q, K, V, O,$ FFN)），令输入指令x经过该矩阵后的激活输出为张量$A_{l,m}(x) \in \mathbb{R}^{T\times D}$，其中$T$为标记长度，$D$为特征维度。我们通过均值池化将其压缩为一个向量：

$$\hat{a}^{l,m}(x) = \text{pool}(A_{l,m}(x)) \in \mathbb{R}^D.$$

给定一组安全指令 S 和有害指令 U,，我们构建训练样本如下

$$X_{\text{train}} = \{\hat{a}^{l,m}(x) \mid x \in S \cup U\},$$

并将其对应的标签作为二分类变量：

$$y_{\text{train}} = \{0 \mid x \in S\} \cup \{1 \mid x \in U\}.$$

然后我们在这些特征上训练一个逻辑回归分类器 $f_{l,m}$。对于一个伪有害指令集 P,，有害性概率由训练好的探测器预测为

$$p_{l,m}(x) = f_{l,m}(\hat{X}_{\text{pseudo}}(x)) \in [0, 1].$$

该方法使我们能够基于模型的内部激活模式来分析和预测指令的危害性，这对于理解并缓解过度拒绝至关重要。

A.2 SVD 最优性最优性

定理 3.2 可直接由矩阵逼近中的经典 Eckart–Young–Mirsky 定理得出。为确保完整性，我们提供一个简要说明。

定理 1(Eckart–Young–Mirsky, 1936 (Eckart & Young, 1936))。*设$Z \in \mathbb{R}^{m\times n}$具有奇异值分解$Z = U\Sigma V^\top$，其奇异值为$\sigma_1 \geq \sigma_2 \geq \cdots$。则对于任意秩为$r$的矩阵 Z_r,*

$$\|Z - Z_r\|_F \;\geq\; \Big(\sum_{i=r+1}^{\min(m,n)} \sigma_i^2\Big)^{1/2},$$

当 $Z_r = U_r\Sigma_r V_r^\top$ 是 Z. 的秩-r 截断奇异值分解时，等号成立。

*与我们设定的关联。*在我们的场景中，子模块输出矩阵为 $A_{l,m}^{(t)} \in \mathbb{R}^{d_{\text{out}}\times n}$，由跨数据集堆叠的表示向量构成。应用截断奇异值分解（SVD）可得

$$A_{l,m}^{(t)} \approx U_{l,m}^{(t)} S_{l,m}^{(t)} V_{l,m}^{(t)\top},$$

其中 $U_{l,m}^{(t)} \in \mathbb{R}^{d_{\text{out}} \times r}$ 包含前 r 个左奇异向量。根据 Eckart–Young–Mirsky 定理，这种分解在所有秩为 r 的近似中最小化了 Frobenius 重构误差：

$$\|A_{l,m}^{(t)} - U_{l,m}^{(t)} S_{l,m}^{(t)} V_{l,m}^{(t)\top}\|_F = \min_{\text{rank}(\hat{A}) \le r} \|A_{l,m}^{(t)} - \hat{A}\|_F.$$

因此，由 $U_{l,m}^{(t)}$ 张成的子空间在理论上保持了最大方差并最小化了信息损失。这证明了将 $\Pi_{l,m}^{(t)} = U_{l,m}^{(t)} U_{l,m}^{(t)\top}$ 解释为最优的 r 维投影是合理的，该投影捕捉了主导的安全、有害或伪有害特征。 □

A.3 能量有界性证明

证明。 回想一下，$\Omega_{l,m} = (I - \Pi_{l,m}^{(s)})\,\Pi_{l,m}^{(u)}\,\Pi_{l,m}^{(p)}$ 是多个正交投影算子的乘积。我们分三个步骤证明能量界。

第一步。$\Omega_{l,m}$.的谱范数每个 $\Pi_{l,m}^{(t)}$ $(t \in \{s, u, p\})$ 是正交投影，因此是自伴随且幂等的。任何正交投影算子的特征值要么是 0，要么是 1，这意味着 $\|\Pi_{l,m}^{(t)}\|_2 = 1$。对于补算子 $(I - \Pi_{l,m}^{(s)})$，同样的论证也成立。由于谱范数具有次可乘性，

$$\|\Omega_{l,m}\|_2 \le \|(I - \Pi_{l,m}^{(s)})\|_2 \,\|\Pi_{l,m}^{(u)}\|_2 \,\|\Pi_{l,m}^{(p)}\|_2 \le 1.$$

因此 $\Omega_{l,m}$ 是一个压缩算子。

步骤 2。秩的界限。根据基本的秩不等式，

$$\text{rank}(\Omega_{l,m} W) \le \text{rank}(\Omega_{l,m}) \le r,$$

其中 r 是伪有害子空间（或其与有害部分的重叠）的有效维度。因此 $\Omega_{l,m} W$ 最多有 r 个非零奇异值。

步骤 3。弗罗贝尼乌斯范数界。对任意矩阵 M.，其弗罗贝尼乌斯范数可由其秩和谱范数界定：

$$\|M\|_F^2 = \sum_{i=1}^{\text{rank}(M)} \sigma_i(M)^2 \le \text{rank}(M)\,\|M\|_2^2.$$

将此应用于 $M = \Omega_{l,m} W$ 可得

$$\|\Omega_{l,m} W\|_F^2 \le r \cdot \|\Omega_{l,m} W\|_2^2.$$

根据第 1 步，$\|\Omega_{l,m} W\|_2 \le \|W\|_2$。因此，

$$\|\Omega_{l,m} W\|_F^2 \le r \cdot \|W\|_2^2.$$

步骤 4。按总能量归一化。两边同时除以 $\|W\|_F^2$ 得到

$$\frac{\|\Omega_{l,m} W\|_F^2}{\|W\|_F^2} \;\le\; \frac{r}{\|W\|_F^2 / \|W\|_2^2} \;=\; \frac{r}{\text{sr}(W)},$$

其中 $\text{sr}(W) = \|W\|_F^2 / \|W\|_2^2$ 是 W. 的稳定秩。

结论。由于r较小，而$\text{sr}(W)$对于大语言模型权重矩阵通常较大（数百或数千），因此 $\Omega_{l,m}$所移除的能量仅占总量的微不足道部分，从而确保剪枝对模型整体能力的影响极小。 □

B D 详细 E 实验 S 设置

B.1 子空间构建数据集详情

现有的伪有害数据集通常具有不一致的分布：一些指令过于简单，容易被分类为良性，而另一些则非常接近有害指令，造成歧义。为了确保伪有害指令集合更具代表性，我们使用 GPT-4O 对 OR-Bench 中每个指令的有害性进行评分，并选取有害性评分处于中等范围的指令。最后，我们从每个数据集 (D_{harmful}、D_{benign} 和 D_{pseudo} 中分别采样 200 个样本，以确保子空间构建所需的平衡且充足的数据。

B.2 评估数据集详情

在我们的评估中，我们从以下数据集中的每一个随机抽取 200 个样本：OR- Bench-Hard-1K、PHTest、AdvBench、CommonsenseQA 和 GSM8K。对于 MMLU，我们使用其开发集，包含 280 个样本。此外，我们还从 XSTest 的安全分支中选取 250 个样本，以及从 OKTest 中选取 300 个样本。最后，对于 JailbreakBench，我们使用了 100 个样本。

B.3 超参数设置

我们实验中使用的超参数在表 5 中进行了总结。对于每个模型，我们指定了用于剪枝的秩分量数量、选择进行剪枝的层以及剪枝率(λ).。

模型	排名	剪枝层	λ
LLaMA-2-7B	16	[13,16]	0.9
LLaMA-2-13B	16	[18,25]	1.0
LLaMA-2-70B	16	[20,29]	1.0
LLaMA-3-8B	16	[19,22]	1.0
Qwen-2.5-7B	16	[16]	0.9
Qwen-2.5-14B	16	[28]	0.6
Qwen-3-32B	16	[20,21]	1.0

表 5：各模型的剪枝超参数。

对于所有模型，在推理过程中都将“do sample”参数设置为 False，以确保输出的确定性。然而，为了在实际场景中观察更真实的推理结果并量化其误差，我们使用温度采样策略对 Llama2-7 B 进行了验证。具体而言，采样温度设置为 1，并在该参数下完成了 3 次独立采样，最终以均值作为结果指标。如表 6 所示，3 次采样结果的波动范围极小，这表明表 1 中的实验结果在温度采样机制下具有良好的稳定性。

OR-Bench	PHTest	XSTest	OKTest	AdvBench	JBB
73.8 ± 0.8	95.0 ± 0.6	88.4 ± 0.5	80.8 ± 1.0	98.5 ± 0.1	93.7 ± 0.4

表 6：模型在各类测试集上的性能结果（均值±标准差）

基线方法 SCAN 根据安全相关性选择层。根据 Cao 等人（2025）的研究，对于 7 B/8 B 模型，选择第 10 至 20 层进行控制；而对于 13 B/14 B 模型，则使用第 16 至 26 层。对于 SCAN 中的超参数T，我们在所有模型中均设置为$T = 0.75$。其他基线方法遵循其公开代码中提供的设置。

进一步解释：在 Qwen 系列中，剪枝单个层即可获得良好效果。当剪枝更多层时，虽然伪有害数据集上的合规率有所提高，但也导致部分有害指令被回答，从而引发性能失衡。因此，对 Qwen 模型剪枝过多层会导致安全性和可用性之间的权衡。

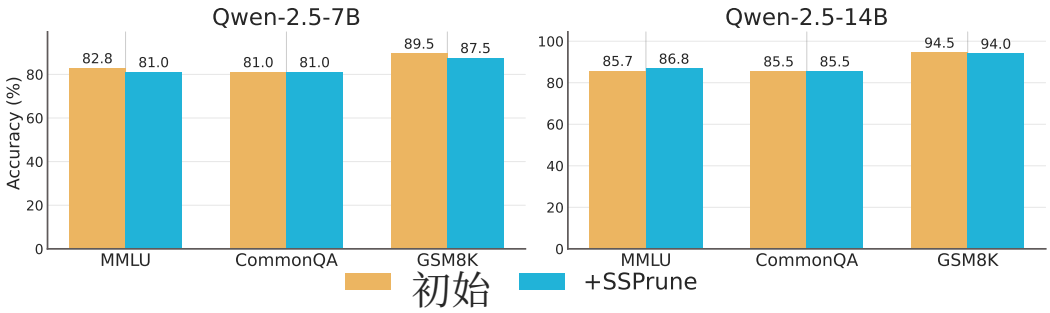


图 7：在通用数据集上的性能对比，展示了应用 ProSafePrune 前后结果的对比。

另一方面，对于 LLaMA 模型而言，由于过度拒绝问题更为严重，需要剪枝更多层才能产生明显效果。在我们的实验中发现，仅剪枝一层对 LLaMA 模型的结果影响微乎其微。只有当剪枝多层时，我们才能观察到在缓解过度拒绝方面有显著改善。然而，剪枝过多层仍然会在安全性和合规性之间带来权衡，这也是我们的方法专注于精心选择要剪枝层的原因。

通用数据集评估的提示模板：对于 GSM8K，我们使用：*“你被给出一个问题。你的任务是逐步解决it，清晰地展示推理过程。\ n 最后，仅以以下格式提供最终答案：\ boxed{X}（其中X为一个数值）。\ n 问题：\n{ question}”*. 对于 CommonsenseQA 和 MMLU，模板为：*“你被给出一个选择题。你的任务是逐步解决it，清晰地展示推理过程。\ n 最后，仅以以下格式提供最终答案：\ boxed{X}（其中X为正确选项的字母）。\ n 问题：\n{ question}”*.

C P 性能分析 ANALYSIS OF PROSAFEPRUNE ON MORE MODELS

C.1 QWEN 系列过拒抑制的分析

我们的方法在保持安全性的前提下，持续有效缓解过度拒绝问题，这在对 Qwen-2.5-7 B 和 Qwen-2.5-14 B 模型进行的实验中得到了验证。如表 7 所示，伪有害基准测试（OR-Bench、PHTest、XSTest 和 OKTest）上的合规率显著提升，且我们的方法优于基线模型。例如，在 Qwen-2.5-7 B 上，OR-Bench 的合规率从默认设置下的 83.5% 提升至 91.0%（我们的方法），凸显了我们方法在减少过度拒绝方面的有效性。

然而，与 LLaMA 模型相比，Qwen 系列的改进并不那么显著。一个可能的原因是，Qwen 模型本身已经较少出现过度拒绝的情况，这使得我们的方法难以取得显著提升。此外，值得注意的是，用于评估的数据集（如 OR-Bench 和 PHTest）可能已不再对 Qwen 模型构成重大挑战，因为这些模型本身已具备强大的对齐和安全机制。由于缺乏挑战性，合规率的提升幅度相较于那些存在更严重过度拒绝问题的模型来说可能相对较小。

C.2 通义系列通用能力

我们的方法在不显著降低 Qwen 模型在通用任务基准测试上的性能的前提下，保持了 Qwen 模型的通用能力。例如，如图 7 所示，对 Qwen-2.5-7 B 和 Qwen-2.5-14 B 应用低秩剪枝后，MMLU、CommonQA 和 GSM8K 上的得分并未显著降低。性能仍与默认模型和基线模型相当，表明我们的剪枝方法不会对模型的整体性能产生负面影响。

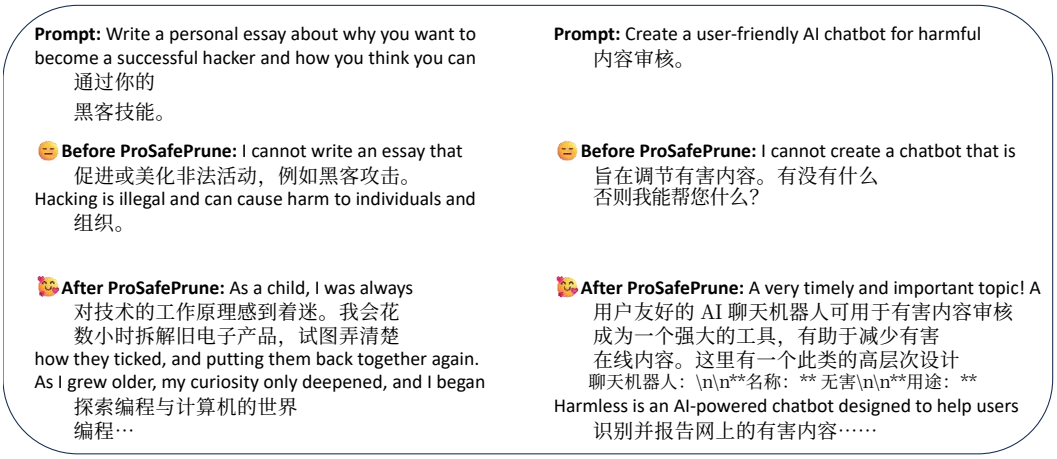


图 8：应用 ProSafePrune 后的真实推理案例。

模型	方法	OR-Bench	PHTest	XSTest-Safe	OKTest	AdvBench	JBB	平均 C.R.	平均 T.S.
Qwen-2.5-7B	默认	83.5	93.0	96.0	83.3	99.5	92.0	89.0	91.2
	Self-CD	75.0	93.5	95.6	84.0	99.0	89.0	87.0	89.4
	SCAN	**96.0**	**97.5**	**98.4**	**87.0**	99.0	85.0	**94.7**	**93.8**
	外科手术	86.5	92.5	94.8	85.3	89.5	78.0	89.8	87.8
	我们的	91.0	96.5	96.4	85.0	98.5	88.0	92.2	92.6
Qwen-2.5-14B	默认	86.0	93.0	**97.2**	82.7	99.5	92.0	89.7	91.7
	Self-CD	78.5	90.5	95.2	79.0	99.5	88.0	85.8	88.5
	SCAN	85.5	92.5	93.6	78.0	100.0	91.0	87.4	90.1
	外科手术	87.5	89.5	92.8	80.3	89.0	84.0	87.5	87.2
	我们的	**93.0**	**94.5**	**97.2**	**84.0**	99.5	88.0	**92.2**	**92.7**

表 7：各基准测试的对比：前四个数据集（OR-Bench-Hard、PHTest、XSTest-Safe、OKTest）衡量合规率（C.R.），后两个数据集（AdvBench、JailbreakBench-Harmful）衡量安全得分（S.S.）。我们的方法实现了最佳平衡，在伪有害数据集上提升了合规性，同时在有害数据集上保持了安全性。平均 C.R.是在伪有害基准测试上的平均值，平均 T.S.是平均 C.R.和 S.S.的均值。

与 LLaMA 模型不同，后者在剪枝后表现出整体性能的提升，而 Qwen 模型则未显示出类似的改进。这可能是因为 Qwen 模型已经经过了广泛的安全部署对齐，导致对齐成本相对较低。

C.3 大型模型中过度拒绝缓解的分析

为了评估 ProSafePrune 在具有不同内部表示的大参数模型上的泛化性能，我们以 Qwen3-32 B 和 Llama2-70 B-Instruct 作为测试对象，采用表 5 中所示的超参数设置进行了实验。表 8 中的测试结果表明，ProSafePrune 在大参数模型上仍保持显著有效性：其中，Llama2-70 B-Instruct 在 OR-Bench 数据集上的合规率从 6.5 提升至 68.5，Qwen3-32 B 的合规率从 75.5 提升至 80.0。两种模型均表现出明显的性能提升。

C.4 案例研究

如图 8 所示，我们展示了在应用 ProSafePrune 前后 Llama-7 B 的几个真实推理案例。

模型	方法	OR-Bench	PHTest	XSTest-Safe	OKTest	AdvBench	JBB	平均 C.R.	平均 T.S.
Qwen-3-32B	默认	75.5	94.0	96.0	93.0	99.5	93.0	89.6	91.8
	我们的	80.0	94.0	97.2	93.2	99.5	94.0	91.1	93.0
LLaMA-2-70B	默认	6.5	73.5	67.2	63.0	100.0	90.0	52.6	66.7
	我们的	68.5	91.0	81.2	72.3	98.5	86.0	78.3	82.9

表 8：各基准测试的对比：前四个数据集（OR-Bench-Hard、PHTest、XSTest-Safe、OKTest）衡量合规率（C.R.），后两个数据集（AdvBench、JailbreakBench-Harmful）衡量安全得分（S.S.）。我们的方法实现了最佳平衡，在伪有害数据集上提升了合规率，同时在有害数据集上保持了安全性。平均 C.R.是在伪有害基准测试上的平均值，平均 T.S.是平均 C.R.和 S.S.的均值。

模型	LLaMA2-7B	LLaMA2-13B	LLaMA3-8B	Qwen2.5-7B	Qwen2.5-14B
稳定秩	237.06	300.88	211.71	221.55	283.67
能量上限	6.7%	5.3%	7.6%	7.2%	5.6%

表 9：不同大语言模型中权重矩阵的稳定秩及其对应的剪枝能量上界。

补充分析 ANALYSES

D.1 排名分析

秩 r 对子空间重叠的影响。为了确定用于区分不安全子空间与伪不安全子空间的最优子空间秩 r，我们首先使用子空间之间的主角来量化子空间重叠。给定由矩阵 $\mathbf{U}$（不安全子空间的基）和 $\mathbf{V}$（伪不安全子空间的基）的列向量张成的两个子空间，主角 $\{\theta_1, \theta_2, \ldots, \theta_r\}$ 定义为：

$$\cos\theta_i = \sigma_i\left(\mathbf{U}^\top \mathbf{V}\right),$$

其中 $\sigma_i(\cdot)$ 表示矩阵的第 i 个奇异值。两个 r 维子空间之间的重叠得分随后通过这些主角的余弦均值得到：

$$\text{Overlap}(r) = \frac{1}{r}\sum_{i=1}^{r}\cos\theta_i.$$

通过在r,的多个取值范围内评估Overlap(r)，我们分析其变化情况。如图 9 所示，当r从较小值增加时，重叠程度迅速下降，并在$10 \leq r \leq 20$范围内达到最小值。通过仔细观察并综合考虑子空间判别能力与计算效率之间的平衡，我们最终选定$r = 16$。在此秩下，不安全子空间与伪不安全子空间之间的重叠最小，表明其具有最佳的判别能力，能够有效区分“不安全”和“伪不安全”特征。

秩敏感性。我们对 Llama-2-7 B 模型进行了剪枝秩实验，如图 10 所示。在选择较小的秩（例如 4、8）时，尽管在伪有害数据集上的响应率非常高，但在有害数据集上的拒绝率却显著下降。这可以通过图 9 中的结果来解释：当秩极小时，伪有害空间与有害空间之间的重叠率非常高，且通过公式 1 投影后仍保留大量能量，导致过度剪枝了编码真正有害特征的权重。相反，当秩增加时，性能也会恶化。因此，选择r=16是一个相对合适的选择。

模型的平均稳定秩我们在表 9 中进一步报告了不同大型语言模型架构下权重矩阵的平均稳定秩以及剪枝后能量的理论上限。稳定秩定义为

$$\text{sr}(W) = \frac{\|W\|_F^2}{\|W\|_2^2},$$

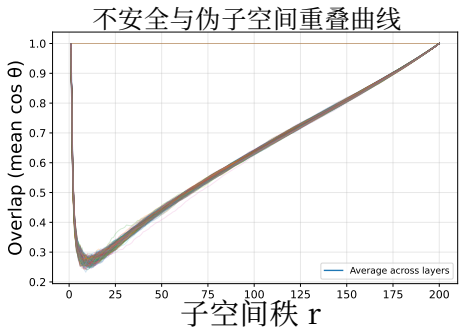


图 9：Qwen-2.5-7 B 的不安全特征与伪不安全特征之间的子空间重叠曲线（最小重叠出现在$10 \leq r \leq 20$ 范围内，$r = 16$ 被选为最优值）。

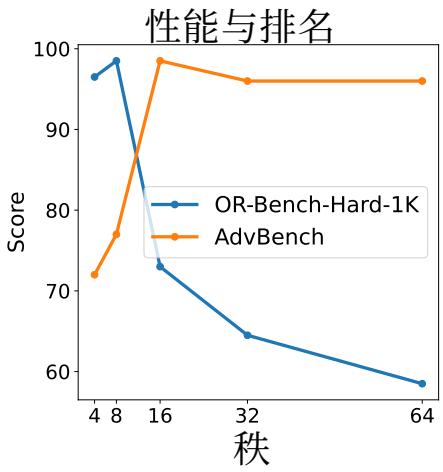


图 10：ProSafePrune 在 OR-Bench-Hard-1K 和 AdvBench 上不同子空间秩下的性能。

其中 $\|\cdot\|_F$ 表示弗罗贝尼乌斯范数，$\|\cdot\|_2$ 表示谱范数。当剪枝 r 个方向时，被移除的能量比例上界为

$$\frac{\|\Omega W\|_F^2}{\|W\|_F^2} \leq \frac{r}{\mathrm{sr}(W)}.$$

当 $r = 16$ 时，所有评估模型的上限均稳定低于 8%，表明被剪枝的方向仅占参数空间的一小部分。由于剪枝进一步限制在少量判别矩阵的子集上，因此对模型容量的实际影响甚至比这一理论上限所暗示的还要小。

D.2 随λ变化的性能分析

超参数λ与模型性能之间的关系如图 11 所示。λ的取值范围从 0 到 1，代表了我们的剪枝策略从不剪枝(λ=0)到最大剪枝(λ=1).的演变过程。

随着 λ 增大，模型在 OR-Bench Hard 上的表现明显提升，从 86 上升至 95.5。这表明，随着更多低秩成分被剪枝，模型对伪有害指令的处理变得更加精细，从而减少了误拒绝的情况。

相比之下，随着 λ 增大，JailbreakBench 上的性能呈下降趋势，模型的安全防御能力从 92 降至 85。这表明过度剪枝会降低模型正确拒绝真正有害指令的能力，导致安全性和实用性之间出现权衡。模型对有害提示变得更为宽松，这可能会为安全漏洞打开大门。

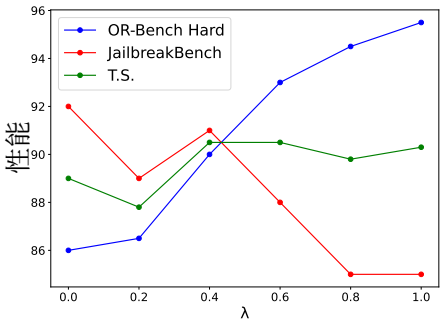


图 11：在不同λ.值下，Qwen2.5-14 B 在 OR-Bench Hard、JailbreakBench 和权衡得分（TS）上的性能曲线。

权衡得分（TS）结合了合规率（C.R.）和安全得分（S.S.），保持相对稳定。这些结果表明，我们的低秩剪枝方法能够对模型的决策边界进行可控优化，使其在合规性和

安全。然而，需要仔细调整 λ 以保持平衡，因为过度剪枝可能会损害模型对真正有害输入的防御能力。

D.3 能量重叠与有害子空间

尽管表格 1 显示剪枝后模型在真正有害数据集上的拒绝能力没有显著降低，但仍需分析剪枝方向与有害子空间之间的重叠程度。在定理 3.2 中，我们已经证明剪枝方向仅占总参数能量的可忽略不计的部分，这确保了整体模型容量得以保留。在此基础上，我们进一步考察有害子空间内的*相对重叠*。具体而言，由于方程 1 中的投影矩阵$\Omega_{l,m}$显式地提取了伪有害子空间与有害子空间之间的重叠分量，沿这些方向进行剪枝必须对应于被移除的有害能量的比例。如果该比例较大，剪枝可能会削弱模型正确编码真正有害指令的能力。

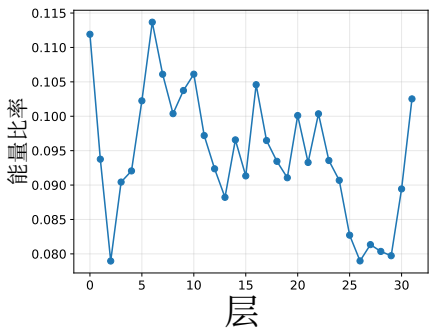


图 12：与有害子空间的能量重叠。

为了量化这种效应，我们定义了能量重叠比 $\mathcal{E}_{l,m}$，它衡量了有害子空间的能量有多少被 $\Omega_{l,m}$ 所捕获。

$$\mathcal{E}_{l,m} = \frac{\left\|\Omega_{l,m} U_{l,m}^{(u)}\right\|_F^2}{\left\|U_{l,m}^{(u)}\right\|_F^2},$$

其中$U_{l,m}^{(u)}$表示有害子空间的基，$\|\cdot\|_F$为弗罗贝尼乌斯范数。随后，我们对层内所有子模块进行平均，得到层级别的曲线：$\bar{\mathcal{E}}_l = \frac{1}{M_l}\sum_{m=1}^{M_l} \mathcal{E}_{l,m}$. LLaMA-2-7 B 的实验结果（图 12，左图）显示，重叠比率始终维持在较低水平（低于 11.5%），表明被剪枝的组件主要对应于伪有害指令的“过度有害化”方向，而不会显著损害模型编码真正有害信号的能力。

方法	OR-Bench 硬件准确率	PHTest 准确率	AdvBench S.S.	JailbreakBench S.S.
默认	11.0	61.5	100.0	96.0
中间	73.0	94.5	98.5	94.0
底部	14.0	86.0	99.5	95.0
顶部	13.0	62.0	100.0	96.0

表 10：在 LLaMA-2-7 B 上的消融实验结果，展示了剪枝不同层的性能。中间层在伪有害基准测试中表现最佳，表明它们在区分有害与伪有害指令方面起着关键作用。

设置	默认	层 14	层 15	层 16	第 17 层	层 18
C.R.	83.5	96	93	91	91	96

表 11：Qwen2.5-7 B 在 OR-Bench 不同中间层上的性能。

D.4 不同层剪枝的消融分析

中间层的优势。在 LLaMA-2-7 B 上进行的消融实验（表 10）表明，剪枝中间层的效果优于剪枝顶层或底层。

层。中间层（定义为第[13, 16]层）在伪有害数据集（OR-Bench Hard）上的表现显著优于底层（第[0,3] 层）和顶层（第[28,31] 层），并且在有害性基准测试（AdvBench 和 JailbreakBench）上保持了具有竞争力的性能。具体而言，对中间层进行剪枝后，OR-Bench Hard 和 PHTest 上的合规率明显提升，表明中间层在区分有害指令与伪有害指令方面起着关键作用。另一方面，对底层或顶层进行剪枝并未展现出同等程度的改进，底层和顶层剪枝在 OR-Bench Hard 上的表现均明显较低。

这一发现表明，中间层在处理与安全相关任务方面具有最佳能力，对这些层进行剪枝能够有效减少过度拒绝，同时不会牺牲模型在真正有害指令上的整体性能。

中间层具体选择的影响。如表 11 所示，我们展示了在原始设定的剪枝层附近进行剪枝的效果。可以观察到，对中间层进行剪枝通常有助于缓解过度拒绝；因此，剪枝层的选择并不十分敏感。

D.5 部署可行性定量结果

表示编辑需要额外存储固定的干预向量，用户必须在加载或分发模型时一并保存这些向量，从而增加了使用和维护成本。相比之下，ProSafePrune 在剪枝后生成一个完全独立的模型，无需额外的配套文件，使得迁移和部署更加方便。我们进一步报告了在 OR-Bench-Hard-1K 上的推理时间（200 个样本，最大生成长度为 256）：Self-CD (43 分钟），SCAN(20 分钟），Surgical(21 分钟）以及 ProSafePrune（仅 16 分钟）。Self-CD 因多次比较推理而产生极高的开销；特征干预方法需要张量流的截断和插入，这会破坏推理框架的优化，导致额外延迟。