



虚假新闻检测综述：多模态方法的全面回顾

Juyeob Lee a,1, Junyeop Cha ^{a,1}, Minsu Park a,1, Minyoung Lee b,1, Taeun Kim c, Seul-Ki Choi c,
Angel P. del Pobil d, Eunil Park ^{a,d,*}

a 成均馆大学 应用 人工智能 系, 首尔 03063, 韩国 共和国 b 三星 电子 有限公司, 水原 16677,
韩国 共和国 c 韩国 互联网 与 安全 局, 全罗南道 58324, 韩国 共和国 d 计算机 科学 与 工程 系,
海梅 一世 大学, 卡斯蒂利翁 12007, 西班牙

文章信息

关键词: 虚假 新闻
检测 机器 学习 深度
学习 多模态 系统 综
述

ABSTRACT

随着社交媒体和人工智能的快速发展, 假新闻成为一项关键的社会挑战, 加剧了虚假新闻的泛滥和社会极化。为了应对这些挑战, 多模态方法被认为是极具前景的解决方案, 它们通过整合多样化的数据模态来捕捉互补信息。本研究全面审视了假新闻检测模型的演变, 强调了多模态技术的独特潜力。我们提出了一种新颖的多模态方法分类体系, 该体系围绕三个关键维度构建: 特征提取、融合方法和学习目标。我们的综述首先对关键数据集进行了详细比较, 强调了它们的特征、局限性以及对多模态任务的适用性。随后, 我们对多模态检测技术进行了深入分析, 探讨了它们的方法论和性能表现。此外, 我们还探讨了诸如生成式AI等用于鲁棒检测的新兴技术, 以及可能的伦理考量, 包括隐私风险和模型偏见。为了应对跨平台泛化性和现实世界可扩展性等挑战, 我们提出了未来开发有效多模态假新闻检测系统的几个方向和机遇。通过这篇全面的综述, 我们旨在为该领域的研究人员和从业者提供有价值的见解和可行的指导, 从而为打击假新闻的持续努力做出贡献。

1. 引言

在当今的数字社会中, 假新闻的快速传播已成为一项严峻的社会挑战, 它破坏了公众信任并加剧了政治极化。社交媒体平台的普及——如今大多数美国人都依赖其获取新闻[1], ——放大了虚假信息的制造与传播, 使得个人越来越难以区分真实与虚假内容[2,3]。

假新闻的社会影响是多方面的, 影响着政治[4], 公共卫生[5] 和经济稳定[6]等关键领域。例如, 在2016年美国总统选举期间, 大量假新闻在社交媒体平台上传播, 研究表明它们影响了选民的选举决定[7]。除了政治之外, 假新闻还构成了重大风险

* 通讯 至: 310 国际 馆, 成均馆 大学, 25-2 成均馆路, 钟路区, 首尔 03063, 韩国 。 电子邮件 地址: eunilpark@skku.edu (E. Park).¹ 同等 贡献




图 1. 2015 至 2024 年假新闻检测研究趋势。

对公共卫生。COVID-19大流行伴随着关于病毒和疫苗安全性的假信息的“信息疫情”，这削弱了公众对循证卫生政策的信心[8,9]。这些例子凸显了假新闻在各个领域构成的深刻社会威胁。

假新闻的泛滥已成为一项严峻挑战，推动了假新闻检测领域的重大进展和日益增多的研究，如图1所示，2015年至2024年间假新闻检测的出版物数量不断增加。该领域的早期工作主要集中于分析单一模态，例如孤立地分析文本内容[10]或视觉元素[11,12]。然而，这种单模态方法存在固有的局限性，因为它们往往无法捕捉不良行为者利用不同数据类型之间复杂的相互作用和不一致性，从而使假新闻更具说服力和欺骗性[13]。随着现代社交媒体平台从基于文本和图像的内容向视频和音频格式[14,15]转变，这一局限性正变得日益关键。

针对这些局限性，多模态方法应运而生，成为强有力的解决方案。开创性研究开始整合不同的数据模态，例如文本与图像，以捕捉互补信息并检测它们之间的一致性[16]。随后深度学习的进展推动了强大模型的开发，例如VisualBERT[17]和UNITER[18]，它们学习文本和视觉数据之间的相关性以提高检测准确率。除了文本与图像，一些研究人员还扩展到了其他模态，例如音频[19]和社交互动信息[20]。研究一致表明，多模态框架优于单模态模型。因此，多模态假新闻检测的研究迅速扩展，如图1所示，近年来出版物数量的增加清楚地说明了这一趋势。

然而，这种快速扩张导致了研究领域的碎片化。尽管模型激增，该领域仍处于起步阶段，存在必须解决的显著研究空白和技术挑战。例如，对于各种融合策略的相对优势及其应用的最佳条件，仍明显缺乏共识。此外，许多可用的数据集仅限于特定领域或语言，这对在多样化的真实世界环境中验证模型性能提出了挑战。因此，一项系统综述对于梳理这一新兴研究体系、识别关键趋势与局限性，并为未来研究确立明确方向至关重要。

因此，本研究旨在通过系统性地审视关键趋势以指导未来研究，从而对该领域提供全面且结构化的分析。为实现这一目标，我们引入了一种用于对多模态方法进行分类的新颖分类法，该分类法围绕三个关键维度构建：特征提取、融合方法和学习目标。通过对关键数据集的详细比较并应用我们的框架，我们追溯了检测模型的发展，清晰地理解了其底层方法，并批判性地评估了其局限性。目标是研究人员和从业者提供有价值的见解和可操作的指导，最终促进更稳健、更有效的假新闻检测系统的发展。

本文的其余部分组织如下。第2节回顾了先前的文献和相关综述，指出了它们的局限性，从而确立了我们这篇全面综述的独特贡献。第3节对多模态假新闻检测中使用的关键数据集进行了详细分析，重点介绍了它们的属性和局限性。第4节应用我们提出的三轴分类法，从特征提取、融合策略和学习目标三个方面对检测模型进行分析和基准评估。最后，第5节讨论了新兴挑战，例如AI生成内容和跨平台泛化性，并概述了未来的潜在研究方向，以推动有效且可扩展的假新闻检测系统的发展。




图2. 多模态假新闻数据集的趋势；绿色：文本 + 图像，橙色：文本 + 图像 + 社交上下文元数据；蓝色：视频。（关于本图例中颜色的解释，读者可参考本文的网络版。）

2. 相关工作

早期关于假新闻检测的研究自然而然地倾向于书面文本。Shu等人[21]以及Zhou和Zafarani的全面综合研究[22]建立了一个基础分类法，确定了欺骗检测的四个主要维度：文体特征、基于知识的线索、传播模式和来源可信度评估。在这个形成期，实证研究受到数据可用性有限的制约，研究人员主要使用小规模的单语英语数据集，例如LIAR[23]。这些研究主要采用支持向量机、早期的卷积神经网络（CNN）和长短期记忆（LSTM）分类器。

随着更大型数据集和Transformer模型[24]的出现，研究重点转向了资源和端到端架构。D'ulizia等人[25]编目了四十多个语料库，记录了它们的构建方式以及可能存在偏见的环节，而Alam等人[26]列出了数十种CNN、Bi-LSTM和BERT变体。尽管这些综述无疑具有价值，但它们仅对多模态研究作了简要提及，完全忽略了音频和视频模态。此外，它们未能考虑数据集的结构和组成如何制约模型可采用的融合策略。

最近，讨论的焦点再次转移，坚定地转向了多模态。Nasser等人[27]遵循精确调查与荟萃分析（PRISMA）流程，筛选了近千条记录，并保留了涵盖文本、图像、视频和音频的121项研究。Zidan等人[28]专注于文本-图像融合，比较了Transformer交叉注意力与多模态图神经网络，同时对可解释性提出了疑问。

早期的研究几乎将假新闻检测完全概念化为文本分类任务。他们在单模态假设下将算法围绕词汇、风格和心理语言学线索进行聚类，并主要依赖于英语的政治导向语料库。因此，文本证据与社交上下文信号（如用户图）之间的交互在很大程度上仍未被研究。

图像丰富平台的普及推动了下一波综述浪潮，这些综述在传统的以文本为中心的方法中附加了简短的“视觉”小节。这些研究大多分析了简单的早期和晚期融合，忽略了音频和视频模态，并且仅对跨模态注意力或双线性池化等高阶算子进行了肤浅的处理。

在这些局部尝试的基础上，出现了一系列更全面的多模态综述。最近的多模态综述涵盖了文本-图像、文本-视频和文本-音频研究。然而，这些综述仍然单独评估模型，并且大多忽略了训练数据偏差、元数据、语音信号和高级融合组件等问题。

为了解决这些差距，我们以一种综合的方式推进该领域。

- 我们引入了一个统一的三轴图，通过特征提取、融合策略和学习目标来定位所有研究
- 我们考察了众多广泛使用的假新闻数据集，揭示了模态和语言偏差，并为构建平衡的多模态基准提出了指导原则
- 我们探讨了新兴的生成式模型如何重塑检测挑战，并引发了隐私和偏差相关考量

3. 数据集

假新闻检测作为现代社会中一个关键的研究领域应运而生，旨在评估信息的真实性。为解决这一问题而开发的假新闻检测模型严重依赖于值得信赖的数据集进行训练和评估，而这些数据集的多样性和质量显著影响着研究成果。由于假新闻可以通过各种模态传播，例如文本、图像和视频，因此包含多模态数据的数据集的重要性正变得日益突出。

图2展示了多模态数据集的增长趋势，涵盖文本、图像和视频模态。多模态数据集的出现始于2014年，并在早期逐渐被采用和发展。然而，自2020年以来，多模态假新闻数据集的创建出现了显著激增，这与深度和多模态学习研究的快速发展相吻合。这一时期标志着多模态方法的探索和应用发生了关键性转变，特别是在假新闻检测等领域。多模态数据集在提高检测系统的准确率和鲁棒性方面发挥着关键作用，使其成为应对各种上下文中错误信息复杂性的不可或缺的工具。




图 3. 虚假新闻基准数据集示例。

图3展示了假新闻文章及其对应图像样本的示例。用于假新闻检测的数据集可大致分为单模态数据集和多模态数据集。每种类型都捕捉了特定模态的独特特征，同时提供了检测和理解假新闻传播所需的多样化元数据。本节根据模态系统地对假新闻检测的常用数据集进行分类，并讨论了它们的主要特征和应用。

3.1. 基于单模态的数据集

单模态数据集用于虚假例如文本或图像。这些数据集在理解虚假新闻特征方面发挥着基础作用。代表性单模态数据集的汇总见表1。

基于文本的数据集是使用最广泛的，通常包含新闻文章、社交媒体帖子以及被标记为虚假或真实的标题。这些数据集提供深入了解，了解Linguistic patterns, 情感, 以及语法特征与假新闻相关。

例如，LIAR [23] 数据集可作为评估政治声明真实性的基准。它包含从PolitiFact² 2007年至2016年间收集的12,836条声明，每条声明都标注了六种细粒度标签之一：裤子着火、假、勉强真实、半真、大部分真和真。这些类别使得LIAR数据集特别适合评估需要细粒度分类的基于文本的假新闻检测模型。除了新闻文章的标题和正文外，该数据集还包含元数据，如声明来源、上下文信息以及发表声明者的职业。这些丰富的上下文数据使研究人员能够在更广泛的社会政治背景下考察假新闻。LIAR数据集主要用于检测政治假新闻，并支持多类分类任务，为推动基于文本的假新闻检测方法提供了宝贵的资源。

ISOT [31] 数据集是政治假新闻检测的另一个重要资源。它由来自路透社的12,600篇真实新闻文章和来自Kaggle的12,600篇虚假新闻文章组成。虚假新闻样本以煽情标题和误导性内容为特征，使得该数据集非常适合研究区分假新闻与合法新闻的语言模式和情感线索。

CREDBANK [32] 数据集是一个大规模的文本资源，专为可信度分析研究而设计。它包含2014年10月至2015年2月期间收集的6000万条全球推文，涵盖1000个事件。每个事件都标注了可信度评级，使研究人员能够评估社交媒体平台上共享信息的可靠性。

FacebookHoax [33] 数据集关注从Facebook收集的科学新闻和阴谋论相关新闻，区分了虚假和真实新闻报道。它包含8923个恶作剧帖子和6577个非恶作剧帖子，使其成为分析假新闻在社交媒体生态系统中传播和特征的重要资源。该数据集能够研究区分恶作剧与合法内容的语言和上下文特征，为开发减轻假新闻对社交媒体影响的模型奠定了基础。

PHEME [41] 数据集通过提供与重大社会事件相关的Twitter数据来支持谣言检测研究。它包含了从五起重大事件中收集的推文：弗格森骚乱（2014年8月）、渥太华枪击案（2014年10月）、悉尼人质危机（2014年12月）、查理周刊袭击案（2015年1月）和德国之翼航空坠机事件（2015年3月）。该数据集分为谣言和非谣言，包含1972条谣言推文和3830条非谣言推文。每条推文还根据其引用的具体事件进行分类，使得该数据集在分析谣言的传播和上下文特征方面具有特别的价值。

²
<https://www.politifact.com/>。

表 1 单模态虚假新闻数据集 汇总。

D数据集	描述 iption	M模态	来源	标签	Data 数据量
2CTweets [34]	Tweets 分类 for 事件相关 事件	Text	Twitter	相关, 非相关 ated	N 未 指定
BuzzFeed [35]	Hyperpartis an 和 虚假 新闻 文章	Text	Facebook	Mostly y 真实, 混合, m ostly false, no f actua l 内容	1627
COVID-19 [36]	COVID-19 虚假 新闻 数据集	Text	公共 事实核查 网站 , 社交 media	Real (22,916), Fake (9,728)	42,644
CREDBANK [32]	媒体 可信 度 ty Social m 标注 语料库	Text	Global 推文	可信度 标 nn注	1000
CrisisLex [37]	与危机相关的 词汇 n 用于 微博	Text	Twitter	Disaste r-rel ated (关键词 ; 9,777,964, location-base: 639,667)	10,417,63 1
Em 涌现 [38]	立场 c lassification 数据集 针对 谣言	Text	Rumor sites, Twitter	对于 (12 38), Again st (394), 观察 s (963)	2595
FacebookH 骗局 [33]	恶作剧 与 非骗 局 观 n 社交 网络 s 政治 虚假 n 闻 检测 n 数据集	Text	Facebook	H 骗局 (8923) , Non-h 恶作剧 (6577)	15,500
George McIntire 数据集 [39]	数据集 fo r 虚假 新闻 detectio n	Text	各类 新闻 websites	Fake (3164), 实 l (3171)	6335
ISOT [31]	基准 数据集 fo r 虚假 新闻 detectio n	Text	路透社, PolitiFact , Kaggle	虚假 (12 , 600), 雷 l (12,600)	25,200
LIAR [23]	真实性 a nnotati ons o 简短 声明	Text	PolitiFact	裤子着火 e, False, Barely-true, 半真半假 ue, M基本属实, True	12,836
MICC [40]	图像 取证 数据集 fo r 复制-移动 检测	Image	Columbi a, 摄影 图像 仓库	Fake, 真实	MICC-F220, MICC-F2000, MICC-F6000
PEHEME [41]	Rumor detectio n 数据集 fo r 主要 社会 l 事件	Text	Twitter	谣言 (1972), 非谣言 (3830)	5802
Twitter 印度 D 数据集 v3 [42]	Fake 新闻 检测 n in 政治 与 宗教 内容	Image	Twitter	F 虚假 (61), 有效 (49)	110

虽然基于文本的分析至关重要，但它通常无法解释强化虚假叙事的视觉欺骗。因此，基于图像的数据集被开发出来以分析这些视觉线索。这些数据集由经过篡改或具有误导性的视觉内容以及配对的标注组成，使研究人员能够分析诸如不一致性、篡改或语境不匹配等视觉线索。单模态数据集不仅有助于开发特定模态检测方法，而且通过提供对每种模态独特属性的更深入理解，为更复杂的多模态方法奠定了基础。

MICC [40] 数据集是一个专为复制移动伪造的检测和分析而设计的取证图像数据集。它由三个子集组成，每个子集都针对伪造检测中不同的尺度和复杂性而定制。MICC-F220包含220张带有复制移动伪造的图像，MICC-F2000包含2000张图像，而MICC-F6000则是一个包含6000张带有复制移动伪造的高分辨率图像的综合集。该数据集对于学习图像篡改的特征以及评估为伪造检测设计的算法的性能非常有效。MICC数据集特别适合测试传统方法（如基于SIFT的聚类）以及用于检测合成篡改的高级深度学习技术。其多样化的子集使其成为开发能够识别和定位各种场景下图像伪造的鲁棒模型的宝贵资源。

Twitter印度数据集v3 [42] 专注于分析2019年11月至2020年11月期间在印度Twitter上分享的虚假图像和真实图像，特别强调政治和宗教事件，这些是假新闻的常见目标。该数据集由110张图像组成，其中61张被标记为虚假，49张被标记为真实。这些图像是通过在印度事实核查网站（如BoomLive、Alt News和India Today）上搜索变形或伪造新闻图像，然后从Twitter检索相应的推文和新闻文章而收集的。该数据集经历了两阶段的验证过程：首先，在事实核查网站上对图像进行交叉核对；随后，由同行评审员进行手动标注，确认图像在Twitter平台上的真实性。该数据集为研究虚假图像在社交媒体上的传播以及开发旨在检测假新闻的模型提供了宝贵的见解。

3.2. 基于多模态的 数据集

单模态数据集对于理解假新闻在每种模态中的独特特征至关重要。然而，在现实场景中，假新闻通常涉及多种模态，例如文本与图像或视频的配对。为了应对这种复杂性，多模态数据集作为重要资源应运而生，使得能够整合各种模态以捕捉假新闻丰富且微妙的本质。通过将文本、图像和视频与同步标注相结合，这些数据集促进了对跨模态关系的分析，并提供了对假新闻更真实的表征。这支持了先进的

检测模型的发展, 这些模型能够有效地处理多模态输入。多模态数据集的示例呈现在表2中。

深度伪造检测挑战赛 (DFDC) [43] 数据集是Facebook开发的大规模资源, 旨在推进深度伪造检测研究。该数据集包含104,500个被操纵的视频和23,654个真实视频。该数据集包括使用先进深度伪造技术生成的合成视频, 具有面部操控和音频篡改特征。它被广泛用于评估视频操控检测算法的性能。通过提供高质量、逼真的合成视频, 该数据集使研究人员能够在实际且具有挑战性的条件下测试其模型。因此, 它是开发强大解决方案以打击基于视频的假新闻和操纵行为的关键资源。

AraFacts [45] 数据集是一个多模态资源, 旨在检测阿拉伯语世界的假新闻。它整合了文本、图像和视频数据, 为该领域的研究提供了全面的基础。该数据集使用从国际事实核查网络 (IFCN) 附属的各个事实核查组织收集的数据构建。它涵盖多个关键主题, 包括政治、健康、社会问题、宗教以及综合科学与艺术。政治类别涉及与选举和政治事件相关的假新闻, 而健康类别则侧重于有关医疗和公共卫生话题的虚假信息。社会类别包括与社会问题和文化叙事相关的内容, 宗教类别包括涉及宗教主题和争议的声明。最后, 综合科学与艺术呈现了常识和艺术主题的更广泛话题。

WEIBO [57] 数据集包含从中国社交媒体平台微博收集的文本与图像数据, 分为谣言和非谣言两类。该数据集由2012年5月至2018年11月期间收集的3749个谣言样本和3783个非谣言样本组成。该数据集考察了文本与视觉元素之间的交互, 并探讨了图像如何强化与特定主题相关的谣言。它是中国语境下假新闻检测研究的重要资源, 能够在多模态学习框架内实现对文本与图像模态的整合分析。

MMHS150K [51] 数据集是从Twitter收集的文本与图像多模态数据集, 旨在完成检测仇恨言论等任务。它被分为多个类别, 包括非仇恨、种族主义和性别歧视内容, 反映了仇恨言论的多样性。MMHS150K为研究人员提供了在网络有害内容上下文中研究语言与图像之间复杂关系的机会。其多模态特性加深了我们对文本与图像如何促进攻击性信息传播的理解, 使其成为开发和评估更稳健的有害内容检测模型的宝贵资源。

MediaEval [50] 数据集包含与重大灾难相关的文本与视觉信息, 例如飓风桑迪 (HS) 和波士顿马拉松 (BM)。它包含10,757个虚假文本-图像对, 其中HS有3540个真实样本和281个虚假样本, BM有460个真实样本和281个虚假样本。该数据集支持专注于检测灾难期间通过社交媒体传播的假视觉信息的研究。这对于评估紧急上下文中信息的可靠性, 以及应对关键情况下的假新闻挑战, 具有特别的价值。

多模态多语言事实核查假新闻 (MuMIN) [55] 数据集是一个综合性的集合, 包含从社交媒体平台收集的经过事实核查的多语言多模态数据, 旨在支持包括COVID-19在内的各种主题的假新闻检测。它包含文本、图像、推文和用户元数据, 涵盖多种语言和主题。该数据集的关键组件包括带有相应事实核查信息的推文文本、链接到推文的视觉内容, 以及关于推文作者的元数据。MuMIN非常适合研究文本与图像之间的交互, 并分析假新闻在特定用户群体中的传播。该数据集能够实现针对不同社交和语言上下文中假新闻的理解与缓解的整体方法。

FakeNewsNet [48] 数据集是一个广泛用于假新闻检测的多模态资源。它包含文本与图像数据, 其中文本由新闻文章正文和标题组成, 图像则是与新闻文章相关的视觉内容。除了文本和视觉数据外, FakeNewsNet还融合了社会语境, 使研究人员能够研究假新闻如何在社交媒体平台上传播。该数据集分为两类: 来自PolitiFact的政治新闻和来自GossipCop的娱乐新闻。这种划分有助于针对这些特定领域中与虚假和真实新闻相关的文本与视觉特征进行重点分析。通过整合多模态数据, FakeNewsNet支持探索文本与图像之间的相关性, 使其成为识别假新闻独有特征和促进检测模型发展的重要工具。

Fakeddit [47] 数据集是一个旨在支持假新闻检测研究的多模态资源, 由从Reddit收集的文本与图像组成。该数据集共有1,155,550个样本, 其中包括628,501个假新闻样本和527,049个真实新闻样本, Fakeddit能够支持结合文本和视觉数据的复杂分析。这使得它对于利用图像中的上下文线索来识别假新闻的研究尤为宝贵。该数据集被广泛用于探索与虚假和真实新闻相关的文本与视觉模式, 使研究人员能够评估多模态数据的协同效应。此外, Reddit独特的社会语境的融入, 为理解假新闻的创造和传播提供了重要资源, 从而深入洞察假新闻如何在网络社区中传播。

MULTI-Fake-DetectiVE [53] 数据集聚焦于俄乌战争, 整合了文本与图像以支持假新闻检测与验证。该数据集围绕两个子任务构建: 子任务 #1 将新闻分类为确属虚假、可能虚假、可能真实或确属真实, 而子任务 #2 评估帖子的意图, 将其分类为误导性、非误导性或无关。该数据集旨在评估多模态方法的有效性, 因为结合文本与图像使研究人员能够探索假新闻的复杂结构。MULTI-Fake-DetectiVE 作为一项关键资源, 用于开发和评估分析假新闻中文本与视觉元素相互作用的模型, 并应对假新闻检测与意图分析的细微挑战。

表 2 多模态虚假新闻数据集 汇总。

D数据集	描述 iption	M模态	来源	标签	D数据 量
所有数据 [44]	包含 文本 和 图像 的 虚假 新闻 检测 多模态	文本, 图像 age	各种 新闻 文 章 和 图像 ages	Real (8074), 虚假 (11,941)	20,015
阿拉伯 [45]	数据集 A 事实 数据集 的 自然 发生 声明 用于 核查	文本, 图 age, 视频	F像, 6,1M, Arabi Factu, Misraabi Verify-Sy	False, 部分错误 se, 讽刺 m, True	6,222
BIEN 数据 [46]	D数据集 for fak BIEN 来自 竞赛	文本, 图像 age, OCR	新闻 与 ebsites	Real (文本: 19,86, Image: 11,064, 光字字符识别: 5276), Fake (文本: 19,285, Image: 10,768, 光字字符识别: 3286)	68,865
DFDC [43]	enge 数据集 用于 深度伪 造 视频	视频	合成 videos	Real (23,654), Fak e (104,500)	128,154
Fakeddit [47]	检测 多模态 数据集 fo r 细粒度 虚假 新闻 检测 在 Reddit	文本, 图像 age	Reddit 帖子	Real (527,049), Fake (628,501)	1,155,550
虚假Fakenewsnet [48]	仓库 itory with n ews 内容, 社交 上下文 , and 时空 通知 ation	ext, 社交 T ial 上下文	F事实核查 websites	Real, Fake	N 非 指定的
IFND [49]	印度 数据集 fo r 虚假 新闻 检测 和 URL with titles, im 年龄,	文本 (标题, URL), Image (URL)	印度 新闻 网站	Real (37,809), Fak e (7271)	45,080
MediaEv al [50]	Dataset focusi ng on 计算 验证 n in 危机 期间 的多媒体	文本, 图 age, URL	Twitter	真实 (飓风 桑迪: 3540, 波士顿 M arath 马拉松: 460), Fake (飓 风 桑迪: 10,757, 波士顿 马拉松: 281)	15,038
MMHS150K [51]	仇恨 言 h 检测 在 多模态 Tw itter 中 图像	文本, 图 age	Twitter	非恐同 (112,845), 种族主义 (11,92 5), 性别歧视 (3495) , 恐同 (3870), 基于宗教 (163), 其他 (5811)	138,109
MR2 [52]	多模态 l 检索增强 谣言 检测 数据集	文本, 图 age	Twitter, 微博	谣言谣语, 未验证 帖 子	14,700
MULTI-Fake-D etect iVE [53]	多模态 数据集 fo r 俄乌 战争 虚假 新闻 检测	文本, 图像 age	社交 媒体 帖子, 新闻 文章	Real e (196), k (485), 非 误导性 (705)	1,638
MultiOFF [54]	多模态 冒犯性 内容 检测	文本, Im age	Social media	Off 详尽的 (305), 非冒犯性 (438)	743
MuMiN [55]	Multilingual 多模态 l 虚假 新闻 数据集	文本, Tw eet, 图像, 使用 r	Fact-checkin g orga 组织, Twitter	虚假 新闻, F 实际的, 其他	984
ReCOVerY [29]	仓库 itory f 或 COV ID-19 news 可信度 研究	Text, Image	Social media platforms (NewsGuard , Media 偏见/事实 C heck)	Reliabl e (1364), 不可靠 (665)	2,029
TI-CNN [30]	D数据集 f inin fake 新闻 检测 n	文本, 图 age	Megan Ri sda (240 网站) , 权威 news 网站	Real (8074), 虚假 (11,941)	20,015
微博 [56]	Chin 语 数据集 用于 虚假 新闻 检测 包含 文本 和 图 ges	文本, 图 age	Weib o 帖子	Real (文本: 19,186, 图像: 20,461), 虚假 (文本: 19,2 85, 图像: 13,635)	72,567
WEIBO [57]	D数据集 for rumor 检测 ion using 多模 态 信息 tion	Tweet Text, Im, 社交 语境	Weib o 帖子	Rumor (3749), Non-Rumor (3783)	7,532

3.3. 特定 领域 数据集

此外, 特定领域 数据集 被 开发 以 支持 假 新闻 检测, 聚焦 于 特定 主题 或 领域。这些 数据集 促进 了 对 特定领域内 假 新闻 特征 与 传播 机制 的 深入 研究。值得注意的是,

以COVID-19大流行和美国总统选举为中心的数据集是突出的例子。此类数据集对于理解这些领域中假新闻的独特结构和特征至关重要，对于开发有针对性且有效的检测模型具有不可估量的价值。通过纳入这些特定领域的见解，特定领域数据集提高了整体研究效率，并扩展了假新闻检测在不同且关键的现实环境中的范围。

3.3.1. COVID-19

在COVID-19大流行期间，假新闻在全球范围内产生了重大的社交影响。与这场危机相关的数据集侧重于分析和检测有关公共卫生和传染病的假信息。这些资源为开发能够应对健康危机期间假新闻挑战的模型提供了坚实的基础，从而确保在紧急情况下进行准确且可靠的沟通。

ReCOVery [29] 数据集是在COVID-19大流行期间收集的多模态资源，包含文本、图像和视频数据。该数据集基于来自NewsGuard和Media Bias/Fact Check等可靠来源的新闻，为假新闻研究提供了坚实的基础。这有助于研究多种模态之间的相互作用，以检测和理解与COVID-19相关的假新闻。

相比之下，COVID-19 Fake News [36] 数据集是一个基于文本的资源，收集自PolitiFact、Snopes和Boomlive等事实核查平台。它专注于分析疫情期间假新闻对公共卫生的影响，并被广泛用于开发遏制假新闻传播的模型。该数据集对于研究文本形式假新闻的语言模式和上下文特征尤为宝贵，有助于为在健康相关上下文中检测假新闻创建有效的工具。

3.3.2. 美国 选举

美国总统选举，特别是2016年选举，由于假新闻通过社交媒体平台的广泛传播，成为了假新闻研究的焦点之一。与选举相关的数据集有助于研究政治假新闻文章的生成和传播机制。

TI-CNN [30] 数据集包含与2016年美国总统选举相关的文本和图像数据，专门为假新闻检测而设计。该数据集是分析政治假新闻中文本和视觉元素之间相互作用以及评估多模态检测模型的宝贵资源。

BuzzFeed [35] 数据集基于从Facebook收集的政治新闻，侧重于理解政治假新闻如何在社交媒体上传播并获得可信度。这对于研究用户在Facebook等平台上对假新闻的互动和反应特别有用，为假新闻传播的行为动态提供了见解。

George McIntire [39] 数据集包含与2016年美国总统选举相关的文本数据，包括3164篇假新闻文章和3171篇真实新闻文章。它被广泛用于检测政治假新闻，支持对文本数据中语言线索和情感要素的研究，以更好地理解政治上下文中假新闻的特征。

3.4. 错误信息 的 分类

随着多模态假新闻检测的成熟，该领域已从简单的真实与虚假二元分类转向更细致的标签方案。这种转变在基于意图和内容扭曲性质对错误信息进行分类的现代基准构建中最为明显。正如Nakamura等人 [47] 以及Segura-Bedmar和Alonso-Bartolome [58]，所观察到的，假新闻可以分为几种不同的技术和风格类型，包括讽刺或恶搞，其无意造成伤害但具有欺骗的潜力；以及误导性内容，涉及对信息的误导性使用来构陷问题或个人。其他突出的类别包括冒充内容，即冒充真实来源；虚假关联，即标题、图像或说明不支持内容；以及篡改内容，即篡改真实信息或图像以进行欺骗。此外，一些最近的框架引入了三分法分类方法。例如，Yang等人 [59] 将新闻分为真实、假和未经证实类别，反映了实时社交媒体流中存在的实际模糊性。

3.5. 关于 数据集 的 讨论

多模态假新闻数据集已从规模较小的手动策划基准转变为大规模的自动收集存储库。这种增长在数据量与标注质量之间引入了关键的权衡。早期数据集（如LIAR和微博）提供了经过验证的标签；然而，其有限的规模和对简单分类标签的依赖，往往无法捕捉现代错误信息的复杂谱系，包括微妙的讽刺或数字篡改的上下文。相比之下，包括Fakeddit在内的大规模数据集，提供了训练基于深度Transformer的模型所需的空前数据量，但其抓取和标注过程的自动化性质不可避免地引入了噪声以及文本与图像之间潜在的不对齐。这种数量上的扩张可能会损害检测系统在高风险现实场景中的精确率，而在这些场景中，细致入微的判断至关重要。

严重的领域和文化偏见也限制了当前检测框架的全球适用性。大多数现有的基准严重集中在以美国为中心的政治事件或特定的全球危机（如COVID-19大流行）上，这可能导致模型过度拟合特定的语言模式或事件特定线索。这种集中现象因英语内容的主导地位而加剧，从而忽略了非西方语境所固有的独特句法、习语和文化细微差别，这些细微差别存在于




图4. 模型类别的结构化概述。特征提取类别在第4.1节中描述，融合方法类别在第4.2节中，学习目标类别在第4.3节中。

非西方语境[60]中。因此，仅在这些基准上进行验证的模型在部署到多样化的语言环境中时，往往难以具备泛化能力。要解决这些偏见，需要向多语言和文化多样性的数据整理转变，而这只能通过与区域专家和母语使用者的合作努力来实现，以确保标注在上下文中保持准确，并能代表当地的虚假信息策略。

社交媒体消费的快速转变突显了当前研究中显著的模态差距。虽然文本和图像对曾是主要焦点，但短视频平台和生成式AI的兴起迫切需要向更复杂的格式转变，包括音频、视频和交互式合成媒体。目前的资源，如DFDC和AraFacts，已开始应对这些挑战；然而，仍然迫切需要提供同步、跨平台和多格式数据的数据集，以跟上不断变化的欺骗手段。最终，研究界应优先考虑动态基准测试和整合新兴的AI生成内容，以构建更强大的检测系统，在不断变化的数字环境中可靠地运行。

4. 多模态 检测

在本节中，我们通过关注三个关键要素来分析多模态假新闻检测模型：特征提取、融合方法和学习目标。特征提取在第4.1节中介绍，融合方法在第4.2节中讨论，学习目标在第4.3节中探讨。图4-6分别展示了模型类别、每种数据模态的编码器以及融合方法的结构化概述。我们考虑使用Web of Science数据库来选择文章。应用的搜索字符串为‘(Machine Learning OR Deep Learning) AND (Multimodal) AND (Fake News) AND (Detect*)’。在结果中，我们仅考虑以英文撰写的论文，并排除综述论文。最终收录的论文总结在表3中。

4.1. 特征 提取

数字平台上假新闻的兴起引发了对多模态假新闻检测的广泛研究。这种日益增长的兴趣源于对分析和整合文本、图像和视频等多种数据模态的需求，以准确识别欺骗性内容。多模态假新闻检测利用了深度学习和自然语言处理（NLP）的进步，采用了最先进的架构，如卷积神经网络（CNN）、循环神经网络（RNN）、基于Transformer的模型（如BERT）[116]，和视觉Transformer（ViT）[117]。这些方法旨在利用各种模态的互补优势，为假新闻检测提供更全面的视角。在本节中，我们探讨了多模态模型中采用的各种方法，根据其架构设计进行分类，并强调它们对这一快速发展领域的独特贡献。

4.1.1. 基于CNN的 模型

基于CNN的架构在多模态假新闻检测的早期阶段发挥着至关重要的作用，能够从文本和视觉数据中进行有效的特征提取。这些研究中的大多数提出了将文本CNN与预训练图像CNN相结合的框架，以利用这些模态的互补性。

多模态 虚假 新闻 检测 的先驱 方法 之一， Wang et al. [16], 引入了 EANN 模型， 该模型利用 文本CNN 从 文本 数据 中提取 语义 特征， 并利用 预训练的 VGG-19 [118] 进行 视觉 特征 提取。 A

表 3 综述 方法 摘要; T: 文本, I: 图像, A: 准确率, P: 精确率, R: 召回率, F: F1分数.

A方法	M模式	数据集	Evaluation 指标
Qian 等人 [61]	T, I	Twitter, PHEME	A, P, R, F
Xiong 等人 [62]	T, I	WEIBO, GossipCop	A, P, R, F
Qi 等人 [63]	T, I, Knowledge	WEIBO, Twitter, PHEME	A, P, R, F
Wei 等人 [64]	T, I	WEIBO, Twitter	A, P, R, F
Raj 和 Meel [65]	T, I	TI-CNN, 涌现, MI, CC	A, P, R, F
Luqman 等人 [66]	T, I	Fakeddit	A, P, R, F, Matthews 相关系数, 优势比
Singhal 等人 [67]	T, I	Twitter, Facebook	A, P, R, F
Wang 等人 [16]	T, I	WEIBO, Twitter	A, P, R, F
Zhang 等人 [68]	T, I	WEIBO, Twitter	A, P, R, F
Al-Alshai 等人 [69]	T, I	ISOT, MediaEval	A, P, R, F
Athira 等人 [70]	T, I	FakeNewsNet	A
Segura-Bedmar 和 Alonso-Bartolome [58]	T, I	Fakeddit	A, P, R, F
Lv et al. [71]	T, I	微博, Twitter	A, P, R, F
Nakamura 等人 [47]	T, I	Fakeddit	A, P, R, F
Yang 等人 [59]	T, I	微博, Twitter, IKCEST-2023	A, P, R, F
Sharma and Garg [49]	T, I	微博, IFND	A, P, R
Xu 等人 [72]	T, I	微博, Twitter	A, P, R, F
Peng 等人 [73]	T, I	微博, Twitter	A, P, R, F
Yadav and Gupta [74]	T, I	Twitter, Fakeddit, Jruvika 虚假新闻, Puentes Datasets	A, P, R, F
Hua et al. [75]	T, I	ReCOVe, ICT 和 BAAI Dataset	A, P, R
Li 等人 [76]	T, I, OCR	BIENdata, MediaEval	A, P, R
Sharma 等人 [77]	T, I	微博, Fakeddit, MediaEval	A, P, R, F
Lu 和 Ye [78]	T, I, 用户侧通知	微博, Fakeddit	A, P, R, F
Huang 等人 [79]	T, I	WEIBO, Fakeddit	A, F
Lin et al. [80]	T, I	Fakeddit, GossipCop	A, P, R, F
Liang [81]	T, I	微博, GossipCop	A, P, R, F
Goto 等人 [82]	T, Linguistic features	FakeB, R, F, 事实核查新闻, Fakenewsnet, FakeNewsCorpus	F, AUC-ROC
Kumari 和 Ekbal [83]	T, I	Twitter, 微博, PHEME, GossipCop, MR2	A, P, R, F
Yan 等人 [84]	T, I, N-HIN	Twitter, 微博	A, P, R, F
Li et al. [85]	T, I	微博, Twitter	A, P, R, F
Guo [86]	T, I	PolitiFact, GossipCop	A, R, P, F, 特异度, Mean
Al Obaid 等人 [87]	T, I	Jruvika 虚假新闻数据集, Puentes Datasets	A, P, R, F
Meel 和 Vishwakarma [44]	T, I	Fake News Dataset	A, P, R, F
Rani 和 Shokeen [88]	T, I	PHEME, CrisisLex, ISOT	A, P, R
Guo 等人 [89]	T, I, OCR	微博, Twitter	A, P, R, F
Nadeem 等人 [90]	T, I	Jruvika 虚假新闻数据集, TI-CNN, Puentes Fake News Dataset	A, P, R, F
Qu et al. [91]	T, I	GossipCop, PolitiFact	A, R, P, F, TNR
Q et al. [92]	T, I, Knowledge, Time	GRFN, IFND	A, P, R, F, MCC
Wang 等人 [93]	T, I	PolitiFact, GossipCop, Twitter	A, R, P, F
Yadav 等人 [94]	T, I	Twitter, Jruvika 虚假新闻, Puentes Fake News, 和 Risdal 虚假新闻数据集	A, P, R, F, AUC-ROC
Yan 等人 [95]	T, I	ReCOVe, GossipCop, MR2	A, P, R, F, MCC
Ayetiran 和 Özgöbek [96]	T, I, 光学字符识别	PolitiFact, MMHS150K, MultiOFF	A, P, R, F
Nadeem 等人 [97]	T, I	PolitiFact, 事实, 谣言, ipCop	A, P, R, F
Palani 等人 [98]	T, I	PolitiFact, 事实, 谣言, ipCop	A, P, R, F
Wang 等人 [99]	T, I	WEIBO, Twitter	A, F
Yu 等人 [100]	T, I	WEIBO, Twitter, PolitiFact, 行为, GossipCop	A, P, R, F
Wang 等人 [101]	T, I, 用户侧通知	微博	A, P, R, F, AUC, AP
Yin 等人 [102]	T, I	Twitter, 微博	A, P, R, F
Meel 和 Vishwakarma [103]	T, I	MediaEval, 微博	A, P, R, F
Jarrahi and Safari [104]	T, Social 上下文	Fakenewsnet	A, P, R, F
Zhang 等人 [105]	T, I	微博, Twitter, Facebook k	TP, FP, TN, FN, 基尼 coefficient
Sciucca 等人 [106]	T, I	Fakeddit	A, F

(下页 续 下页 下一页)

表 3 (续)。

Approach	Modality	数据集	Evaluation metrics
Raj 和 Meel [107]	T, I	Covid, ReCOVeRy, CoAID, MediaEval	A, P, R, F, 特异性, Mathew's 校正系数
peng 和 al. [19]	T, I, 音频	Twitter, 微博	A, P, R, F
Goyal et al. [108]	T, I, Social 上下文	Twitter	A, P, R, F
Ahuja 和 Kumar [20]	T, I, 社交 上下文	Fakenewsnet, MKLab-ITI	A, F, Sensitivity, 特异性
Kumari 等人 [109]	T, 视频, 音频	FakeClips, FVCv2.0, FVCv3.0, VAVD	A, P, R, F
Kumari 等人 [110]	T, I, 情感	NovEmoFake	A, F
Azri 等人 [111]	T, I, Sentiment	Fakenewsnet, DAT@Z20	A, P, R, F, MAE, A, F, R
Kopev 等人 [112]	T, Audio, Metadata	CT-FCC-18	A, P, R, F
张 et al. [113]	T, I, Knowledge	Fakenewsnet, Evons, Fakeddit, Cosmos, MM-Covid	A, P, R, F
ang 等人 [114]	T, I, Propagation 信息	PolitiFact, GoodNews, Twitter, PHEME	A, P, R, F
Zhang 等人 [115]	T, I, Propagation information	PolitiFact, GossipCop, PHEME	A, P, R, F




图 5. 各模态的编码器。

他们方法的一个显著特点是引入了对抗学习，使模型能够泛化到特定的新闻事件之外，并在不同的上下文中有效地识别假新闻。这突显了卷积神经网络在文本和图像模态上的潜力，并为将对抗技术整合到多模态架构中奠定了基础。

在此基础上，后续研究探索了用于多模态假新闻检测的其他CNN架构。例如，Wang等人[99]采用了类似的设置，使用文本CNN提取文本特征，并使用预训练VGG-19进行视觉分析，重点在于通过有效的特征融合来增强跨模态学习。此外，Raj和Meel[65]通过评估一系列预训练CNN模型扩大了研究范围，包括ResNet50 [119], VGG-16、InceptionV3 [120], DenseNet[121], 和 MobileNet[122], 并结合文本CNN提取文本特征。他们的结果为各种架构之间的性能权衡提供了宝贵的见解，为基于计算资源和数据集特征进行模型选择提供了实用指导。

尽管基于CNN的模型在多模态假新闻检测中取得了成功，但它们仍表现出一定的局限性，特别是在捕捉文本数据中的序列依赖方面。为了应对这些挑战，一些研究探索了混合方法，将RNN的序列建模能力与CNN的特征提取优势相结合。这些基于RNN-CNN的模型旨在通过利用两种架构的互补优势来弥合这一差距。

4.1.2. RNN-CNN 混合模型

为了解决卷积神经网络在捕捉序列依赖方面的局限性，结合RNN和CNN的混合模型被广泛应用于多模态假新闻检测。这些基于RNN-CNN的模型利用RNN对文本数据的上下文学习能力和CNN对图像的特征提取能力，从而实现更全面的多模态分析。

Kumari和Ekbal [83] 引入了一个注意力增强框架, 该框架采用双向长短期记忆网络 (Bi-LSTM) [123] 结合注意力机制处理文本数据, 并结合CNN和双向门控循环单元 (Bi-GRU) [124] 处理视觉特征。类似地, Raj和Meel [107], Sharma和Garg [49], 以及Guo [86] 使用LSTM提取序列文本特征, 并使用预训练的VGG网络进行视觉特征提取。此外, Guo [86] 证明了纹理和边缘等低层视觉特征对于有效假新闻检测的重要性。另外, Ayetiran和Özgöbek [96] 提出了一种新的方法, 该方法不仅处理文本和图像数据, 还处理图像与文本之间的关系。他们利用LAVIS [125] 等工具生成图像标题, 并使用EasyOCR提取嵌入图像中的文本。随后应用Bi-LSTM和CNN层为这些多模态输入生成特征向量, 证明了整合文本、视觉和上下文特征以增强假新闻检测的潜力。

4.1.3. Transformer-CNN 混合 模型

与完全基于Transformer的模型不同, Transformer-CNN混合模型保留了CNN编码器用于视觉特征提取, 同时采用基于Transformer的架构 (特别是BERT) 进行文本编码。这种混合设计弥合了序列建模与上下文理解之间的差距, 解决了RNN-CNN方法在捕获长文本序列全局上下文方面的局限性。

在基于Transformer的模型中, BERT成为了一项显著的创新。其双向自注意力机制能够更有效地理解文本的上下文, 克服了在捕获长文本序列中的上下文和细微依赖关系方面的局限性。这种能力, 结合在大规模语料库上的预训练以及针对特定下游任务的微调, 使得BERT在包括假新闻检测和多模态分析在内的各个领域都取得了最先进的性能。

顺应这一趋势, 许多关于多模态假新闻检测的研究采用BERT作为文本编码器, 利用其强大的上下文理解能力来提升文本与图像模态的性能。BERT可以与各种视觉编码器结合使用, 例如VGG [62,73,93], ResNet [61,69,80], EfficientNet [77], 和Inception-ResNet-v2 [103]。具有代表性的是, Nakamura等人 [47] 引入了Fakeddit数据集 [126], 评估了多种预训练的文本模型 (BERT、InferSent [127]) 和图像模型 (VGG-16、ResNet50、EfficientNet-b4 [128]), 为未来的多模态研究提供了宝贵的基础。然而, 为了克服池化操作忽略图像中空间关系的局限性, Palani等人 [98] 分别采用BERT和CapsNet [129] 来提取文本与视觉特征。CapsNet捕获图像中空间层次的能力, 使得在多模态框架中能够更准确地表示视觉内容。

随后的研究 [64,71,75] 通过引入创新组件增强了Transformer-CNN架构。Wei等人 [64] 采用BERT和VGG-19进行特征提取, 并引入了新颖的损失函数, 如重建损失、模态判别器损失和事件判别器损失, 以改善跨模态表征学习。Hua等人 [75] 利用回译方法来增强文本数据, 通过翻译原始文本然后再翻译回来以生成额外的文本数据。他们将原始文本和回译文本连同相应的图像一起用于训练模型。使用BERT和ResNet50提取文本和图像特征, 从而实现有效的多模态假新闻检测。此外, Transformer中的注意力机制被集成到混合架构中以增强假新闻检测。例如, Guo等人 [89] 使用PP-OCrv3 [130] 从图像中提取嵌入文本, 并将其作为多模态模型中的辅助特征。

推进到基于BERT的方法, 一些研究采用了XLNet [131], 它使用基于排列的训练扩展了BERT, 使其能够更有效地捕获双向上下文。Al Obaid等人 [87] 使用XLNet、Bi-GRU和VGG构建了一个基于注意力的模型集成, 以聚合预测结果。Qu等人 [91] 提出了一种新颖的基于量子多模态融合模型, 结合了量子编码和量子卷积神经网络。他们使用text-davinci-003总结了文本内容, 并使用预训练的XLNet将其嵌入。使用VGG提取图像特征。每个模态特征被拼接并使用量子电路进行处理。振幅编码将数据编码为量子态。三层量子卷积神经网络从量子比特中提取判别性特征。

4.1.4. 基于Transformer的 模型

与前述的混合方法相比, 完全基于Transformer的模型在文本和视觉模态上均采用Transformer架构。代表性示例包括用于图像块分词的ViT, 以及如CLIP和BLIP等跨模态预训练模型, 这些模型在统一的嵌入空间中学习联合文本图像表征。

Huang等人 [79] 和Yadav等人 [94] 采用ViT进行图像特征提取, 并采用BERT进行文本特征表征, 强调了这两种架构在处理多模态输入时的互补协同作用。类似地, Yu等人 [100] 通过将BERT与数据高效图像Transformer (DeiT) [132], (ViT的轻量级版本) 相结合, 扩展了这一框架, 从而增强了模型捕获上下文和视觉嵌入的能力, 并提高了计算效率。

基于这些架构上的进步, 近期的研究越来越多地采用了对比语言-图像预训练 (CLIP) 框架 [85], 标志着多模态学习的重大飞跃。在多模态假新闻检测的上下文中, Xu等人 [72] 证明了预训练的CLIP模型在提取全面的视觉-语言特征方面的有效性。Liang [81] 通过引入自举语言-图像预训练 (BLIP) [133], 扩展了这一方法, 进一步增强了多模态特征提取。Yan等人 [95] 提出了一种将CLIP与BERT和ResNet架构相结合的混合框架, 以优化文本和视觉特征提取。同样, Zhang等人 [105] 实现了一种结合RoBERTa用于文本分析和CLIP-ViT用于视觉处理的先进方法, 促进了稳健的跨模态特征融合。这些基于Transformer的框架代表了多模态假新闻检测的重大进步, 提供了稳健的特征提取, 能够捕获文本与图像的上下文和语义细微差别。然而, 高效的大规模数据处理和有效的跨模态对齐等挑战依然存在, 这凸显了对先进架构的需求, 这些架构需要能够在保持计算效率和跨模态性能的同时, 无缝集成多模态特征。

4.1.5. 基于GNN的 模型

假新闻的传播通常通过复杂的社交媒体网络发生, 其中用户、帖子和互动(例如, 评论、点赞和分享)之间的关系在传播过程中起着至关重要的作用[134]。图神经网络(GNNs)因其建模关系数据和捕获图结构信息内依赖关系的能力, 在假新闻检测中尤为有效。通过将帖子、用户和社交互动表示为图中的节点和边, 图神经网络为理解假新闻传播背后的结构和上下文模式提供了全面的认识。此外, 图神经网络集成多模态和辅助信息的能力使其在应对假新闻检测的挑战时具有不可估量的价值。

结合社会语境(如关注者和点赞)显著提升了基于GNN的模型检测假新闻的有效性。Goyal等人[108]、Yan等人[84]以及Ahuja和Kumar[20]展示了在基于图的框架中融合文本、视觉和社交特征的方法。Goyal等人[108]使用LSTMs处理文本数据以提取语言和上下文模式, 而包括头像和横幅图像在内的视觉数据则使用CNN架构进行分析。他们进一步结合了基于网络的特征, 如关注数、点赞数、转发数和提及数, 通过使用图卷积网络(GCNs)编码这些关系来对假新闻传播的社交动态进行建模。类似地, Ahuja和Kumar[20]通过使用BERT、VGG和图神经网络[135]提取并融合跨模态特征, 扩展了整合文本、视觉和社会语境这三种模态的范围。这些研究共同突显了图神经网络在整合多模态和社交信息方面的多功能性, 为检测假新闻提供了一个强大的框架。最后, Yan等人[84]构建了一个异构信息网络, 整合了新闻帖子、用户画像和评论, 以语义对齐文本和视觉表示。他们的研究展示了图神经网络如何有效捕捉不同模态与社交互动之间的关系, 这对于在复杂的在线环境中检测假新闻至关重要。

除了结合社会语境外, 图神经网络还用于提取假新闻检测的特征。例如, Qian等人[63]引入了知识概念化模块, 从文本数据中提取实体。这些实体被链接到外部知识图谱以创建概念解释, 当与文本结合时, 生成了图结构数据。随后应用图卷积网络(GCN)[136]来提取文本特征, 同时使用VGG网络处理图像特征。类似地, Qu等人[92]通过聚类具有相似主题的新闻, 并分别使用BERT和场景图生成器从新闻文本和图像中提取实体构建图, 从而整合了时序和内容信息。随后采用图注意力网络(GATs)[137]和GCNs来生成多模态和时序特征, 强调了利用图结构和时序关系在理解假新闻传播模式中的重要性。

4.1.6. 其他

在多模态假新闻检测中, 一些研究采用了额外的特征, 如情感、用户特定特征和音频, 表明这些特征可以显著提升检测性能。这些特征为传统的文本和视觉模态提供了互补的视角, 为信息传播的心理、社交和听觉维度提供了细致的见解。例如, 一系列情感分析可以捕捉内容的潜在基调和意图, 这通常可以揭示操纵或欺骗模式[138,139]。本节回顾了结合这些特征的研究工作, 突出了它们对多模态假新闻检测系统发展的贡献。

人们提出了几种方法来整合情感和情绪特征以进行假新闻检测。在情感分析中, 诸如VADER[111]和TextBlob[66]等基于规则的方法常被用于检测假新闻。其他研究则依赖于预训练的深度学习模型, 以进行更细致、更鲁棒的情绪特征提取。Wang等人[101]使用了从SKEP[140], (一种预训练的情感分析工具)导出的情感分数。Kumari等人[110]将图像分为六种情绪类别(喜悦、爱、悲伤、恐惧、惊讶和愤怒), 并使用ResNet提取情绪特征。类似地, Yadav和Gupta[74]使用预训练的VGG网络从图像中提取情绪特征, 并使用表情符号结合NRC word-emo从文本中提取情绪特征

面向用户的特征也被用于多模态假新闻检测。Lu和Ye[78]使用BERT提取文本特征, 并从帖子中获取上下文特征, 例如用户个人资料描述和粉丝/关注数。其他几项研究也结合了面向用户的特征, 包括点赞数、粉丝数 and 用户活动指标[101,104]。

除了文本、视觉和面向用户的特征外, 最近的研究还探索了用于多模态假新闻检测的音频和视频模态。Kumari等人[109]和Peng等人[19]结合了用于文本编码的BERT、用于视频特征提取的VGG-19, 以及各种音频处理技术(包括MFCC特征和OpenS MILE), 以捕获用于情感分析的声学模式。类似地, Kopev等人[112]利用了诸如LIWC类别和BERT嵌入的文本特征, 以及从ComParE[141]和li-vector[142], 提取的声学特征, 整合了诸如说话人ID的元数据, 构建了一个全面的多模态框架。

最近多模态假新闻检测的进展试图通过利用领域知识并将多种模态整合到视频中, 来改进特征提取和融合技术。Choi和Ko[143]提出了一个域自适应框架, 将文本、声学和以用户为中心的特征与视频特定线索相结合, 并融入ResNet和基于BERT的嵌入, 以增强多模态特征对齐。此外, Qi等人[144]和Zeng等人[145]通过同时利用文本、视觉、声学和视频模态, 探索了一种更全面的多模态方法。这些研究强调了纳入多种数据源对于提高检测准确率以及减轻单模态或弱多模态系统中固有的偏见的重要性。通过整合多种模态, 他们旨在捕捉在社交媒体和视频分享平台上传播的假新闻的复杂性质, 使检测更加鲁棒且具备上下文感知能力。




图 6. 第 4.2 节 中 阐述 的 用于 生成 多模态 表示 的 各种 融合方法。

综上所述，多模态假新闻检测中采用的多种方法凸显了利用多种模态来提升检测性能的潜力。卷积神经网络、RNN-CNN混合模型、Transformer和图神经网络各自在捕捉多模态数据中的空间、时间和关系模式方面展现出独特的优势。此外，互补特征（如情感、用户特定元数据和视听线索）的整合，极大地丰富了检测框架，提供了超越传统文本与图像分析的细微见解。这些进展强调了统一且适应性强的多模态方法对于构建鲁棒的假新闻检测系统的重要性。

4.1.7. 关于特征提取的讨论

每种特征提取范式在性能、计算成本和适用性方面都呈现出不同的权衡。基于CNN的模型轻量且适用于实时场景；然而，它们缺乏捕获长距离文本依赖的能力。RNN-CNN混合模型改进了序列文本建模，但在处理长文档的全局上下文时存在困难。Transformer-CNN和完全基于Transformer的模型以更高的计算需求为代价实现了更强的跨模态语义理解，这使得它们在资源受限环境中不如其他模型实用。基于GNN的模型独特地捕获了社交传播模式，在检测协同虚假信息方面具有优势。然而，它们需要可能并不总是可用的丰富社交图数据。总体而言，架构的选择应取决于可用的模态、计算预算以及所针对的错误信息的具体性质。

4.2. 融合方法

4.2.1. 基于拼接的融合方法

一些研究采用拼接作为融合文本与视觉特征以形成多模态表示的策略。例如，Wei等人[64]应用了模态与事件判别器损失以及特征拼接来增强融合过程。类似地，Wang等人[16]、Singhal等人[67]、Zhang等人[68]，和Luqman等人[66]使用简单拼接来整合图像与文本特征。Segura-Bedmar和Alonso-Bartolome[58]也采用了拼接，但使用的是通过CNN模型提取的嵌入。

进一步的研究，如Sharma和Garg[49]、Sharma等人[77]，以及Yadav和Gupta[74]，利用拼接来生成鲁棒的多模态特征。此外，Al Obaid等人[87]和Guo等人[89]将拼接与分类器层结合以做出最终预测。Kopev等人[112]通过整合来自多种模态（包括文本、图像、声学 and 元数据）的特征，显著突出了拼接的灵活性。

4.2.2. 注意力增强的融合技术

注意力机制通常与拼接结合使用，对多模态融合非常有效，因为它们增强了文本与视觉特征之间的交互。例如，Qian等人[61]引入了一个多模态上下文注意力网络，利用transformer模块来融合文本和图像特征。Zhang等人[113]也对多模态特征采用了交叉注意力。类似地，Xiong等人[62]设计了一种先进架构，其中包含一个用于评估模态相似度的不一致性度量模块。随后通过共注意力层和多次拼接操作来实现




图 7. 模型发生 特征融合 的不同阶段， 在 第 4.2 节中 进行 了 讨论。

鲁棒的多模态表征。Qian 等人 [63] 也采用了注意力机制，将一个共注意力模块应用于 GCN 和 VGG-19 特征，随后通过池化和拼接来完成特征整合。

此外，一些研究人员探索了用于特征融合的多头自注意力。例如，Hua 等人 [75] 和 Yang [59] 利用自注意力机制来融合提取的文本与视觉特征，增强了模态交互并生成了统一的多模态表示。Peng 等人 [73] 应用交叉多头注意力来有效对齐和融合文本和图像嵌入。类似地，Lu 和 Ye [78] 与 Huang 等人 [79] 利用自注意力层来融合特定模态特征，从而提升了多模态融合的性能。

跨模态注意力已成为多模态假新闻检测中特征融合的有效方法。Liang [81] 采用跨模态注意力在融合之前细化特定模态特征嵌入。类似地，Guo [86] 提出了一种互注意力机制，其中一种模态作为另一种模态注意力机制的输入，生成丰富的模态特征，随后将其拼接以形成最终表示。进一步拓展这些概念，Yadav 等人 [94] 引入了视觉-语义和自注意力块来提取显著特征，确保图像与文本特征在融合过程中相互补充。

将注意力机制融入多模态 Transformer 也取得了令人瞩目的成果。Yan 等人 [95] 和 Zhang 等人 [105] 分别利用共注意力和交叉融合机制，实现了文本与视觉模态之间的紧密对齐。Ayteiran 和 Özgöbek [96] 将模态间注意力与加权特征拼接相结合，突出了每种模态中最重要的特征。Lv 等人 [71] 通过在单模态嵌入上采用交叉注意力，随后进行后期融合，进一步完善了基于注意力的技术，以确保特定模态的贡献在最终输出中得到良好体现。同样，Zhang 等人 [115] 结合自注意力和交叉注意力来融合传播路径的时间和结构特征，从而增强了从多模态输入中对假新闻的早期检测。这些研究证明了注意力机制的适应性，能够实现模态之间更深层次、更有意义的交互。

4.2.3. 其他

一些融合方法结合了多种融合技术，以捕捉模态之间错综复杂的关系。Nakamura 等人 [47] 探索了多种融合方法，包括求和、拼接、最大池化和平均池化，来融合图像和文本嵌入，展示了结合不同策略的通用性。同样，Xu 等人 [72] 采用双线性融合与注意力模块相结合来生成鲁棒的多模态特征，突显了混合简单与高级融合技术在改善特征融合方面的优势。Zhang 等人 [114] 结合注意力机制和扩散模型来融合各种模态的特征，并构建了传播图以检测假新闻传播路径。

对比学习被认为是特征融合框架中的强大工具。Kumari 等人 [109] 应用对比学习在共享潜空间内对齐特定模态特征，确保了文本与视觉表示之间的连贯性。类似地，Kumari 等人 [110] 使用对比学习将多模态特征表示与目标类别对齐，增强了模态间协同和类别判别。这些方法说明了这些策略如何通过使用对齐技术来改善特征级理解 and 多模态表示。此外，Yan 等人 [84] 自适应地拼接了对比学习的、语义对齐的和网络衍生特征，以创建多模态输入的综合表示。

特征堆叠和模态特定处理是高级融合策略的关键组成部分。Li等人[85]堆叠了学习到的特征,并将其与CNN-MobileNet V2融合以创建鲁棒的帖子表示。Azri等人[111]使用堆叠LSTM层拼接了文本和情感特征以创建联合表示,然后将其与视觉特征融合以生成全面的多模态表示。这些研究证明了将堆叠架构与高级融合技术相结合以捕获复杂多模态关系的灵活性和有效性。

复杂的融合方法架构无缝集成了早期、后期和自定义融合技术。例如,Peng等人[19]引入了一种层次化方法,该方法结合了多种融合策略以捕获模态间和模态内相关性。该框架结合了深度度量学习以增强特征,确保了跨文本、视觉和声学模态的稳健集成。类似地,Yin等人[102]采用了多步融合策略,从用于基本特征对齐的早期融合开始,推进到使用共注意力Transformer的联合融合,最后以集成增强特征的后期融合结束。这些迭代融合技术实现了对多模态输入的全面理解。

其他高级技术涉及不同模态的加权组合。Yu等人[100]结合了线性适配、自注意力和门控组件来融合文本与视觉特征。然后,他们将融合后的文本与视觉特征及其差异进行拼接,以形成最终的集成特征。类似地,Nadeem等人[97]引入了特征堆叠和加权求和来整合单模态和多模态预测。Raj和Meel[107]通过实验各种策略,证明了加权平均融合的有效性,并得出结论:该方法优于更简单的融合方法。

总之,高级融合方法提供了灵活性和鲁棒性,使其非常适合广泛的模态和任务。通过将早期融合、后期融合和联合融合技术与注意力机制、对比学习和领域特定知识相结合,这些方法实现了最先进的多模态集成性能。

4.2.4. 特征融合的阶段:早期、后期和混合融合

多模态假新闻检测中的特征融合方法通常分为三种类型:早期融合、后期融合和混合融合[146]。本节回顾了与每种融合策略相关的代表性工作,并提供了作者自己对其实际意义、权衡以及现实世界部署考虑的分析。

早期融合。在早期融合中,如图7(a)所示,来自不同模态的特征在特征提取后立即进行组合。该阶段常见的融合操作包括拼接、注意力机制以及其他向量级集成技术,例如多头自注意力。然后,将得到的多模态特征表示传递给分类器进行预测。

后期融合。后期融合策略如图7(b)所示,涉及对每个模态应用单独的分类器,然后组合得到的输出概率。Raj和Meel[65]提出了一种加权后期融合技术,其中特定模态的预测分数通过网络搜索进行优化,以提高准确率。Goyal等人[108]同样采用加权求和方法来聚合单模态输出,确保每个模态对最终决策做出适当贡献。Jarrahi和Safari[104]探索了潜在文本特征和发布者相关元数据之间的后期融合,证明了领域特定信号如何增强检测性能。

混合融合。混合融合结合了早期和后期融合阶段,如图7(c)所示。在这种方法中,来自多个模态的特征首先通过早期融合进行融合,然后传递给单独的分类器。得到的预测结果进一步使用后期融合进行聚合。Lin等人[80]研究了这种策略,发现结合联合和决策级融合方法提高了各种基准上的多模态性能。

4.2.5. 关于融合方法的讨论

不同的融合策略根据任务需求、计算预算和模态可用性提供不同的优势。基于拼接的方法因其简单性、低计算成本和易于实现而依然具有吸引力。这些方法特别适用于需要快速推理且所有模态均持续可用的实时假新闻检测系统。然而,简单拼接通常无法捕捉文本与视觉特征之间更深层的语义关系,这可能限制其在更复杂的多模态场景中的性能。

基于注意力的融合方法通过显式地建模模态之间的交互,提供了更强的跨模态推理能力。特别是,自注意力、交叉注意力和共注意力机制使模型能够识别显著特征,并在不同模态间对齐语义相关的信息。这些方法对于检测涉及误导性配文、篡改图像或文本与视觉内容之间细微不一致性的假新闻特别有效。尽管如此,这些方法通常比简单的融合技术需要高得多的计算资源和内存消耗,这使得它们不太适合低资源或实时部署环境。

类似地,基于对比学习的融合方法在共享嵌入空间中对齐模态特定表示方面展现出了强大的潜力。通过促使语义相关的文本-图像对更近,同时分离不相关的对,对比学习提升了跨模态一致性和域泛化能力。当目标在于增强从不同领域或社交媒体平台收集的数据集的鲁棒性时,这些方法尤为有用。然而,对比学习通常需要大规模的训练数据、精心设计的正负样本对,以及训练期间额外的计算开销。

基于所综述的文献,每种融合策略都有其独特的优势和权衡。早期融合方法,例如简单的拼接,轻量级且计算高效,这使其适合于实时应用,例如虚假新闻

检测在现场辩论期间。然而, 尽管计算开销更大, 复杂的融合技术(例如, 基于注意力的方法)通常能提供更高的准确率, 因为它们有能力来建模复杂的特征交互。

后期融合在某些模态可能缺失或不可靠的场景中特别有利。由于分类是针对每个模态独立进行的, 后期融合支持对部分或不完整数据的灵活整合, 这是动态环境中的一项重要特性。

混合融合策略旨在平衡性能和鲁棒性, 尽管它们通常涉及高昂的计算成本。这些方法利用了早期和后期融合的优势, 提供了更好的泛化能力, 特别是当特定领域的和上下文特征可用时。

尽管文献中报告了令人瞩目的成果, 但仍存在一些局限性。首先, 大多数现有方法假设所有模态始终可用, 这在实际应用中往往是不切实际的。其次, 很少有研究在相同的实验设置下对早期、后期和混合融合方法进行系统比较, 这使得难以确定针对特定应用场景最有效的策略。此外, 在有噪声、不完整或低质量的多模态输入(如模糊的图像、短文本或缺失的上下文信息)下, 假新闻检测总体上仍然具有挑战性。

未来的研究可能会关注自适应融合框架, 该框架根据每个模态的可靠性和质量动态分配模态权重。此外, 对轻量级多模态融合方法的需求日益增长, 以支持在资源受限环境下的实时推理。更鲁棒的缺失模态融合策略、可解释多模态架构以及跨域泛化技术也可能成为未来重要的研究方向。最后, 大语言模型和视觉语言模型的最新进展表明, 可训练融合模块结合预训练多模态编码器可能为提高多模态假新闻检测的鲁棒性和泛化能力提供一个有前景的方向。

4.3. 学习目标

4.3.1. 分类目标

为了检测假新闻, 该任务可以被表述为一个二分类问题, 其目标是将新闻分类为虚假或真实。机器学习方法, 例如逻辑回归(LR)和支持向量机(SVM), 已被用于此任务[80]。对于深度学习方法, 通常在输出层应用Sigmoid函数, 将模型的原始分数映射为概率 $p \in [0, 1]$ [72,76,77]。该公式使用二元交叉熵损失进行优化[65,97,102], 其定义如下:

$$\mathcal{L}_{BCE} = -(y \log(p) + (1 - y) \log(1 - p)), \quad (1)$$

其中 y 代表真实标签。相反, 当任务需要识别多种特定类别的错误信息时, 使用Softmax函数来生成跨 K 个类别[70,81,98]的概率分布。此方法与分类交叉熵损失[63,71,94,100], 配对使用, 以最小化预测分布与独热编码真实标签之间的散度:

$$\mathcal{L}_{CE} = - \sum_{i=1}^K y_i \log(\hat{y}_i). \quad (2)$$

4.3.2. 表示目标

已提出多种方法来学习更好的假新闻检测表示。Wei等人[64]开发了一种方法, 通过重建文本和图像嵌入并同时新闻分类为虚假或真实来学习表示。Gôlo et al. [82]引入了一种多模态变分自编码器, 用于重建与文本相关的指标, 从而为假新闻检测获得更全面的多模态表示。另一种方法利用多任务学习, 结合对新闻内容[16,68,85,86]的事件类别进行分类的网络。通过训练模型以最小化特定事件的性能, 排除了与事件相关的信息, 从而增强了模型在不同事件或领域间检测假新闻的能力。Kumari等人[109]强调了情感诉求在假新闻传播中的作用, 整合了视听和文本情感识别以捕捉微妙的线索, 从而丰富模型的表示, 以更好地进行假新闻检测。

4.3.3. 相似度目标

测量数据间的相似度对于假新闻检测至关重要。Meel和Vishwakarma [44]计算了图像标题与新闻正文之间的余弦相似度, 认为通过分析其连贯性, 可以识别出包含不匹配文本和上下文无关图像的假新闻。类似方法也可用于测量文本、图像和OCR文本之间的相似度[89], 以及新闻正文摘要、图像和新闻标题之间的相似度[90]。余弦相似度还被用于损失函数中, 以对齐具有相同标签的表示[84]。此外, 诸如三元组学习[19,73,79]和切比雪夫距离[93]等技术主要作为表示对齐的损失函数被采用。




图 8. ELA 示例。(a) 和 (c) 是伪造 图像，(b) 和 (d) 是经ELA处理的 图像。

4.3.4. 对比 学习

对比学习是一种有效的方法，能够为共享相似信息的对生成嵌入，同时使具有不同内容的对相互远离。研究人员利用训练样本的标签，通过对比学习将假新闻的表示进行聚类，确保假新闻内容具有相近的表示[19,75,95,110]。对比学习的另一种方法涉及将来自不同模态的表示进行配对。Yan等人[84]将文本和视觉信息进行配对，使来自相同内容的嵌入位置相近。类似地，Kumari等人[109]使用文本、音频和视频嵌入来进行对比学习。除了模态级别之外，对比学习还被应用于社交图以捕获结构与语义关系。例如，Zhang等人[115]提出了一个双视图自监督对比学习框架，以联合建模全局传播拓扑以及用户、发布者和新闻内容之间的高阶异构关系。通过整合节点级和基于元路径的对比目标，他们的方法产生了丰富的用户嵌入，随后将其用于强化传播路径生成和早期假新闻检测。

4.3.5. 误差 估计

Meel和Vishwakarma [44] 利用K均值聚类对图像块估计噪声不一致性，断言被篡改的图像会根据图像内的位置表现出不同的噪声水平。误差水平分析 (ELA) [147] 被用于评估误差水平的极端程度以进行假新闻检测[44,90]。ELA是一种用于确定图像是否经过数字篡改的取证技术。图8展示了ELA的示例。

4.3.6. 其他

Wang等人 [99] 采用少样本学习来增强针对新兴事件的假新闻检测。他们利用元学习使检测器能够高效适应新事件。Al Obaid等人 [87] 强调了现实世界新闻中显著的类别不平衡，即真实新闻的数量远超虚假新闻。为了解决这一问题，他们采用了焦点损失，该损失比交叉熵损失更适合不平衡数据集。此外，Gôlo et al. [82] 使用单类学习，仅用真实新闻训练其模型。Qu等人 [92] 提出了一种结合时序信息的两级交叉熵损失方法，认为同一主题连续新闻能提供互补的见解。最后，Zhang等人 [105] 基于贝叶斯定理开发了贝叶斯分类器，利用了其有效泛化的能力。

4.3.7. 关于 学习 目标 的讨论

多模态假新闻检测中学习目标的演变，反映了从简单的基于标签的分类到结构感知表示学习的转变。尽管分类目标仍是最终决策的标准，但它们往往缺乏捕捉模态间细微欺骗模式的粒度。二元交叉熵在计算上很高效，但如果单独使用，可能无法解决文本和视觉数据之间固有的语义鸿沟。

相比之下，表征和相似性目标提供了一个稳健的框架，通过迫使模型学习新闻主体和图像之间的潜在连贯性。这些方法在检测脱离上下文的虚假新闻时特别有效，

其中各个模态是真实的，但它们的组合却具有误导性。然而，这些目标增加了架构复杂性，并且需要精心策划的数据以避免学习到琐碎的相关性。

对比学习通过最大化相关对之间的一致性，对齐了跨模态的高维特征。这增强了模型在不同领域和新闻事件中的泛化能力。然而，对比学习目标的性能对负样本的质量和多样性高度敏感，这对小规模数据集构成了挑战。此外，正如误差估计中所指出的，学习使用取证驱动目标来识别数字篡改，增加了一层纯粹的语义模型可能忽略的关键防御。

最后，解决现实世界的的数据不平衡仍然是一个关键挑战。尽管焦点损失和元学习提供了潜在的解决方案，但将它们整合到多模态流程中可能会导致训练不稳定。未来的研究应优先开发混合学习目标，以同时优化分类准确率、跨模态对齐以及对新兴AI生成内容的鲁棒性。

5. 未来研究

尽管多模态虚假新闻检测取得了显著进展，但仍有若干挑战持续存在。通过解决这些方向，该领域可以朝着创建稳健、通用且具有影响力的解决方案迈进，以在不断演变的数字环境中打击虚假新闻。

5.1. 跨平台检测

大多数现有研究集中在从单一平台获取的数据上，这限制了检测模型在不同环境中的泛化能力。未来的研究应侧重于开发能够跨多个平台检测假新闻的模型。每个平台具有独特的模态和特征，解决缺失的模态是提高鲁棒性的关键。可以探索条件生成框架 [148] 和跨模态Transformer [149] 等方法，以处理多模态环境中的不完整数据，为构建更具适应性的模型提供途径。

5.2. AI生成内容

随着人工智能的不断进步，假新闻检测面临着新的挑战。生成式模型的演进，如ChatGPT，催生了AI生成假新闻，与人工伪造错误信息相比，它展现出截然不同的特征 [150]。这些发展凸显了创建先进检测模型的必要性，此类模型不仅要能够应对传统假新闻，还要能处理AI生成内容的独特属性。未来的研究应优先整合多模态方法，并利用前沿技术来构建鲁棒的系统，以适应这一快速演变的环境。

5.3. 模态

随着社交媒体日益从基于文本和图像的内容向基于视频的平台转型，[14,151]，检测这些新格式中的假新闻变得势在必行。此外，随着深度伪造技术的兴起，检测视频和音频格式的假新闻变得越来越关键。然而，最近的研究主要集中在文本和图像模态上。未来的研究应优先开发专门的数据集和模型，用于检测视频和音频格式的假新闻，以应对该领域新兴的挑战与机遇。

5.4. 上下文信息

现代平台提供了大量超出新闻项主要内容的辅助信息，包括用户交互模式、内容元数据和时间数据。未来的研究应侧重于通过使用合适的融合方法，将这种辅助信息整合到假新闻检测模型中。通过纳入此类数据，模型可以实现更细致、更准确的检测，捕捉超出内容本身的上下文和关系动态。这种方法可以更深入地理解影响新闻传播的因素，最终提高检测系统的鲁棒性和可靠性。

5.5. 学习目标

大多数研究主要依赖于以分类为中心的学习目标，例如交叉熵损失。然而，这些学习目标可能无法完全解决现实世界中的挑战，包括处理不平衡数据集和捕捉预测中的不确定性。未来的研究应探索替代的学习目标。自监督学习方法，例如自举法 [152]，可以增强多模态数据的表示。对抗训练方法可以通过生成和检测对抗样本 [153,154] 来提高鲁棒性。对抗领域自适应可以提高泛化能力和适应性 [155]。通过使学习目标多样化，模型可以更好地符合实际需求，并在多样化和动态的现实世界环境中更有效地运行。

5.6. 系统级 实现

一些现实世界中的事实核查服务，例如PolitiFact，处理包括图像和视频在内的多种模态，但它们主要关注文本。这些服务依赖人工驱动核查过程来确保准确率和上下文理解。然而，这种以人为中心的方法在本质上限制了可扩展性，使其难以跟上该领域不断增长的信息量和信息的快速传播。这凸显了在有效应对假新闻传播速度和范围方面的关键瓶颈。因此，开发和部署自动化系统对于应对这些挑战以及提高事实核查过程的效率和可扩展性至关重要。尽管先前的大多数研究集中在开发检测模型上，但了解如何将这些模型有效地部署到现实世界场景中同样至关重要。例如，Rani和Shokeen [88] 提出了一个结合深度学习和区块链技术的假新闻检测系统，以提高可靠性和透明度，突显了实际应用的一条有前景的途径。然而，关于检测模型在实际运营系统中的部署和集成的研究仍然有限。未来的研究应探索可扩展且高效的系统架构，并考虑为不同上下文量身定制的计算资源。此外，解决包括用户隐私和数据安全在内的伦理问题，对于培养社会信任和更广泛的采用至关重要，特别是在处理用户数据（如用户元数据或交互数据）时。此外，此类系统的设计必须在引入偏见或生成假新闻的情况下运行。提供可解释和可理解输出的透明机制，对于确保此类系统的问责制和用户信心至关重要。

6. 结论

数字媒体和社交网络的快速发展已使假新闻成为一项严峻的社会挑战，它削弱了公众信任并影响了政治决策。虽然早期的检测工作依赖于单模态数据，如文本或图像，但它们往往无法应对假新闻的复杂性质，因为假新闻经常结合多种模态来制造更具说服力和欺骗性的叙事。作为应对，多模态方法通过整合和分析来自各种来源（包括文本、图像、视频和元数据）的信息，已成为极具前景且必不可少的解决方案。

本研究系统地探讨了多模态假新闻检测的进展，对该领域进行了全面综述，并概述了未来研究的关键方向。具体而言，我们提出了一种新颖的分类法，从三个关键维度构建了多模态方法：特征提取、融合方法和学习目标。该框架允许对现有模型进行深入分析，并对关键数据集进行详细比较，突出了它们的特征、局限性以及对多模态任务的适用性。

我们追溯了特征提取的演变，从早期的基于CNN的模型到更先进的基于Transformer的架构（例如BERT、ViT）和图神经网络（GNNs），这些模型能更好地捕获上下文与关系数据。我们分析了融合方法的演进，从简单拼接到复杂的注意力增强和混合策略，这些方法能够对复杂的模态间关系进行建模。最后，我们探讨了所采用的学习目标的多样性，超越了标准分类，涵盖了表征学习、相似性目标和对比学习，从而能够构建更鲁棒的模型。

这项全面的分析揭示了几个关键挑战，包括缺乏限制模型泛化能力的多样化数据集，以及检测AI生成内容（即深度伪造）的新前沿。要克服这些障碍，未来的工作需要侧重于整合辅助信息（如用户交互模式和元数据），以构建上下文感知系统。此外，探索替代的学习目标（如自监督和对抗训练）是增强模型鲁棒性的关键。最终，将这些先进模型从研究推向现实世界应用是最后也是至关重要的一步，这需要可扩展、透明和伦理的系统。这就需要学术界、产业界和政策制定者之间的通力合作，以培育一个具有韧性且值得信赖的数字信息生态系统。

CRedit 作者 贡献 声明

Juyeob Lee: 写作——初稿，资源，方法论，形式分析，数据整理，概念化。Junyeop Cha: 写作——初稿，监督，软件，资源，调查，概念化。Minsu Park: 写作——初稿，方法论，数据整理，概念化。Minyoung Lee: 写作——初稿，软件，形式分析，数据整理，概念化。Taeun Kim: 可视化，监督，资源，资金获取，形式分析，数据整理。Seul-Ki Choi: 可视化，软件，资源，资金获取，数据整理。Angel P. del Pobil: 可视化，监督，资金获取。Eunil Park: 写作——初稿，可视化，验证，资金获取，形式分析，数据整理，概念化。

利益 冲突 声明

作者 声明 他们 没有 可能 影响 本文 所 报告 工作 的 已知 竞争性 经济 利益 或 人际 关系 。

致谢

本研究得到了MSIT（科学和信息通信技术部）、韩国的数字领域全球研究支持计划项目（RS-2024-00419073）、ITRC（信息技术研究中心）支持项目（RS-2024-00436936）以及ICAN（ICT挑战与HRD高级网络）支持项目（RS-2024-00436934）的支持。本工作还得到了韩国政府（MSIT）资助的IITP拨款（编号：RS-2024-00439139，网络危机响应与弹性测试评估系统的开发）以及国土交通部资助的韩国基础设施技术振兴院（KAIA）拨款（RS-2026-25523576）的支持。

数据 可用性

数据 将 根据 请求 予以 提供 。

参考文献

- [1] 皮尤研究中心, 2021年社交媒体使用情况, 2021, <https://www.pewresearch.org/>. [2] 皮尤研究中心, 许多美国人发现从社交媒体获取新闻有价值, 但对不准确定性的担忧有所上升, 2024, <https://pewrsr.ch/3urDwjM>. [3] 纽约邮报, 算法和人工智能让人越来越难分辨真实与虚构, 2024, <https://nypost.com/2024/09/07/opinion/algorithms-and-ai-are-making-it-harder-to-know-whats-real/>. [4] 大型科技公司, 深度伪造及其对全球民主的威胁, 2024, <https://nypost.com/2024/09/07/opinion/algorithms-and-ai-are-making-it-harder-to-know-whats-real/>. [5] K.T. Gradon, 生成式人工智能与医疗虚假信息, 英国医学杂志 384 (2024) 1–2. [6] T. Assenza, F. Collard, P. Fève, S.J. Huber, 从喧嚣到破产: 假新闻如何塑造商业周期, 技术报告 ECONtribute 讨论论文, 2024. [7] H. Allcott, M. Gentzkow, 社交媒体与2016年选举中的假新闻, J. Econ. Perspect. 31 (2017) 211–236. [8] J. Zarocostas, 如何对抗信息疫情, 柳叶刀 395 (2020) 676. [9] J. Kim, J. Aum, S. Lee, Y. Jang, E. Park, D. Choi, Fibvid: COVID-19期间的综合假新闻传播数据集, Telemat. Inform. 64 (2021) 101688. [10] C. Castillo, M. Mendoza, B. Poblete, Twitter上的信息可信度, 载于: Proc. of WWW '11, 2011, pp. 675–684. [11] A. Gupta, H. Lamba, P. Kumaraguru, A. Joshi, 伪造桑迪: 飓风桑迪期间Twitter上虚假图像的表征与识别, 载于: Proc. of WWW '13, 2013, pp. 729–736. [12] M. Huh, A. Liu, A. Owens, A.A. Efros, 对抗假新闻: 通过学习自洽性进行图像拼接检测, 载于: Proc. of ECCV '18, 2018, pp. 101–117. [13] K. Shu, S. Wang, H. Liu, 超越新闻内容: 社会语境在假新闻检测中的作用, 载于: Proc. of WSDM '19, 2019, pp. 312–320. [14] L. Sun, H. Zhang, S. Zhang, J. Luo, 基于内容的TikTok与抖音文化差异分析, 载于: Proc. of Big Data '20, IEEE, 2020, pp. 4779–4786. [15] J. Kim, H. Ahn, E. Park, Multi-pop: 通过社交媒体中基于内容的多模态流行度预测增强用户参与度, Expert Syst. 41 (2024) e13707. [16] Y. Wang, F. Ma, Z. Jin, Y. Yuan, G. Xun, K. Jha, L. Su, J. Gao, EANN: 用于多模态假新闻检测的事件对抗神经网络, 载于: Proc. of KDD '18, 2018, pp. 849–857. [17] L.H. Li, M. Yatskar, D. Yin, C.-J. Hsieh, K.-W. Chang, VisualBERT: 一个简单且高效的视觉与语言基线, 2019, URL <https://arxiv.org/abs/1908.03557>. arXiv:1908.03557. [18] J.-C. Chen, L. Li, L. Yu, A.E. Kholy, F. Ahmed, Z. Gan, Y. Cheng, J. Liu, {UNITER}: 学习通用图像-文本表征, 2020, URL <https://openreview.net/forum?id=S1eL4kBYwr>. [19] L. Peng, S. Jian, M. Li, Z. Kan, L. Qiao, D. Li, 基于深度度量学习的统一多模态分类框架, 神经网络 181 (2025) 106747. [20] N. Ahuja, S. Kumar, 语义、视觉与网络信息融合用于社交媒体错误信息检测, Cybern. Syst. 55 (2024) 1063–1085. [21] K. Shu, A. Sliva, S. Wang, J. Tang, H. Liu, 社交媒体上的假新闻检测: 数据挖掘视角, ACM SIGKDD Explor. Newsl. 19 (2017) 22–36. [22] X. Zhou, R. Zafarani, 假新闻综述: 基础理论、检测方法与机遇, ACM Comput. Surv. 53 (2020) 1–40. [23] W.Y. Wang, “骗子, 骗子, 裤子着火”: 一个新的假新闻检测基准数据集, 载于: Proc. of ACL '17, 计算语言学协会, 2017, pp. 422–426, <http://dx.doi.org/10.18653/v1/P17-2067>. [24] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A.N. Gomez, L.u. Kaiser, I. Polosukhin, 注意力就是你所需要的, 载于: Proc. of NeurIPS '17, Vol. 30, Curran Associates, Inc., 2017. [25] A. D'ulizia, M. Caschera, F. Ferri, P. Grifoni, 假新闻检测: 评估数据集综述, PeerJ Comput. Sci. 7 (2021) 1–40. [26] F. Alam, S. Cresci, T. Chakraborty, F. Silvestri, D. Dimitrov, G. Martino, S. Shaar, H. Firooz, P. Nakov, 多模态虚假信息检测综述, 载于: Proc. of COLING '22, 2022, pp. 6625–6643. [27] M. Nasser, N. Arshad, A. Ali, H. Alhussian, F. Saeed, A. Da'ui, I. Nafea, 使用深度学习模型进行社交媒体多模态假新闻检测的系统综述, Results Eng. 26 (2025) 104752. [28] M. Zidan, A. Sleem, A. Nabil, M. Othman, 多模态假新闻检测: 文本与视觉内容融合方法综述, Int. J. Comput. Inform. 7 (2025) 13–25. [29] X. Zhou, A. Mulay, E. Ferrara, R. Zafarani, ReCOvery: 一个用于COVID-19新闻可信度研究的多模态仓库, 载于: Proc. of CIKM '20, 2020, pp. 3205–3212. [30] Y. Yang, L. Zheng, J. Zhang, Q. Cui, Z. Li, P.S. Yu, TI-CNN: 用于假新闻检测的卷积神经网络, 2023, URL <https://arxiv.org/abs/1806.00749>. [31] H. Ahmed, I. Traore, S. Saad, 使用N元语法分析和机器学习技术检测在线假新闻, 载于: Proc. of ISDDC '17, Springer, 2017, pp. 127–138. [32] T. Mitra, E. Gilbert, Credbank: 带有相关可信度标注的大规模社交媒体语料库, 载于: Proc. of ICWSM'15, Vol. 9, 2015, pp. 258–267. [33] E. Tacchini, G. Ballarin, M.L. Della Vedova, S. Moret, L. de Alfaro, 等, 有人喜欢骗局: 社交网络中的自动假新闻检测, 载于: CEUR Workshop Proceedings, CEUR-WS, 2017, pp. 1–15.

- [34] A. Schulz, C. Guckelsberger, F. Janssen, 用于推文分类泛化的语义抽象: 对事件相关推文的评估, *Semant. Web* 8 (2017) 353–372. [35] M. Potthast, J. Kiesel, K. Reinartz, J. Bevendorff, B. Stein, 对极端党派和假新闻的文体计量学探究, 载于: *Proc. of ACL '18*, 2018, pp. 231–240. [36] P. Patwa, S. Sharma, S. Pykl, V. Guptha, G. Kumari, M.S. Akhtar, A. Ekbal, A. Das, T. Chakraborty, 对抗信息疫情: Covid-19假新闻数据集, 载于: *Proc. of CONSTRAINT '21*, Springer, 2021, pp. 21–29. [37] A. Olteanu, C. Castillo, F. Diaz, S. Vieweg, Crisislex: 用于收集和过滤危机中微博通信的词典, 载于: *Proc. of ICWSM '14*, Vol. 8, 2014, pp. 376–385. [38] W. Ferreira, A. Vlachos, 涌现: 一个用于立场分类的新数据集, 载于: *Proc. of NAACL '16*, 计算语言学协会, 2016. [39] G. McIntire, 真假新闻数据集, 2017, https://github.com/GeorgeMcIntire/fake_real_news_dataset. [40] I. Amerini, L. Ballan, R. Caldelli, A. Del Bimbo, G. Serra, 一种基于SIFT的复制-粘贴攻击检测与变换恢复取证方法, *IEEE Trans. Inf. Forensics Secur.* 6 (2011) 1099–1110. [41] A. Zubiaga, M. Liakata, R. Procter, 利用上下文进行社交媒体中的谣言检测, 载于: *Proc. of SocInfo '17*, Springer, 2017, pp. 109–123. [42] B. Singh, D.K. Sharma, 使用多模态方法预测社交媒体假新闻中的图像可信度, *Neural Comput. Appl.* 34 (2022) 21503–21517. [43] B. Dolhansky, J. Bittton, B. Pflaum, J. Lu, R. Howes, M. Wang, C.C. Ferrer, 深度伪造检测挑战赛 (DFDC) 数据集, 2020, URL <https://arxiv.org/abs/2006.07397>. [44] P. Meel, D.K. Vishwakarma, HAN、图像描述与取证集成多模态假新闻检测, *Inform. Sci.* 567 (2021) 23–41. [45] Z.S. Ali, W. Mansour, T. Elsayed, A. Al-Ali, Arafacts: 首个大型自然出现的阿拉伯语声明数据集, 载于: *Proc. of WANLP '21*, 2021, pp. 231–236. [46] Bien Data, 假新闻竞赛, 2019, <https://www.biendata.xyz/competition/falsenews/>. [47] K. Nakamura, S. Levy, W.Y. Wang, Fakeddit: 一个新的用于细粒度假新闻检测的多模态基准数据集, 载于: *Proc. of LREC '20*, 2020, pp. 6149–6157. [48] K. Shu, D. Mahudeswaran, S. Wang, D. Lee, H. Liu, Fakenewsnet: 包含新闻内容、社会语境和时空信息用于研究社交媒体假新闻的数据仓库, *Big Data* 8 (2020) 171–188. [49] D.K. Sharma, S. Garg, IFND: 一个用于假新闻检测的基准数据集, *Complex Intell. Syst.* 9 (2023) 2843–2863. [50] C. Boididou, S. Papadopoulos, Y. Kompatsiaris, S. Schifferes, N. Newman, 社交多媒体中计算验证的挑战, 载于: *Proc. of WWW '14*, 2014, pp. 743–748. [51] R. Gomez, J. Gibert, L. Gomez, D. Karatzas, 探索多模态出版物中的仇恨言论检测, 载于: *Proc. of WACV '20*, 2020, pp. 1470–1478. [52] X. Hu, Z. Guo, J. Chen, L. Wen, P.S. Yu, Mr2 23, 2023, 29012912: 社交媒体中多模态检索增强谣言检测的基准, 载于: *Proc. of SIGIR '23*, pp. –. [53] A. Bondielli, P. Dell'Oglio, A. Lenci, F. Marcelloni, L.C. Passaro, M. Sabbatini, 等, EVALITA 2023上的MULTI-Fake-Detective: 多模态假新闻检测与验证任务概述, 载于: *Proc. of EVALITA '23*, Vol. 3473, CUEER-WS, 2023, pp. 1–8. [54] S. Suryawanshi, B.R. Chakravarthi, M. Arcan, P. Buitelaar, 用于识别图像和文本中冒犯性内容的多模态迷因数据集 (MultiOFF), 载于: *Proc. of TRAC '20*, 2020, pp. 32–41. [55] D.S. Nielsen, R. McConville, MuMIN: 一个大规模多语言多模态经事实核查的错误信息社交网络数据集, 载于: *Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval*, 2022, pp. 3141–3153. [56] J. Cao, Q. Sheng, P. Qi, L. Zhong, Y. Wang, X. Zhang, 社交媒体上的假新闻检测, 2019, URL <https://arxiv.org/abs/1908.10818>. arXiv: 1908.10818. [57] Z. Jin, J. Cao, H. Guo, Y. Zhang, J. Luo, 使用循环神经网络进行多模态融合以检测微博上的谣言, 载于: *Proc. of MM '17*, 2017, 795816pp. –. [58] I. Segura-Bedmar, S. Alonso-Bartolome, 多模态假新闻检测, *Information* 13 (2022) 284. [59] Y. Yang, J. Liu, Y. Yang, L. Cen, 用于多模态假新闻检测的带多头注意力的双流融合网络, *应用智能* 167 (2024) 112358. [60] S. Oh, J. Kim, S. Lee, E. Park, Jujeop: 社交媒体上韩流明星的韩语双关语, 载于: *Proceedings of the Ninth International Workshop on Natural Language Processing for Social Media*, 2021, pp. 170–177. [61] S. Qian, J. Wang, J. Hu, Q. Fang, C. Xu, 用于假新闻检测的层次多模态上下文注意力网络, 载于: *Proc. of SIGIR '21*, 2021b, pp. 153–162. [62] S. Xiong, G. Zhang, V. Batra, L. Xi, L. Shi, L. Liu, Trimoon: 用于假新闻检测的两轮基于不一致性的多模态融合网络, *信息融合* 93 (2023) 150–158. [63] S. Qian, J. Hu, Q. Fang, C. Xu, 用于假新闻检测的知识感知多模态自适应图卷积网络, *ACM Trans. Multimed. Comput. Commun. Appl. (TOMM)* 17 (2021a) 1–23. [64] P. Wei, F. Wu, Y. Sun, H. Zhou, X.-Y. Jing, 用于多模态假新闻检测的模态与事件对抗网络, *IEEE Signal Process. Lett.* 29 (2022) 1382–1386. [65] C. Raj, P. Meel, 用于多模态假新闻检测的卷积网络框架, *应用智能* 51 (2021) 8132–8148. [66] M. Luqman, M. Faheem, W.Y. Ramay, M.K. Saeed, M.B. Ahmad, 利用集成学习检测多模态假新闻, *IEEE Access* 12 (2024) 15037–15049. [67] S. Singhal, R.R. Shah, T. Chakraborty, P. Kumaraguru, S. Satoh, Spofake: 一个用于假新闻检测的多模态框架, 载于: *Proc. of BigMM '19*, IEEE, 2019, pp. 39–47. [68] T. Zhang, D. Wang, H. Chen, Z. Zeng, W. Guo, C. Miao, L. Cui, BDANN: 用于多模态假新闻检测的基于 BERT 的领域自适应神经网络, 载于: *Proc. of IJCNN '20*, IEEE, 2020, pp. 1–8. [69] M. Al-Alshaqi, D.B. Rawat, C. Liu, 用于鲁棒假新闻检测的集成技术: 融合Transformer、自然语言处理和机器学习, *Sensors* 24 (2024) 6062. [70] A. Athira, A. Tiwari, S.M. Kumar, A.M. Chacko, 用于假新闻检测的多模态数据融合框架, 载于: *Proc. of INDICON '22*, IEEE, 2022, pp. 1–4. [71] J. Lv, X. Wang, C. Shao, TMIF: 用于自动谣言检测的基于Transformer的多模态交互融合, *Multimedia Syst.* 29 (2023) 2979–2989. [72] J. Xu, Y. Zhang, W. Liu, 基于CLIP多模态机制的假新闻检测研究, 载于: *Proc. of CSAIDE '24*, 2024a, pp. 72–79. [73] L. Peng, S. Jian, Z. Kan, L. Qiao, D. Li, 并非所有假新闻在语义上都相似: 用于多模态假新闻检测的上下文语义表征学习, *信息处理与管理* 61 (2024) 103564. [74] A. Yadav, A. Gupta, 一种情感驱动的、基于Transformer的网络用于多模态假新闻检测, *Int. J. Multimed. Inf. Retr.* 13 (2024) 7. [75] J. Hua, X. Cui, X. Li, K. Tang, P. Zhu, 通过基于数据增强的对比学习进行多模态假新闻检测, *Appl. Soft Comput.* 136 (2023) 110125. [76] Y. Li, K. Ji, K. Ma, Z. Chen, J. Zhou, J. Wu, 基于多模态信息相关性扩展的假新闻检测, 载于: *Proc. of APWeb-WAIM '22*, Springer, 2022d, pp. 443–450.

- [77] D.K. Sharma, B. Singh, S. Agarwal, H. Kim, R. Sharma, Fakedbits-使用多模态特征检测社交平台上的虚假信息, KSII互联网信息系统汇刊 17 (2023). [78] Y. Lu, H. Ye, 基于深度学习的社交网络假新闻传播检测方法, 载于: ADHIP '22会议论文集, Springer, 2022, pp. 473–488. [79] Z. Huang, Y. Hu, Z. Zeng, X. Li, Y. Sha, 用于细粒度假新闻检测的多模态堆叠交叉注意力网络, 载于: ICME '23会议论文集, IEEE, 2023, pp. 2837–2842. [80] S.-Y. Lin, Y.-C. Chen, Y.-H. Chang, S.-H. Lo, K.-M. Chao, 用于增强假新闻检测的文本-图像多模态融合模型, 科学进展 107 (2024) 00368504241292685. [81] Z. Liang, 基于多模态输入的假新闻检测, 计算机与连续物质 75 (2023). [82] M.P.S. Gôlo, M.C. de Souza, R.G. Rossi, S.O. Rezende, B.M. Nogueira, R.M. Marcacini, 通过多模态变分自编码器进行假新闻检测的单类学习, 工程与人工智能应用 122 (2023) 106088. [83] R. Kumari, A. Ekbal, Amfb: 用于多模态假新闻检测的基于注意力的多模态分解双线性池化, 专家系统与应用 184 (2021) 115412. [84] F. Yan, M. Zhang, B. Wei, K. Ren, W. Jiang, Sard: 基于CLIP对比学习和多模态语义对齐的假新闻检测, 沙特国王大学学报-计算机与信息科学 36 (2024) 102160. [85] S. Li, T. Yao, S. Li, L. Yan, 用于假新闻检测的语义增强多模态融合网络, 国际智能系统杂志 37 (2022c) 12235–12251. [86] Y. Guo, 社交网络上基于互注意力的多模态融合假新闻检测, 应用智能 53 (2023) 15311–15320. [87] A. Al Obaid, H. Khotanlou, M. Mansoorizadeh, D. Zabihzadeh, 使用深度学习器集成的多模态假新闻识别, 第 24 (2022) 1242. [88] P. Rani, J. Shokeen, Fnnet: 一种使用区块链的安全集成假新闻检测方法, 超级计算杂志 80 (2024) 20042–20079. [89] Y. Guo, B. Li, H. Ge, C. Di, 用于假新闻检测的基于辅助模态的文本-图像匹配方法, 载于: ICANN '23会议论文集, Springer, 2023, pp. 65–76. [90] M.I. Nadeem, K. Ahmed, Z. Zheng, D. Li, M. Assam, Y.Y. Ghadi, F.H. Alghamedy, E.T. Eldin, Ssm: 基于文体和语义相似度的多模态假新闻检测, 沙特国王大学学报-计算机与信息科学 35 (2023) 101559. [91] Z. Qu, Y. Meng, G. Muhammad, P. Tiwari, Qmfnr: 面向社交媒体的基于量子多模态融合的假新闻检测模型, 信息融合 104 (2024a) 102172. [92] Z. Qu, F. Zhou, X. Song, R. Ding, L. Yuan, Q. Wu, 用于假新闻检测的时间增强多模态图神经网络, IEEE计算与社会系统汇刊 11 (2024b) 7286–7298. [93] J. Wang, J. Zheng, S. Yao, R. Wang, H. Du, Tlfnd: 基于三层特征匹配距离的多模态融合假新闻检测模型, 第 25 (2023) 1533. [94] A. Yadav, S. Gaba, H. Khan, I. Budhiraja, A. Singh, K.K. Singh, Etma: 用于多模态假新闻检测的高效基于变换器的多层注意力框架, IEEE计算与社会系统汇刊 11 (2024) 5015–5027. [95] F. Yan, M. Zhang, B. Wei, K. Ren, W. Jiang, Fmc: 基于多粒度特征融合和对比学习的多模态假新闻检测, 亚历山大工程杂志 109 (2024) 376–393. [96] E.F. Ayetiran, Ö. Özgöbek, 使用统一模态的基于模态间注意力的深度学习框架用于多模态假新闻、仇恨言论和冒犯性语言检测, 信息系统 123 (2024) 102378. [97] M.I. Nadeem, K. Ahmed, D. Li, Z. Zheng, H.K. Alkahtani, S.M. Mostafa, O. Mamrybayev, H. Abdel Hameed, Efnr: 用于极端假新闻检测的语义、视觉和社交增强的深度框架, 可持续性 15 (2022) 133. [98] B. Palani, S. Elango, V. Viswanathan K, Cb-fake: 使用胶囊神经网络和BERT的自动假新闻检测多模态深度学习框架, 多媒体工具与应用 81 (2022) 5587–5620. [99] Y. Wang, F. Ma, H. Wang, K. Jha, J. Gao, 通过元神经网络进行多模态突发假新闻检测, 载于: KDD '21会议论文集, 2021, pp. 3708–3716. [100] C. Yu, Y. Ma, L. An, G. Li, Bcmf: 用于假新闻检测的双向跨模态融合模型, 信息处理与管理 59 (2022) 103063. [101] H. Wang, S. Wang, Y. Han, 基于混合特征融合方法的中国社交媒体假新闻检测, 专家系统与应用 208 (2022) 118111. [102] X. Yin, T. Sun, C. Yang, Z. Zhang, X. Zhang, M. Su, 基于多层语义增强的假新闻检测方法研究, 载于: IJCNN '23会议论文集, IEEE, 2023, pp. 1–8. [103] P. Meel, D.K. Vishwakarma, 使用微调自注意力和迁移学习进行多模态融合以实现网络信息真实性分析, 专家系统与应用 229 (2023) 120537. [104] A. Jarrahi, L. Safari, 评估社交媒体假新闻检测中发布者特征的有效性, 多媒体工具与应用 82 (2023) 2913–2939. [105] W. Zhang, A.I. Alzahrani, M.Y. Lee, 使用广义贝叶斯分类的大规模社交网络假新闻检测, 移动网络与应用 (2024) 1–17. [106] L.D. Sciuca, M. Marneli, E. Balloni, L. Rossi, E. Frontoni, P. Zingaretti, M. Paolanti, Fakened: 基于深度学习的社交媒体假新闻检测系统, 载于: ICIAP '22会议论文集, Springer, 2022, pp. 303–313. [107] C. Raj, P. Meel, 用于多模态信息疫情检测的ARCNN框架, 神经网络 146 (2022) 36–68. [108] B. Goyal, N.S. Gill, P. Gulia, O. Prakash, I. Priyadarshini, R. Sharma, A.J. Obaid, K. Yadav, 使用多模态数据和深度学习检测社交媒体上的虚假账号, IEEE计算与社会系统汇刊 (2023). [109] R. Kumari, V. Gupta, N. Ashok, T. Ghosal, A. Ekbal, 用于视频嵌入式虚假信息检测的情感辅助多任务框架, 多媒体工具与应用 83 (2024) 37161–37185. [110] R. Kumari, N. Ashok, P.K. Agrawal, T. Ghosal, A. Ekbal, 利用新奇检测和情感识别识别多模态虚假信息, 智能信息系统杂志 61 (2023) 673–694. [111] A. Azri, C. Favre, N. Harbi, J. Darmont, C. Nôus, 调用 CNN-LSTM进行谣言检测: 用于微博消息真实性分类的深度多通道模型, 载于: ECML PKDD '21会议论文集, Springer, 2021, pp. 497–513. [112] D. Kopev, A. Ali, I. Koychev, P. Nakov, 使用声学和本体特征检测政治辩论中的欺骗, 载于: ASRU '19会议论文集, IEEE, 2019, pp. 652–659. [113] L. Zhang, X. Zhang, Z. Zhou, X. Zhang, P. Yu, C. Li, 用于假新闻检测的知识感知多模态预训练, 信息融合 114 (2025) 102715. [114] L. Zhang, X. Zhang, C. Li, Z. Zhou, J. Liu, F. Huang, X. Zhang, 减轻社会危害: 通过扩散引导传播路径生成早期检测假新闻, 载于: MM '24会议论文集, 2024, pp. 2842–2851. [115] L. Zhang, X. Zhang, Z. Zhou, X. Zhang, S. Wang, P. Yu, C. Li, 通过强化传播路径生成早期检测多模态假新闻, IEEE知识与数据工程汇刊 37 (2024) 613–625. [116] J.D.M.-W.C. Kenton, L.K. Toutanova, BERT: 用于语言理解的深度双向变换器预训练, 载于: NaacL-HLT '19会议论文集, Vol. 1, 明尼阿波利斯, 明尼苏达, 2019, p. 2. [117] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, N. Houlsby, 一张图像等于16x16个词: 用于大规模图像识别的Transformer, 载于: ICLR '21会议论文集, 2021. [118] K. Simonyan, A. Zisserman, 用于大规模图像识别的超深卷积网络, 载于: ICLR '15会议论文集, 2015. [119] K. He, X. Zhang, S. Ren, J. Sun, 用于图像识别的深度残差学习, 载于: CVPR '16会议论文集, 2016, pp. 770–778.

- [120] C. Szegedy, V. Vanhoucke, S. Ioffe, J. Shlens, Z. Wojna, 重新思考计算机视觉的Inception架构, 载于: CVPR '16会议论文集, 2016, pp. 2818–2826. [121] G. Huang, Z. Liu, L. Van Der Maaten, K.Q. Weinberger, 密集连接卷积网络, 载于: CVPR '17会议论文集, 2017, pp. 4700–4708. [122] A.G. Howard, M. Zhu, B. Chen, D. Kalenichenko, W. Wang, T. Weyand, M. Andreetto, H. Adam, MobileNets: 用于移动视觉应用的高效卷积神经网络, 2017, URL <https://arxiv.org/abs/1704.04861>. [123] J. Schmidhuber, S. Hochreiter, et al., 长短期记忆, 神经计算 9 (1997) 1735–1780. [124] J. Chung, C. Gulcehre, K. Cho, Y. Bengio, 门控循环神经网络在序列建模上的经验评估, 2014, URL <https://arxiv.org/abs/1412.3555>. arXiv:1412.3555. [125] D. Li, J. Li, H. Le, G. Wang, S. Savarese, S.C. Hoi, LAVIS: 语言视觉智能的一站式库, 载于: ACL '23会议论文集, 计算语言学协会, 2023, pp. 31–41, <http://dx.doi.org/10.18653/v1/2023.acl-demo.3>. [126] K. Nakamura, S. Levy, W.Y. Wang, Fakeddit: 一个用于细粒度假新闻检测的新多模态基准数据集, 载于: LREC '20会议论文集, 欧洲语言资源协会, 2020, pp. 6149–6157. [127] A. Conneau, D. Kiela, H. Schwenk, L. Barrault, A. Bordes, 从自然语言推理数据中监督学习通用句子表示, 载于: EMNLP '17会议论文集, 计算语言学协会, 2017, pp. 670–680. [128] M. Tan, Q. Le, EfficientNet: 重新思考卷积神经网络的模型缩放, 载于: ICML '19会议论文集, PMLR, 2019, pp. 6105–6114. [129] S. Sabour, N. Frosst, G.E. Hinton, 胶囊间动态路由, 载于: NeurIPS '17会议论文集, Vol. 30, Curran Associates, Inc., 2017. [130] C. Li, W. Liu, R. Guo, X. Yin, K. Jiang, Y. Du, Y. Du, L. Zhu, B. Lai, X. Hu, D. Yu, Y. Ma, PP-OCRv3: 改进超轻量级OCR系统的更多尝试, 2022a, URL <https://arxiv.org/abs/2206.03001>. [131] Z. Yang, Z. Dai, Y. Yang, J. Carbonell, R.R. Salakhutdinov, Q.V. Le, XLNet: 用于语言理解的广义自回归预训练, 载于: NeurIPS '19会议论文集, Vol. 32, Curran Associates, Inc., 2019. [132] H. Touvron, M. Cord, M. Douze, F. Massa, A. Sablayrolles, H. Jegou, 训练数据高效的图像Transformer和通过注意力进行蒸馏, 载于: ICML '21会议论文集, Vol. 139, PMLR, 2021, pp. 10347–10357. [133] J. Li, D. Li, C. Xiong, S. Hoi, BLIP: 用于统一视觉-语言理解与生成的自举语言-图像预训练, 载于: ICML '22会议论文集, PMLR, 2022b, pp. 12888–12900. [134] J. Kim, D. Kim, E. Park, 我知道你的立场! 分析Twitter用户在多元视角下的政治立场, 大数据杂志 12 (2025) 14. [135] F. Scarselli, M. Gori, A.C. Tsoi, M. Hagenbuchner, G. Monfardini, 图神经网络模型, IEEE神经网络汇刊 20 (2008) 61–80. [136] T.N. Kipf, M. Welling, 使用图卷积网络进行半监督分类, 载于: ICLR '17会议论文集, 2017. [137] P. Veličković, G. Cucurull, A. Casanova, A. Romero, P. Liò, Y. Bengio, 图注意力网络, 载于: ICLR '18会议论文集, 2018. [138] F. Liu, X. Zhang, Q. Liu, 用于假新闻检测的情感感知方法, IEEE计算与社会系统汇刊 11 (2023) 3516–3524. [139] J. Wilson, S.E. Hosseini, S. Pervez, 使用情感分析识别社交媒体中的假新闻, 载于: IEACON '23会议论文集, IEEE, 2023, pp. 220–224. [140] H. Tian, C. Gao, X. Xiao, H. Liu, B. He, H. Wu, H. Wang, F. Wu, SKEP: 用于情感分析的情感知识增强预训练, 载于: ACL '20会议论文集, 计算语言学协会, 2020, pp. 4067–4076. [141] B. Schuller, S. Steidl, A. Batliner, A. Vinciarelli, K. Scherer, F. Ringeval, M. Chetouani, F. Wengner, F. Eyben, E. Marchi, et al., INTERSPEECH 2013计算副语言挑战赛: 社会信号、冲突、情感、自闭症, 载于: INTERSPEECH '13会议论文集, 2013. [142] A. Ali, N. Dehak, P. Cardinal, S. Khurana, S.H. Yella, J. Glass, P. Bell, S. Renals, 阿拉伯语广播语音中的自动方言检测, 载于: INTERSPEECH '16会议论文集, 2016, pp. 2934–2938. [143] H. Choi, Y. Ko, 在YouTube上使用领域知识和多模态数据融合的有效假新闻视频检测, 模式识别快报 154 (2022) 44–52. [144] P. Qi, Y. Bu, J. Cao, W. Ji, R. Shui, J. Xiao, D. Wang, T.-S. Chua, FakeSV: 一个具有丰富社会语境的短视频平台假新闻检测多模态基准, 载于: AAAI '23会议论文集, Vol. 37, 2023, pp. 14444–14452. [145] Z. Zeng, M. Luo, X. Kong, H. Liu, H. Guo, H. Yang, Z. Ma, X. Zhao, 减轻世界偏差: 用于假新闻视频检测的多模态多视图去偏框架, 载于: 第32届ACM国际多媒体会议论文集, 2024, pp. 6492–6500. [146] Z. Ma, M. Luo, H. Guo, Z. Zeng, Y. Hao, X. Zhao, Event-Radar: 用于多模态假新闻检测的事件驱动多视图学习, 载于: 第62届计算语言学协会年会议论文集(第1卷: 长论文), 2024, pp. 5809–5821. [147] Z. Lin, J. He, X. Tang, C.-K. Tang, 通过DCT系数分析进行快速、自动和细粒度的篡改JPEG图像检测, 模式识别 42 (2009) 2492–2501. [148] X. Meng, Y. Gu, Y. Pan, N. Wang, P. Xue, M. Lu, X. He, Y. Zhan, D. Shen, 一种用于多模态医学图像补全的新型统一条件基于分数的生成框架, 2022, URL <https://arxiv.org/abs/2207.03430>. [149] Y.-H.H. Tsai, S. Bai, P.P. Liang, J.Z. Kolter, L.-P. Morency, R. Salakhutdinov, 用于未对齐多模态语言序列的多模态Transformer, 载于: ACL '19会议论文集, 计算语言学协会, 2019, pp. 6558–6569. [150] Y. Huang, K. Shu, P.S. Yu, L. Sun, 从创造到澄清: ChatGPT穿越假新闻泥潭的旅程, 载于: 2024年ACM万维网会议伴随论文集, 2024, pp. 513–516. [151] S. Lee, C. Ryu, E. Park, OSANet: 用于视觉情感分析的对象语义注意力网络, IEEE多媒体汇刊 25 (2022) 7139–7148. [152] J.-B. Grill, F. Strub, F. Altché, C. Tallec, P. Richemond, E. Buchatskaya, C. Doersch, B. Avila Pires, Z. Guo, M. Gheshlaghi Azar, B. Piot, k. kavukcuoglu, R. Munos, M. Valko, 自举你自己的潜在表示 - 一种自监督学习的新方法, 载于: NeurIPS '20会议论文集, Vol. 33, Curran Associates, Inc., 2020, pp. 21271–21284. [153] T. Bai, J. Luo, J. Zhao, B. Wen, Q. Wang, 对抗鲁棒性对抗训练的最新进展, 载于: IJCAI '21会议论文集, 国际人工智能联合会议组织, 2021, pp. 4312–4321, <http://dx.doi.org/10.24963/ijcai.2021/591>. [154] I. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, Y. Bengio, 生成对抗网络, 载于: NeurIPS '14会议论文集, Vol. 27, Curran Associates, Inc., 2014. [155] Y. Ganin, E. Ustinova, H. Ajakan, P. Germain, H. Larochelle, F. Laviolette, M. March, V. Lempitsky, 神经网络的领域对抗训练, 机器学习研究杂志 17 (2016) 1–35.

Juyeob Lee 是 成均馆大学 应用人工智能系 的 博士 研究生。他的 研究 兴趣 包括 数据分析 与 生成式 AI。

俊桦 C h a 是一名 博士研究生 就读于 该 department o f A应用 人工 智 能, 成均 馆 大学。他的 研 究兴 h in 趣 include LLM, multim odal 融合 与 com putationa l socia l science .

Minsu Park 是 成均馆大学 应用人工智能系 的 博士 研究生。他的 研究 兴趣 包括 生成式 AI、 安全建模、 信息科学 和 数据分析。

Minyoung Lee 是 三星电子 的 研究员。 她的 研究 兴趣 包括 多模态融合 和 语音识别。

泰恩 金 i s 韩国 互联网 与 安全 局 的 一名 研究员。 他的 研究 兴趣 包括 网络安全 和 面向AI的 安全 y.

Seul-Ki Choi 是 韩国 互联网 与 安全 局 的 一名 研究员。 他的 研究 兴趣 包括 网络安全。

Angel P. del Pobil 是 海梅 一世 大学 的 正教授。 他的 研究 兴趣 包括 生成式 AI 和 机器人 s.

Eunil Park 是成均馆大学交互科学系的副教授。他的研究兴趣包括数据安全和用户行为。他是韩国（跨学科研究）NRF-爱思唯尔青年研究员奖的首位获得者。作为该领域的跨学科科学家之一，他的研究成果发表在众多国际社会科学期刊以及科学期刊上。

电子邮件: nilpark@skku.edu