



多模态融合结合大语言模型内容通过分层渐进式Transformer用于可解释虚假新闻检测

王立东^{a,*}, 李^力^a, 周斌^{a,*}, 张寅^b, 袁杰^c, 胡华^a

^a School of Engineering, Hangzhou Normal University, Hangzhou Zhejiang, China

^b College of Computer Science and Technology, Zhejiang University, Hangzhou Zhejiang, China

^c College of Big Data and Software Engineering, Zhejiang Wanli University, Ningbo Zhejiang, China

文章信息

关键词: 虚假新闻
检测 多模态 大语言
模型 Transformer 可
解释性

摘要

由于误导性信息的快速传播,在社交媒体上检测虚假新闻已成为一项重大挑战。现有工作通常侧重于结合有限的模态,缺乏对多样化特征的深入、渐进式整合。除了文本和图像特征之外,如何在融入其他特征的同时确保检测结果的可解释性仍然是一项挑战。为了解决这些问题,我们提出了一种新颖的可解释虚假新闻检测方法,该方法将多模态融合与大语言模型生成的内容相结合(LLM-MFEFND)。该模型利用大语言模型(LLMs)生成背景知识和评论,以整合大语言模型对新闻的解读。为了提取深层的跨模态知识,我们提出了分层渐进式Transformer(HPT),以深入且渐进地整合图像、文本、对齐多模态特征、背景信息和用户评论。此外,我们设计了多模态局部可解释模型无关解释(MLIME)方法,为检测结果提供解释。通过在WeiBo21(6,010条新闻条目)和FineFake(15,140条新闻条目)等数据集上开展的大量实验,我们证明了使用DeepSeek的LLM-MFEFND模型优于现有方法。具体而言,我们的方法在WeiBo21上达到了94.5%的准确率,在FineFake上达到了81.1%的准确率,分别比现有方法至少提升了1.7%和2.2%。通过将大语言模型驱动的上下文增强与稳健的多模态融合及可解释性相结合,我们的框架推动了对抗错误信息的进程。代码可在<https://github.com/li1608335419/LLM-MFEFND>获取。

1. 引言

社交媒体是用户获取知识的主要渠道,例如英文国家的推特和脸书,以及中文地区的微博、小红书和今日头条等平台。例如,微博每月吸引5.98亿访客浏览信息。然而,虚假新闻已成为一个紧迫的社会问题,这很大程度上源于其在社交媒体平台上的广泛传播(Zhou & Zafarani, 2018)。生成式人工智能的进步进一步加剧了这一问题。例如,ChatGPT、GPT-4和DeepSeek等大语言模型可以生成大量虚假新闻(Neha & Bhati, 2025)。尽管人类事实核查专业人员能够准确核实新闻的真实性,但他们的努力难以跟上海量网络内容的步伐。显然,如果所有虚假新闻都要由事实核查专业人员核实,这将

*通讯作者。电子邮箱地址: wld@hznu.edu.cn (L. Wang), lixun666@stu.hznu.edu.cn (X. Li), zhoubin@hznu.edu.cn (B. Zhou), yinzh@zju.edu.cn (Y. Zhang), [yuanjie@zww.edu.cn](mailto: yuanjie@zww.edu.cn) (J. Yuan), hh@hznu.edu.cn (H. Hu).



Fig. 1. Fake news examples: (a) Drinking boiled garlic water will cure COVID-19. (b) A picture shows a massive tsunami headed for a crowded beach. (c) The stormwall in real life in Paris. This is always how I've envisioned it.

导致公众认知的延误并消耗大量人力。因此，社交平台上的自动虚假新闻检测正受到研究人员越来越多的关注。

以往的研究大多主要采用基于文本的分析来检测虚假新闻。然而，如果虚假新闻的传播者改变其写作风格，模型的准确率可能会下降。视觉元素在虚假新闻中发挥着至关重要的作用，它们利用图像和视频等多媒体来吸引和误导读者，从而加速虚假新闻的传播。鉴于近来虚假内容融合了音频和视频的发展趋势，纳入对辅助元素的分析对于提高模型的精确率至关重要 (Athira 等人, 2023)。Jing 等人 (2023) 的研究表明，带图像的推文比不带图像的推文被转发的可能性要高得多。图1展示了三个多模态虚假新闻示例，每个示例均同时包含图像和文本。在图1(a)中，帖子中的图像看起来正常，但文本内容具有误导性。相比之下，图1(b)中的文本正常，而图像明显是伪造的。图1(c)则展示了图像和文本均在传播虚假信息的情形。正如上述示例所示，多模态信息能够取得更好的虚假新闻检测效果。

大多数多模态融合方法侧重于两个或三个特征（主要是图像和文本），但关于三个以上特征融合的研究仍然相对匮乏 (Comito et al., 2023)。来自不同模态的特征包含冗余、互补和相关的语义信息 (Chen et al., 2022; Liu et al., 2023; Wu et al., 2023)。在处理三个或更多特征时，有必要在特征集成过程中关注逐步深入的融合以及高阶互补信息的保留。此外，大多数新闻文本缺乏上下文背景，使得准确识别错误信息变得困难。这些局限性直接加剧了虚假新闻检测的挑战。除了数据层面的问题外，由于神经网络的黑盒特性，基于深度学习的方法还面临透明度方面的挑战 (Liu et al., 2023; Ma et al., 2023)。这些虚假新闻检测模型的可解释性在很大程度上仍然不明确，使人们对其可靠性产生了怀疑。Athira et al. (2023) 提到，研究人员已经融合了视觉和文本信息来检测虚假新闻，但在这方面的解释问题尚未得到解决。因此，越来越多的研究人员开始关注确保这些系统的可靠性和可解释性的重要性 (Wu et al., 2021b)。

鉴于上述分析，现有的虚假新闻检测仍面临以下挑战：(1) 稀疏语义表示和不完整的上下文理解所带来的局限；(2) 由于互补性、冗余性和语义相关性之间的复杂相互作用，难以有效融合和集成三种以上的特征；(3) 检测结果缺乏可解释性，尤其是在多模态融合场景中，限制了模型决策的透明度和可信度。

为缓解上述局限,我们提出了一种新颖的可解释虚假新闻检测方法,该方法将多模态融合与大语言模型生成内容相结合(LLM-MFEFND)。我们的方法包含三个组件:知识抽取、知识融合和解释模块。知识抽取阶段通过将多模态输入与增强特征相结合来解决上下文理解不完整的问题,增强特征包括:1)由大语言模型生成的背景知识,2)融入大语言模型判断与解读的消息评论,以及3)由文本-图像融合得到的对齐多模态特征。在知识融合中,为实现对三种以上特征数据的深度渐进式集成,我们设计了分层渐进式Transformer(HPT)模块,用于多模态数据的迭代融合。在解释模块中,我们引入MLIME方法,对推文文本、图像以及大语言模型生成的内容进行可解释性分析,以提供事后解释(Athira et al., 2023)。此外,我们使用t-SNE来可视化特征融合的效果。

综上所述,本研究旨在利用大语言模型生成有用的特征,并探索一种渐进式深度融合策略,将这些增强特征与多模态数据相结合,从而提取重要的深度表征以及文本与图像之间的跨模态知识,同时在多模态融合场景下为检测结果提供可解释性分析。该工作填补了以往研究的空白。

本文的研究贡献可概括如下所述:

(1)我们提出了LLM-MFEFND,这是一种融合多种模态与大语言模型生成内容的新型多模态虚假新闻检测模型,能够从多个角度充分利用不同特征。(2)我们引入HPT模块,以捕获跨多层级特征交互的深度融合信息,支持至少三种不同特征的集成。(3)我们构建了一个经过专家严格验证的、面向本任务的中文和英文数据集的大语言模型背景与评论集合,并已将该数据集公开发布。(4)我们开发了MLIME,这是一种通过多种特征来解释检测结果的多模态解释方法。在WeiBo21和FineFake数据集上的综合实验结果验证了LLM-MFEFND的有效性。

本文后续章节的组织安排如下。第2节批判性地综述了虚假新闻检测领域的既有研究,分析了现有方法的能力与不足。第3节介绍了所提出的方法LLM-MFEFND。实现细节与所得结果在第4节中呈现,该节包括对我们模型相对于现有先进方法的能力的深入评估,以及对参数、鲁棒性、效率、消融和可解释性的全面分析。第5节讨论了我们模型的理论与实践意义,并概述了未来的工作。第6节总结了本研究面临的挑战与关键发现。

2. 相关工作

虚假新闻被定义为故意捏造并传播的虚假信息,其目的是误导读者,使他们对可验证的事实产生怀疑,且这一点可由其他来源证实(Zhang & Ghorbani, 2020)。虚假新闻已变得日益多样化并持续演变,促使现有方法逐渐从单模态方法过渡到多模态方法。此外,随着大语言模型的发展,一些研究开始探索将这些技术融入虚假新闻检测任务中。本节详细介绍了虚假新闻检测技术的发展历程,主要聚焦于多模态检测、基于大语言模型的检测以及可解释性分析(见表A.9)。

2.1. 多模态 虚假 新闻 检测

近年来,研究人员对利用多模态技术开展虚假新闻检测给予了高度关注,研究成果不断涌现。Gao等人(2024)采用知识图谱嵌入(KGE)将知识融入语言与视觉嵌入模型,为文本和图像生成通用表示。Gôlo等人(2023)利用单类学习(OCL)从多模态信息(包括新闻内容、主题和语言信息)中学习表示。Tong等人(2024)通过融合图像与文本,构建领域特定与跨领域知识抽取,提出了一种新颖的多领域检测框架。Ying等人(2023)提出了一种改进的MMoE网络,结合多种特征细化,包括图像语义、文本和图像模式。KEAN(Zhou等人, 2024)通过联合建模知识增强与对抗性领域自适应,并结合多模态编码与标签重加权,解决了虚假新闻检测中的协变量偏移与标签偏移问题。为建模不同模态之间的复杂关系,一些研究采用了注意力机制,如MCAN(多模态协同注意力网络)(Wu等人, 2021b)、EMIF(证据感知的多源信息融合)(Dong等人, 2024)以及ETMA(基于Transformer的高效多级注意力框架)(Yadav等人, 2024)。

此外,由于短视频的广泛普及,短视频平台上的虚假新闻检测预计将成为未来的研究趋势。一些研究者在短视频平台上利用了视觉大语言模型(Bu et al., 2024)和多视角去偏框架(Zeng et al., 2024),并结合了评论、视频、图像、音频和新闻内容。然而,如果将多种模态同时输入融合模型(如多层感知机、变分编码器等),可能会产生过多的冗余信息,导致跨模态交互的丢失。在我们的研究中,我们旨在深入且渐进地融合文本和图像数据,同时考虑跨模态注意力关系。

2.2. 基于大语言模型的 虚假 新闻 检测

近期研究表明,大语言模型在各类分类和推理任务中表现出强劲的性能。尽管需要大量时间对最新信息进行训练,许多学者仍肯定了大语言模型在虚假新闻检测方面的巨大潜力。Wang等人(2024a)提出了一种基于防御的可解释虚假新闻检测框架,该框架搭载大语言模型,通过证据

表 1 关键 符
号。

符号	描述
$X = (I, T)$	A text-image pair comprising text and visual components
r_r	LLM-generated background
r_c	LLM-generated comment
ϕ_i	Image I using ViT
ϕ_t	Representation of text T using BERT
R_r	Background r_r using BERT
R_c	Comment r_c using BERT
f_i	Visual (image) features
f_t	Textual features
f_{t-i}	Aligned multimodal features
$f_{r \rightarrow x}$	News-background interaction features
$f_{c \rightarrow x}$	News-comment interaction features
F_{fused}	Fused information fed into the classifier

提取，通过对立双方推断理由，提供高质量的论证。Li等人（2023）提出了SELF-CHECKER，这是一种利用大语言模型的模块化框架，能够以有限的训练需求实现高效的事实核查。Hu等人（2024）发现，尽管在真实性判断方面表现欠佳，大语言模型仍擅长提供富有洞察力的多视角理由，帮助小型语言模型检测虚假新闻。Li等人（2024）提出了FactAgent，该方法通过实施结构化工作流利用大语言模型检测虚假新闻，无需模型训练，从而将验证新闻真实性这一复杂任务划分为若干步骤。Park等人（2024）提出了AdStyle，这是一种对抗式风格增强技术，旨在训练能够抵御多种风格转换攻击的鲁棒假新闻检测器。风格转换攻击由风格转换提示生成。Kareem和Abbas（2023）采用微调的大语言模型，通过生成逻辑推理来检测虚假新闻。Zhou等人（2025）整合了大语言模型和小型语言模型的功能，采用两阶段检索过程选取相关知识，该方法优于纯小型语言模型方法。尽管基于大语言模型的虚假新闻检测已取得进展，但由于幻觉和不对齐问题，与大语言模型日益深入的融合带来了不可控问题的风险，限制了其在虚假新闻检测中的应用（Hoy & Koulouri, 2025）。为避免直接使用大语言模型进行虚假新闻检测，本文主要利用大语言模型生成额外的文本信息，以辅助虚假新闻检测。

2.3. 可解释的 虚 假 新 闻 检 测

某些研究者致力于通过权重系数（注意力机制）来获得内在的可解释性。Lu和Li（2020）借助注意力权重，利用了推文的内容、转发序列和用户画像。该模型能够实现可解释的检测结果。Shu等人（2019）采用句子-评论共注意力来捕捉新闻内容与评论之间的语义亲和性，同时学习句子和评论的注意力权重。Han等人（2024a）提出了一种针对评论嵌入向量的共注意力子网络，以把握top-k可解释的值得核查的用户评论和句子。

其他研究者利用知识图谱或外部资源来验证新闻真实性并提供解释性见解。Wu等人（2021a）通过识别虚假新闻中的实体及实体之间的关系来判定新闻是否为虚假新闻。该方法依赖于基于现有虚假新闻数据库构建多关系知识图谱，以推断新实体及其关系。Silva等人（2021a）提出了Propagation2Vec，通过采用注意力机制为节点和传播级联分配不同的权重，以增强模型的可解释性。然而，该方法需要获取虚假新闻的传播路径，这在大多数研究中具有挑战性。Chi和Liao（2022）提出了一种决策系统，该系统能够自主获取人类水平的知识，并通过对话树与用户互动，帮助用户理解其内部推理过程。在Han等人（2024b）的工作中，基于社交网络图和新闻知识图谱，该方法中的可解释推理模块将自注意力机制应用于社交图和新闻知识图谱中的节点。Wei等人（2025）明确提取了三种类型的跨模态线索：增强、互补性和冲突，并将关键线索作为解释检测结果的基础。

现有方法主要检测虚假新闻，却未能向公众充分解释其结果，尤其是在多模态特征融合场景下。大多数引入注意力机制的方法被认为是可解释的。然而，注意力机制并不能就其底层原理和推理过程提供透明度。其可解释性仍然较弱，在某些情况下甚至会造成困惑。在本文中，我们以局部优化理论为核心扩展了现有的可解释性方法，并将其应用于多模态领域。我们对多种特征（如文本、图像和大语言模型生成内容）进行了可解释性分析，以阐明所提模型的有效性。

3. 方法

给定一个表示为文本-图像对 $X = (I, T)$ 的新消息，我们工作的目标是判断该新消息的真实性。本文使用的关键符号汇总于表 1。

如图2所示，我们提出了一个名为LLM-MFEFND的新型多模态虚假新闻检测模型。我们首先从多视角提取单模态特征和多模态特征，包括CLIP（对比语言-图像预训练）模型（Radford




图 2. 该工作流程的 LLM-MFEFND。

et al., 2021)、BERT和视觉Transformer (ViT) (He et al., 2022)。然后, 我们的方法生成外部的LLM生成的背景知识和用户评论作为文本描述。接着, 设计了新闻-背景-评论交互模块, 以增强新闻与背景信息之间以及新闻与评论之间的交互。随后, HPT模块融合来自LLM生成的信息和多模态信息。最后, 采用MLIME为结果提供解释。

3.1. 多模态 特征 提取

我们开展多模态特征提取, 从多个视角切入。首先, 我们利用预训练模型来提取单模态特征, 这些特征来自不同视图。随后, 我们对齐该视觉和文本特征, (提取自该CLIP模型), 以得到对齐的多模态特征。

3.1.1. 视觉 特征

给定图像 I , 我们将图像尺寸缩放至 224×224 , 并利用 ViT 模块获得图像表示。该模型通过掩码自编码任务在海量图像数据集上进行预训练, 使其能够有效捕获图像的全局和局部特征。我们将图像表示记为 $\phi_i \in \mathbb{R}^{L_i \times d_i}$, 其中 L_i 是图像块的数量, d_i 是每个图像块的嵌入维度。随后, 我们利用带有 SiLU 激活函数的注意力机制来捕获图像中不同区域之间的重要性差异:

$$S = FC(\text{SiLU}(FC(\phi_i))) \quad (1)$$

$$\alpha = \text{softmax}(S, \text{dim} = 1) \quad (2)$$

$$f_i = \alpha \cdot \phi_i \quad (3)$$

其中 FC 为编码器和解码器模块完整的 connected layer。In addition, aligned visual embedding f_{c-i} is extracted using CLIP's pre-trained image encoder module.

3.1.2. 文本 特征

给定一段文本 T , 我们使用预训练的BERT模型提取文本 T 中每个词的嵌入向量。我们将文本 T 的嵌入向量表示为 φ_i , $\varphi_i \in \mathbb{R}^{L_i \times d_i}$, 其中 L_i 为词元的数量, d_i 为每个词元的维度。此外, 我们采用注意力机制来捕捉文本中不同词元之间的重要性差异:

$$f_t = \text{softmax}((FC(\varphi_i))^T) \cdot \varphi_i \quad (4)$$

此外, 对齐文本嵌入 f_{c-t} 是使用 CLIP 的预训练文本编码器模块提取的。

```
PROMPT_TEMPLATE = (
    "You are designed as an auxiliary tool for a fake news detection system. Your main
    function is to provide a brief explanation of the relevant background knowledge and simulate
    five comments from real users based on a given message."
    "Your goal is to output a concise explanation of the background knowledge and user
    comments, separated by commas, which will help people assess the authenticity of the message
    without needing additional background information."
    "Your explanation should be under 300 words. Return the output in JSON format with
    fields named 'background' and 'comment'."
)
```

图 3. 提示 模板。

3.1.3. 对齐的 多模态 特征

由ViT和BERT提取的视觉特征与文本特征之间存在跨模态语义差异，这使得直接融合这两种特征并不合适。因此，我们采用CLIP模型来获得对齐的文本嵌入与视觉嵌入。我们将二者拼接后输入多层感知神经网络，生成对齐多模态嵌入，记为 f_{t-i} ：

$$f_{t-i} = MLP(f_{c-t} \oplus f_{c-i}) \quad (5)$$

3.2. 大语言模型生成的 内容

3.2.1. 提示 工程

我们评估了 ChatGLM，它是由智谱AI发布的一款开源中英文双语对话式大语言模型。针对特定任务的微调需要大量时间和计算资源，因此我们采用零样本提示学习方法，仅通过特定指令即可让模型学习任务（Li, 2023）。Hu 等人（2024）已证明，当前的大语言模型可以作为指导性理由的良好生成器。社交网络上的虚假新闻大多由短文本构成。通过大语言模型扩展这些短文本的潜在知识，有助于理解虚假消息的内容并评估其真实性。我们设计了一个提示模板来生成额外的评论和背景知识，如图 3 所示。该提示模板包括功能描述、目标与要求以及输出格式。由于大语言模型无需执行复杂的事实核查、思维链推理或多步决策，生成过程保持稳健，且对提示措辞的细微变化相对不敏感。

在实验之前，所有大语言模型生成的输出都经过新闻专家严格的人工验证，以确保其合理性和相关性。与图像/文本模态冲突的生成输出会被自动标记，并从最终数据集中排除。在实践中，大多数大语言模型生成内容都表现出令人满意的合理性，只有一小部分需要迭代重新生成和验证，直至满足我们的要求。

3.2.2. 新闻-背景-评论 交互

给定一条新闻消息 $X = (T, I)$ 及其背景 r_r 和由大语言模型生成的评论 r_c ，我们使用BERT对 T 、 r_r 和 r_c 进行编码，得到 φ_t 、 R_r 和 R_c 。然后，我们通过引入双向交叉注意力模块来构建新闻-背景和新闻-评论交互特征，以增强特征之间的关联性。用于生成新闻-背景关联特征的双向交叉注意力模块如下所示：

$$\ell_{r \rightarrow x} = \text{AvgPool}(\text{CrossAtt}(R_r, \varphi_t, \varphi_t)) \quad (6)$$

$$\ell_{x \rightarrow r} = \text{AvgPool}(\text{CrossAtt}(\varphi_t, R_r, R_r)) \quad (7)$$

$$\text{CrossAtt}(R_r, \varphi_t, \varphi_t) = \text{softmax}\left(\frac{R_r' \cdot \varphi_t'}{\sqrt{d}}\right) \varphi_t' \quad (8)$$

¹ <https://github.com/THUDM/ChatGLM>




图 4. 分层 渐进式 Transformer 的 结构。

其中 $R'_r = W_r R_r$, $\varphi'_t = W_t \varphi_t$, d 表示维度。 $AvgPool()$ 指的是对交叉注意力输出的词元嵌入进行平均池化。我们将 $\ell_{x \rightarrow r}$ 输入到多层感知机模块中, 得到一个标量值 $w_{x \rightarrow r}$, 用于对向量 $\ell_{r \rightarrow x}$ 进行重新加权:

$$f_{r \rightarrow x} = w_{x \rightarrow r} \cdot \ell_{r \rightarrow x} \quad (9)$$

该 相 同 操 作 可 以 被 执 行 来 获 得 新 闻-评 论 相 关 性 特 征 $\ell_{c \rightarrow x}$ 与 $\ell_{x \rightarrow c}$:

$$\ell_{c \rightarrow x} = AvgPool(CrossAtt(R_c, \varphi_t, \varphi'_t)) \quad (10)$$

$$\ell_{x \rightarrow c} = AvgPool(CrossAtt(\varphi_t, R_c, R'_c)) \quad (11)$$

$$CrossAtt(R_c, \varphi_t, \varphi'_t) = softmax\left(\frac{R'_c \cdot \varphi'_t}{\sqrt{d}}\right) \varphi'_t \quad (12)$$

where $R'_c = W_c R_c$, $\ell_{x \rightarrow c}$ 被 随 后 输 入 到 一 个 多 层 感 知 机 模 块 以 获 得 一 个 标 量 值 $w_{x \rightarrow c}$ 来 重 新 加 权 $\ell_{c \rightarrow x}$:

$$f_{c \rightarrow x} = w_{x \rightarrow c} \cdot \ell_{c \rightarrow x} \quad (13)$$

3.3. 分 层 渐 进 式 Transformer

在 获 得 上 述 五 种 特 征 的 嵌 入 后, 即 图 像 (f_i)、文 本 (f_t)、对 齐 多 模 态 融 合 (f_{t-i})、新 闻-背 景 交 互 (f_{r-x}) 和 新 闻-评 论 交 互 (f_{c-x}), 设 计 一 个 有 效 的 模 型 对 它 们 进 行 整 合 至 关 重 要。如 图 4 所 示, 与 简 单 拼 接 $f_i \oplus f_t \oplus f_{t-i} \oplus f_{r-x} \oplus f_{c-x}$ 不 同, 简 单 拼 接 只 是 将 多 模 态 特 征 堆 叠 在 一 起 而 缺 乏 交 互, 并 且 由 于 对 所 有 模 态 一 视 同 仁, 往 往 会 引 入 冗 余 信 息, 而 HPT 采 用 分 层 注 意 力 机 制 来 渐 进 地 融 合 信 息。在 通 过 多 层 感 知 机 生 成 特 征 嵌 入 后, HPT 首 先 通 过 渐 进 式 Transformer 编 码 器 层 构 建 跨 模 态 交 互 与 依 赖 关 系。随 后, 它 通 过 多 个 渐 进 式 Transformer 阶 段 对 这 些 表 示 进 行 迭 代 细 化, 在 充 分 整 合 信 息 的 同 时 提 取 互 补 特 征。该 架 构 使 模 型 能 够 有 效 捕 获 融 合 表 示, 这 一 能 力 已 在 我 们 的 消 融 实 验 中 得 到 定 量 验 证 (见 第 4.4 节 图 9)。

首先, 我们 通过 多个 多层感知机 网络 生成 特征 嵌入 序列:

$$F_i = \text{Concat}(\text{MLPs}(f_i)) \quad (14)$$

$$F_t = \text{Concat}(\text{MLPs}(f_t)) \quad (15)$$

$$F_{t-i} = \text{Concat}(\text{MLPs}(f_{t-i})) \quad (16)$$

$$F_{r \rightarrow x} = \text{Concat}(\text{MLPs}(f_{r \rightarrow x})) \quad (17)$$

$$F_{c \rightarrow x} = \text{Concat}(\text{MLPs}(f_{c \rightarrow x})) \quad (18)$$

where $F_i, F_t, F_{t-i}, F_{r \rightarrow x}, F_{c \rightarrow x} \in \mathbb{R}^{m \times q}$ represent the generated embedding sequences, q is the number of MLP networks.

Secondly, we create a sequence combination $\mathcal{R}^l = [R_1, R_2, \dots, R_q]^l \in \mathbb{R}^{m \times q}$ to progressively fuse information from different features, l is the index of the fusion level, $l \in [0, 4]$. The steps of hierarchical progressive fusion can be summarized as follows:

$$\text{Level } 0/l = 0 : [F_i^1, \mathcal{R}_i^1] = \text{Trans_encoder}([F_i^0, \mathcal{R}^0]) \quad (19)$$

$$\mathcal{R}^1 = (\mathcal{R}_i^1 + \mathcal{R}^0)/2 \quad (20)$$

$$\text{Level } 1/l = 1 : [F_t^2, \mathcal{R}_t^2] = \text{Trans_编码器}([F_t^1, \mathcal{R}^1]) \quad (21)$$

$$\mathcal{R}^2 = (\mathcal{R}_t^2 + \mathcal{R}^1)/2 \quad (22)$$

$$\text{Level } 2/l = 2 : [F_{t-i}^3, \mathcal{R}_{t-i}^3] = \text{Trans_encoder}([F_{t-i}^2, \mathcal{R}^2]) \quad (23)$$

$$\mathcal{R}^3 = (\mathcal{R}_{t-i}^3 + \mathcal{R}^2)/2 \quad (24)$$

$$\text{Level } 3/l = 3 : [F_{r \rightarrow x}^4, \mathcal{R}_{r \rightarrow x}^4] = \text{Trans_encoder}([F_{r \rightarrow x}^3, \mathcal{R}^3]) \quad (25)$$

$$\mathcal{R}^4 = (\mathcal{R}_{r \rightarrow x}^4 + \mathcal{R}^3)/2 \quad (26)$$

$$\text{Level } 4/l = 4 : [F_{c \rightarrow x}^5, \mathcal{R}_{c \rightarrow x}^5] = \text{Trans_encoder}([F_{c \rightarrow x}^4, \mathcal{R}^4]) \quad (27)$$

$$\mathcal{R}^5 = (\mathcal{R}_{c \rightarrow x}^5 + \mathcal{R}^4)/2 \quad (28)$$

Trans_encoder() denotes a standard Transformer encoder layer. F_i^l is the image feature embedding in level l . We set $F_i^0 = F_i$, $F_t^0 = F_t$, $F_{t-i}^0 = F_{t-i}$, $F_{r \rightarrow x}^0 = F_{r \rightarrow x}$, $F_{c \rightarrow x}^0 = F_{c \rightarrow x}$.

$$\mathcal{R}^0 = (F_i^0 + F_t^0 + F_{t-i}^0 + F_{r \rightarrow x}^0 + F_{c \rightarrow x}^0)/5 \quad (29)$$

如上所示, 序列组合 $\mathcal{R}$ 整合了不同的特征。如式(21)所示, $\mathcal{R}^l$ 首先结合图像视图, 随后通过Transformer编码器层融合文本信息。为了充分整合来自各种嵌入的信息, 我们将渐进融合模块迭代 N 次。最后, 在迭代渐进融合完成后, 我们拼接 $\mathcal{R}$ 中的序列, 并通过多个MLP网络提取融合信息:

$$F_{fused} = \text{MLPs}(\mathcal{R}^N) \quad (30)$$

3.3.1. HPT 的 理论 基础

式(19)-(30)的原理可见图5。渐进融合能够实现渐进的特征细化, 避免单步融合带来的信息稀释。基于Transformer编码器模块的自注意力机制, 我们设计了式(19)、(21)、(23)、(25)、(27), 以在实现跨模态融合的同时保留各模态/特征的独特信息。假设 $\Psi = \{i, t, t-i, r \rightarrow x, c \rightarrow x\}$, 其中 $\psi \in \Psi$, 当 $Q = K = V = [F_\psi^l, \mathcal{R}^l]$ 时, 自注意力机制会保留模态内的关键特征。同时, F_ψ^l 与 $\mathcal{R}^l$ 的拼接确保了跨模态信息的融合。在前向传播中, 式(20)、22、24、26、28可改写为残差形式:

$$\mathcal{R}^{l+1} = \mathcal{R}^l + \frac{1}{2}(\mathcal{R}_\psi^{l+1} - \mathcal{R}^l) \quad (31)$$

在 反向传播中, 梯度 变为:

$$\frac{\partial \mathcal{L}}{\partial \mathcal{R}^l} = \frac{\partial \mathcal{L}}{\partial \mathcal{R}^{l+1}} \frac{\partial \mathcal{R}^{l+1}}{\partial \mathcal{R}^l} = \frac{\partial \mathcal{L}}{\partial \mathcal{R}^{l+1}} (1 + \frac{1}{2}(\frac{\partial (\mathcal{R}_\psi^{l+1} - \mathcal{R}^l)}{\partial \mathcal{R}^l})) \quad (32)$$

其中 $\mathcal{L}$ 表示损失函数。可以看出, 上述设计的优点如下: (1) 平均加权在保留先前融合结果的同时加入了新信息; (2) 系数1/2 在式 (32) 中压缩了残差项的梯度幅值, 防止梯度爆炸; (3) 即使非线性变换引入梯度不稳定, 恒等路径 (梯度= 1) 也能稳定反向传播。




图 5. 图形表示的式 (20-29).

3.4. 损失函数

融合后的信息 F_{fused} 被输入到该分类器，其组成部分为一个多层感知神经网络和一个 sigmoid 输出层。该预测标签 $\hat{y}$ 可以被表示为：

$$\hat{y} = \text{Sigmoid}(\text{MLP}(F_{fused})) \quad (33)$$

虚假新闻检测本质上是一个二元决策问题。因此，该损失函数可通过以下公式推导得出：

$$\mathcal{L}(\theta) = -\frac{1}{D} \sum_{\Gamma} [y \log(p(\hat{y})) + (1 - y) \log(1 - p(\hat{y}))] \quad (34)$$

其中 θ 表示该参数集合在我们的模型中。该训练集被记为 Γ 包含 D 个样本，其中 y 和 $\hat{y}$ 分别表示真实和预测标签。

3.5. 解释模块

3.5.1. MLIME 概述

为了解释每种模态和大语言模型生成内容对虚假新闻检测结果的影响，我们对每个特征进行了详细的定性分析。然而，模态/特征之间可能具有互补性，因此有必要考虑能够刻画模态/特征之间交互作用的可解释性模型。因此，我们提出 MLIME，将 LIME (Ribeiro et al., 2016) 扩展到多模态场景中。超越复杂多模态模型的黑盒特性，MLIME 提供事后解释，帮助用户理解某条新闻为何被判定为真实或虚假。目前，主流的事后方法主要包括 SHAP (Lundberg & Lee, 2017) 和 Grad-CAM (Selvaraju et al., 2017)。在实验部分，我们评估了 SHAP 和 MLIME 的有效性。Grad-CAM 旨在单模态（尤其是图像）场景中可视化卷积神经网络。与这些方法不同，MLIME 专为多模态场景而设计。对于给定的新闻条目，我们在保持其他模态固定的同时，通过在扰动样本上训练可解释模型并融入多模态融合信息，分别为每个特征生成解释。

3.5.2. MLIME 的过程

为新闻条目生成解释的过程如下：(1) 我们生成用于虚假新闻检测的文本模态解释。假设 G 是一组可解释模型，每个解释模型 $g(\cdot) \in G$ 都有一个复杂度度量，记为 $O(g(\cdot))$ 。给定一条新闻文本 T 及其表示 f_t ，我们将 $h(t)$ 定义为 T 被分配到指定类别的似然。 π_t 被定义为 f_t 周围的局部性。通过最小化 $\mathcal{L}(h(\cdot), g(\cdot), \pi_t)$ ，将实例 f_t 的解释模型 $g(\cdot)$ 与原始模型 $h(\cdot)$ 进行比较， $\mathcal{L}(h(\cdot), g(\cdot), \pi_t)$ 表示 $g(\cdot)$ 在 f_t 周围区域内无法准确逼近 $h(\cdot)$ 的程度。因此，实例 f_t 的解释生成可表示如下：

$$\xi(f_t) = \arg\min_{g \in G} \mathcal{L}(h(\cdot), g(\cdot), \pi_t) + O(g(\cdot)) \quad (35)$$

式(35)定义了最优解释模型 $g(\cdot)$ ，其通过同时最小化相对原始模型 $h(\cdot)$ 的近似误差与模型复杂度得到。我们通过抽取样本近似 $\mathcal{L}(h(\cdot), g(\cdot), \pi_t)$ 。通过随机选择 f_t 的非零元素，我们在 f_t 附近采样实例。给定扰动实例 $z' \in Z$ （其包含 f_t 的部分非零元素），我们检索该实例的原始形式 z ，并用初始模型计算 $h(z)$ ，该结果可被视为解释模型 $g(\cdot)$ 的标签 c 。为了




Fig. 6. The flowchart of MLIME for the generation of the explanation on text modality.

推导实例 f_t 的解释, 我们使用扰动样本 z 优化式(35)。在训练之前, 解释模型 $g(\cdot)$ 被初始化为岭回归模型, 而 $O(g(\cdot))$ 配置如下:

$$O(g(\cdot)) = \begin{cases} \infty & \text{if } \|w_g\|_0 > \gamma \\ 0 & \text{otherwise} \end{cases} \quad (36)$$

其中 w_g 是模型 $g(\cdot)$ 中非零权重的数量, γ 是一个常数值。该公式的理论基础在于通过强制仅使用 γ 个特征来约束 $g(\cdot)$ 的复杂度, 这与人类认知模式相一致。 $\pi_t(z)$ 基于余弦距离函数定义:

$$\pi_t(z) = \exp\left(-\frac{(1 - \frac{f_t \cdot z}{\|f_t\| \|z\|})^2}{\sigma^2}\right) \quad (37)$$

基于上述公式, $\mathcal{L}(h(\cdot), g(\cdot), \pi_t)$ 被定义如下:

$$\mathcal{L}(h(\cdot), g(\cdot), \pi_t) = \sum_{z' \in Z} \pi_t(z) (h(z) - g(z'))^2 \quad (38)$$

(2) 考虑到我们的方法涉及输入的多个特征, 我们仅对文本模态进行扰动, 而其他模态对于每个 z' 将具有相同的表示。具体而言, 每个扰动样本 z' 生成不同的文本表示, 而其他特征(如图像特征、背景知识和评论)的表示保持固定。对于每个扰动样本 z' 及其恢复空间 z , 我们通过HPT融合所有特征, 可表示为 $F_z = \text{HPT}(z, f_i, f_{t-i}, f_{r-x}, f_{c-x})$ 。然后, 我们使用原始模型对每个扰动样本 F_z 进行预测, 并获得预测结果 $c = h(F_z)$ 。这样, 公式(38)应改写为:

$$\mathcal{L}(h(\cdot), g(\cdot), \pi_t) = \sum_{z' \in Z} \pi_t(z) (h(F_z) - g(z'))^2 \quad (39)$$

式(39)是一个扩展的损失函数, 它结合了多模态融合(通过HPT), 用于在保持非文本特征不变的情况下评估扰动。在我们的实验中, 我们为文本实例 f_t 生成了1000个扰动样本及其对应的标签。MLIME的流程图如图6所示, 它展示了文本模态上解释的生成过程。

(3) 我们对其他特征采用相同的方法, 以完成对每个特征对虚假新闻检测结果影响的解释。MLIME的最终输出是以用户可理解的方式高亮显示最具影响力的词语和图像块。此外, 我们可以将每个模态/特征的可视化结果与人类认知相结合, 以解释模型检测结果的有效性。

4. 实验

我们首先介绍两个数据集, 然后详细说明实验设置。随后, 我们将所提方法与最先进的方法进行对比评估。此外, 我们进行了消融分析、参数分析、鲁棒性测试和效率评估(见附录C), 以全面讨论模型的有效性。最后, 我们使用MLIME对模型可解释性进行分析, 并对特征融合的结果进行可视化展示。

表 2 详细 信息 的 该 新闻 数据集。

数据集	WeiBo21	FineFake
语言领域	Chinese (科学, 军事, 教育, 灾难, 政治, health, finance, 娱乐, 和 社会)	English (政治, 娱乐, business, 健康, 社会, 和 conflict)
假新闻	2987	8595
Real 新闻	3023	6545
平均数量 per word	122.06	1392.07

4.1. 数据集 与 评估

我们在两个公开基准数据集上测试模型，分别为WeiBo21 (Nan等人, 2021a) 和FineFake (Zhou等人, 2024)。在数据预处理过程中，我们移除了不完整的样本（仅文本、仅图像或损坏的图像文件），这些样本通常会引入噪声并阻碍跨模态特征学习。数据集中仅保留同时包含文本和图像的新闻条目，以确保稳定的跨模态关系学习。此外，我们还排除了可能触发大语言模型拒绝的敏感内容样本，以保持辅助信息生成的一致性。这种预处理策略通过确保完整的多模态表示和可靠的辅助信息生成，提高了数据一致性，同时增强了模型的泛化能力和鲁棒性。

该 WeiBo21 数据集 是一个 中文 数据集， 涵盖 了 九个 不同 领域 的 新闻 内容。 原始 的 Weibo21 数据集 包含 9128 个 样本， 经过 预处理后 保留 了 6010 个 有效样本：

- (1) 训练集： 4,808 个样本 （2,425 真实/2,383 虚假）；
- (2) 测试集： 601 个样本 （294 真实/307 虚假）；
- (3) 验证集： 601 个样本 （304 真实/297 虚假）。

FineFake数据集是一个英文数据集，涵盖来自六个领域和八个不同平台的新闻。每个新闻条目均包含多种模态、潜在的社交上下文、半验证的常识知识，以及超越简单二元标签的详细标注。该数据集最初包含16,909个样本，处理后剩余15,140个。该数据集由以下部分组成：

- (1) 训练集： 9,084 个样本 （3,858 条真实 / 5226 条虚假）；
- (2) 测试集： 3,028 个样本 （1,331 条真实 / 1697 条虚假）；
- (3) 验证集： 3,028 个样本 （1,356 条真实 / 1672 条虚假）。

两个数据集汇总于表2。我们采用准确率（Acc.）、精确率（Prec.）、召回率（Rec.）、F1分数（F1）和AUC作为该任务的评估指标。除这两个数据集外，我们还在LLM生成的假新闻数据集上开展了鲁棒性实验。详见附录D。

4.2. 实验 设置

4.2.1. 实现 细节

对于中文和英文文本数据，分别采用预训练的BERT模型“chinese-bert-wwm-ext”和“bert-base-uncased”进行嵌入表示，最大词元长度为170，嵌入维度为768。训练过程中采用早停策略，耐心参数设为5。所采用的损失函数为二元交叉熵。分类器为多层感知机，输入层和隐藏层维度分别为768和384。我们以128的批大小将模型训练50个轮次，并使用Adam优化模型。学习率通过StepLR（即PyTorch中的学习率调度器）进行优化，其中步长step.size设为100，gamma设为0.98，即每经过100个训练步，便将当前学习率乘以0.98进行调整。

图像特征提取使用 ViT 模型,输入图像大小为 224×224,输出嵌入维度为 768。CLIP 中的图像编码器模块采用预训练的 ViT 架构,输入图像大小为 224×224 ,输出嵌入维度为 512。文本编码器模块同样输出 512 的嵌入维度。

4.2.2. 基线

我们将LLM-MFEFND与基于文本的单模态方法（TM）、多模态方法（MM）以及基于大语言模型的方法（LLM）进行了比较。我们在实验中选择DeepSeek和ChatGLM，是因为它们具有开源特性、在中文和多语言处理方面的优势以及计算效率。表3列出了各种方法所使用的特征。我们还将DeepSeek和ChatGLM与其他开源大语言模型进行了比较（详见附录B）。

TM1: TextCNN (Kim, 2014) : 该 TextCNN 模型 是一种 非常 有效 的 文本 编码器。 该 原始 论文 使用 word2vec 用于 词 d 嵌入， 我们 利用 BERT e 嵌入 在 我们 的 实验 中。

TM2: BERT (Devlin et al., 2019) : BERT 模型是一种基于Transformer架构的双向编码表示模型。我们使用 BERT 对新闻内容的词元进行编码，并将提取的平均嵌入向量输入多层感知机，以生成最终预测。

表 3 基线 实验 中的 特征 组成。

类别	方法	Text	图像	领域	信息	Aligned 多模	odal F特征	背景	评论	ts
Unimodal M方法	TextCNN	✓	×	×		×		×		×
	BERT	✓	×	×		×		×		×
	MoSE	✓	×	×		×		×		×
M多模态 1 M方法	EDDFN	✓	×	✓		×		×		×
	EANN	✓	✓	×		×		×		×
	MDFEND	✓	×	✓		×		×		×
	MMFN	✓	✓	×		×		×		×
	MSACA	✓	✓	×		×		×		×
	MTS	✓	✓	×		×		×		×
大语言模型-based Method	ARG	✓	×	×		×		✓		×
	LLM-Zero-GLM	✓	×	×		×		×		×
	LLM-Few-GLM	✓	×	×		×		×		×
	LLM-Zero-DS	✓	×	×		×		×		×
	LLM-Few-DS	✓	×	×		×		×		×
Ours	LLM-MFEFND	✓	✓	×		✓		✓		✓

TM3: MoSE (Qin et al., 2020) : MoSE 方法提出了一种称为序列专家混合 (MoSE) 的新颖框架, 该框架通过将 LSTM 网络与多门控专家混合 (MMoE) 模型相结合, 有效处理用于虚假新闻检测的用户文本数据。

MM1: EDDFN (Silva 等人, 2021b) : 该 EDDFN 模型由两个关键组件组成: 无监督领域嵌入学习以及有监督领域无关分类, 共同提取领域特定和跨领域知识。

MM2: EANN (Wang 等人, 2018) : EANN 模型主要提取文本特征和视觉特征。该模型利用事件判别器区分事件并消除事件特定特征, 同时多模态特征提取器与事件判别器进行对抗学习, 从而有效检测虚假新闻。

MM3: MDFEND (Nan 等人, 2021b) : MDFEND 模型通过整合多领域数据来解决领域偏移问题 (即不同领域之间数据分布的差异)。该模型的核心在于采用领域门控机制, 根据新闻的领域特征和内容特征, 动态选择最合适的专家网络来提取新闻表示。

MM4: MMFN (Zhou 等人, 2023) : MMFN 模型整合了多尺度特征提取, 充分利用新闻内容中的细粒度细节和粗粒度语义。该模型通过 CLIP 编码处理文本和视觉输入以提取全局特征, 并利用协同注意力 Transformer 捕捉局部模式。

MM5: MSACA (Wang et al., 2024b): The MSACA model enhances the semantic consistency between text and image data, selecting the most discriminative unimodal and cross-modal embeddings for fake news detection.

MM6: MTS (Sun et al., 2025): The MTS model leverages Taylor series expansion to capture low-order and high-order cross-modal interactions for fake news detection, ensuring linear scalability and enhanced interpretability.

LLM1: ARG (Hu et al., 2024): The ARG model utilizes LLMs to generate multi-perspective, informative rationales to assist smaller language models in fake news detection.

LLM2: LLM-Zero-GLM (GLM et al., 2024): The LLM-Zero-GLM model employs Zero-Shot Prompting based on ChatGLM (GLM-4-Air), constructing prompts that consist solely of the task description and the provided news.

LLM3: LLM-Few-GLM (GLM 等, 2024) : LLM-Few-GLM 模型采用基于 ChatGLM (GLM-4-Air) 的少样本提示, 即向模型提供少量带标注的示例, 以引导其理解任务并提升性能。我们采用 4 样本提示策略, 其中包含两个真实样本和两个虚假样本。

LLM4: LLM-Zero-DS (Liu 等, 2024) : LLM-Zero-DS 模型采用基于 DeepSeek (DeepSeek-v3) 的零样本提示。²LLM5: LLM-Few-DS (Liu 等, 2024) : LLM-Few-DS 模型采用基于 DeepSeek (DeepSeek-v3) 的少样本提示。OUR1

: LLM-MFEFND -GLM: The LLM-MFEFND model utilizes ChatGLM (GLM-4-Air) for augmented feature generation.

OUR2 : LLM-MFEFND-DS: 该 LLM-MFEFND 模型使用 DeepSeek (DeepSeek-V3) 进行增强特征生成。上述参数对应于各基线模型的配置如下:

TextCNN, BERT, MoSE: The dimensions of the MLP (classifier) are {{320,384,0.2},{768,384,0.2},{320,384,0.2}}, where 0.2 is the parameter of the dropout layer. batch size = 64, epochs = 50, early_stop = {NaN, 3, 5};

EDDFN, EANN, MDFEND, MMFN, MSACA: 该维度的该多层感知机 (分类器) 为 {{320,384,0.2}, {320,384,0.2}, {320,384,0.2}, {48,48,2}, {256,64,2}}, 批量大小 = 64, 轮数={50,50,50,50,100}, 提前_停止={5,5,5,NaN};

TextCNN: 输出通道保持恒定为 64, 适用于所有卷积核尺寸: {1, 2, 3, 5, 10};

² <https://github.com/deepseek-ai>

表 4 比较 LLM-MFEFND 与 最新 方法 在 WeiBo21上的表现。 最佳 结果 以 粗体标出。 (*: 开源)。 +(p ≤ 0.05), + +(p ≤ 0.005), 表明 统计 显著性 (通过 配对 t 检验 与 最佳 基线 相比)。

类别	方法	AUC	Acc.	虚假 新闻			真实 新闻		
				精确率	Rec.	F1	精确率	Rec.	F1
Unimodal M方法	TTextCNN	0.944	0.845	0.796	0.909	0.833	0.922	0.798	0.856
	BERT	0.935	0.866	0.840	0.848	0.844	0.887	0.880	0.883
	MoSE*	0.946	0.901	0.904	0.858	0.880	0.899	0.932	0.915
M多模态 1 M方法	EDDFN*	0.931	0.871	0.834	0.868	0.851	0.900	0.873	0.886
	EANN*	0.952	0.884	0.882	0.838	0.860	0.884	0.917	0.901
	MDFEND*	0.980	0.928	0.900	0.959	0.929	0.958	0.899	0.927
	MMFN*	0.977	0.925	0.938	0.911	0.924	0.911	0.939	0.925
	MSACA*	0.952	0.905	0.910	0.894	0.902	0.898	0.914	0.906
	MTS*	0.979	0.928	0.898	0.963	0.929	0.962	0.896	0.927
大语言模型-based M方法	ARG*	0.965	0.911	0.907	0.916	0.912	0.915	0.905	0.910
	LLM-Zero-GLM	0.621	0.613	0.802	0.329	0.467	0.563	0.914	0.696
	LLM-Few-GLM	0.659	0.652	0.589	0.934	0.723	0.861	0.384	0.532
	LLM-Zero-DS	0.812	0.811	0.779	0.861	0.817	0.850	0.763	0.804
	LLM-Few-D S	0.716	0.711	0.632	0.976	0.767	0.952	0.456	0.617
Ours	LLM-MFEFND-GLM	0.982	0.943 ⁺	0.930	0.955	0.942 ⁺⁺	0.956	0.931	0.943 ⁺
	LLM-MFEFND-D S	0.983	0.945 ⁺	0.945	0.942	0.944 ⁺⁺	0.945	0.948 ⁺⁺	0.946 ⁺

EANN: 输出 通道 保持 恒定 为 64 , 适用于 所有 卷积核 尺寸: {1, 2, 3, 5, 10}, 并且 该 参数 α 被 定义 如下:

$$\alpha = \max \left(\frac{2}{1 + \exp \left(-\frac{10 \cdot \text{epoch}}{\text{epochs}} \right)} - 1, 0.1 \right)$$

(40)

其中 epoch 表示 当前 训练 轮次, epochs 表示 总 数量 的 训练 轮次。

ARG: 该 维度 的 该 分类器 为 {320,348,0.2}, 该 维度 的 该 协同注意力机制 网络 为 300, 批量 大小 = 64, 轮次 = 50.

MTS: The training uses a batch size of 24 and limits input sequences to 200 tokens. The learning rate is fixed at 2e-5 to ensure stable training.

4.3. 整体 性能

为了从整体角度评估我们提出的方法, 我们分别在两个数据集上, 将LLM-MFEFND与多种最先进的单模态和多模态虚假新闻检测方法进行了比较。我们还将LLM-MFEFND与基于大语言模型的方法进行了比较, 以评估将大语言模型融入虚假新闻检测任务的有效性。表4和表5展示了LLM-MFEFND与其他方法的对比结果。图7和图8展示了所有方法平均性能的热力图。

表4和表5以及图7和图8中的数据表明, LLM-MFEFND在整体准确率方面优于所有其他模型, 证实了我们所提出方法的有效性。值得注意的是, LLM-MFEFND-DS在WeiBo21上取得了94.5%的准确率和0.945的F1分数, 并在FineFake上取得了81.1%的准确率和0.807的F1分数。此外, 这些结果证实了大语言模型的选择会影响模型性能。虽然两个模型在中文数据集上的表现相当, 但在英文数据集上, DeepSeek的性能优于ChatGLM。

在单模态方法中, MoSE的表现优于 TextCNN 和 BERT, 这是因为 MoSE 使用了一个共享专家池, 其中包含多个面向不同领域的独立主体。TextCNN 和 BERT 仅从文本中提取特征, 无法理解图像中的信息。许多虚假新闻因其所使用的图像而具有误导性, 仅依赖文本信息的模型往往难以捕捉这些多模态线索。

在多模态方法中, MTS 和 MMFN 的表现优于 MDFEND、MSACA、EANN 和 EDDFN。与其他方法相比, MTS 和 MMFN 的卓越性能可归因于其先进的多模态表示学习机制。具体而言, MMFN 通过以不同粒度处理多模态输入来增强特征提取。MTS 能够通过多模态泰勒级数在文本与图像之间建立更深层次的交互。MDFEND 利用软共享机制聚合跨领域知识, 因此相比 EANN 和 EDDFN 取得了更好的性能。然而, MDFEND 主要关注跨领域知识, 难以有效融合跨模态信息, 这限制了其性能。在某些情况下, 文本与图像的语义可能无法完全对齐, 导致模型性能欠佳。尽管 MSACA 通过变分自编码器模型减少了文本与图像之间的语义歧义, 但跨模态语义对齐仍是一个具有挑战性的问题。此外, MSACA 表现出明显的差距: 虚假新闻 F1值较高 (0.808), 而真实新闻 F1值则显著较低 (0.742)。相比之下, LLM-MFEFND 在两个类别上均表现良好。在图 7 和图 8 中, 当考虑对两个类别平等汇总性能的宏平均指标时, 我们的方法展现出更优的整体性能。在基于大语言模型的方法中, ARG 的表现优于

表5 LLM-MFEFND与最新方法在FineFake上的对比。最佳结果以粗体标出。（*：开源）。+ ($p \leq 0.05$)、++ ($p \leq 0.005$)，表明与最佳基线相比，经配对t检验具有统计显著性。

类别	方法	AUC	Acc.	假新闻			真新闻		
				精确率	Rec.	F1	精确率	Rec.	F1
Unimodal M方法	TextCNN	0.830	0.753	0.750	0.656	0.700	0.754	0.829	0.790
	BERT	0.848	0.764	0.727	0.742	0.735	0.794	0.782	0.788
	MoSE*	0.862	0.776	0.760	0.718	0.738	0.788	0.822	0.804
M多模态 1 M方法	EDDFN*	0.824	0.746	0.766	0.607	0.677	0.735	0.854	0.790
	EANN*	0.858	0.773	0.773	0.686	0.727	0.773	0.842	0.806
	MDFEND*	0.858	0.776	0.806	0.646	0.717	0.760	0.878	0.814
	MMFN*	0.866	0.789	0.780	0.762	0.752	0.796	0.839	0.817
	MSACA*	0.834	0.781	0.777	0.842	0.808	0.785	0.705	0.742
	MTS*	0.875	0.788	0.759	0.758	0.758	0.810	0.811	0.811
大语言模型-based M方法	ARG*	0.866	0.776	0.795	0.806	0.800	0.752	0.738	0.745
	LLM-Zero-GLM	0.662	0.640	0.794	0.486	0.603	0.559	0.838	0.671
	LLM-Few-GLM	0.685	0.672	0.779	0.581	0.666	0.595	0.789	0.678
	LLM-Zero-D S	0.692	0.672	0.811	0.561	0.663	0.581	0.823	0.681
	LLM-Few-D S	0.672	0.669	0.742	0.651	0.694	0.595	0.693	0.640
Ours	LLM-MFEFND-GLM	0.881 ++	0.800 ++	0.797	0.730	0.762	0.801	0.854	0.827 +
	LLM-MFEFND-D S	0.882 ++	0.811 ++	0.811 ++	0.745	0.776	0.812 +	0.864	0.837 +



图 7. WeiBo21 上的性能热力图可视化。

其他基于大语言模型的方法。这可能是因为 ARG 利用大语言模型提供多视角推理，从而增强了较小模型的识别能力。DeepSeek 的性能优于 ChatGLM，这可能是由于 DeepSeek 拥有更广泛的知识覆盖，并使用了更丰富、更多样化的虚假新闻数据集，涵盖了更多的语言风格。LLM-Zero 和 LLM-Few 都直接使用大语言模型来判断新闻的真实性，但未能取得有效结果。这一结果也表明，大语言模型无法直接替代用于虚假新闻检测的模型。尽管人们普遍认为少样本设置能通过提供任务示例来提升性能，但我们观察到 DeepSeek 在零样本条件下的表现优于少样本条件。这可能是由于 DeepSeek 更强的零样本推理能力。在预训练期间，它融合了高质量的指令微调数据和泛化训练，使其无需显式示例即可基于输入上下文和内部知识做出准确判断。在零样本条件下，模型可以基于任务描述进行高效推理；而在少样本条件下，添加的示例会干扰其推理路径，导致性能下降。这表明，在使用大语言模型时，应根据模型的特性灵活选择零样本或少样本策略。



图 8. 性能 热力图 可视化 用于 FineFake。

与上述模型相比，LLM-MFEFND 具有三大优势：(1) LLM-MFEFND 从多视角提取文本特征和视觉特征，以确保新闻特征的全面性；(2) LLM-MFEFND 利用大语言模型生成背景和评论，极大地丰富了语义信息；(3) LLM-MFEFND 通过 HPT 实现高效的渐进式跨特征融合，并提升了整体性能。

4.4. 消融 研究

4.4.1. 消融 研究 关于 特征 组件

为 评估 各个 组件 的贡献 在 LLM-MFEFND中， 我们 进行 消融 研究 通过 依次 移除 每个 组件。 实验 设置 概述 如下：

(1) W/o T：移除文本特征提取组件；移除文本模态后，新闻-背景-评论交互模块实际上随之失效。因此，背景特征和评论特征仅通过注意力机制处理，随后直接传播至HPT。(2) W/o V：移除图像特征提取组件；其余四个特征被输入HPT模块。(3) W/o B：移除背景知识；文本特征不再与背景交互，而其余四个特征被输入HPT模块。(4) W/o F：移除对齐的多模态特征；其余四个特征被输入HPT模块。(5) W/o C：移除评论；文本特征不再与评论交互，而其余四个特征被输入HPT模块。(6) W/o U：移除新闻-背景-评论交互模块；作为替代，背景特征和评论特征（由BERT提取）经池化后直接输入HPT。

如表6和表7所示，给出了各项消融实验的结果。从实验结果可以看出，原始的 LLM-MFEFND-GLM 和 LLM-MFEFND-DS 优于所有消融变体，每个模块的引入都显著提升了模型性能。这证明了模型中每个模块的有效性。主要发现如下：


(1) 移除文本编码器后，准确率和 AUC 的下降最为显著：在 WeiBo21 上，使用 GLM 时分别下降 3.0% 和 0.5%，使用 DS 时分别下降 3.3% 和 2.6%。这凸显了文本特征在虚假新闻检测中的关键作用。(2) 移除图像特征提取模块后，使用 GLM 和 DS 在两个数据集上的准确率均出现明显下降。这凸显了图像特征在检测中的重要性。(3) 省略对齐多模态模块后，使用 GLM 在 WeiBo21 和 FineFake 上的准确率分别下降 2.8% 和 1.3%，使用 DS 时分别下降 1.5% 和 3.7%。这表明同时从文本和图像中提取特征可以提升检测性能。

表 6 消融 研究 在 两个 数据集 使用 ChatGLM.

数据集	方法	AUC	Acc.	假 新闻			真 实 新闻		
				精确率	Rec.	F1	精确率	Rec.	F1
WeiBo21	LLM-MFEFND-GLM	0.982	0.943	0.930	0.955	0.942	0.956	0.931	0.943
	w/o T	0.977	0.913	0.926	0.901	0.913	0.902	0.926	0.914
	w/o V	0.980	0.921	0.882	0.969	0.923	0.967	0.923	0.919
	w/o F	0.976	0.915	0.888	0.945	0.915	0.944	0.885	0.914
	w/o B	0.979	0.936	0.902	0.976	0.937	0.975	0.899	0.935
	w/o C	0.978	0.933	0.917	0.948	0.933	0.949	0.918	0.933
	w/o U	0.971	0.925	0.897	0.955	0.925	0.954	0.895	0.924
FineFake	LLM-MFEFND-GLM	0.881	0.800	0.797	0.730	0.762	0.801	0.854	0.827
	w/o T	0.873	0.791	0.800	0.701	0.747	0.786	0.862	0.822
	w/o V	0.880	0.791	0.729	0.832	0.777	0.852	0.758	0.802
	w/o F	0.868	0.787	0.766	0.741	0.753	0.802	0.822	0.812
	w/o B	0.863	0.779	0.766	0.718	0.741	0.789	0.828	0.808
	w/o C	0.879	0.788	0.719	0.849	0.778	0.862	0.739	0.796
	w/o U	0.860	0.779	0.743	0.762	0.752	0.809	0.793	0.801

表 7 使用 DeepSeek 在 两个 数据集 上的 消 融研究。

数据集	方法	AUC	Acc.	假 新闻			真 新闻		
				精确率	Rec.	F1	精确率	Rec.	F1
WeiBo21	LLM-MFEFND-D S	0.983	0.945	0.945	0.942	0.944	0.945	0.948	0.946
	w/o T	0.957	0.912	0.893	0.932	0.912	0.932	0.893	0.912
	w/o V	0.980	0.938	0.924	0.952	0.938	0.953	0.925	0.939
	w/o F	0.974	0.930	0.938	0.918	0.928	0.923	0.941	0.932
	w/o B	0.979	0.933	0.918	0.949	0.933	0.949	0.919	0.934
	w/o C	0.973	0.931	0.904	0.963	0.932	0.962	0.902	0.931
	w/o U	0.979	0.928	0.934	0.924	0.929	0.923	0.933	0.928
FineFake	LLM-MFEFND-D S	0.882	0.811	0.811	0.745	0.776	0.812	0.864	0.837
	w/o T	0.873	0.789	0.781	0.723	0.751	0.794	0.841	0.817
	w/o V	0.877	0.792	0.763	0.763	0.763	0.814	0.814	0.814
	w/o F	0.862	0.774	0.741	0.748	0.744	0.801	0.795	0.798
	w/o B	0.876	0.792	0.759	0.772	0.765	0.819	0.808	0.813
	w/o C	0.875	0.788	0.759	0.758	0.759	0.811	0.795	0.811
	w/o U	0.825	0.789	0.840	0.653	0.735	0.762	0.899	0.825



(4) 移除背景模块后，使用 GLM 在 WeiBo21 和 FineFake 上的准确率分别下降 0.7% 和 2.1%，使用 DS 时分别下降 1.2% 和 1.9%。这证明了背景模块在提升模型精确率方面的重要性。(5) 移除评论模块后，使用 GLM 在两个数据集上的准确率分别下降 1.0% 和 1.2%，使用 DS 时分别下降 1.4% 和 2.3%，凸显了其对检测性能的显著影响。(6) 移除交互模块后，使用 GLM 时准确率分别下降 1.8% 和 2.1%，使用 DS 时分别下降 1.7% 和 2.2%。这表明结合新闻、背景和评论特征能够提供额外的语义信息，从而提升模型性能。

表 8 实验 结果 的 不同 融合 顺序。

数据集	融合 顺序 r	AUC	Acc.	F1
WeiBo21	$F_t, F_p, F_{l-p}, F_{r \rightarrow x}, F_{c \rightarrow x}$	0.983	0.945	0.945
	$F_p, F_p, F_{l-p}, F_{r \rightarrow x}, F_{c \rightarrow x}$	0.973	0.940	0.940
	$F_{r \rightarrow x}, F_p, F_p, F_{l-p}, F_{c \rightarrow x}$	0.983	0.938	0.938
	$F_{c \rightarrow x}, F_{r \rightarrow x}, F_p, F_p, F_{l-i}$	0.979	0.935	0.935
FineFake	$F_t, F_p, F_{l-p}, F_{r \rightarrow x}, F_{c \rightarrow x}$	0.882	0.811	0.807
	$F_p, F_p, F_{l-p}, F_{r \rightarrow x}, F_{c \rightarrow x}$	0.892	0.804	0.804
	$F_{r \rightarrow x}, F_p, F_p, F_{l-p}, F_{c \rightarrow x}$	0.882	0.796	0.795
	$F_{c \rightarrow x}, F_{r \rightarrow x}, F_p, F_p, F_{l-i}$	0.875	0.798	0.796




图 10. 该 tr 训练 准确率 和 损失 值 在 不同 学习 率 评估 于 WeiBo21。

4.4.2. 融合 模块 的 消融 研究

为了评估HPT模块的性能，我们将其与拼接方法进行了比较。如图9所示，在WeiBo21数据集上，HPT方法在准确率和精确率方面分别比拼接方法高出1.3%和1.1%。在FineFake数据集上的对比评估表明，与拼接方法相比，HPT技术在准确率上提升了0.8%，在精确率上提升了1%。我们认为，HPT不仅能够捕捉文本模态内的长距离依赖，还能逐步捕捉模态之间的复杂交互。这在涉及两个以上特征的复杂任务中尤为有利。相比之下，传统的拼接方法往往效率更高。然而，当处理更多特征时，这种方法无法直接捕捉不同特征之间的复杂关系。

4.4.3. 关于 融合顺序 的 消融 实验

如表8所示，尽管存在大量可能的顺序，我们选取了几种关键的备选方案进行比较，例如下上文优先和核心特征优先融合。结果表明，虽然不同的融合顺序对模型性能有一定影响，但影响并不显著。即使采用不同的顺序，其性能仍优于其他基线。在两个数据集上，最优融合顺序始终是 $F_p, F_p, F_{l-p}, F_{r \rightarrow x}, F_{c \rightarrow x}$ 。值得注意的是，先融合图像再融合文本会降低性能。这可能表明文本特征比视觉特征更重要，这与我们的消融实验（第4.4.1节）结果一致。

Overall, these results confirm that the most effective strategy is to first fuse the core features, namely text and image with their aligned features, and then gradually integrate contextual information generated by LLMs.

4.5. 参数 分析

4.5.1. 学习 率

在本节中，我们使用不同的学习率对LLM-MFEFND进行训练。图10展示了在WeiBo21数据集上不同学习率下准确率和损失的学习曲线。模型在不同学习率下均表现出稳定的收敛性，并在学习率为0.0001时取得最佳性能，获得了最高的准确率和训练效率。虽然在1e-5时模型仍能收敛，但需要大幅增加迭代次数。然而，学习率为0.0003时对该任务的效果较差。

图 11 展示了 该 学习 曲线 的 准确率 和 损失 在 不同 学习 率 下 在 该 FineFake 数据集上。二者 该 模型 的 训练 效率 和 准确率 均 达到 最大 当 该 学习 率 为 0.0002时。

4.5.2. HPT 中的第 N 轮迭代

我们通过在两个数据集上使用 DeepSeek 和 ChatGLM 开展实验，评估了 HPT模块中交互轮次 (N) 的影响。我们进行了交互轮次数量不同 (范围从 1 到 8) 的实验。如图 12 所示，结果表明，在两种语言场景下，当 $N = 4$ 时模型均取得最优 F1 分数，这表明适当数量的多轮交互能够增强模型整合多样化特征的能力，从而提升虚假新闻检测性能。然而，当 $N > 4$ 时，性能略有下降，这说明过多的交互轮次可能引入冗余或噪声信息，从而削弱 HPT 的融合效果。




图 11. FineFake 数据集上不同学习率下的训练准确率和损失值。




图 12. 迭代轮次 (N) 对虚假新闻检测性能的影响。




图 13. WeiBo21 上不同虚假/真实新闻比例下不同方法的性能。

4.6. 鲁棒性分析

如图 13 和图 14 所示, 我们在 FineFake 和 WeiBo21 数据集上开展了虚假新闻与真实新闻比例不同 (如 1:1、2:1、1.5:1、1:2 等) 的实验, 以评估其鲁棒性和泛化能力。

在 FineFake 数据集上, 该模型在各种类别比例下均表现出良好的性能。F1 值始终稳定在 0.802 至 0.808 之间, 波动范围极小 (± 0.006), 表明分类性能稳定, 且对类别比例的变化不敏感。例如, 在 1:1 比例下 F1 值为 0.804, 在 2:1 比例下略升至 0.808。同时, AUC 在 0.877 至 0.886 之间保持稳定。这证实了即使在不平衡类别分布下, 模型也能有效捕捉真实新闻与虚假新闻之间的判别性特征, 而不会过拟合多数类。

在 WeiBo21 数据集上, 模型在 1:1 比例下取得了最佳性能 (F1 值: 0.945, AUC: 0.983)。当类别比例调整为 2:1 或 1:1.5 时, 性能略有下降, 但仍保持较高水平 (F1 > 0.928, AUC > 0.973)。这一轻微下降主要是由于



图 14. 在 FineFake 数据集上不同假/真新闻比例下不同方法的性能。




图 15. MLIME 与 SHAP 的对比定量分析。

WeiBo21 数据集的规模相对较小，其中类别不平衡放大了样本差异，并导致决策边界发生轻微偏移。尽管如此，该模型在所有比例下均保持了稳健的性能，证明了其在中文数据上的一致有效性。

此外，我们选取在FineFake数据集上表现良好的MMFN和MTS，以及在WeiBo21数据集上表现良好的MDFEND和MTS，与我们的方法进行对比。在FineFake数据集上，当类别分布不平衡（如2:1或1:2）时，MMFN和MTS的F1值和准确率均显著下降，在0.762至0.788之间波动。相比之下，我们的方法在不同比例下始终将F1值和准确率维持在0.800以上，表现出更小的性能波动和更强的稳定性。同样，在WeiBo21数据集上，我们的方法以更优的结果和更小的波动优于MDFEND和MTS。总体而言，与其他方法相比，我们的方法展现出更好的鲁棒性和泛化能力。

4.7. 可解释性分析

4.7.1. 定量分析

为了量化 MLIME 的可解释性，我们从测试集中随机选取了 400 条被正确检测的新闻条目。由于图像解释难以标注，尤其是对于较小的图像块，我们聚焦于文本信息（如文本、背景、评论），并由新闻专业人士进行人工标注。基于 MLIME 的解释结果，我们按如下方式计算解释命中率：

$$\text{Average_Hit_Rate}(K) = \frac{1}{M} \sum_{i=1}^M \frac{|\text{TopK_Words}_i \cap \text{GroundTruth_Words}_i|}{K} \quad (41)$$



Image	  
	Original imageExplanation by SHAPExplanation by MLIME
Text	MLIME: A woman living in Houston, Texas, successfully baked bread in her mailbox during a heat wave. SHAP: A woman living in Houston, Texas, successfully baked bread in her mailbox during a heat wave.
Back-ground	MLIME: Houston, Texas, is known for its hot and humid climate, especially during the summer months. The average high temperature in the summer can exceed 90°F (32°C). Mailboxes in the United States are typically made of metal or other materials that can conduct heat, and they are not designed to maintain temperatures suitable for baking. Bread baking typically requires a consistent internal temperature of around 350-375°F (175-190°C) for a duration of time, which is not achievable in a mailbox exposed to the elements. Furthermore, the insulation and heat retention of a mailbox are not sufficient for baking bread, and the uneven heat distribution would likely result in an improperly cooked product. SHAP: Houston, Texas, is known for its hot and humid climate, especially during the summer months. The average high temperature in the summer can exceed 90°F (32°C). Mailboxes in the United States are typically made of metal or other materials that can conduct heat, and they are not designed to maintain temperatures suitable for baking. Bread baking typically requires a consistent internal temperature of around 350-375°F (175-190°C) for a duration of time, which is not achievable in a mailbox exposed to the elements. Furthermore, the insulation and heat retention of a mailbox are not sufficient for baking bread, and the uneven heat distribution would likely result in an improperly cooked product.
Comments	MLIME: This is such an interesting story! It's a brilliant example of creativity and survival instinct during a heatwave. While it may seem a bit crazy, it shows how people can adapt and make use of what's around them. Who knew a mailbox could be used for baking bread! This sounds ridiculous! Sure, heatwaves can be extreme, but using a mailbox to bake bread is just impractical. It's not safe at all and could easily cause a fire or disrupt the mail system. Definitely not something to encourage." SHAP: This is such an interesting story! It's a brilliant example of creativity and survival instinct during a heatwave. While it may seem a bit crazy, it shows how people can adapt and make use of what's around them. Who knew a mailbox could be used for baking bread! This sounds ridiculous! Sure, heatwaves can be extreme, but using a mailbox to bake bread is just impractical. It's not safe at all and could easily cause a fire or disrupt the mail system. Definitely not something to encourage."

图 16. MLIME 和 SHAP 在 FineFake 数据集 中 的 一 条 假 新 闻 上 的 结 果 。

其中， $GroundTruth_Words$ 表示人工标注中与被标注类别（虚假或真实）相对应的关键特征词集合。 $M = 400$ ， $TopK_Words$ 表示 MLIME 解释输出中排名前 K 的词集合。 $|TopK_Words_i \cap GroundTruth_Words_i|$ 表示 MLIME 排

名靠前的解释输出与真实标签之间相匹配的词数。如图 15 所示，当 K 相对较小时，模型的解释命中率保持在 93% 以上。随着 K 增大，平均命中率呈现下降趋势。这主要是因为排名更靠前的解释词能更准确地反映模型注意力机制的核心特征。即使当 $K = 6$ 时，解释命中率仍约为 70% ~ 86%。

此外，我们实现了一种基于 SHAP 的解释方法，专门面向多模态虚假新闻输入。鉴于 SHAP 缺乏原生多模态版本，我们的实现会独立处理每种模态。结果表明，在两个数据集上，MLIME 的解释命中率始终优于 SHAP。MLIME 能更好地捕捉多源文本的交互特征，而 SHAP 依赖特征独立性假设，并通过采样近似进行加性归因。因此，MLIME 生成的解释更稳定，并展现出更优的解释可靠性。


Image	  
	Original image Explanation by SHAP Explanation by MLIME
Text	MLIME: 【Online Reports of Camels Begging in Multiple Places: Camels' Limbs Were Amputated】 Recently, a netizen @XiamenFoot reported that beggars were seen leading camels to beg on the streets of Foshan, Guangdong. The camels had their limbs amputated at the knees and could only lie on the ground, which is very pitiful. Since the beginning of this year, instances of camels being used for begging have appeared in various places across our country. We call on the relevant authorities to rescue the camels that are being forced to beg in different locations! Please spread the word! Online reports of camels begging in multiple places: Camels' limbs were amputated (photo collection).
	SHAP: 【Online Reports of Camels Begging in Multiple Places: Camels' Limbs Were Amputated】 Recently, a netizen @XiamenFoot reported that beggars were seen leading camels to beg on the streets of Foshan, Guangdong. The camels had their limbs amputated at the knees and could only lie on the ground, which is very pitiful. Since the beginning of this year, instances of camels being used for begging have appeared in various places across our country. We call on the relevant authorities to rescue the camels that are being forced to beg in different locations! Please spread the word! Online reports of camels begging in multiple places: Camels' limbs were amputated (photo collection).
Back-ground	MLIME: In recent years, there have indeed been reports of animal begging phenomena in some regions, including the use of camels for begging. However, news regarding "camels' limbs being amputated" should be approached with caution, as it may involve animal abuse and illegal activities. Typically, such reports quickly attract public attention and prompt relevant law enforcement agencies to intervene and investigate. In China, animal protection laws are gradually being improved, and there are clear penalties for acts of animal cruelty.
	SHAP: In recent years, there have indeed been reports of animal begging phenomena in some regions, including the use of camels for begging. However, news regarding "camels' limbs being amputated" should be approached with caution, as it may involve animal abuse and illegal activities. Typically, such reports quickly attract public attention and prompt relevant law enforcement agencies to intervene and investigate. In China, animal protection laws are gradually being improved, and there are clear penalties for acts of animal cruelty.
Comments	MLIME: This is so cruel, I hope the authorities will investigate and deal with it as soon as possible. I've seen similar things on the news before and it's really sad. I hope this is fake news, such behaviour is really intolerable. If it is true, these people should be punished severely by the law. We should raise our awareness of animal protection and not let this happen again.
	SHAP: This is so cruel, I hope the authorities will investigate and deal with it as soon as possible. I've seen similar things on the news before and it's really sad. I hope this is fake news, such behaviour is really intolerable. If it is true, these people should be punished severely by the law. We should raise our awareness of animal protection and not let this happen again.

图 17. MLIME 和 SHAP 在 WeiBo21 数据集中的 一条 虚假新闻 上的结果 。

4.7.2. 案例 研究

图 16 和图 17 分别给出了 MLIME 与 SHAP 在 WeiBo21 和 FineFake 上的两个示例。可以观察到，大语言模型生成的背景和评论不仅提供了补充性的事实语境，还带来了多视角见解，从而为模型提供丰富的上下文信息和额外线索。

Words highlighted in red represent positive contributions to the detection of fake news, while those in blue indicate negative contributions. MLIME explanation results show that in an example from WeiBo21, words that clearly convey violence and exaggeration




图 18. 在 WeiBo21 上各表示方法的特征可视化

(例如“amputated”)以及负面和怀疑的情感(例如“cruel”“intolerable”)对模型将新闻判定为假产生了积极影响。对于图像特征,我们可以看到骆驼和行人的特征都被保留下来,并且这些特征对新闻虚假性的评估做出了积极贡献。同样,在FineFake中,单词的积极贡献确实涵盖了与虚假新闻相关的丰富语义场,例如“baked”“bread”和“ridiculous”。这表明,对虚假新闻的判断做出积极贡献的单词包含与虚假信息相关的关键语义。该示例保留了“用Email收件箱烤面包”的图像区域,表明模型有效地突出了这一视觉元素,同时与文本中荒谬的语义保持一致。

MLIME在定位重要线索和建立跨模态关联方面显著优于SHAP。SHAP的视觉解释往往忽略关键上下文,反而关注无关背景,其文本归因也与人类认知相背离,缺乏跨模态相关性。例如,在FineFake数据集上,SHAP遗漏了“baked”和“bread”等关键正面词汇,也未能清晰解析图像中的“mailbox”等物体。同样,在WeiBo21上,它忽略了“beggars”等与视觉内容相对应的关键术语。相比之下,MLIME通过聚焦与事件相关的主体,提供了更为集中的视觉解释。其文本归因与人类直觉高度一致,实现了与图像稳健的语义对齐。

4.8. 可视化分析

特征可视化是一种针对融合特征的解释方法。我们利用t-SNE,将融合特征投影到二维空间中进行可视化展示。

如图18和图19所示,最终的可视化结果表明,与其他方法相比,我们的HPT方法能够将同类型的新闻更好地聚类在一起。此外,我们的方法所生成的簇边界更清晰、重叠更少。具体而言,在WeiBo21数据集上,LLM-MFEFND的特征分布呈现出明显的新月形结构,实现了真实新闻与虚假新闻样本之间的清晰分离。即使在样本多样性更高、图文关系更为复杂的FineFake数据集上,该模型仍保持了有效的聚类性能,特征点形成了明显的拉长簇状分布。相比之下,对比方法(如MTS、MSACA、MMFN等)则呈现出分散且未聚类的数据模式。这些结果证实,HPT模块能够有效融合多模态特征,捕捉文本-图像语义关系,同时保留用于检测的判别性特征。此外,在不同数据集上的一致表现凸显了LLM-MFEFND强大的泛化能力和卓越的判别能力。

5. 讨论

5.1. 理论启示

所提出的LLM-MFEFND模型通过将大语言模型生成的内容与层级渐进融合和可解释性相结合,在多模态虚假新闻检测领域取得了重大进展。以往的方法通常侧重于有限的模态/特征,如文本或图像,由于上下文理解不完整,可能导致次优的性能。同时,大语言模型在虚假新闻检测中的直接应用受到幻觉和不对齐等问题的阻碍。据我们所知,我们的方法是首个解决这一问题的研究,它借助大语言模型的辅助,实现了五种不同特征(文本、图像、对齐多模态特征、背景知识和评论)的深度渐进融合,而不依赖大语言模型进行直接分类。我们的方法捕捉了高阶互补信息和跨模态交互,为虚假新闻检测中的多模态融合技术树立了新的基准。此外,与以往研究不同,我们的MLIME方法能够为多模态场景下的模型决策提供事后解释。

5.2. 实践意义

LLM-MFEFND模型在打击虚假新闻方面具有重要的实际应用价值,可为社交媒体平台、事实核查组织和政策制定者带来明显的益处。该模型的高准确率(在WeiBo21上为94.5%,在FineFake上为81.1%)使推特、脸书和微博等平台能够以更高的可靠性自动标记可疑内容,从而降低对人工审核的依赖。此外,LLM-MFEFND可供事实核查机构使用,对潜在的虚假新闻进行优先审核,并利用其可解释输出快速识别误导性内容。更重要的是,得益于模型的可解释性,该模型可以通过突出显示哪些特征促成了“虚假”分类,帮助用户理解其决策。

5.3. 未来工作

尽管LLM-MFEFND在测试数据集上表现良好,但其对其他语言或小众领域(如科学虚假信息)的泛化能力仍有待验证。将评估扩展到多样化的数据集和领域将是我们未来研究的重点。具体而言,我们将利用多语言大语言模型(Pokharel et al., 2025)将模型扩展到其他语言,并结合基于适配器的微调来降低计算成本。对于科学和医学虚假信息领域,我们将尝试将领域特定知识图谱(如BioBERT (Lee et al., 2020)、SciBERT (Lobanova et al., 2023))与HPT模块相结合,以捕捉技术语义。

大语言模型的集成虽然提升了检测性能,但在延迟、成本和可靠性方面也带来了局限性。推理延迟受API调用和硬件限制的影响,可能会影响实时使用。这一问题可通过本地部署或升级硬件来解决。主流模型的成本(例如每百万词元0.5元人民币)仍然是大规模部署的一大障碍。为确保输出的可靠性,本研究中的生成内容均由领域专家进行人工验证。未来的工作将侧重于对性能-成本-延迟权衡进行更系统的评估,并探索自动过滤机制,以增强大语言模型生成的输出的可信度,减少对人工验证的依赖。




图 19. 特征可视化的每种表示方法在 FineFake.

6. 结论

当前的新闻信息往往存在上下文语义不足的问题。如何在扩展上下文语义的同时，有效整合多模态特征并提供可解释分析，仍是虚假新闻检测面临的关键挑战。为解决这一问题，我们提出了一种新颖的可解释虚假新闻检测方法，即将多模态融合与大语言模型生成内容相结合的（LLM-MFEFND）模型。我们的方法利用DeepSeek/ChatGLM生成背景信息和评论，以解决稀疏语义表示和上下文理解不完整的问题。随后，我们通过HPT模块对文本、图像、对齐多模态特征和LLM生成增强特征进行有效整合，从而实现深度

并对各类特征进行渐进融合,同时解决以往方法往往只关注较少特征的局限性。此外,我们设计了MLIME,使其在多模态融合的情况下能够透明地展现其决策依据,从而增强可靠性和可解释性。最后,我们进一步提供定量分析和案例研究,以展示实验结果的可解释性。

我们在WeiBo21和FineFake数据集上开展了实验,主要发现如下:(1) LLM-MFEFND-DS优于现有方法,取得了令人满意且稳健的性能,F1分数较高(在WeiBo21上为0.945,在FineFake上为0.807)。此外,MLIME展现出强大的可解释性,显示出推广到其他多模态任务的潜力。(2)大语言模型的选择会影响虚假新闻检测性能。同时,零样本和少样本策略的有效性随大语言模型的选择而变化,且少样本并不始终优于零样本。

CRediT 作者 贡献 声明

Lidong Wang: 概念化, 方法论, 写作——初稿, 写作——审阅与编辑, 软件, 监督指导, 项目管理; Xun Li: 软件, 数据整理; Bin Zhou: 监督指导, 写作——审阅与编辑, 项目管理; Yin Zhang: 可视化; Jie Yuan: 调查研究, 验证; Hua Hu: 监督指导, 写作——审阅与编辑。

数据 可用性

The code is available on GitHub <https://github.com/li1608335419/LLM-MFEFND>, as mentioned in the experimental evaluation section.

声明 关于 利益 冲突

作者们声明,他们没有任何已知的竞争性财务利益或个人关系,而这些可能会被视为影响本文所报告的工作。

致谢

本研究得到浙江省自然科学基金联合基金(项目批准号:LGEY26E090014)、浙江省影视媒体技术重点实验室(编号:2020E10015)以及宁波市自然科学基金(编号:2023J297)的资助。

附录 A. 假新闻检测方法 的 对比

Table A.9
Comparison of fake news detection methods.

Category	Method	Core Innovation	Features	Dataset	F1
Multi-modal methods	MCAN (Wu et al., 2021b)	Co-attention networks	Text + Image	Twitter / Weibo	0.809 / 0.899
	EMIF (Dong et al., 2024)	Multi-source fusion	Text + Context	FibVID	0.847
	ETMA (Yadav et al., 2024)	Transformer attention	Text + Image	Twitter / Jhwiki / Pontes	0.920 / 0.960 / 0.950
	MMFN (Zhou et al., 2023)	Feature fusion	Text + Image	Weibo / Twitter / GossipCop	0.924 / 0.905 / 0.684
	MSACA (Wang et al., 2024b)	Semantic alignment	Text + Image	Weibo / GossipCop	0.903 / 0.933
	KEMFND (Gao et al., 2024)	Knowledge-enhanced	Text + Image + KG	PolitiFact / GossipCop	0.919 / 0.856
	MVAEs (Gólo et al., 2023)	Variational autoencoders	Multi-modal	FCN / PNNFake.Br	0.885 / 0.396 / 0.650
	MMFEND (Tong et al., 2024)	Multi-domain detection	Text + multi-domain	WeiBo21	0.9137
	BMR (Ying et al., 2023)	Multi-view representations	Text + Image	Weibo / GossipCop / WeiBo21	0.914 / 0.691 / 0.927
	MMVD (Zeng et al., 2024)	Multi-view debiasing	Text + Image + Video	FakeSV / FVC	0.8264 / 0.8928
	KEAN (Zhou et al., 2024)	Domain adaptation	Text + Image	FineFake	0.797
LLM-based methods	ARG (Hu et al., 2024)	LLM rationales	Text	GossipCop / WeiBo21	0.771 / 0.778
	SELF-CHECK (Li et al., 2023)	Fact verification	Text	BINGcheck / FeverWice	0.605 / 0.430
	FactAgent (Li et al., 2024)	Structured workflow	Text	PolitiFact / GossipCop / Snopes	0.830 / 0.750
	AdStyle (Park et al., 2024)	Style augmentation	Text	PolitiFact / GossipCop / Constraint	AUC:0.922 / 0.953 / 0.972
	FLAN-T5 (Kareem & Abbas, 2023)	Chain of thought	Text	LIAR	0.7741
	SFSM (Hoy & Koulouri, 2025)	Stylistic features	Text	NELA / Facebook URLs	0.620
	MRCd (Zhou et al., 2025)	Multi-round learning	Text	PHEME / Twitter16	0.814 / 0.774
	GCAN (Lu & Li, 2020)	Graph attention	Text + Graph	Twitter15 / 16	0.876 / 0.908
	DEFEND (Shu et al., 2019)	Explainable detection	Text + comments	PolitiFact / GossipCop	0.928 / 0.755
	PCAN (Khan et al., 2024)	Pyramidal attention	Text + Network	PolitiFact / GossipCop	0.951 / 0.791
Explainable methods	KGF (Ribeiro et al., 2016)	Knowledge graph	Text + KG + GCN	Celebrity / PolitiFact / GossipCop	0.721 / 0.853 / 0.723
	Prop-2Vec (Silva et al., 2021a)	Propagation paths	Text + Cascades	PolitiFact / GossipCop	0.928 / 0.755
	QA-AXDS (Chi & Liao, 2022)	Argumentation system	Text	Twitter17 / 19 / Reddit	0.741 / 0.723 / 0.926
	Multifaceted (Han et al., 2024b)	Graph reasoning	Text + KG + Graph	PolitiFact / GossipCop / PHEME	0.939 / 0.894 / 0.890
	DCCMA (Wei et al., 2025)	Cross-modal mining	Text + Image	Weibo / PHEME / Gossipcop	0.929 / 0.932 / 0.911

附录 B. 大语言模型 对比 实验

为全面评估开源大语言模型对检测结果的影响，我们在保持检测模型架构和训练参数不变的前提下，采用 Llama 2-7B、Qwen-7B 和 Mistral-7B 生成增强信息。随后，我们在 WeiBo21 和 FineFake 上重新评估这些配置（见表 B.10）。结果表明，替换不同的大语言模型对整体检测性能的影响很小。例如，准确率在 WeiBo21 上介于 0.931 至 0.938 之间，在 FineFake 上介于 0.792 至 0.794 之间。总体而言，ChatGLM 和 DeepSeek 优于其他模型，其中 DeepSeek 取得了最佳性能。

此外，为了将 GLM-4-Air 和 DeepSeek-V3 与前沿模型（如 GPT-5）进行比较，我们分别从中英文数据库中各选取了 200 个样本。对于每个样本，我们使用 GPT-5 生成背景和评论。随后，新闻专业人士对生成材料的内容相关性进行评估。总体而言，与 DeepSeek 生成的内容相比，GPT-5 和 ChatGLM 生成的内容与原始新闻的相关性较低。详细的对比数据已在以下地址公开：<https://github.com/li1608335419/LLM-MFEFND>。总体而言，如表 B.11 所示，ChatGLM-4-air 和 DeepSeek-V3 比其他商业模型显著更具成本效益。DeepSeek-V3 在性能与成本之间实现了良好的平衡。

表 B.10 开源 大语言模型 实验的 对比 结果 。 最佳 结果 以 粗体 标出。

D数据集	M方法	AUC	Acc.	虚假 新闻			Real 新闻			平均 F1值
				Prec.	Rec.	F1	Prec.	Rec.	F1	
WeiBo21	LLM-MFEFND-Llama 2	0.978	0.938	0.924	0.957	0.940	0.955	0.919	0.937	0.939
	LLM-MFEFND-Qwen	0.977	0.931	0.937	0.928	0.932	0.927	0.936	0.931	0.932
	LLM-MFEFND-Mistral	0.983	0.937	0.952	0.921	0.937	0.922	0.953	0.936	0.937
	LLM-MFEFND-GLM	0.982	0.943	0.930	0.955	0.942	0.956	0.931	0.943	0.943
	LLM-MFEFND-D S	0.983	0.945	0.945	0.942	0.944	0.945	0.948	0.946	0.945
FineFake	LLM-MFEFND-Llama 2	0.877	0.792	0.785	0.726	0.754	0.797	0.844	0.820	0.787
	LLM-MFEFND-Qwen	0.878	0.794	0.816	0.811	0.813	0.768	0.774	0.771	0.792
	LLM-MFEFND-Mistral	0.882	0.794	0.833	0.791	0.812	0.750	0.798	0.773	0.793
	LLM-MFEFND-GLM	0.881	0.800	0.797	0.730	0.762	0.801	0.854	0.827	0.795
	LLM-MFEFND-D S	0.882	0.811	0.811	0.745	0.776	0.812	0.864	0.837	0.807

表 B.11 比较 分析 的 不同 商用 大语言模型： 上下文 窗口 和 价格。

LLM	上下文 胜 dow	Input Pri ^{ce} (per 1M 词元)	输出 Pri ^{ce} (每 1M 词元)
DeepSeek-v3	128K	\$0.29	\$0.43
ChatGLM-4-air	128K	\$0.07	\$0.04
GPT-5.2	400K	\$1.75	\$14.00
GPT-5	400K	\$1.25	\$10.00
Qwen3-max	256K	\$1.37	\$5.50
Mistral Large 3	256K	\$0.50	\$1.50
Llama 3.1-405b	128K	\$5.32	\$16.0

附录 C. 效率 对比

在图 C.20 中，我们进一步展示了在相同硬件（NVIDIA RTX 4090、AMD EPYC 7T83）和相同软件（PyTorch 2.2.1、CUDA 12.2）条件下，不同方法在模型规模和计算效率方面的可视化对比。对于中文任务，我们的模型实现了 6.94 毫秒/样本的训练速度和 6.27 毫秒/样本的推理速度。对于英文任务，推理速度达到 5.39 毫秒/秒。

LLM-MFEFND的参数规模与MMFN相当，但略高于MTS和MDFEND，这主要是由于集成了五种模态并采用了堆叠HPT架构。在训练和推理延迟方面，LLM-MFEFND与MMFN表现相近；虽然略慢于另外两个基线，但仍完全能够满足实时推理的需求。




图 C.20. 效率 比较 与 基线。

附录 D. 针对 大语言模型 生成的 假 新闻的 鲁棒性测试

为了评估LLM-MFEFND抵御LLM生成的假新闻的鲁棒性，我们在MiRAGeNews数据集（Huang et al., 2024）上与强基线（MDFEND、MMFN和MTS）进行了对比实验。MiRAGeNews包含15,000个样本，其中的文本和图像由GPT-4和Midjourney V5.2生成。结果表明，LLM-MFEFND实现了稳定且最先进的性能：GLM变体达到了0.963的准确率，且各类别上的指标均衡，而DS变体则进一步将准确率提升至0.969（见表D.12）。

相比之下，MDFEND 的性能显著下降（Acc=0.840），这很可能是因为 MiRAGeNews 中缺乏明确的领域标签。MMFN 的表现同样不佳，表明传统的视觉-语言融合方式不足以应对大语言模型生成内容。与此同时，MTS 表现出明显的类别不平衡（虚假新闻召回率=0.992，真实新闻召回率=0.892）。这些发现表明，LLM-MFEFND 在检测 LLM生成的假新闻方面具有更优越的鲁棒性。



图 D.21. MiRAGeNews 的 案例 研究。

表 D.12 不同方法 在 大语言模型 生成 的 假新闻 上的 性能。

Model	AUC	Acc.	假 新闻			Rea ¹ 新闻		
			Prec.	Rec.	F1	Prec.	Rec.	F1
MDFEND	0.907	0.840	0.868	0.802	0.834	0.816	0.878	0.846
MMFN	0.992	0.947	0.961	0.932	0.946	0.934	0.962	0.948
MTS	0.995	0.942	0.902	0.992	0.945	0.991	0.892	0.939
LLM-MFEFND-GLM	0.993	0.963	0.964	0.963	0.962	0.962	0.964	0.963
LLM-MFEFND-D S	0.992	0.969	0.972	0.966	0.969	0.966	0.972	0.969

图 D.21 展示了来自 MiRAGeNews 数据库的两个案例研究。这些案例属于具有挑战性的样本：新闻文本与配图在语义上保持一致，且文本本身较为简短，仅凭文本内容难以进行检测。在这种情况下，MDFEND、MTS 和 MMFN 等模型会将其错误地分类为真实新闻（如图 D.21 所示）。相比之下，我们的方法利用大语言模型为模型提供更丰富的上下文信息，从而能够在这类模糊案例中做出正确识别。

参考文献

Athira, A. B., Kumar, S. D. M., & Chacko, A. M. (2023). 可解释人工智能应用于虚假新闻检测的系统综述. 人工智能工程应用, 122, 106087. Bu, Y., Sheng, Q., Cao, J., Qi, P., Wang, D., & Li, J. (2024). FakingRecipe: 从创作过程视角检测短视频平台上的虚假新闻. 载于第32届ACM国际多媒体会议论文集 (第1351–1360页) . Chen, Y., Li, D., Zhang, P., Sui, J., Lv, Q., Tun, L., & Shang, L. (2022). 用于多模态虚假新闻检测的跨模态歧义学习. 载于2022年ACM网络会议论文集 (第2897–2905页) . Chi, H., & Liao, B. (2022). 用于社交媒体虚假新闻检测的基于定量论证的自动化可解释决策系统. 基于知识的系统, 242, 108378. Comito, C., Caroprese, L., & Zumpano, E. (2023). 社交媒体上的多模态虚假新闻检测: 深度学习技术综述. 社会网络分析与挖掘, 13(1), 101. Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: 用于语言理解的深度双向Transformer预训练. 载于2019年计算语言学协会北美分会会议: 人类语言技术论文集 (第4171–4186页) . Dong, Q., Zhang, M., Wu, S., & Wu, X. (2024). EMIF: 用于可解释虚假新闻检测的证据感知多源信息融合网络. arXiv:2407.01213. Gao, X., Wang, X., Chen, Z., Zhou, W., & Hoi, S. C. H. (2024). 用于多模态虚假新闻检测的知识增强视觉语言模型. IEEE多媒体汇刊, 26, 8312–8322. GLM, T., Zeng, A., Xu, B., Wang, B., Zhang, C., Yin, D., Zhang, D., Rojas, D., Feng, G., Zhao, H. et al. (2024). ChatGLM: 从GLM-130B到GLM-4的大语言模型系列及全部工具. arXiv:2406.12793. Gôlo, M. P. S., de Souza, M. C., Rossi, R. G., Rezende, S. O., Nogueira, B. M., & Marcacini, R. M. (2023). 通过多模态变分自编码器实现虚假新闻检测的单类学习. 人工智能工程应用, 122, 106088. Han, L., Zhang, X., Zhou, Z., & Liu, Y. (2024a). 用于可解释虚假新闻检测的多面推理网络. 信息处理与管理, 61(6), 103822. Han, L., Zhang, X., Zhou, Z., & Liu, Y. (2024b). 用于可解释虚假新闻检测的多面推理网络. 信息处理与管理, 61(6), 103822. He, K., Chen, X., Xie, S., Li, Y., Dollár, P., & Girshick, R. (2022). 掩码自编码器是可扩展的视觉学习器. 载于IEEE/CVF计算机视觉与模式识别会议论文集 (第16000–16009页) . Hoy, N., & Koulouri, T. (2025). 提升虚假新闻检测模型泛化能力的特征探索. 专家系统与应用, 275, 126949. Hu, B., Sheng, Q., Cao, J., Shi, Y., Li, Y., Wang, D., & Qi, P. (2024). 坏演员，好顾问：探索大语言模型在虚假新闻检测中的作用. 载于AAAI人工智能会议论文集, 20 (第22105–22113页) . Huang, R., Dugan, L., Yang, Y., & Callison-Burch, C. (2024). MiRAGeNews: 多模态逼真AI生成新闻检测. arXiv:2501.05629. Jing, J., Wu, H., Sun, J., Fang, X., & Zhang, H. (2023). 基于渐进式融合网络的多模态虚假新闻检测. 信息处理与管理, 60(1), 103120. Kareem, W., & Abbas, N. (2023). 以智能对抗谎言：利用大语言模型与思维链技术打击虚假新闻. 载于人工智能创新技术与应用国际会议论文集 (第253–258页) . Khan, F., Alturki, R., Srivastava, G., Gazzawe, F., Shah, S. T. U., & Mastorakis, S. (2024). 基于金字塔协同注意力网络的社交媒体虚假新闻可解释检测. IEEE计算社会系统汇刊, 11(4), 4574–4583. Kim, Y. (2014). 用于句子分类的卷积神经网络. 载于A. Moschitti, B. Pang, & W. Daelemans (编) , 2014年自然语言处理实证方法会议 (EMNLP) 论文集 (第1746–1751页) . Lee, J., Yoon, W., Kim, S., Kim, D., Kim, S., So, C. H., & Kang, J. (2020). BioBERT: 用于生物医学文本挖掘的预训练生物医学语言表示模型. 生物信息学 (英国牛津) , 36(4), 1234–1240. Li, M., Peng, B., Galley, M., Gao, J., & Zhang, Z. (2023). Self-Checker: 利用大语言模型进行事实核查的即插即用模块. arXiv:2305.14623. Li, X., Zhang, Y., & Malthouse, E. C. (2024). 用于虚假新闻检测的大语言模型智能体. arXiv:2405.01593. Li, Y. (2023). 面向上下文学习的零样本提示设计实用综述. arXiv预印本 arXiv:2309.13205. Liu, A., Feng, B., Xue, B., Wang, B., Wu, B., Lu, C., Zhao, C., Deng, C., Zhang, C., Ruan, C. et al. (2024). DeepSeek-V3技术报告. arXiv:2412.19437. Liu, H., Wang, W., Sun, H., Rocha, A., & Li, H. (2023). 基于多模态特征对齐的鲁棒领域错误信息检测. IEEE信息取证与安全汇刊, 19, 793–806. Lobanova, P., Bakhtin, P., & Sergienko, Y. (2023). 利用SciBERT识别和可视化科学、技术与创新趋势. IEEE工程管理汇刊, 71, 11898–11906. Lu, Y.-j., & Li, C.-T. (2020). GCAN: 用于社交媒体可解释虚假新闻检测的图感知协同注意力网络. arXiv:2004.11648. Lundberg, S. M., & Lee, S.-I. (2017). 解释模型预测的统一方法. 载于第31届神经信息处理系统国际会议NIPS'17论文集 (第4768—4777页) . 美国纽约州红钩镇: Curran Associates出版社. Ma, J., Li, J., Gao, W., Yang, Y., & Wong, K.-F. (2023). 利用基于Transformer的生成对抗学习推动信息宣传活动以改进谣言检测. IEEE知识与数据工程汇刊, 35(3), 2657–2670. Nan, Q., Cao, J., Zhu, Y., Wang, Y., & Li, J. (2021a). MDFEND: 多领域假新闻检测. 载于第30届ACM信息与知识管理国际会议CIKM '21论文集 (第3343–3347页) .

- Nan, Q., Cao, J., Zhu, Y., Wang, Y., & Li, J. (2021b). Mdfend: Multi-domain fake news detection. In *Proceedings of the 30th ACM international conference on information & knowledge management* (pp. 3343–3347).
- Neha, F., & Bhati, D. (2025). A survey of deepseek models. *Authorea Preprints*.
- Park, S., Han, S., & Cha, M. (2024). Adversarial style augmentation via large language model for robust fake news detection. *arXiv:2406.11260*.
- Pokharel, R., Nezhad, S. B., Agrawal, A., & Singh, S. (2025). The impact of model scaling on seen and unseen language performance. *arXiv:2501.05629*.
- Qin, Z., Cheng, Y., Zhao, Z., Chen, Z., Metzler, D., & Qin, J. (2020). Multitask mixture of sequential experts for user activity streams. In *Proceedings of the 26th ACM SIGKDD international conference on knowledge discovery and data mining* (pp. 3083–3091).
- Radford, A., Kim, J. W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., Sastry, G., Askell, A., Mishkin, P., Clark, J. et al. (2021). Learning transferable visual models from natural language supervision. In *International conference on machine learning* (pp. 8748–8763).
- Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). "Why should i trust you?": Explaining the predictions of any classifier. In *Proceedings of the 22nd ACM SIGKDD international conference on knowledge discovery and data mining* (pp. 1135–1144).
- Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2017). Grad-CAM: Visual explanations from deep networks via gradient-based localization. In *2017 IEEE International conference on computer vision (ICCV)* (pp. 618–626).
- Shu, K., Cui, L., Wang, S., Lee, D., & Liu, H. (2019). Defend: Explainable fake news detection. In *Proceedings of the 25th ACM SIGKDD international conference on knowledge discovery and data mining* (pp. 395–405).
- Silva, A., Han, Y., Luo, L., Karunasekera, S., & Leckie, C. (2021a). Propagation2vec: Embedding partial propagation networks for explainable fake news early detection. *Information Processing and Management*, 58(5), 102618.
- Silva, A., Luo, L., Karunasekera, S., & Leckie, C. (2021b). Embracing domain differences in fake news: Cross-domain fake news detection using multi-modal data. In *Proceedings of the AAAI conference on artificial intelligence* (pp. 557–565).
- Sun, J., Chen, C., Hou, C., Wu, Y., & Yuan, X. (2025). Multimodal taylor series network for misinformation detection. In *Proceedings of the ACM on web conference 2025* (pp. 2540–2548).
- Tong, Y., Lu, W., Zhao, Z., Lai, S., & Shi, T. (2024). Mmdfnd: Multi-modal multi-domain fake news detection. In *Proceedings of the 32nd ACM international conference on multimedia* (pp. 1178–1186).
- Wang, B., Ma, J., Lin, H., Yang, Z., Yang, R., Tian, Y., & Chang, Y. (2024a). Explainable fake news detection with large language model via defense among competing wisdom. In *Proceedings of the ACM web conference 2024* (pp. 2452–2463).
- Wang, J., Zhang, H., Liu, C., & Yang, X. (2024b). Fake news detection via multi-scale semantic alignment and cross-modal attention. In *Proceedings of the 47th International ACM SIGIR conference on research and development in information retrieval* (pp. 2406–2410).
- Wang, Y., Ma, F., Jin, Z., Yuan, Y., Xun, G., Jha, K., Su, L., & Gao, J. (2018). Eann: Event adversarial neural networks for multi-modal fake news detection. In *Proceedings of the 24th ACM SIGKDD international conference on knowledge discovery and data mining* (pp. 849–857).
- Wei, S., Wang, Z., Li, M., Liu, X., & Wu, B. (2025). Dccma-net: Disentanglement-based cross-modal clues mining and aggregation network for explainable multimodal fake news detection. *Information Processing and Management*, 62(4), 104089.
- Wu, K., Yuan, X., & Ning, Y. (2021a). Incorporating relational knowledge in explainable fake news detection. In *Pacific-Asia conference on knowledge discovery and data mining* (pp. 403–415).
- Wu, L., Long, Y., Gao, C., Wang, Z., & Zhang, Y. (2023). Mfir: Multimodal fusion and inconsistency reasoning for explainable fake news detection. *Information Fusion*, 100, 101944.
- Wu, Y., Zhan, P., Zhang, Y., Wang, L., & Xu, Z. (2021b). Multimodal fusion with co-attention networks for fake news detection. In *Findings of the association for computational linguistics: ACL-IJCNLP 2021* (pp. 2560–2569).
- Yadav, A., Gaba, S., Khan, H., Budhiraja, I., Singh, A., & Singh, K. K. (2024). Etma: Efficient transformer-based multilevel attention framework for multimodal fake news detection. *IEEE Transactions on Computational Social Systems*, 11(4), 5015–5027.
- Ying, Q., Hu, X., Zhou, Y., Qian, Z., Zeng, D., & Ge, S. (2023). Bootstrapping multi-view representations for fake news detection. In *Proceedings of the AAAI conference on artificial intelligence* (pp. 5384–5392).
- Zeng, Z., Luo, M., Kong, X., Liu, H., Guo, H., Yang, H., Ma, Z., & Zhao, X. (2024). Mitigating world biases: a multimodal multi-view debiasing framework for fake news video detection. In *Proceedings of the 32nd ACM international conference on multimedia* (pp. 6492–6500).
- Zhang, X., & Ghorbani, A. A. (2020). An overview of online fake news: Characterization, detection, and discussion. *Information Processing and Management*, 57(2), 102025.
- Zhou, X., & Zafarani, R. (2018). Fake news: A survey of research, detection methods, and opportunities. *arXiv:1812.00315*.
- Zhou, Y., Yang, Y., Ying, Q., Qian, Z., & Zhang, X. (2023). Multi-modal fake news detection on social media via multi-grained information fusion. In *Proceedings of the 2023 ACM international conference on multimedia retrieval* (pp. 343–352).
- Zhou, Z., Zhang, X., Tan, S., Zhang, L., & Li, C. (2025). Collaborative evolution: Multi-round learning between large and small language models for emergent fake news detection. In *Proceedings of the AAAI conference on artificial intelligence* (pp. 1210–1218).
- Zhou, Z., Zhang, X., Zhang, L., Liu, J., Wang, S., Liu, Z., Zhang, X., Li, C., & Yu, P. S. (2024). FineFake: A knowledge-enriched dataset for fine-grained multi-domain fake news detection. *arXiv:2404.01336*.