

分类号

密级 公开

UDC

编号 20231010051

广东外语外贸大学

硕士学位论文
(专业学位)

面向稀疏分布与高噪声文本的生成式与结
构化数据增强方法研究

申请人姓名 廖信峰

导师姓名及职称 王连喜, 教授

专业学位类别 电子信息硕士

专业学位领域 大数据技术与工程

培养单位 信息科学与技术学院(网络空间安全学院)

学位授予单位 广东外语外贸大学

2026 年 5 月 22 日

分类号

密级 公开

UDC

编号 20231010051

广东外语外贸大学硕士学位论文

(专业学位)

面向稀疏分布与高噪声文本的生成式与结构化
数据增强方法研究

Research on Generative and Structured Data
Augmentation for Data Sparsity and High-Noise
Text

申请人姓名 廖信峰

导师姓名及职称 王连喜, 教授

专业学位类别 电子信息硕士

专业学位领域 大数据技术与工程

论文提交日期 2026年5月22日

论文答辩日期 2026年5月22日

答辩委员会

学位授予单位 广东外语外贸大学

独创性声明

本人声明：所呈交的学位论文是本人在导师指导下，独立进行的研究工作及取得的研究成果。除了文中特别加以标注和致谢的地方外，本论文不包含任何其他个人或集体已经发表或撰写过的研究成果。对本文的研究作出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律后果由本人承担。

学位论文作者签名：

签字日期： 2026 年 5 月 22 日

学位论文版权使用授权书

本学位论文作者完全了解广东外语外贸大学有关保留、使用学位论文的规定，即：研究生在校攻读学位期间论文工作的知识产权单位属于广东外语外贸大学，同意广东外语外贸大学保留并向国家有关部门或机构送交论文的印刷本和电子版本，允许学位论文被检索、查阅和借阅。本人同意授权广东外语外贸大学可以将学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印、扫描或数字化等复制手段保存、汇编学位论文。

(保密的学位论文在解密后适用本授权书)

学位论文作者签名：

导师签名：

签字日期： 2026 年 5 月 22 日

签字日期： 2026 年 5 月 22 日

摘要

随着移动互联网的普及，社交媒体已成为洞察社会舆情、公众情感及群体行为的重要窗口。然而，多源异构的社交媒体文本普遍存在字符噪声密集、样本分布长尾失衡及特征语义对齐失效等缺陷，导致模型在输入层面难以有效去噪、在类别层面难以覆盖少数样本、在语义层面难以精准匹配细粒度关联，从而严重制约了拼写纠错、谣言检测、情感分析等下游任务的实际性能。针对上述挑战，本文立足于数据增强视角，围绕字符、样本、特征三个粒度，提出了针对性的增强策略，并在多项代表性任务上完成了有效性验证。主要研究内容与贡献如下：

第一，针对字符级噪声干扰导致模型难以处理非规范输入的问题，提出了一种融合规则与大语言模型协同的字符级数据增强方法。该方法通过规则机制构建混淆集，实现对常见错误的广谱覆盖；同时引入指令微调的轻量化 Qwen 模型生成具有复杂上下文依赖的伪错样本，弥补了传统规则在语义多样性上的不足，进一步设计了多阶段渐进式训练策略以缓解伪数据偏差。在 IMLIP 2025 低资源拼写纠错评测中，该方法在印尼语和越南语上的检测 F1 值分别达到 91.17% 和 90.36%，纠错 F1 值分别达到 80.35% 和 79.75%，显著提升了模型对字符级噪声的检错与纠错能力。

第二，针对样本分布失衡导致模型对少数类欠拟合的问题，提出了一种基于扩散模型与对比学习的样本级数据增强方法（DMDA）。该框架引入标签感知条件掩码与动态噪声调度策略，在生成多样化样本的同时通过标签嵌入约束语义一致性，并结合对比学习驱动的对抗训练重构特征空间分布平衡。在多语言谣言检测任务中，DMDA 的 F1 值较最强基线提升 0.2-2.6 个百分点；在低资源情感分析场景下也获得稳定增益，有效增强了模型在少样本与长尾分布下的鲁棒性。

第三，针对特征语义错位导致方面词与观点词难以精准匹配的问题，提出了一种基于最优传输与句法图网络的特征级数据增强方法（OTESGN）。该方法突破传统图神经网络对静态句法结构的依赖，将语义对齐建模为特征分布间的传输代价最小化问题，并通过句法-语义协同注意力机制自适应融合显式结构与隐式语义分布，从而在特征层面实现鲁棒对齐。在通用基准数据集上，OTESGN 的 F1 值较最优模型最高提升 1.30 个百分点；在高度不平衡的目标实体负面情感识别任务中，F1 值较最优基线提升 3.38 个百分点，证明了特征级增强对细粒度语义匹配的有效性。

综上所述，本文从字符、样本、特征三个维度，系统揭示了数据增强与社交

媒体文本核心质量瓶颈之间的对应关系，并分别提出了针对性的解决方案。研究成果不仅在多项基准评测与真实场景任务中验证了算法的有效性，也为复杂多语言环境下的舆情监控与社会治理提供了可落地的技术支撑与理论参考。

关键词： 自然语言处理; 数据增强; 大语言模型; 扩散模型; 最优传输; 对比学习

ABSTRACT

With the popularization of the mobile Internet, social media has become an important window for gaining insights into public opinion, public sentiment, and group behavior. However, multi-source and heterogeneous social media texts universally suffer from defects such as dense character-level noise, long-tail imbalanced sample distributions, and failures in feature semantic alignment. These defects cause models to struggle with effective denoising at the input level, covering minority samples at the category level, and accurately matching fine-grained associations at the semantic level. Consequently, this severely constrains the practical performance of downstream tasks such as spelling correction, rumor detection, and sentiment analysis. To address these challenges, this paper adopts a data augmentation perspective and proposes targeted enhancement strategies focusing on three granularities: character, sample, and feature. The effectiveness of these strategies is validated across multiple representative tasks. The main research content and contributions are as follows:

First, to address the issue of models struggling with non-standard inputs caused by character-level noise interference, we propose a character-level data augmentation method that synergizes a rule-driven mechanism with a Large Language Model (LLM). This method constructs a confusion set through a rule mechanism to achieve broad-spectrum coverage of common errors. Simultaneously, it introduces an instruction-tuned, lightweight Qwen model to generate pseudo-error samples with complex contextual dependencies, compensating for the lack of semantic diversity in traditional rules. Furthermore, a multi-stage progressive training strategy is designed to alleviate pseudo-data bias. In the IMLIP 2025 low-resource spelling correction evaluation, this method achieved detection F1 scores of 91.17% and 90.36%, and correction F1 scores of 80.35% and 79.75% in Indonesian and Vietnamese, respectively, significantly improving the model’s error detection and correction capabilities against character-level noise.

Second, to address the problem of model underfitting on minority classes caused by imbalanced sample distributions, we propose a sample-level data augmentation method based on Diffusion Models and Contrastive Learning (DMDA). This framework introduces label-aware conditional masking and dynamic noise scheduling strategies, gen-

erating diverse samples while constraining semantic consistency through label embeddings. It also combines contrastive learning-driven adversarial training to reconstruct a balanced distribution within the feature space. In multilingual rumor detection tasks, DMDA improves the F1 score by 0.2 to 2.6 percentage points over the strongest baselines; it also achieves stable gains in low-resource sentiment analysis scenarios, effectively enhancing the model’s robustness under few-shot and long-tail distribution conditions.

Third, to resolve the difficulty of accurately matching aspect terms with opinion terms caused by feature semantic misalignment, we propose a feature-level data augmentation method based on Optimal Transport and Syntactic Graph Networks (OTESGN). This method breaks through the reliance of traditional graph neural networks on static syntactic structures by modeling semantic alignment as a transport cost minimization problem between feature distributions. Through a syntactic-semantic collaborative attention mechanism, it adaptively fuses explicit structures and implicit semantic distributions, thereby achieving robust alignment at the feature level. On general benchmark datasets, OTESGN’s F1 score improves by up to 1.30 percentage points compared to state-of-the-art models; in the highly imbalanced target-entity negative sentiment recognition task, the F1 score improves by 3.38 percentage points over the best baseline, proving the effectiveness of feature-level augmentation for fine-grained semantic matching.

In summary, from the three dimensions of character, sample, and feature, this paper systematically reveals the corresponding relationships between data augmentation and the core quality bottlenecks of social media texts, proposing targeted solutions for each. The research findings not only validate the effectiveness of the algorithms across multiple benchmark evaluations and real-world scenario tasks, but also provide actionable technical support and theoretical references for public opinion monitoring and social governance in complex, multilingual environments.

Keywords: Natural Language Processing; Data Augmentation; Large Language Models; Diffusion Models; Optimal Transport; Contrastive Learning

目 录

摘要	II
ABSTRACT.....	IV
第 1 章 绪论	1
1.1 研究背景与意义	1
1.1.1 研究背景.....	1
1.1.2 研究意义.....	3
1.2 国内外研究现状和相关工作	4
1.2.1 字符级数据增强方法	5
1.2.2 样本级数据增强方法	6
1.2.3 特征级数据增强方法	7
1.2.4 现有研究总结与本文切入点.....	8
1.3 本文的主要内容与组织结构	8
1.3.1 本文主要研究内容.....	8
1.3.2 本文组织结构	10
第 2 章 相关理论与技术基础	12
2.1 文本数据增强技术核心范式	12
2.1.1 基于规则的离散增强范式	12
2.1.2 基于生成式模型的深层增强范式	13
2.1.3 基于图结构的结构化增强范式.....	13
2.2 预训练语言模型与提示学习	13
2.2.1 核心预训练语言模型架构	14
2.2.2 提示学习与参数高效微调机制.....	14
2.3 扩散概率模型	15
2.3.1 前向加噪与反向去噪过程	15
2.3.2 标签感知条件生成机制	16
2.4 图神经网络与最优传输理论	17
2.4.1 依存句法分析与图卷积网络.....	17

2.4.2 最优传输理论与 Sinkhorn 算法	18
第 3 章 融合规则与大语言模型协同的字符级数据增强方法	19
3.1 研究动机	19
3.2 多阶段字符级增强框架设计	20
3.2.1 问题定义	20
3.2.2 多源语料构建与混合增强机制	21
3.2.3 多阶段渐进式检测训练	23
3.2.4 提示词融合纠正策略	24
3.3 实验与分析	24
3.3.1 数据集	24
3.3.2 实施细节	25
3.3.3 实验与结果分析	27
3.4 本章小结	31
第 4 章 基于扩散模型与对比学习的样本级数据增强方法	32
4.1 研究动机	32
4.2 基于扩散模型数据增强的分类检测方法	33
4.2.1 样本生成条件掩码	33
4.2.2 扩散语言模型数据增强	36
4.2.3 下游分类检测任务	37
4.3 实验与分析	38
4.3.1 突发公共卫生事件谣言检测实验	38
4.3.2 低资源文本分类与情感分析实验	44
4.4 本章小结	48
第 5 章 基于最优传输与句法图网络的特征级数据增强方法	49
5.1 研究动机	49
5.2 融合最优传输与图网络的特征级数据增强方法	51
5.2.1 输入编码层	51
5.2.2 句法-语义协同注意力	52
5.2.3 渐进式方面感知学习	55
5.2.4 多目标训练	56
5.3 实验与分析	56

5.3.1 方面级情感分析主任务实验.....	57
5.3.2 目标实体负面情感识别实验.....	62
5.4 本章小结.....	66
第 6 章 总结与展望	68
6.1 全文总结.....	68
6.2 研究展望.....	69
参考文献.....	70
致 谢.....	82
在学期间的科研成果及发表的论文	85

第 1 章 绪论

1.1 研究背景与意义

1.1.1 研究背景

(1) 文本分析的时代价值

随着移动互联网技术的飞速演进与智能终端的全面普及，微博、微信、新闻评论区、Twitter 等社交媒体平台，已彻底重塑社会信息传播模式与公众交互形态。海量用户生成内容（User-Generated Content, UGC）实时映射社会舆论倾向、公众情感态度与群体行为规律，成为数字化时代洞察社会态势、支撑决策落地的核心数据载体，其应用价值贯穿公共治理、商业智能、跨文化交流等关键领域。

在公共安全与突发事件治理层面，社交媒体是突发公共卫生事件、社会热点事件的信息首发阵地与传播核心。此类文本具备极强的时效性与覆盖面，可作为官方监测体系的重要补充。通过对社交媒体文本开展谣言检测、情感分析与舆情挖掘，能够快速捕捉公众情绪波动、阻断虚假信息传播、实现社会风险早期预警，为突发事件应急处置与社会稳定治理提供关键技术支撑。

在商业智能与市场决策层面，用户在社交平台发布的产品评论、服务反馈、消费体验等文本，蕴含细粒度的需求偏好与情感倾向。依托方面级情感分析等技术挖掘文本深层价值，可帮助企业精准定位用户需求、优化产品设计、制定差异化市场策略，是企业实现数字化转型、提升市场竞争力的重要手段。

在跨语言信息交互层面，“一带一路”倡议持续推进，印尼语、越南语等沿线低资源语言的用户群体快速增长。提升多语言文本的处理能力，消除低资源语言的数字鸿沟，对促进跨文化交流、保障经贸合作顺利开展具有重要意义。

(2) 政策背景与高质量数据需求

上述应用场景的落地效果，高度依赖于自然语言处理模型所使用数据的质量。近年来，全球人工智能发展已进入以高质量数据为核心驱动力的新阶段。2025 年 7 月，2025 世界人工智能大会暨人工智能全球治理高级别会议发表《人工智能全球治理行动计划》，明确提出“以优质数据推动人工智能发展”“合作打

造高质量数据集，为人工智能发展注入更多养料”。^① 2025 年 8 月，国务院印发《关于深入实施“人工智能+”行动的意见》（国发〔2025〕11 号），系统部署六大重点行动，强调“打造开放共享的高质量科学数据集”。^② 截至 2025 年底，全国已建成的高质量数据集超过 10 万个，总体量超过 890PB，日均 Token 调用量已超过 140 万亿。^③ 国家数据局更明确提出“人工智能发展到哪里，我们就把高质量数据集建设到哪里”。^④ 上述政策信号表明，数据质量已成为制约人工智能模型性能提升的关键瓶颈，构建高质量、高可信的数据资源体系是当前技术发展的核心任务之一。这为本文从数据质量角度切入、开展社交媒体文本数据增强研究提供了明确的政策导向与现实需求。

（3）真实场景下的数据质量挑战

尽管社交媒体文本价值显著，但用户生成内容具有非规范性、分布长尾性与语义离散性特征，在数据处理全流程中形成三大核心质量瓶颈。若直接使用未经处理的原始社交媒体文本训练模型，将严重制约模型在谣言检测、情感分析、低资源语言处理等下游任务中的实际性能：

字符级表层噪声干扰。社交媒体文本输入随意，普遍存在拼写错误、空格冗余/缺失、方言缩写、字符乱码等问题，在印尼语、越南语等低资源语言中表现尤为突出。此类噪声直接导致分词错误、特征提取失效，现有规范化工具与标注语料匮乏，模型难以有效处理非规范原始输入。

样本级分布长尾失衡。谣言检测、突发事件情感分析等任务中，高价值标注样本占比极低，数据呈现严重的类别失衡与长尾分布。模型训练易向多数类过拟合，丧失对少数关键类别的识别敏感度；传统数据增强方法难以兼顾样本多样性与语义一致性，易引入额外噪声降低模型鲁棒性。

特征级深层语义错位。社交媒体文本口语化、句式碎片化、语法不规范，在方面级情感分析等细粒度任务中，评价对象与情感观点词常存在长距离依赖、隐式关联。传统注意力机制、图神经网络依赖线性运算与静态句法结构，难以捕捉非线性语义关系，易出现语义对齐错误，无法精准识别细粒度情感关联。

（4）数据增强的必要性与研究目的

面对上述三大数据质量瓶颈，现有文本处理与数据增强方法存在明显局限：基于规则的方法语义僵化、泛化性差；传统生成模型易出现模式崩塌、语义漂

^① 《人工智能全球治理行动计划》，2025 年 7 月 26 日发表于 2025 世界人工智能大会暨人工智能全球治理高级别会议。

^② 国务院，《关于深入实施“人工智能+”行动的意见》（国发〔2025〕11 号），2025 年 8 月。

^③ 国家数据局局长刘烈宏在国新办新闻发布会（2026 年 3 月 24 日）上公布的数据。

^④ 国家数据局局长刘烈宏在国新办新闻发布会（2026 年 3 月 24 日）上的表述。

移；大语言模型在低资源场景下计算成本高、生成可控性弱；图神经网络依赖外部句法工具，无法适配非规范文本的动态语义交互。单纯依赖原始数据采集或传统增强技术，均难以满足国家战略对“高质量数据集”的技术要求，也无法支撑社交媒体文本分析在复杂真实场景下的可靠落地。

数据增强的核心目的，正是在不改变文本核心语义的前提下，通过系统化的数据生成与优化策略，从三个粒度分别破解上述瓶颈：在**字符级**，通过模拟与生成多样化噪声样本，提升模型对表层错误的鲁棒性；在**样本级**，通过标签感知的条件生成与对比学习，重构类别分布平衡，增强模型对少数类样本的判别能力；在**特征级**，通过最优传输与句法语义协同，实现细粒度语义的精准对齐。通过上述多粒度、场景化的数据增强方法，可以从数据根源上提升模型在真实开放场景中的泛化能力与鲁棒性，为社交媒体文本分析的全链条任务提供高质量的数据支撑。这正是本文开展面向稀疏分布与高噪声文本的生成式与结构化数据增强方法研究的核心出发点。

1.1.2 研究意义

前文指出，社交媒体文本在公共治理、商业智能、跨文化交流等领域具有重要价值，然而真实场景下的字符级噪声、样本级失衡与特征级错位三大质量瓶颈，叠加现有数据增强方法的固有局限，导致模型实际性能严重受限。与此同时，国家对“高质量数据集”建设的战略部署对数据质量提出了更高要求。在此背景下，本文从数据增强视角出发，围绕字符、样本、特征三个粒度，系统开展了生成式与结构化数据增强方法研究，兼具重要的理论创新与实际应用价值。

在**理论层面**，本文突破了“数据增强仅等同于样本数量扩充”的传统认知，构建了“字符去噪—样本重构—特征对齐”的多粒度数据增强理论体系，为低资源、高噪声、长尾分布场景下的文本增强提供了可复用的分析框架。同时，本文探索了多种前沿技术的融合路径：在字符级首次实现规则与大语言模型的协同增强，化解了规则语义僵化与大模型生成不可控的矛盾；在样本级将扩散概率模型与对比学习引入文本增强，克服了传统生成模型的模式崩塌与语义漂移问题；在特征级将最优传输理论融入句法语义图网络，突破了静态句法结构的依赖，实现了非规范文本中细粒度语义的鲁棒对齐。上述探索拓展了扩散模型、最优传输等理论在自然语言处理领域的应用边界。

在**应用层面**，本文提出的字符级增强方法显著提升了印尼语、越南语等低资

源语言的拼写检错纠错能力，在 IMLIP 2025 国际评测中取得领先性能，为“一带一路”跨文化交流与小语种资源建设提供了低成本技术方案。样本级增强方法（DMDA）在汉、英、阿、德四类谣言检测数据集上均取得最优性能，可有效支撑突发公共卫生事件中的谣言识别与舆情预警。特征级增强方法（OTESGN）在方面级情感分析基准及高噪声不平衡的目标实体负面情感识别任务中均取得显著提升，可帮助企业从海量用户评论中精准挖掘细粒度情感需求。总体而言，本文的三个粒度方法均面向数据稀缺、标注成本高昂的现实约束，在有限标注样本下显著提升了模型性能，有助于推动自然语言处理技术向低资源、多语言、高噪声的真实工程场景加速落地，为“人工智能+”行动在舆论治理、智慧政务、跨境服务等领域的深入实施提供可靠的数据层保障。

在方法论贡献层面，本文形成了“问题驱动—粒度分解—技术融合—场景验证”的系统性研究范式。具体而言，本文首先识别出社交媒体文本分析中的三大数据质量瓶颈，然后将其分别映射到字符、样本、特征三个可独立攻关的粒度，再针对每个粒度选取最适配的前沿技术：规则与大模型协同、扩散模型与对比学习、最优传输与图神经网络进行深度融合，最后在真实场景任务中完成端到端的验证。从数据质量问题的本质出发，通过粒度拆解与技术协同，实现从“通用增强”到“场景适配”的转变。此外，本文在三个粒度上分别公开了构建的大规模低资源语言拼写纠错语料库、多语言谣言检测增强数据集以及方面级情感分析的最优传输对齐代码，为后续研究提供了可复现的基础资源与基准。

1.2 国内外研究现状和相关工作

自然语言处理（Natural Language Processing, NLP）在实际落地应用与社交媒体文本分析中，面临的两大本质困难是**数据稀疏分布**与**高噪声干扰**。数据增强（Data Augmentation, DA）技术作为突破上述瓶颈的关键路径，通过对原始数据进行转换与生成，在不改变核心语义与任务标签的前提下，有效扩充样本规模、平滑决策边界^[1,2]。近年来，数据增强技术已逐渐从单一的文本表层操作，发展为覆盖多维度的立体架构^[3]。

本章从字符级、样本级、特征级三个操作粒度出发，系统梳理现有文本数据增强方法的研究进展。针对每个粒度，本章首先阐述其解决稀疏与噪声问题的核心机理，随后综述国内外主流增强技术的演进路线，最后结合拼写纠错、谣言检测、方面级情感分析等下游任务，探讨其实际验证效果与当前方法的局限性。

1.2.1 字符级数据增强方法

字符级数据增强（Character-level Data Augmentation, CDA）是文本数据增强的核心基础分支，以字符为最小操作粒度，通过对字符序列进行可控变换、扰动、生成与补全，构造符合目标语言字符分布规律的新样本。从核心原理来看，该方法精准靶向文本处理中的数据稀疏与输入噪声痛点。针对数据稀疏，该方法无需依赖复杂的语义建模，仅通过轻量化变换即可在有限语料上生成海量有效样本，显著缓解低资源语言场景下的模型过拟合；针对输入噪声，社交媒体等真实场景中普遍存在字符增删、形近/音近字符混淆等非规范输入，该方法通过模拟真实噪声分布，让模型在训练阶段充分接触扰动模式，从而大幅提升对表层噪声的容错能力与泛化性能。

在主流技术演进方面，国外研究起步较早，早期以启发式随机操作为核心，形成了以随机插入、删除、替换、相邻字符交换为代表的基础增强范式^[4,5]，凭借其高效性成为通用基线。后续研究逐步向语言专属化与生成式方向演进：一方面针对不同语言构建混淆集实现可控增强；另一方面基于 Seq2Seq 架构构建数据驱动的生成式方法^[6,7]。

国内研究近年在低资源语言适配与增强质量优化上实现了快速追赶。一方面，针对东南亚等“一带一路”小语种的特殊字符体系，国内学者构建了专属增强规则与低资源适配模型^[8,9]；针对中文的高资源特性，则深度融合了拼音、字形等语音和视觉相似性先验知识^[10,11]。另一方面，国内研究提出了融合预训练模型的增强框架，典型的如 SpellGCN、FASpell、DAGA^[12-15] 等方法；利用条件掩码语言模型（Masked Language Model, MLM）进行高质量生成^[16,17]。近期，基于大语言模型（Large Language Model, LLM）的指令微调（Instruction Tuning, IT）生成技术也被引入字符级增强，进一步降低了语义偏移^[18-21]。

在印尼语、越南语等拼写纠错场景的有效性验证中，字符级增强展现了不可替代的作用^[22]。这两类语言作为典型的低资源拉丁字母语言，存在变音符号遗漏率高等痛点。国外研究中，Nguyen 等人^[23] 针对越南语构建了声调符号与音近字符的专属混淆集，将纠错模型的字符错误修正率提升了 12.3%；Purnamasari 等人^[24] 设计基于规则的词性标注器，在低资源场景下的测试中，准确率平均为 87.4%。国内研究针对多语言拼写纠错提出了融合语言专属特征与掩码生成的框架，在零样本场景下修正准确率提升超 15%^[25,26]，验证了仅需少量的标注语料即可实现基线全量数据的性能，为低资源纠错提供了新的解决方案。

1.2.2 样本级数据增强方法

样本级数据增强（Sample-level Data Augmentation, SDA）是应用最广泛的核心分支，以完整句子或篇章文本为操作粒度。在严格保留样本核心语义与任务标签一致性的前提下，通过句式变换、语义重写或生成式建模构造全新样本。针对数据稀疏问题，在突发事件等场景下标语料迭代快、获取成本高，该方法通过语义等价变换直接扩充有效样本，填补训练集的语义空间盲区；针对语义表达噪声问题，社交媒体文本口语化严重、句式变体多，该方法通过模拟表达变体，引导模型学习核心语义而非表层句式，大幅提升了模型的跨场景泛化能力^[27]。

在技术演进上，国外研究率先完成了从规则驱动到数据驱动的迭代。早期以随机词操作（Easy Data Augmentation, EDA）^[28]、随机标点符号操作（Augmented Easy Data Augmentation, AEDA）^[29]以及回译（Back-translation）^[30]为代表，其中回译凭借优秀的语义保留能力成为经典基线^[31]。随着预训练模型的发展，研究重心转向基于 BERT、GPT 的生成式增强，解决了规则方法多样性不足的痛点^[32]。

国内研究则聚焦于本土化场景适配与任务专属增强。针对中文特性，国内学者构建了简单数据增强和反向翻译的文本增强技术融合的多层次增强方法^[33]。在突发公共卫生事件与谣言检测场景中，国内提出了融合事件知识与标签约束的可控增强框架^[34-36]，并广泛引入 GPT-4 等大语言模型的上下文生成能力^[37,38]。近年来，扩散模型（Diffusion Models, DM）凭借对长尾分布的优秀拟合能力，被创新性地引入低资源样本生成，展现出巨大的发展潜力^[39,40]。

在下游任务的有效性验证中，样本级增强在谣言检测与低资源情感分析等场景中展现了卓越的性能。针对谣言检测任务中新变体迭代快、跨事件泛化弱的痛点，Ma 等^[41]提出了基于生成对抗网络（Generative Adversarial Network, GAN）的条件生成增强框架，在 Twitter 公开数据集上有效扩充了少数类样本的特征分布，将检测的宏 F1 值显著提升了 9.7%；国内团队针对中文微博环境，提出了融合事件背景与知识图谱的增强策略，使零样本跨事件谣言检测的准确率大幅提升^[34,40]。此外，针对低资源情感分析任务，国外研究者广泛探索了基于回译的样本生成技术，在涵盖十余种低资源语言的跨语言情感分类基准测试中，通过多语言回译有效丰富了句法与词汇多样性，有效提升了分类性能^[42]；而在国内的垂直领域应用中，基于扩散模型与生成式大语言模型的条件增强方法，进一步克服了长尾类别数据的冷启动难题，将模型 F1 值稳定提升超 2%^[39]。这些研究成果确立了样本级数据增强在缓解长尾分布与数据稀疏问题中的核心支撑地位。

1.2.3 特征级数据增强方法

特征级数据增强 (Feature-level Data Augmentation, FDA) 是适配深度神经网络的高阶分支。区别于在离散文本空间的显式操作, 该方法以模型编码的高维隐层特征或拓扑结构为操作粒度, 通过插值、扰动与流形融合构造虚拟特征样本。在方面级情感分析^[43] 这类细粒度文本任务中, 标注不仅成本极高, 且由于多方面交叉和上下文嵌套, 特征层面的语义关联异常稀疏且充满噪声。特征级增强能够在隐空间精准保留核心判别特征的前提下, 对无关上下文特征进行抑制与扰动, 扩充有效特征边界, 从根本上缓解细粒度模型的过拟合与特征混淆问题。

在特征级数据增强的演进历程中, 国外研究率先完成了从基础启发式扰动到深层特征空间可控生成的跨越。早期工作主要以在特征表示中注入高斯噪声或应用随机特征掩码作为通用基线, 但这种无针对性的扰动难以保证语义的完整性。为突破这一瓶颈, 后续研究以隐层特征插值与对比学习为核心实现了关键技术迭代。在特征插值方面, 研究者提出了 Manifold Mixup^[44] 与面向文本隐空间的 MixText (TMix)^[45] 等流形混合方法。这类方法通过在深层神经网络中对不同样本的隐层特征及其对应标签进行连续的线性插值, 在特征空间中生成平滑且合规的虚拟样本, 显著缓解了模型决策边界的过拟合问题; 与此同时, 对比学习框架的引入则进一步优化了特征空间的几何分布, 大幅提升了隐层特征的判别性与抗噪能力^[46,47]。此外, 针对依赖外部先验的图神经网络架构 (Graph Neural Network, GNN), 研究者在图拓扑结构层面提出了 DropEdge 和 NodeDrop 等结构增强策略^[48-50], 有效防止了节点特征在聚合过程中的过度平滑现象。

国内研究则深度聚焦细粒度任务专属优化。围绕方面级情感分析 (Aspect-based Sentiment Analysis, ABSA) 的语义对齐需求, 国内学者提出了大量结合 AMR、句法依赖树等外部知识的图神经网络增强方案^[51-56]。进一步地, 通过构建双通道 GCN、关系图注意力网络 (RGAT) 等机制定向增强核心特征^[57-62], 并引入胶囊网络与自注意力变分自编码器进行深层特征重构^[63-70]。针对句法图结构的“硬性”约束痛点, 最新研究引入最优传输 (Optimal Transport, OT) 理论^[71-73], 将方面-观点对齐建模为分布传输代价最小化问题, 实现了更为柔性、鲁棒的隐式特征增强^[74]。

在方面级情感分析任务中, 特征级增强的优势得到有效证实。基于对比学习的特征增强有效缓解了多方面情感冲突, 使跨领域准确率提升超 5%^[46,47]。国内提出的方面引导自适应特征混合方法, 在中文电商与舆情数据集上使宏 F1 提升

超 4%，对极少样本的小众方面类别提升可达 8%^[75]。此外，相关研究证明，特征级增强能与样本级增强形成正交互补，二者协同能在低资源细粒度任务中实现性能的叠加突破^[76]，二者共同构成了文本数据增强的多维度技术闭环。

1.2.4 现有研究总结与本文切入点

综合上述三个粒度的综述，现有研究存在三大空白，即本文的攻关目标：

第一，缺乏场景适配的数据增强方案。现有研究一方面追求跨任务通用的增强方法，忽略了不同场景的专属数据特性，导致在低资源、高噪声场景下性能显著衰减^[77]；另一方面，针对单一任务的场景化增强多为零散的单点优化，未能形成同研究范式下、覆盖全链条的系统性解决方案。具体而言：低资源拼写纠错缺少规则与大模型协同的字符级增强；谣言检测缺少兼顾多样性与一致性的样本级增强；ABSA 缺少突破静态句法依赖、引入全局语义对齐的特征级增强。

第二，数据增强方法未能精准破解任务核心矛盾。在字符级，规则方法的可控性与大模型生成的语义多样性之间的矛盾未解；在样本级，多样性与一致性的权衡难题未破；在特征级，静态句法依赖与动态语义对齐的错位未纠。

第三，验证场景与真实工程需求脱节。现有增强方法大多在规范的通用基准数据集上验证，而针对低资源、高噪声、长尾分布等极端条件的场景化研究仍不充分，无法为真实舆情治理、商业智能等工程场景提供全链条的数据支撑。

针对上述空白，本文聚焦舆情分析全链条的三大关键环节——文本前置规范化、核心舆情事件分类、细粒度公众情感挖掘，分别提出：融合规则与 LLM 协同的字符级增强方法（第 3 章）、基于扩散模型与对比学习的样本级增强方法（第 4 章）、基于最优传输与句法图网络的特征级增强方法（第 5 章），形成同范式下、覆盖字符—样本—特征三个粒度的系统性数据增强解决方案。

1.3 本文的主要内容与组织结构

1.3.1 本文主要研究内容

本文以数据增强破解社交媒体文本分析全链条数据质量瓶颈为研究主线，针对真实场景中社交媒体文本的字符级表层噪声干扰、样本级分布长尾失衡、特征

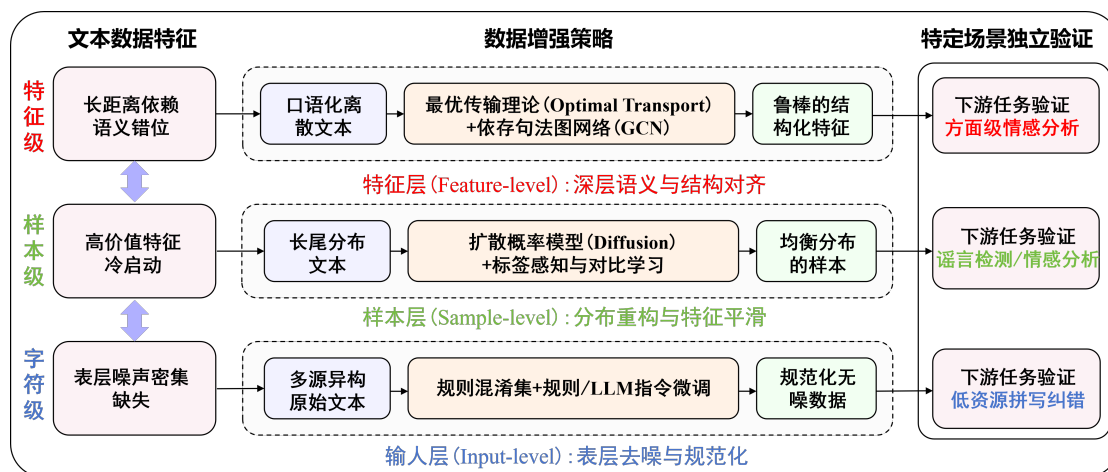


图 1-1 多粒度数据增强与鲁棒分析总体研究框架

级深层语义错位三大核心挑战，围绕舆情分析从文本规范化、事件分类到细粒度情感挖掘的关键环节，设计了场景适配的专属数据增强方法，形成覆盖**字符—样本—特征**三个粒度的系统性研究成果，总体研究框架如图1-1所示。

本文三项研究工作相互独立、平行展开，每项工作均针对对应任务的场景特性完成专属设计。为严谨验证方法有效性，本文选取三个独立的代表性真实任务作为测试床：字符粒度以低资源语言拼写纠错验证文本去噪能力，样本粒度以突发公共卫生事件谣言检测验证长尾分布重构能力，特征粒度以方面级情感分析验证细粒度语义对齐能力。三项工作在统一研究视角下形成互补，完整覆盖了社交媒体文本分析的核心数据痛点。具体研究内容如下：

(1) 融合规则与大语言模型协同的字符级数据增强方法

针对低资源语言拼写纠错中错误模式覆盖不足、规则生成语义僵化、大模型生成不可控的核心缺陷，本文提出规则与大语言模型协同的字符级增强框架。通过规则机制构建多类型混淆集，实现常见表层噪声的广谱覆盖；利用指令微调的轻量化 Qwen 模型生成具备复杂上下文依赖的伪错样本，弥补规则方法的语义多样性短板；结合多阶段渐进式训练策略与分层提示模板，有效缓解了低资源场景下的标注数据匮乏问题。实验结果表明，该方法在 IMLIP 2025 低资源拼写纠错评测中取得领先性能，显著提升了模型的检错与纠错能力，为社交媒体文本分析提供了前置规范化方案。

(2) 基于扩散模型与对比学习的样本级数据增强方法

针对谣言检测、低资源情感分析中样本稀缺、类别失衡的核心痛点，本文

构建基于扩散模型的标签感知增强框架 (Diffusion Model-based Data Augmentation, DMDA)。创新性引入标签感知条件掩码与动态噪声调度策略,在生成多样化样本的同时严格约束标签语义一致性;结合对比学习驱动的噪声对抗训练与相似性加权筛选,有效重构了特征空间的类别分布平衡。在多语言谣言检测及低资源情感分析数据集上的实验表明,该方法显著增强了模型在少样本、长尾分布场景下的判别鲁棒性,为突发事件舆情监测与谣言治理提供了技术支撑。

(3) 基于最优传输与句法图网络的特征级数据增强方法

针对方面级情感分析中静态句法结构依赖、语义错位、长距离关联捕捉不足的核心缺陷,本文提出最优传输增强句法-语义图网络 (Optimal Transport-Enhanced Syntactic-Semantic Graph Network, OTESGN)。突破传统图神经网络的硬性结构约束,将语义对齐建模为特征分布间的传输代价最小化问题;设计句法-语义协同注意力机制,自适应融合显式句法结构与隐式语义分布,精准捕捉非规范文本中的细粒度语义关联。在通用基准数据集及突发事件场景下的扩展实验表明,该模型能够有效滤除上下文冗余噪声,实现特征层面的鲁棒语义对齐。

1.3.2 本文组织结构

本文共分为六章,遵循**提出问题—理论支撑—分场景研究—总结展望**的学术逻辑展开,各章节具体安排如下:

第一章 绪论 阐述社交媒体文本分析的研究背景与时代价值,剖析三大核心数据质量挑战,梳理国内外研究现状与局限,锚定研究切入点,明确本文的核心研究内容、创新点与组织结构。

第二章 相关理论与技术基础 系统介绍本研究依托的核心理论与技术,包括预训练语言模型与提示学习、扩散概率模型、图神经网络与依存句法分析、最优传输理论,为后续各章的方法设计提供统一的理论支撑。

第三章 融合规则与大语言模型协同的字符级数据增强方法 聚焦低资源语言字符级去噪问题,阐述规则与 LLM 协同增强框架的设计思路、多阶段训练策略及提示融合机制,通过多组实验验证该方法在低资源拼写纠错任务中的有效性。

第四章 基于扩散模型与对比学习的样本级数据增强方法 聚焦样本级分布重构问题，系统介绍 DMDA 框架的标签感知条件掩码、动态噪声调度及对比学习对抗训练等核心模块，通过多语言、多数据集实验验证该方法在少样本、长尾分布场景下的鲁棒性。

第五章 基于最优传输与句法图网络的特征级数据增强方法 聚焦特征级语义对齐问题，详细阐述 OTESGN 模型的句法-语义协同注意力机制、最优传输求解及多目标训练策略，通过基准数据集及扩展实验验证该方法在细粒度情感分析任务中的精准性与抗噪声能力。

第六章 总结与展望 概括全文的核心研究工作、创新点与主要结论，客观分析研究存在的局限性，结合领域发展趋势提出未来研究展望。

第2章 相关理论与技术基础

本章为全文三项平行开展的多粒度数据增强研究提供完整的理论支撑与技术依据，所有内容均围绕**破解社交媒体文本分析三大数据质量瓶颈**的核心研究主线展开，与后续第3、4、5章的核心研究工作一一对应。本章首先系统梳理文本数据增强技术的核心范式与演进脉络，明确本文研究的技术定位；随后分别阐述三项核心工作对应的基础理论与关键技术：一是支撑字符级增强的预训练语言模型、提示学习与参数高效微调技术；二是支撑样本级增强的扩散概率模型与条件生成机制；三是支撑特征级增强的图神经网络与最优传输理论，为后续方法设计与实验验证奠定坚实的理论基础。

2.1 文本数据增强技术核心范式

数据增强旨在通过对原始数据的转换或生成，在不改变核心语义与标签的前提下扩充训练样本规模、优化数据质量，是解决自然语言处理领域低资源数据稀缺、模型过拟合、噪声场景鲁棒性不足的核心技术。结合本文的研究粒度，文本数据增强可分为三大核心范式，分别对应本文字符、样本、特征三个维度的研究场景。

2.1.1 基于规则的离散增强范式

基于规则的方法作用于文本表层符号，通过显式编辑操作实现数据增强，核心优势是计算成本低、可解释性强，是本文第3章构建低资源语言拼写纠错混淆集的核心基础。

该范式的经典框架为，确立了随机同义词替换、随机插入、随机交换、随机删除四种标准操作范式，通过表层符号编辑引入可控噪声，提升模型基础鲁棒性。另一类经典方法为回译，通过“源语言-中间语言-源语言”的双向翻译生成释义样本，可增加句法结构多样性。但该方法高度依赖高质量翻译模型，针对印尼语、越南语等低资源语言易出现语义漂移，且无法精准控制错误模式。

2.1.2 基于生成式模型的深层增强范式

为突破规则方法的局限，基于生成式模型的增强通过拟合真实数据分布生成高质量样本，是本文第 4 章解决样本稀缺与类别失衡问题的核心技术路径。

该范式的早期主流方案为生成对抗网络与变分自编码器 (Variational Autoencoder, VAE)，但二者在文本生成中存在固有缺陷：变分自编码器易出现“后验坍塌”，生成文本趋于平庸、多样性不足；生成对抗网络因文本离散性导致梯度反向传播困难，训练不稳定且易出现“模式崩塌”，无法覆盖真实数据的长尾分布。因此本文第 4 章未采用上述方案，转而选用生成质量更高、训练更稳定、可控性更强的扩散概率模型。

随着 Transformer 架构的发展，大语言模型成为生成式增强的主流方案，可通过提示学习、指令微调引导模型生成符合特定约束的样本，解决了规则方法难以模拟复杂上下文依赖的痛点，是本文第 3 章字符级增强的核心生成工具。

2.1.3 基于图结构的结构化增强范式

针对离散增强易破坏句法结构、生成式增强缺乏细粒度可控性的双重局限，基于图结构的结构化增强在文本句法依存树层面执行操作，在扩充数据的同时保留语义与拓扑结构完整性，是本文第 5 章实现特征级语义对齐的核心基础。

该范式通过依存句法分析将线性文本转化为图结构，依托图神经网络实现句法相关节点的信息聚合，有效解决长距离依赖问题；通过子树交换、边丢弃、节点掩码等图级增强操作，在不破坏核心语义的前提下提升模型鲁棒性。本文第 5 章在此基础上，引入最优传输理论优化全局语义对齐，突破了传统结构化方法依赖静态句法结构的局限。

2.2 预训练语言模型与提示学习

预训练语言模型 (Pre-trained Language Models, PLMs) 是本文多粒度数据增强框架的核心基础，本文既依托 BERT 类双向编码器模型实现特征提取与判别分析，也利用生成式大模型实现可控文本增强；同时通过提示学习与参数高效微调技术，实现大模型在低资源场景下的高效适配。

2.2.1 核心预训练语言模型架构

根据模型架构与预训练目标的差异，本文主要用到双向编码器表征模型与自回归生成模型两类，分别对应判别与生成两大核心需求。

(1) 双向编码器模型：BERT 及其领域变体

BERT (Bidirectional Encoder Representations from Transformers) 以多层 Transformer Encoder 为核心，通过掩码语言模型任务实现双向语义建模，核心训练目标为最大化被掩盖 Token 的对数似然：

$$\mathcal{L}_{MLM} = \sum_{i \in M} \log P(x_i | X_{\setminus M}) \quad (2-1)$$

其中 X 为输入序列， M 为被掩盖的 Token 集合。

本文中，BERT 类模型主要承担特征提取与判别分析任务：第 5 章的细粒度情感分析模型采用 BERT-base 提取上下文词嵌入；第 4 章的谣言检测任务采用 RoBERTa 模型，其移除了下一句预测 (NSP) 任务，采用动态掩码机制，特征鲁棒性更优；针对低资源语言与特定领域场景，分别采用 IndoBERT (印尼语)、CafeBERT (越南语)、CT-BERT，解决通用模型的领域语义漂移问题。

(2) 自回归生成模型：Qwen 系列

以 Qwen 为代表的自回归模型基于 Transformer Decoder 架构，核心训练目标为根据上文预测下一个 Token，实现可控文本生成：

$$\mathcal{L}_{CL} = \sum_i \log P(x_i | x_1, \dots, x_{i-1}) \quad (2-2)$$

本文第 3 章选用 Qwen2.5-3B-Instruct 模型作为核心生成器，其在小参数规模下具备优异的多语言生成能力与指令遵循能力，可生成规则方法难以模拟的、具备复杂上下文依赖的拼写错误样本，实现低资源场景下的可控字符级增强。

2.2.2 提示学习与参数高效微调机制

传统“预训练-微调”范式在大模型场景下面临参数量大、训练成本高的问题，本文引入提示学习与 LoRA 参数高效微调技术，实现大模型在低资源场景下的低成本适配。

(1) 提示学习与指令微调

提示学习的核心是将下游任务重构为预训练文本生成形式，通过设计提示模板挖掘模型内置知识，无需修改模型参数即可在零样本/少样本场景下实现任务适配，本文第 3 章通过分层提示模板激发模型的纠错与错例生成能力。

指令微调通过在（指令，响应）配对数据集上微调，使模型精准遵循复杂任务约束，本文基于 Qwen-Instruct 模型，构建特定错误类型的指令数据集，引导模型生成符合目标分布的增强样本。

(2) 低秩适配：LoRA

本文采用 LoRA 技术实现轻量化微调，其假设模型参数更新矩阵具有低秩特性，通过冻结预训练权重 W_0 ，仅训练两个低秩矩阵 A 、 B 近似参数更新量 ΔW ：

$$W = W_0 + \Delta W = W_0 + BA \quad (2-3)$$

其中 $B \in \mathbb{R}^{d \times r}$, $A \in \mathbb{R}^{r \times k}$ ，秩 $r \ll \min(d, k)$ 。

本文第 3 章通过 LoRA 对 Qwen 模型进行指令微调，既保留了基座模型的通用生成能力，又显著提升了模型在拼写纠错任务中的指令遵循度与输出可控性。

2.3 扩散概率模型

扩散概率模型（Diffusion Probabilistic Models, DPMs）是本文第 4 章样本级增强的核心理论基础，其基于热力学扩散原理，通过“加噪-去噪”的马尔可夫过程建模数据分布，相比 GAN/VAE 具备更优的分布覆盖能力与训练稳定性，可完美适配谣言检测场景下长尾分布样本的可控生成需求。

2.3.1 前向加噪与反向去噪过程

扩散模型的核心由两个马尔可夫链组成，所有运算均在文本的连续词嵌入空间中执行，最终通过分类头映射回离散 Token。

(1) 前向扩散过程

前向过程为预定义的无参数马尔可夫链，给定初始数据 $x_0 \sim q(x)$ ，通过 T 步逐步添加高斯噪声，最终将数据映射为标准高斯噪声 $x_T \sim \mathcal{N}(0, I)$ 。任意时间

步 t 的转移概率为：

$$q(x_t|x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t}x_{t-1}, \beta_t I) \quad (2-4)$$

其中 $\beta_t \in (0, 1)$ 为预定义的噪声方差调度表。

利用高斯分布可加性与重参数化技巧，可直接从 x_0 采样任意时间步的 x_t ，令 $\alpha_t = 1 - \beta_t$ ， $\bar{\alpha}_t = \prod_{i=1}^t \alpha_i$ ，则：

$$q(x_t|x_0) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t}x_0, (1 - \bar{\alpha}_t)I) \quad (2-5)$$

通过采样 $\epsilon \sim \mathcal{N}(0, I)$ ，可得 x_t 的解析形式：

$$x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon \quad (2-6)$$

该特性实现了训练过程中任意时刻噪声样本的并行采样，大幅提升了大规模文本数据的处理效率。

(2) 反向去噪过程

反向过程通过训练基于 Transformer 的去噪神经网络，近似反向后验分布 $p_\theta(x_{t-1}|x_t)$ ，从高斯噪声 x_T 中逐步恢复原始数据 x_0 ：

$$p_\theta(x_{t-1}|x_t) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t)) \quad (2-7)$$

其中 μ_θ 、 Σ_θ 为模型预测的均值与方差。

通过简化变分下界，模型优化目标可转化为预测每一步添加的真实噪声 ϵ ，损失函数为均方误差：

$$\mathcal{L}_{simple}(\theta) = \mathbb{E}_{x_0, \epsilon, t} \left[\|\epsilon - \epsilon_\theta(\sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon, t)\|^2 \right] \quad (2-8)$$

2.3.2 标签感知条件生成机制

标准扩散模型为无约束生成，而本文谣言检测任务需要生成特定标签类别的样本，因此采用基于标签嵌入的条件注入机制，将类别标签 y 映射为向量输入

去噪网络，使噪声预测网络变为 $\epsilon_\theta(x_t, t, y)$ ，反向生成的每一步均受标签约束：

$$x_{t-1} \leftarrow \text{Denoise}(x_t, \epsilon_\theta(x_t, t, y)) \quad (2-9)$$

该机制使模型同时学习文本分布特征与“标签-文本”的强关联，本文第 4 章的 DMDA 框架正是基于此，将标签嵌入扩散全流程，确保生成样本在保持多样性的同时严格遵循语义类别，解决了传统生成式增强的语义漂移问题。

2.4 图神经网络与最优传输理论

本文第 5 章的特征级增强研究，依托图神经网络建模文本句法结构，同时引入最优传输理论解决细粒度语义对齐难题，突破了传统注意力机制与静态图网络的局限，实现非规范文本中方面词与观点词的鲁棒语义匹配。

2.4.1 依存句法分析与图卷积网络

(1) 依存句法分析

依存句法分析通过挖掘词与词之间的修饰依存关系，将线性词序列转化为图状结构。对于包含 n 个单词的句子，依存分析器可生成邻接矩阵 $A \in \mathbb{R}^{n \times n}$ ，其中 $A_{ij} = 1$ 表示词 w_i 与 w_j 存在依存弧，否则为 0。

本文第 5 章将依存树转化为无向图，计算节点间的最短依存距离，构建多粒度句法掩码矩阵，将语言学先验注入注意力机制，过滤无关上下文噪声。

(2) 图卷积网络 (GCN)

GCN 实现了图结构上的特征提取与信息聚合，给定图 $G = (V, E)$ ，节点特征矩阵 $H \in \mathbb{R}^{n \times d}$ ，邻接矩阵 A ，单层 GCN 的特征传播公式为：

$$H^{(l+1)} = \sigma(\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} H^{(l)} W^{(l)}) \quad (2-10)$$

其中 $\tilde{A} = A + I_n$ 为添加自环的邻接矩阵， $\tilde{D}$ 为对应的度矩阵， $W^{(l)}$ 为可学习权重矩阵， $\sigma(\cdot)$ 为非线性激活函数。

在细粒度情感分析任务中，GCN 依托依存句法图，使方面词直接聚合句法相关的观点词特征，有效解决长距离依赖问题，是本文结构化语义建模的基础。

2.4.2 最优传输理论与 Sinkhorn 算法

传统点积注意力仅能实现特征局部对齐，难以捕捉全局结构化语义关联，最优传输理论从几何视角衡量两个概率分布的距离，可实现更鲁棒的全局语义软对齐，是本文第 5 章 OTESGN 模型的核心理论创新点。

(1) 最优传输问题定义

给定源分布 $\mu \in \Sigma_n$ （上下文词特征分布）、目标分布 $\nu \in \Sigma_m$ （方面词特征分布），代价矩阵 $C \in \mathbb{R}^{n \times m}$ （ C_{ij} 为源节点 i 到目标节点 j 的传输代价，通常为特征余弦距离），Monge-Kantorovich 最优传输问题旨在寻找总传输代价最小的传输方案 π ：

$$L_{OT}(\mu, \nu) = \min_{\pi \in \Pi(\mu, \nu)} \sum_{i,j} \pi_{ij} C_{ij} = \min_{\pi \in \Pi(\mu, \nu)} \langle \pi, C \rangle_F \quad (2-11)$$

其中 $\Pi(\mu, \nu) = \{\pi \in \mathbb{R}_+^{n \times m} | \pi 1_m = \mu, \pi^T 1_n = \nu\}$ 为可行传输方案集合，最优传输方案 π^* 即为全局语义软对齐权重。

(2) 熵正则化与 Sinkhorn 算法

直接求解上述线性规划复杂度较高，引入熵正则项后可通过 Sinkhorn-Knopp 算法高效迭代求解。熵正则化最优传输目标函数为：

$$L_{OT}^\epsilon(\mu, \nu) = \min_{\pi \in \Pi(\mu, \nu)} \langle \pi, C \rangle_F - \epsilon H(\pi) \quad (2-12)$$

其中 $\epsilon > 0$ 为正则化系数， $H(\pi)$ 为熵正则项。该问题最优解为 $\pi_{ij} = u_i K_{ij} v_j$ （ $K = \exp(-C/\epsilon)$ 为吉布斯核），通过交替更新缩放向量 u 、 v 快速收敛：

$$u^{(t+1)} \leftarrow \frac{\mu}{K v^{(t)}}, \quad v^{(t+1)} \leftarrow \frac{\nu}{K^T u^{(t+1)}} \quad (2-13)$$

本文第 5 章将最优传输方案 π^* 作为语义注意力矩阵，相比传统 Softmax 注意力，其天然满足边缘分布约束，可避免权重向无意义停用词偏移，实现非规范文本中更精准、鲁棒的特征级语义对齐。

第3章 融合规则与大语言模型协同的字符级数据增强方法

3.1 研究动机

社交媒体文本中普遍存在的**字符级噪声**，具体表现为拼写讹误（如字母颠倒、缺失或冗余）、空格冗余与缺失（如“ab c”误写为“abc”）、方言缩写（如“u”代“you”）、字符乱码等非规范输入现象。这类位于文本表层符号层的噪声，会直接导致自动分词错误、词嵌入特征失效、句法解析偏离，进而引发语义理解偏差，成为制约下游舆情分析、情感挖掘、跨语言信息处理等任务性能的关键前置性瓶颈。针对这一痛点，本章以字符级数据增强为技术路径，开展独立的方法研究，旨在从输入源头修复符号级数据缺陷，为后续分析任务提供高质量的规范化文本。该研究是全文多粒度数据增强方法论体系中最基础、最前置的一环。

拼写纠错（Spelling Correction, SC）作为文本预处理的核心环节，旨在检测并修正文本中的字符级错误，生成符合语言规范的标准化文本，为下游任务提供高质量输入。当前拼写纠错的主流研究多聚焦于英语、汉语等高资源语言，而针对印尼语、越南语等“一带一路”沿线低资源语言的研究仍存在显著空白：此类语言普遍缺乏大规模高质量平行标注语料，且社交媒体场景下的错误模式复杂多样，现有方法难以兼顾错误模式的全量覆盖与生成内容的可控性。

拼写纠错任务本质上是字符级错误的检测与修复问题，是评估字符级数据增强效果的典型应用场景。现有方法主要分为三类，均在低资源场景下面临难以突破的局限：其一，基于规则与统计的方法，依赖人工构建的混淆集、编辑距离等先验知识，虽具备强可解释性，但泛化能力不足，无法模拟具备上下文依赖的复杂错误模式；其二，基于 Seq2Seq、BERT 等神经网络的方法，高度依赖大规模平行标注语料，在低资源标注稀缺的场景下极易过拟合，泛化性能显著衰减；其三，基于大语言模型的方法，虽具备强大的上下文感知与零样本纠错能力，但存在计算成本高、生成不可控、易出现过度纠错与幻觉等问题，且微调过程对高质量标注数据的需求，与低资源语言的固有特性存在本质冲突。综上，现有研究尚未形成能同时解决低资源语言标注稀缺、错误模式覆盖不足、生成内容可控性差三大核心问题的有效方案。

针对上述研究局限，本章提出了一种**融合规则与大语言模型协同的字符级增强框架**，以印尼语、越南语两大典型低资源语言为验证场景，系统性解决字符级噪声治理的核心难题。本章的核心贡献如下：

(1) 提出了融合规则与大语言模型协同的语料库增强框架，针对印尼语、越南语的错误模式特性，构建了大规模、多领域的低资源语言拼写纠错平行语料库，填补了相关领域的语料空白；

(2) 设计了“规则预训练-LLM 增强训练-人工标注微调”的多阶段渐进式训练策略，有效缓解了弱标注伪数据带来的偏差问题，实现了从刚性规则到柔性语义的平滑过渡，显著提升了低资源场景下的模型泛化能力；

(3) 建立了检测-纠错提示融合机制，通过分层提示模板实现错误位置、候选词与生成指令的协同优化，使轻量级开源模型在 IMLIP 2025 低资源拼写纠错评测任务中取得了 SOTA 性能，为低资源语言字符级文本规范化提供了轻量级、可落地的解决方案。

3.2 多阶段字符级增强框架设计

如图 3-1 所示，本章方法围绕低资源语言拼写纠错任务构建了“数据增强—错误检测—错误纠正”的级联框架。首先，模型从多源无监督语料中构造原始文本集合，并分别通过规则注入和大语言模型生成两类伪错误数据，以扩展字符级错误模式的覆盖范围。随后，检测模型按照规则增强数据、LLM 增强数据和任务标注数据的顺序进行多阶段训练，实现从基础错误先验到真实任务分布的逐步适配。最后，纠错阶段进一步结合检测模块输出的错误位置和候选词信息构造提示模板，引导大语言模型完成更加可控的文本纠正。该框架通过检测与纠错的协同建模，使生成式纠错过程由开放式生成转变为具有位置约束和候选约束的精细化修正过程。

3.2.1 问题定义

本研究面向低资源语言标注数据稀缺的现实约束，将拼写纠错形式化为级联的“检测 - 纠错”任务，并通过可控字符级数据增强解决训练样本不足的核心问题。给定可能包含 a) 词汇替换错误；b) 空格冗余错误；c) 空格缺失错误的输

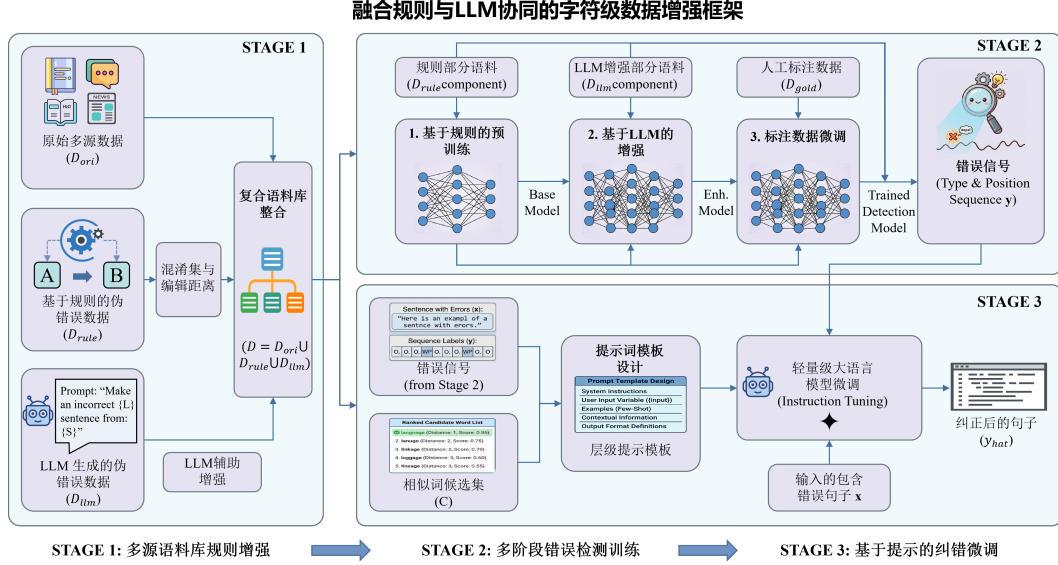


图 3-1 融合规则与大语言模型协同的字符级数据增强框架

入句子 $x = \{w_1, \dots, w_n\}$ (其中 w_i 表示第 i 个词), 模型必须首先通过序列标注识别错误类型和位置序列 y , 然后基于 x 和 y 生成纠正后的句子 $\hat{x}$, 使其在语义和形式上近似于原始正确句子 x^* 。由于低资源语言缺乏大规模人工标注的拼写错误语料, 本研究的核心思路是: 通过字符级数据增强技术, 从少量无标注正确文本中自动生成覆盖上述三类错误的高质量平行语料, 从而训练出能够准确检测并修复各类字符级噪声的拼写纠错模型。

3.2.2 多源语料构建与混合增强机制

为了解决低资源语言的数据稀缺问题, 本文通过整合原始多源数据 ($\mathcal{D}_{ori}$)、基于规则的伪错误 ($\mathcal{D}_{rule}$) 和 LLM 生成的伪错误 ($\mathcal{D}_{llm}$) 来构建复合语料库 $\mathcal{D}$:

$$\mathcal{D} = \mathcal{D}_{ori} \cup \mathcal{D}_{rule} \cup \mathcal{D}_{llm} \quad (3-1)$$

其中, $\mathcal{D}_{ori}$ 为从多源收集的经过去重和采样平衡的无监督原始语料, $\mathcal{D}_{rule}$ 为基于规则注入错误生成的平行语料, $\mathcal{D}_{llm}$ 为大语言模型生成的伪错误平行语料。

(1) 多源语料库构建

优先考虑覆盖率和领域相关性, 本文从多个来源整理了 $\mathcal{D}_{ori}$ (见 3.3.1 节)。为保证质量, 语料库通过文本哈希进行去重, 并进行采样控制以平衡来源比例,

从而获得符合语义和语法规则的标准化数据集。

(2) 基于规则的增强机制

本文通过混淆集和随机注入来模拟常见的错误模式。

混淆集构建

对于高频词集合 $\mathcal{V}$ ，本文计算编辑距离以构建候选集 $Conf(w)$ 。为增加随机性，包含一个权重较低 s^{other} 的特殊标记 $\langle other \rangle$ ：

$$Conf(w) = \{(w'_1, s_1), \dots, (w'_k, s_k), (\langle other \rangle, s^{other})\}, \quad w \in \mathcal{V} \quad (3-2)$$

其中， (w'_i, s_i) 表示候选词及其权重， k 为候选词个数； $\langle other \rangle$ 表示从整个词汇表中随机采样的占位符，其权重 s^{other} 设为一个较小的正数。

错误注入

本文不再将序列视为集合，而是将错误生成函数 $ferr(\cdot)$ 应用于干净句子 $x^* \in \mathcal{D}_{ori}$ 中随机采样的词 w_j 上。由此得到注入错误的输入句子 x ，形式化定义如下：

$$x = (w_1, \dots, w_{j-1}, ferr(w_j), w_{j+1}, \dots, w_n), \quad j \sim \text{Sample}(\{1, \dots, n\}) \quad (3-3)$$

其中， j 为从句子位置索引中均匀随机采样的位置， $ferr(w_j)$ 为错误注入函数。 $ferr$ 包含三种类型：

- **词汇替换 (WP)**: 从 $Conf(w)$ 中采样。如果选中 $\langle other \rangle$ ，则 $v \sim U(\mathcal{V})$ ，即从词汇表 $\mathcal{V}$ 中均匀随机选择一个词。
- **空格冗余 (SR)**: 对于长度 $|w| > 2$ 的单词，在随机位置 p 插入空格字符。
- **空格缺失 (SM)**: 删除相邻单词 (w_i, w_{i+1}) 之间的空格。

(3) LLM 辅助增强机制

为了捕捉复杂的错误分布，本文采用经过 LoRA 微调的 Qwen2.5-3B-Instruct 模型。设计提示函数 $T(\ell, x^*) = Instr(\ell) \oplus x^*$ 以约束错误类型 $\ell (\ell \in \{WP, SM, SR\})$ ，其中 $\oplus$ 表示字符串拼接， $Instr(\ell)$ 为针对错误类型的指令模板。无监督语料库 $\mathcal{D}_{ori}$ 的生成过程定义为：

$$x \sim M_{LLM}^{finetune}(T(\ell, x^*)), \quad x^* \in \mathcal{D}_{ori} \quad (3-4)$$

其中， $M_{LLM}^{finetune}$ 表示经过指令微调后的大语言模型，其输出为根据指令生成的

带噪句子 x 。由此得到 $\mathcal{D}_{llm} = \{(x, x^*)\}$ ，丰富了错误模式的多样性。

3.2.3 多阶段渐进式检测训练

为了缓解伪数据中的噪声并提高泛化能力，本文提出了一个“由粗到细”的课程学习框架。错误检测任务被形式化为序列标注问题，设 $y_{i,t} \in \mathcal{Y}$ 表示第 i 个句子中第 t 个 token 的真实标签，其中 $\mathcal{Y}$ 为标签集（包含 O, WP, SM, SR-B, SR-I，其中 O 表示无错误，WP 为词汇替换，SM 为空格缺失，SR-B/SR-I 为空格冗余的开始和内部标记）。模型通过优化整个训练集 $\mathcal{D}$ 上的交叉熵损失来进行训练：

$$\mathcal{L}_{det}(\theta) = - \sum_{i=1}^{|\mathcal{D}|} \sum_{t=1}^{T_i} \sum_{c \in \mathcal{Y}} \mathbb{I}(y_{i,t} = c) \log P(y_{i,t} = c \mid x_i; \theta) \quad (3-5)$$

其中， θ 为检测模型的参数， T_i 为第 i 个句子的 token 数， $\mathbb{I}(\cdot)$ 为指示函数（当条件为真时取 1，否则取 0）， $P(y_{i,t} = c \mid x_i; \theta)$ 为模型预测第 t 个 token 属于类别 c 的概率。

训练过程分为三个阶段：

- (1) **基于规则的预训练（参数初始化）**：模型在 $\mathcal{D}_{rule}$ 上初始化权重 $\theta^{(1)}$ ，作为对严格语言学约束和基础结构边界具有鲁棒性的特征提取器。
- (2) **基于 LLM 的增强训练（分布平滑）**：在 $\mathcal{D}_{llm}$ 上更新至 $\theta^{(2)}$ ，该阶段起到了关键的桥梁作用。语义丰富的 LLM 伪错数据有助于将模式置于上下文中，平滑在第一阶段建立的刚性决策边界。
- (3) **人工标注微调（目标对齐）**：利用 $\theta^{(2)}$ 作为强大的先验，在少量人工标注的正确数据 $\mathcal{D}_{task}$ 上进行极少量的参数更新，使最终模型（ $\theta^{(3)}$ ）与真实的人类数据分布对齐，同时缓解灾难性遗忘。

训练轨迹形式化为：

$$\theta^{(1)} \leftarrow \text{Train}(\theta^{(0)}, \mathcal{D}_{rule}), \theta^{(2)} \leftarrow \text{Train}(\theta^{(1)}, \mathcal{D}_{llm}), \theta^{(3)} \leftarrow \text{Train}(\theta^{(2)}, \mathcal{D}_{task}) \quad (3-6)$$

其中， $\theta^{(0)}$ 为预训练语言模型的初始参数；表现为 IndoBERT 或 CafeBERT 的预训练权重， $\text{Train}(\cdot, \cdot)$ 表示在指定数据集上使用交叉熵损失进行参数更新的过程。

3.2.4 提示词融合纠正策略

本文将纠错建模为条件生成任务 ($x \rightarrow x^*$), 并通过参数高效指令微调进行优化。给定预测的错误位置集合 $\mathcal{E}$ 和混淆候选集 C , 综合提示模板定义为:

$$\mathcal{T}(x, \mathcal{E}, C) = Instr \oplus x \oplus ErrPos(\mathcal{E}) \oplus Cand(C) \quad (3-7)$$

其中, $Instr$ 为固定的纠错指令字符串, $ErrPos(\mathcal{E})$ 将错误位置信息编码为自然语言描述, $Cand(C)$ 将混淆候选词列表格式化为提示的一部分。本文评估了四种模板变体:

- **基础模板 (P_{instr}):** 仅包含 $Instr \oplus x$ 。
- **候选增强模板 (P_{cand}):** 增加 $Cand(C)$, Top- k 混淆候选词。
- **位置增强模板 (P_{pos}):** 整合 $ErrPos(\mathcal{E})$, 预测的错误位置信息。
- **融合模板 (P_{comb}):** 同时结合 $Cand(C)$ 和 $ErrPos(\mathcal{E})$ 。

模型通过最小化增强数据集 $\mathcal{D}_{corr}$ 上的条件生成损失来进行优化:

$$\mathcal{L}_{corr}(\theta) = - \sum_{i=1}^{|\mathcal{D}_{corr}|} \sum_{t=1}^{T_i} \log P_{\theta}(x_{i,t}^* | \mathcal{T}_i, x_{i,<t}^*) \quad (3-8)$$

其中, $\mathcal{D}_{corr}$ 为纠错微调所用的训练集 (包含输入-输出对), T_i 为目标句子 x_i^* 的长度, $x_{i,t}^*$ 为目标句子的第 t 个 token, $x_{i,<t}^*$ 表示前 $t-1$ 个 token, $\mathcal{T}_i$ 为第 i 个样本的提示模板, $P_{\theta}(\cdot)$ 为生成模型预测下一个 token 的概率分布。

3.3 实验与分析

3.3.1 数据集

本文使用 IMLIP2025 低资源语言拼写纠错任务的官方数据集^①, 包含印尼语和越南语各 10,000 条标注条目。如表 3-1 所示, 两种语言都表现出显著的数据稀缺和类别不平衡, 其中替换错误占主导地位。较低的平均编辑距离表明错误主要源于微小的局部字符偏差。值得注意的是, 错误模式存在差异: 空格冗余在印尼语中很普遍, 而越南语中的空格错误则更为均衡。这些语言特征直接指导了本

^①International Conference on Multilingual Intelligent Information Processing, <http://www.imlip.org>

表 3-1 印尼语和越南语错误类别分布对比

统计指标	WP (替换)		SR (冗余)		SM (缺失)	
	印尼语	越南语	印尼语	越南语	印尼语	越南语
错误数量	8,884	9,771	1,064	26	137	246
错误句中总词数	225,826	426,422	23,956	1,127	9,771	10,740
句级占比 (%)	88.84	97.71	10.64	0.26	1.37	0.25
词级占比 (%)	3.93	2.29	4.44	2.31	3.97	2.29

表 3-2 印尼语和越南语无监督语料库信息概览

语言	数据来源	句子数量	描述
印尼语	IdWiki	4,000,000	结构良好的百科全书文本
	IdUD	7,628	专业级句法标注数据
	Game Corpus	543,000+	原神、星穹铁道等游戏对话文本
	IndoSum	2,056,422	口语化新闻及摘要
越南语	ViWiki	1,500,000	采样自 viwiki dump
	ViUD	3,423	来自 UD 的句法标注数据
	Game Corpus	543,000+	同印尼语，越南语部分
	VietNews	2,974,780	VNDS 项目，新闻摘要数据

文针对性的数据增强策略。

(1) 无监督数据来源

提供丰富的语义多样性是数据增强策略有效性的关键指标之一，为确保语言多样性，本文构建了一个多领域无监督语料库（详见表 3-2），包括：(1) 维基百科和新闻（IndoSum/VietNews）用于覆盖正式模式；(2) 通用依存树库（Universal Dependencies, UD）用于句法结构；以及 (3) 游戏文本（MNBVC）用于捕捉口语表达。这种多样化的组合使模型能够适应从百科全书到对话等多种风格。

3.3.2 实施细节

(1) 数据集构建

表 3-3 多阶段错误检测训练设置

阶段	训练数据	描述	学习率
Stage 1	$\mathcal{D}_{rule}$ (400 万规则增强样本)	预训练阶段	4e-5
Stage 2	$\mathcal{D}_{llm}$ (26 万 LLM 增强样本)	第二阶段训练	2e-5
Stage 3	$\mathcal{D}_{task}$ (8 千人工标注样本, 8:2 切分)	最终微调	1e-5

基于规则的增强：首先计算前 10 万个高频词之间的编辑距离，构建包含前 100 个最近邻的混淆集。按照 3.2 节的策略（相似度阈值 $\tau = 0.1$ ），根据分布感知的过采样策略配置增强参数。如表 3-1 所示，词汇替换（WP）自然占错误的约 90%，构成了本文的基线。然而，为了防止模型对长尾少数类（空格冗余和空格缺失）欠拟合，本文凭经验将其生成概率分别上采样至 25% 和 15%，并通过验证集上的搜索进行了验证。每句的句内错误率固定为 5%。基于此配置，本文构建了约 486 万条印尼语和 455 万条越南语规则增强样本。

LLM 辅助增强：使用 LoRA (fp16) 在训练集的 8:2 切分上对 Qwen2.5-3B-Instruct^① 进行微调。然后利用该模型在 30 万条无监督清洗句子中生成噪声。经过对齐和特定错误类型的过滤，本文获得了约 26 万对（印尼语）和 24 万对（越南语）高质量的 LLM 增强数据对。

(2) 模型架构与实验设置

错误检测：本文将错误检测视为序列标注任务，并针对每种语言微调 BERT 预训练模型^②。对于印尼语，使用 IndoBERT^③；对于越南语，使用 CafeBERT^④。标注方案为 BIO，标签集合为 {O, WP, SM, SR-B, SR-I}。训练使用 fp16 精度，max_grad_norm=2.0，max_length=192，采用 AdamW 优化器和预热（warmup）策略。多阶段训练步骤如表 3-3 所示。

错误纠正：本文将拼写纠错形式化为结合提示工程的条件文本生成任务。基于 Qwen2.5-3B-Instruct，利用 LLaMA-Factory 框架进行 LoRA 微调 ($r = 32$)。训练采用 fp16 精度，学习率为 5×10^{-5} ，梯度裁剪阈值为 1.0。

^①<https://huggingface.co/Qwen/Qwen2.5-3B-Instruct>

^②<https://huggingface.co/google-bert/bert-base-uncased>

^③<https://huggingface.co/indolem/indobert-base-uncased>

^④<https://huggingface.co/uitnlp/CafeBERT>

3.3.3 实验与结果分析

(1) 错误检测结果

表 3-4 展示了印尼语和越南语错误检测任务在验证集上的实验结果。为便于比较, 本文将规则增强数据集、LLM 增强数据集和特定任务数据集分别表示为 $\mathcal{D}_{rule}$ 、 $\mathcal{D}_{llm}$ 和 $\mathcal{D}_{task}$ 。其中, $\mathcal{D}_{rule}$ 主要提供字符级扰动和拼写变体等表层错误先验, $\mathcal{D}_{llm}$ 用于扩展潜在错误表达的多样性, $\mathcal{D}_{task}$ 则更直接地反映目标任务中的真实错误分布。

从表 3-4 可以看出, 仅使用 $\mathcal{D}_{rule}$ 进行训练时, 模型在两种语言上的检测性能均不理想。印尼语的 F1 仅为 24.96%, 越南语的 F1 为 56.83%。进一步观察精确率和召回率可以发现, 规则数据训练下模型的召回率明显偏低, 尤其是印尼语召回率仅为 15.85%。这一现象说明, 规则增强虽然能够构造大量表层错误样本, 但其覆盖的错误类型较为固定, 难以充分匹配真实学习者文本中的复杂错误分布。因此, 单纯依赖大规模规则数据并不能有效解决低资源语言错误检测中的泛化问题。换言之, 数据规模的扩大并不必然带来性能提升, 增强数据与目标任务分布之间的一致性同样重要。

与仅使用 $\mathcal{D}_{rule}$ 相比, $\mathcal{D}_{task}$ 显著提高了模型性能。印尼语和越南语分别取得 82.84% 和 86.61% 的 F1 分数, 说明特定任务数据能够为模型提供更接近真实场景的错误分布信息。尽管 $\mathcal{D}_{task}$ 的数据规模远小于 $\mathcal{D}_{rule}$, 但其在精确率和召回率上的表现更加均衡。这表明, 在低资源错误检测任务中, 少量高质量、任务相关的数据对于模型学习真实错误边界具有关键作用。

进一步地, 将 $\mathcal{D}_{rule}$ 与 $\mathcal{D}_{task}$ 结合后, 模型性能继续提升。与仅使用 $\mathcal{D}_{task}$ 相比, 印尼语 F1 从 82.84% 提升至 88.97%, 越南语 F1 从 86.61% 提升至 89.51%。这一结果说明, 规则增强数据和任务数据之间具有互补性: 前者能够提供更加丰富的字符级错误先验, 帮助模型识别可能的拼写扰动模式; 后者则能够对模型进行任务分布校准, 使模型更好地适应真实验证集中的错误形态。尤其是在召回率方面, 印尼语由 81.47% 提升至 89.72%, 越南语由 85.76% 提升至 90.77%, 表明规则增强数据主要提升了模型对潜在错误样本的覆盖能力。

在引入 $\mathcal{D}_{llm}$ 后, 模型取得了进一步提升。 $\mathcal{D}_{rule+llm+task}$ 在印尼语和越南语上分别达到 91.17% 和 90.36% 的最佳 F1 分数。其中, 印尼语的精确率和召回率分别达到 91.23% 和 91.12%, 表现出较好的均衡性; 越南语虽然召回率略低于 $\mathcal{D}_{rule+task}$ 设置, 但精确率提升至 90.95%, 最终仍获得最高 F1。该结果表明,

表 3-4 印尼语和越南语的错误检测结果（在 2000 条验证样本上评估，单位%）

训练数据	印尼语			越南语		
	P	R	F1	P	R	F1
$\mathcal{D}_{rule}$	58.68	15.85	24.96	74.44	45.96	56.83
$\mathcal{D}_{task}$	84.25	81.47	82.84	87.46	85.76	86.61
$\mathcal{D}_{rule+llm}$	89.49	83.55	86.42	85.23	86.84	86.03
$\mathcal{D}_{rule+task}$	88.23	89.72	88.97	88.29	90.77	89.51
$\mathcal{D}_{rule+llm+task}$	91.23	91.12	91.17	90.95	89.78	90.36

LLM 增强数据能够在规则数据和任务数据之外补充更具语义多样性的错误样本，使模型不仅学习表层字符扰动，还能接触到更加多样的错误表达形式，从而提高整体判别能力。

值得注意的是，两种语言从数据增强中获得的收益并不完全一致。越南语在仅使用规则数据时已经取得相对较高的 F1，说明其规则增强样本与验证集错误形式具有较好的匹配度；而印尼语在规则数据上的初始性能较低，但在融合任务数据和 LLM 增强数据后提升更为明显。这说明本文方法在错误分布更稀疏、规则泛化能力更弱的语言场景中具有更突出的作用。由此可见，多来源数据增强策略的优势并不只是增加训练样本数量，而是在于通过规则先验、生成式扩展和任务分布校准的结合，提高模型对低资源语言复杂错误形态的覆盖能力和适应能力。

综合来看，表 3-4 的结果验证了本文字符级数据增强策略的有效性。规则增强能够提供基础错误先验，任务数据能够校准真实错误分布，LLM 增强则进一步扩展错误表达的多样性。三类数据共同作用，使模型在错误检测任务中获得更加稳定的性能提升。这也说明，对于低资源语言拼写纠错任务而言，单一来源的数据增强难以充分覆盖真实错误空间，而多来源、互补式的数据增强更适合处理稀疏分布和高噪声文本场景。

(2) 错误纠正结果

表 3-5 展示了不同提示策略在印尼语和越南语验证集上的生成式纠错结果。本文比较了四类提示模板：基础指令提示 P_{instr} 、相似候选词增强提示 P_{cand} 、位置感知提示 P_{pos} 以及综合组合提示 P_{comb} 。其中， P_{instr} 不引入显式错误检测信息，主要依赖 LLM 自身的语言理解与生成能力完成纠错，因此可以视为纯生成式纠

表 3-5 印尼语和越南语验证集上的纠错与检测结果（单位%）

方法	纠错 (Correction)			检测 (Detection)		
	P	R	F1	P	R	F1
印尼语						
P_{instr} (基线)	75.16	73.44	74.29	87.71	85.70	86.69
P_{cand} (Top $k=5$)	81.20	77.80	79.46	89.14	85.41	87.23
P_{cand} (Top $k=10$)	81.01	77.58	79.26	89.44	85.66	87.51
P_{pos}	75.94	75.56	75.75	89.12	86.66	88.89
P_{comb} (Top $k=5$)	81.99	78.77	80.35	89.92	86.38	88.11
P_{cand} (Top $k=5$) + LLM	81.24	77.29	79.21	89.82	86.38	87.58
越南语						
P_{instr} (基线)	78.05	76.06	77.04	86.54	84.34	85.43
P_{cand} (Top $k=5$)	79.23	77.66	78.44	86.88	85.16	86.01
P_{cand} (Top $k=10$)	79.20	77.36	78.27	86.84	84.82	85.82
P_{pos}	77.74	78.65	78.19	88.15	89.17	88.66
P_{comb} (Top $k=5$)	79.91	79.60	79.75	88.87	88.52	88.70
P_{cand} (Top $k=5$) + LLM	81.46	77.31	79.33	87.82	83.35	85.53

错基线。相比之下， P_{cand} 和 P_{pos} 分别从候选替换词和错误位置两个角度引入外部约束， P_{comb} 则进一步融合二者，以验证检测信息和候选信息对生成式纠错的联合作用。

从纠错结果来看，基础指令提示 P_{instr} 已经能够取得一定效果，印尼语和越南语的纠错 F1 分别为 74.29% 和 77.04%。这说明 LLM 具备一定的跨语言文本纠错能力，能够根据上下文语义对部分错误进行修正。然而，该方法没有显式错误位置和候选词约束，在面对低资源语言中的拼写变体和噪声文本时，容易出现两类问题：一是无法准确定位需要修改的错误词，导致漏改；二是可能对原本正确的词进行不必要改写，影响纠错精度。因此，纯生成式纠错虽然具有较强的通用性，但在细粒度拼写纠错任务中仍存在可控性不足的问题。

引入相似候选词后， P_{cand} 相较 P_{instr} 取得了明显提升。当 Top $k = 5$ 时，印尼语纠错 F1 从 74.29% 提升至 79.46%，越南语从 77.04% 提升至 78.44%。这一结果表明，相似候选词能够有效缩小 LLM 的生成搜索空间，使模型在进行纠错时更加关注与原始错误词形态接近的候选项。对于拼写纠错任务而言，真实修正词通常与错误词在字符形态上存在一定相似性，因此候选词约束能够帮助模型减

少不合理生成,提高纠错结果的稳定性。该现象在印尼语上更加明显,说明当模型对目标语言的错误模式掌握不足时,显式候选词能够提供更强的词形先验。

然而,当 Top k 从 5 增加到 10 时,模型性能并未继续提升,反而出现轻微下降。印尼语纠错 F1 从 79.46% 下降至 79.26%,越南语从 78.44% 下降至 78.27%。这一结果说明,候选词数量并非越多越好。当候选集合过大时,虽然理论上能够覆盖更多可能修正词,但也会引入更多语义或词形上相近但并不正确的干扰项,增加 LLM 的选择难度。该结果进一步表明,候选增强的关键不在于简单扩大候选规模,而在于保持候选词集合的相关性和精确性。因此,在本文实验设置下,Top $k = 5$ 在覆盖率和噪声控制之间取得了更好的平衡。

位置感知提示 P_{pos} 在检测任务上表现较为突出。对于印尼语和越南语, P_{pos} 的检测召回率分别达到 86.66% 和 89.17%,均为对应语言中的最高值。这说明显式错误位置信息能够有效增强模型对错误片段的关注,使模型更倾向于覆盖潜在错误位置,减少漏检情况。但从纠错结果来看, P_{pos} 的纠错 F1 低于 P_{cand} 和 P_{comb} 。这一现象说明,错误位置线索主要解决“哪里需要修改”的问题,而候选词信息则进一步解决“应该如何修改”的问题。仅有位置提示虽然能够帮助模型识别错误范围,但不足以保证生成正确的替换词。

综合组合提示 P_{comb} 在两种语言的纠错任务上均取得最佳结果,印尼语和越南语的纠错 F1 分别达到 80.35% 和 79.75%。与 P_{instr} 相比, P_{comb} 在印尼语上提升 6.06 个百分点,在越南语上提升 2.71 个百分点。该结果说明,将错误位置线索与候选词约束结合,可以有效弥补纯生成式纠错的不足。具体而言,检测模块提供的错误位置 $\mathcal{E}$ 能够引导 LLM 聚焦于真正需要修改的文本片段,减少无关改写;候选词集合则为模型提供可能的修正方向,降低生成空间的不确定性。二者结合后,模型既能更准确地定位错误,又能更稳定地生成合理修正词,从而提升整体纠错性能。

从检测结果来看, P_{comb} 同样表现出较强的综合能力。虽然在印尼语检测任务中, P_{pos} 获得最高 F1,但 P_{comb} 在纠错任务中取得最佳表现,说明纠错任务不仅依赖错误检测能力,还依赖后续替换词生成的准确性。对于越南语, P_{comb} 同时取得最高检测 F1 和最高纠错 F1,进一步表明位置线索与候选词约束之间具有较强互补性。该结果验证了本文级联式“检测-纠错”框架的必要性,即错误检测不仅是独立任务,也能作为生成式纠错的重要先验信息。

LLM 增强数据对纠错和检测的影响呈现出一定差异。与未增强的 P_{cand} (Top $k = 5$) 相比,加入 LLM 增强数据后,越南语纠错 F1 从 78.44% 提升至 79.33%,

主要得益于精确率从 79.23% 提升至 81.46%；但印尼语纠错 F1 从 79.46% 略降至 79.21%。同时，在检测任务中，LLM 增强对印尼语带来一定提升，但对越南语检测 F1 产生负面影响。该现象说明，LLM 生成数据并不总是稳定提升模型性能，其效果取决于生成样本与真实错误分布之间的匹配程度。当合成错误样本能够补充真实错误模式时，模型性能会得到提升；但当合成数据中包含不自然或与真实学习者错误不一致的噪声时，模型可能会产生偏置，表现为精确率上升但召回率下降，或者对真实错误覆盖不足。

上述结果进一步说明，生成式增强的作用并不是简单地扩大训练数据规模，而是需要保证增强样本的真实性、任务相关性和分布一致性。对于低资源语言纠错任务而言，LLM 能够提供多样化错误样本，但这些样本仍需要通过候选约束、位置引导或任务数据校准来降低噪声影响。相比纯 LLM 纠错方法，本文方法的优势在于将生成能力与显式错误检测信息结合起来，使纠错过程由完全开放式生成转变为受约束的、可解释的候选选择与局部修正过程。

总体而言，表 3-5 的结果表明，本文所提出的检测增强纠错策略能够有效提升低资源语言拼写纠错性能。候选词信息有助于缩小生成空间，位置线索有助于提高错误定位能力，二者结合能够同时改善纠错精度和结果稳定性。进一步结合表 3-4 可以发现，第三章方法的核心优势在于从字符级错误先验、任务分布校准和生成式语义扩展三个方面共同增强模型，使其更适用于稀疏分布和高噪声文本场景下的低资源语言错误检测与纠正任务。

3.4 本章小结

本章提出了融合规则与大语言模型协同的字符级数据增强方法。首先，针对印尼语、越南语的错误模式分布特性，构建了多领域无监督基础语料库，通过规则驱动的混淆集构建与错误注入机制，实现了常见错误模式的广谱覆盖；其次，引入轻量化大语言模型，生成具备上下文依赖的伪错样本，弥补了规则方法语义多样性不足的短板，形成了规则与大语言模型协同的混合增强语料库；再次，设计了多阶段渐进式训练策略，通过由粗到细的课程学习，缓解了伪数据噪声带来的模型偏差；最后，构建了检测-纠错融合的分层提示模板，通过错误位置、候选词信息的协同增强，提升了模型的纠错精度与可控性。是全文统一研究主线下，针对字符粒度数据缺陷的专属解决方案，与样本级、特征级增强方法共同构成了覆盖社交媒体文本分析全链条核心痛点的多粒度数据增强方法论体系。

第 4 章 基于扩散模型与对比学习的样本级数据增强方法

4.1 研究动机

社交媒体文本分析中，样本层面的核心质量缺陷表现为**有效标注样本的极端稀缺与类别分布的严重长尾失衡**。在突发公共卫生事件谣言检测、低资源细粒度情感分析等典型任务中，谣言、负面情感等高价值类别的标注样本占比极低，而多数类样本占据主导地位。这种分布失衡直接导致分类模型向多数类过拟合，丧失对少数关键类别的识别敏感度，成为制约模型泛化能力与落地性能的核心瓶颈^[78]。针对这一痛点，本章以样本级数据增强为技术路径，开展独立的方法研究，旨在从分布层面重构训练集的类别平衡，为下游分类任务提供均衡、多样的样本支撑。该研究是全文多粒度数据增强方法论体系中，与字符级、特征级增强方法平行互补的中间层次。

社交媒体场景下，突发公共卫生事件谣言检测与低资源细粒度情感分析等任务，天然面临标注难度大、成本高、时效性强的现实约束。谣言样本的标注需要事实核查与领域知识，情感标注依赖人工判断，在突发事件中更要求快速响应，导致有效标注样本数量极为有限。与此同时，正负样本或多数类与少数类之间的比例悬殊，进一步加剧了模型的学习偏差。上述问题在低资源语言场景中尤为突出，标注语料的匮乏使得传统监督学习方法难以奏效。

现有解决方案主要分为三类，均在上述挑战下面临难以突破的局限：其一，基于重采样的方法仅能调整样本分布比例，无法生成新的语义信息，易导致模型对少数类过拟合或信息丢失；其二，基于 EDA、AEDA 等规则的增强方法，通过同义词替换、随机插入删除等操作生成样本，但生成内容语义僵化，且易引入破坏语义一致性的噪声；其三，基于 GAN、GPT-2 等生成模型的增强方法，虽能提升样本多样性，但存在训练不稳定、模式崩塌、语义漂移等问题，生成内容的可控性差，难以严格保证标签一致性。综上，现有方法尚未能有效兼顾样本多样性与标签语义一致性，难以适配低资源、强时效的真实场景需求。

针对上述研究局限，本章提出**基于扩散模型的标签感知数据增强框架 (Diffusion Model-based Data Augmentation, DMDA)**，以突发公共卫生事件谣言检

测和低资源文本分类与情感分析为典型测试任务，系统性解决样本稀缺与类别失衡的核心难题。本章的核心贡献如下：

(1) 提出注意力引导的动态噪声调度策略，结合标签感知嵌入机制，有效解决了传统生成方法中多样性与一致性难以平衡的关键问题；

(2) 设计相似性加权筛选与对比学习驱动的噪声对抗训练模块，滤除低质量生成样本，重构特征空间的类别分布平衡，显著提升了模型在少样本、长尾分布场景下的判别鲁棒性；

(3) 在汉、英、阿、德、法、西等多语言、多领域的 6 个基准数据集上完成实验验证，结果表明，DMDA 在谣言检测和低资源情感分析任务中均取得稳定性增益，在低资源、少样本场景下的增益效果尤为显著，表明 DMDA 具备较强的泛化能力与场景适配性。

4.2 基于扩散模型数据增强的分类检测方法

如图 4-1 所示，本章方法以扩散语言模型为核心，构建了面向分类检测任务的样本级数据增强框架。首先，样本生成条件掩码模块根据下游分类模型的注意力权重动态选择需要扰动的关键 token，并引入标签感知嵌入以约束生成样本的类别语义。随后，扩散语言模型在动态噪声调度的引导下逐步完成加噪与去噪过程，从而生成具有一定多样性且保持原始语义一致性的增强样本。最后，分类检测模块对原始样本与增强样本进行联合训练，并通过相似性选择和噪声对抗训练降低低质量伪样本带来的干扰。该框架的核心在于平衡生成样本的多样性与标签一致性，从而提升模型在样本稀疏和类别不均衡场景下的泛化能力。

4.2.1 样本生成条件掩码

生成式模型通常会存在生成结果缺乏多样性和语义一致性的问题，因此探索生成与原始文本语义相近但多样化程度高的样本是关键。为此，本文构建一个基于扩散语言模型的样本生成器，即在扩散语言模型中设计注意力引导的动态噪声调度模块，以帮助模型生成多样化程度高但语义一致性强的样本。此外，本文还将标签感知嵌入融入训练机制，使模型能够掌握特定标签的知识，并在样本生成时作为指导条件。通过两个模块协同，可使生成器在多样性和一致性上达到




图 4-1 基于扩散语言模型数据增强的分类检测框架

平衡，并表现出优异的性能。

(1) 动态噪声调度

扩散模型的生成效果高度依赖于噪声调度策略，但过强的噪声会导致模型生成的样本偏离原始语义，因此适当的噪声调度策略可以帮助扩散模型捕获更准确的语义关系。注意力引导的动态噪声调度可针对特定任务通过代理模型计算每个单词的注意力权重，这些权重表示单词在任务中的重要程度。代理模型可使用预训练模型进行微调，并生成每个单词的注意力分数。其分数来自代理模型的最后一层，并通过量化 [CLS] 标记与其他标记之间的注意力分数来衡量单词在给定上下文和标签信息对分类结果的贡献。权重计算方式如下：

$$w_i = \frac{1}{H} \sum_{h=1}^H s_i^h \quad (4-1)$$

其中 s_i^h 表示第 h 个注意力头中的第 i 个 token 的注意力分数， H 表示注意力头的数量， w_i 表示衡量第 i 个 token 的重要性权重。

动态噪声调度采用基于注意力得分和时间步的噪声调度函数来控制每个被掩码的概率。受 Spindle Noise Schedule^[79] 的启发，噪声的添加是动态的，受每



图 4-2 标签感知嵌入示例

个 token 的注意力得分和当前时间步的影响。具体而言，时间步 t 表示扩散过程的当前阶段：在初期（即较小的值），模型更倾向于保持原始文本中的词语不变；随着 t 的增加，操作逐渐增多，这样可确保生成多样化的样本。对于第 i 个 token，在时间步 t 的掩码概率 q'_i 的计算公式如下：

$$q'_i = 1 - \frac{t}{T} - \lambda \cdot S(t) \cdot w_i \quad (4-2)$$

$$S(t) = \sin\left(\frac{t\pi}{T}\right) \quad (4-3)$$

其中， T 是总的时间步数； λ 是超参数，用来控制 w_i 对掩码概率的影响程度； $S(t)$ 是基于时间步的函数，描述掩码噪声的增加速率。被掩码的概率与其相对于 [CLS] 标记的注意力得分相关，反映了它在下游分类检测任务中的重要性。

(2) 标签感知嵌入

对于每个 token，根据其掩码概率来决定是否对其进行目标掩码操作。目标掩码的生成在于选择输入序列中最关键的部分，这些在后续的数据增强过程中需要受到更多关注。然而，当重要的 token 被屏蔽时，多样性与一致性之间的权衡变得更加复杂，模型更容易生成与目标标签不一致的 token。为了确保生成的样本既能体现出多样性，又能保持原始语义的一致性，本文受条件生成 (conditional generation)^[80] 方法的启发，在训练和推理阶段引入条件信息，并提出一种标签感知嵌入策略。具体而言，通过在模型输入的开头添加标签信息，以更好地捕捉类别间的差异，从而使扩散模型生成的内容更符合标签特征。

如图4-2所示，在噪声调度过程中对样本进行掩码之后，样本的标签会与各自的掩码序列连接在一起。这些附加信息可帮助模型生成与标签一致的样本。

考虑到某些任务（如谣言检测）的真实样本代表的是实际发生的情况，而基于真实样本生成的样本则很难保证其事实性，因此本文还设计了一种标签平衡样本生成机制。该机制可通过参数控制是否对特定标签文本进行目标掩码。具体

而言，当仅掩码某一类别时，该机制结合标签标记的文本信息和分类模型提供的注意力分数，依据文本中每个的重要性权重动态生成掩码序列。然而，不同程度的掩码会导致在生成伪样本时上下文替换的灵活性差异，进而直接影响伪样本的一致性和多样性。因此，将生成的增强样本按步数分组，并通过参数控制最大掩码概率的范围，以确保条件信息输入的适当数量组合。

4.2.2 扩散语言模型数据增强

扩散模型通过逐步将噪声添加到数据中，然后学习去噪的反向过程。这种渐进式的噪声添加与去噪过程使模型能够逐渐生成高质量伪样本。本文借鉴 He 等^[79]的做法，在马尔可夫过程中引入吸收态。序列中的每个标记要么保持不变，要么以一定的概率转变为 [MASK] 状态，即第 i 个 token 被掩码的概率决定了其在时间步 t 中是否转变为 [MASK]，从而实现与预训练的去噪语言模型的结合。具体来说，给定原始数据（即未加噪的数据），时间步 t 上的加噪数据表示为 x_t ，扩散过程将通过在一系列时间步上逐渐加噪，最终得到高噪声的状态。时间步 t 的加噪过程可以表示为：

$$x_t = \sqrt{1 - q'_t} \cdot x_{t-1} + \sqrt{q'_t} \cdot \epsilon_t \quad (4-4)$$

其中， x_t 是时间步 t 时的加噪状态， x_{t-1} 是时间步 $t-1$ 时的数据表示， $\epsilon_t \sim \mathcal{N}(0, 1)$ 是标准高斯噪声，表示噪声的随机部分。

在扩散模型中，噪声样本和时间步长等输入用于在逆过程中预测去噪样本。然而，时间步是 PLM 在训练过程中从未见过的附加变量，因此将时间信息输入 PLM 中并不简单。考虑到生成模型的目标是利用前向加噪过程中的动态噪声调度和目标掩码来恢复数据的结构和语义，而不需要显式的时间步信息，所以在解码过程中可通过目标掩码和注意力得分决定去噪优先级。

另外，通过计算噪声序列中被损坏的标记数量（即 [MASK] 标记），可以更容易地隐式推断扩散过程中的时间步骤。因此，在解码过程中，PLM 在迭代去噪时无需明确知道当前的时间步，即无需依赖显式的时间信息。这种方法使得扩散模型能够生成多样且语义一致的样本，同时避免对显式时间步信息的依赖。

4.2.3 下游分类检测任务

(1) 相似性选择

尽管通过动态噪声调度和标签感知嵌入的策略，能够在一定程度上减少噪声引入的负面影响，但由于生成过程的随机性，仍然不可避免地会引入一定的噪声。考虑到增强样本可能会偏离原始样本的真实分布，导致一致性下降。因此，在获得增强样本后，本文设计一个相似性选择模块。通过选择与原始样本相似的增强样本，从而保证一致性前提下增加样本的多样性。

对于每个样本 $OS \in \mathbb{R}^{1 \times H}$ (H 为隐藏状态的维度)，假设以其为基础产生的 B 个增强样本集合表示为 $ES \in \mathbb{R}^{B \times H}$ ，那么增强样本集和原始样本的相似性 s 计算如下：

$$s = ES \cdot OS^T \quad (4-5)$$

其中， $\cdot$ 表示内积运算。在计算增强样本与原始样本的内积后得到每个增强样本与对应原始样本的相似度向量 $s \in \mathbb{R}^{1 \times H}$ ，并将其沿着第二维度广播得到 $s \in \mathbb{R}^{B \times H}$ 。最后，将相似度向量 s 与增强样本集 ES 相乘，得到加权后的增强样本子集 G 。

$$G = s \times ES \quad (4-6)$$

与所有增强样本一视同仁的简单平均方式不同，相似性加权能够让模型在训练过程中更关注那些与原始样本高度相关的增强样本，从而为基于对比学习的噪声对抗训练创造条件。

(2) 噪声对抗训练

为了进一步降低噪声引入所带来的影响，本文设计了一个结合对比学习的噪声对抗训练模块。假设数据集的类别集合为 $C = \{c_1, c_2\}$ ，首先从原始训练集随机抽取 m 个样本构成一个批次，索引列表为 $J = [1, 2, \dots, m-1, m]$ ，包含句子子集 $T = \{t_1, t_2, \dots, t_{m-1}, t_m\}$ ，且它们对应的标签序列为 $P = [p_1, p_2, \dots, p_{m-1}, p_m]$ ， $p_i \in C$ 。对于每个样本 t_i ，其负样本索引集合为 $N_i = \{k \in J \mid p_k \neq p_i\}$ ，即包含所有与 t_i 标签不同的样本。此外，为了增强训练过程，本文为每个原始样本 t_i 通过样本生成器生成 B 个新的增强样本， t_i 及生成的样本集合记作 $G_i = \{g_{i0}, g_{i1}, \dots, g_{iB-1}, g_{iB}\}$ ，其中 g_{ij} ($j = 0, 1, \dots, B$) 是生成的增强样本。

通过相似性选择对增强样本进行加权后，在计算对比损失时，增强样本与原始样本之间的相似度会影响损失的大小。这意味着，更相似的增强样本在训练过程中会有更大的影响。对比损失的计算方式如下：

$$\mathcal{L}_c = \frac{1}{m} \sum_{i \in J} \sum_{j \in N_i} \exp \left(\frac{\text{sim}(G_i, G_j)}{\tau} \right) \quad (4-7)$$

其中， $\text{sim}(\cdot)$ 是样本和样本之间的余弦相似度， τ 是温度超参数，用于控制相似度的缩放。

在分类任务中，将原始样本和增强样本统一纳入分类损失函数：

$$\mathcal{L}_e = -\frac{1}{m(B+1)} \sum_{i=1}^m \sum_{b=0}^B (p_b^i \log(\hat{p}_b^i) + (1 - p_b^i) \log(1 - \hat{p}_b^i)) \quad (4-8)$$

其中， p_b^i 表示第 i 个样本的标签， $\hat{p}_b^i$ 表示第 i 个样本的第 b 个增强样本属于目标的预测概率。损失中加入 $\frac{1}{m(B+1)}$ 作为归一化因子，用于平衡原始样本和增强样本的贡献。

结合对比损失和分类损失，分类模型的总体训练目标可表示为：

$$\mathcal{L} = \mathcal{L}_e + \mathcal{L}_c \quad (4-9)$$

4.3 实验与分析

为全面验证 DMDA 框架的有效性、鲁棒性与泛化能力，本文分别在突发公共卫生事件谣言检测、低资源文本分类与情感分析两大任务、6 个多语言基准数据集上开展对比实验、消融实验与可视化分析，所有实验均采用相同的硬件环境与公平的参数设置。

4.3.1 突发公共卫生事件谣言检测实验

数据集

本文选取汉、英、阿拉伯、德四种语言的新冠疫情谣言检测基准数据集，覆盖不同规模、不同失衡程度、不同文本长度的真实场景，数据集的核心统计信息如表4-1所示。

表 4-1 谣言检测数据集核心统计信息

数据集	样本总量	谣言占比	平均长度	最小长度	最大长度
CEDADataset	2838	31.11%	165.24	10	4727
EngDataset	10700	47.66%	49.22	5	2880
ArabicDataset	1537	54.33%	29.71	3	70
FangDataset	41242	31.97%	1160.78	49	66092

表 4-2 实验环境配置

实验环境	参数配置
操作系统	Ubuntu 20.04.6 LTS
GPU	NVIDIA GeForce RTX 3090
显存	24G
开发语言	Python 3.8
深度学习框架	PyTorch 2.3.0+CUDA 11.8

各数据集的详细信息如下：

- (1) CEDADataset^[34]：汉语疫情谣言数据集，基于 CHECKED 数据集拓展，补充了腾讯事实核查平台的 718 条标注数据，类别失衡特征显著。
- (2) EngDataset^[81]：英语疫情谣言数据集，来自 CONSTRAINT COVID-19 虚假新闻检测挑战赛，包含经事实核查的真实与虚假新闻样本。
- (3) ArabicDataset^[82]：阿拉伯语疫情谣言数据集，由人工标注的 COVID-19 相关推文构成，属于典型的低资源小样本场景。
- (4) FangDataset^[83]：德语疫情谣言数据集，包含 COVID-19 相关的新闻与推文样本，文本长度差异大，类别分布失衡。

实验设置

对于已提供官方划分的汉语、英语数据集，采用官方训练集、验证集、测试集；对于阿拉伯语、德语数据集，按 7:1:2 的比例随机划分为训练集、验证集、测试集。采用准确率（Accuracy）、宏平均 F1 值（Macro-F1）作为核心评价指标，实验环境与核心参数设置如表4-2、表4-3所示。

表 4-3 谣言检测实验核心参数设置

模块	参数设置	参数值
DMDA	代理模型迭代次数	5-15
	扩散模型迭代次数	1-5
	分类模型迭代次数	5-15
	批次大小	12-24
	学习率	3e-5
	优化器	AdamW
	隐藏层大小	768
EDA/AEDA 基线	单条样本生成数量	9
	同义词替换概率	0.1
	随机插入概率	0.1
	随机交换概率	0.1
	随机删除概率	0.1

基线模型

为全面评估 DMDA 的性能优势，本文选取三类基线模型进行对比：1. 基础分类模型：TextCNN^[84]、BERT^[85]、RoBERTa^[86]、CT-BERT^[87]、AraBERT^[88]、MARBERT^[89]、German BERT^①，均在原始数据集上完成训练与测试。2. 谣言检测模型：Cross-SEAN^[90]、MDFEND^[91]、CEDA-MTL^[34]，为当前谣言检测领域的 SOTA 模型。3. 数据增强基线：EDA^[28]、AEDA^[29]、GPT-2^[32]，均采用与 DMDA 相同的基础分类器，仅替换数据增强策略。

针对不同语言，选用适配的预训练模型：汉语采用 RoBERTa、英语采用 CT-BERT、阿拉伯语采用 MARBERT、德语采用 German BERT。

实验对比及结果

不同方法在四个数据集上的实验结果如表4-4所示，核心结论如下：

- (1) DMDA 在所有数据集上均取得了最优性能，在低资源场景下的提升尤为显著：在阿拉伯语数据集上，较最强基线 MARBERT 的 F1 值提升 2.6 个百分点；在德语、汉语、英语数据集上，较最强基线分别提升 0.7、0.4、0.2 个百分点，充分验证了方法的有效性与跨语言适配能力。
- (2) 特定领域与特定语言的预训练模型（CT-BERT、MARBERT）展现出较强

^①<https://huggingface.co/models>

表 4-4 谣言检测实验结果 (%)

方法	CEDADataset		EngDataset		ArabicDataset		FangDataset	
	Accuracy	F1	Accuracy	F1	Accuracy	F1	Accuracy	F1
TextCNN	96.1	96.1	93.7	93.7	66.5	66.5	79.9	78.7
BERT	95.0	95.1	97.6	97.6	71.4	71.4	93.2	93.2
RoBERTa	97.0	97.0	96.8	96.8	65.2	65.2	91.4	91.4
CT-BERT	/	/	98.3	98.3	/	/	/	/
AraBERT	/	/	/	/	79.2	79.2	/	/
MARBERT	/	/	/	/	82.1	82.1	/	/
German BERT	/	/	/	/	/	/	96.7	96.7
Cross-SEAN	95.4	95.4	93.5	93.5	52.9	36.6	86.6	86.4
MDFEND	97.3	97.3	96.5	96.5	66.5	66.4	88.1	87.8
GPT-2	95.7	95.8	97.9	97.9	56.1	54.4	96.0	96.0
EDA+BERT	96.4	96.5	97.5	97.5	66.2	66.0	90.1	90.2
AEDA+BERT	97.1	97.2	96.4	96.4	70.7	70.2	92.4	92.3
EDA+AEDA+BERT	97.0	97.0	97.3	97.3	63.9	63.3	92.4	92.4
CEDA-MTL*	96.4	97.2	/	/	/	/	/	/
DMDA	97.7	97.7	98.5	98.5	84.7	84.7	97.4	97.4

注：* 表示模型结果来自原始文献，/表示该模型不适用对应数据集

- 的基线性能，仅次于 DMDA，证明领域适配的语义表示对谣言检测任务的重要性，而 DMDA 通过数据增强进一步放大了预训练模型的性能优势。
- (3) 基于规则的增强方法 (EDA、AEDA) 仅在汉语数据集上取得小幅增益，在低资源、长文本数据集上甚至出现性能下降，原因在于随机编辑操作易破坏核心语义，引入无效噪声，无法适配复杂的真实场景。
- (4) GPT-2 生成式增强在英语大样本数据集上表现较好，但在低资源阿拉伯语数据集上性能严重衰减，原因在于缺乏低资源语言的领域微调，生成样本语义一致性差，易引入语义漂移。

综上，DMDA 通过标签感知的可控生成，有效平衡了样本多样性与语义一致性，在不同语言、不同样本规模、不同失衡程度的数据集上均实现了稳定的性能提升，展现出极强的场景适配能力与鲁棒性。

不同数据增强策略的对比实验

针对谣言检测任务的事实性约束，本文对比了全量数据增强与仅增强少数类（谣言）数据两种策略的性能差异，实验结果如图4-3所示。




图 4-3 不同数据增强策略的性能对比




图 4-4 最大掩码概率对模型性能的影响




图 4-5 扩散步数对模型性能的影响

结果表明，在类别失衡显著的汉语数据集上，仅增强谣言数据的策略优于全量数据增强，既实现了类别分布平衡，又避免了对非谣言样本的事实性扰动；在分布相对均衡的阿拉伯语数据集上，两种策略的性能差距仅为 0.3 个百分点。综上，针对长尾分布场景，定向增强少数类样本是更高效、更安全的增强策略。

超参数敏感性分析

本文进一步分析了最大掩码概率、扩散步数两个核心超参数对模型性能的影响，实验在阿拉伯语数据集上完成。如图4-4所示，模型性能随最大掩码概率的提升呈现单峰趋势，过低的掩码概率无法保证样本多样性，过高的掩码概率则会破坏核心语义，导致性能下降。如图4-5所示，模型性能在第 5 组扩散步数 (17-20 步) 达到峰值，进一步验证了多样性与一致性的权衡关系：适度的掩码与扩散步数，能在保留标签语义的前提下最大化样本多样性。

消融实验




图 4-6 CEDADataset 的 t-SNE 特征空间可视化

为验证 DMDA 框架中核心模块的有效性，本文在 CEDADataset 和 Eng-Dataset 上开展消融实验，结果如表4-5所示。实验结果表明：1. 同时启用 DA 与 CL 模块时，模型取得最优性能，两个模块形成了显著的协同增益效果；2. 仅启用 CL 模块时，模型性能较基线有稳定提升，证明对比学习能有效提升模型的特征判别能力与抗噪声能力；3. 仅启用 DA 模块、不结合 CL 模块时，模型性能出现下降，原因在于未经筛选的增强样本易引入噪声，而对比学习的相似性加权机制能有效滤除低质量样本，最大化数据增强的增益效果。

本文进一步通过 t 分布随机邻域嵌入 (t-SNE) 特征空间可视化，验证了 DMDA 的作用机制，结果如图4-6所示。增强样本以原始样本簇为中心呈辐射分布，核心区与原始样本高度重叠保证了语义一致性，边缘区拓展了特征空间覆盖度，结合对比学习的类间区分优化，有效提升了分类器的判别边界鲁棒性。

可解释性验证

为验证基于注意力权重的动态掩码策略的合理性，本文通过沙普利可加解释值 (SHAP) 与注意力权重的相关性分析开展可解释性验证，结果如图4-7所示。

结果显示，在疫情相关文本中，模型注意力权重与 SHAP 值在地理名称、量化数据、专业术语等核心语义单元上呈现显著正相关 (Spearman $\rho = 0.5971$, $p = 0.0146$)，证明二者对分类任务的关键信息评估高度一致，验证了基于注意力权重的差异化掩码策略的合理性。而在中性描述文本中，二者相关性显著减弱，符合模型对非关键文本的语义处理逻辑。

表 4-5 谣言检测消融实验结果

数据增强 (DA)	对比学习 (CL)	CEDADataset		EngDataset	
		Accuracy	F1	Accuracy	F1
0	0	96.8	96.8	96.1	96.0
1	0	95.4	95.3	95.2	95.2
0	1	97.2	97.1	97.4	97.4
1	1	97.7	97.7	98.5	98.5

注：1 表示启用对应模块，0 表示禁用对应模块




图 4-7 注意力分数与 SHAP 值的分布对比

4.3.2 低资源文本分类与情感分析实验

为验证 DMDA 在更多低资源场景下的泛化能力，本文在多语言、多领域的文本分类与情感分析基准数据集上开展补充实验，覆盖通用领域与特定疫情领域，验证方法的普适性。

数据集与基线方法

本文选取 4 个基准数据集开展实验，覆盖中、英、阿、法、西 5 种语言，具体如下：1. SMP2020-EWECT^①：中文微博疫情情感分析数据集，包含通用与疫情两个子集，6 类情感标签，存在显著的类别分布失衡问题。2. India-COVID-X：英语疫情推文情感分析数据集，来自 Kaggle 公开平台^②。3. SenWave^[92]：多语言疫情情感分析数据集，包含阿拉伯语、法语、西班牙语等低资源语言。4. SST-2^[93]：

^①<https://smp2020ewect.github.io>

^②<https://www.kaggle.com/datasets/surajkum1198/twitterdata>

表 4-6 全量数据模式下的情感分类实验结果

方法	策略	SMP2020-EWECT				India-COVID-X			
		Macro-F	Acc	ΔF	ΔAcc	Macro-F	Acc	ΔF	ΔAcc
原始 PLM	N/A	65.87%	79.17%	-	-	70.99%	70.63%	-	-
+ Resample	B/D	64.84%	78.17%	-1.03%	-1.00%	72.74%	72.57%	1.75%	1.94%
+ BT ^[94]	B/D	64.03%	77.93%	-1.84%	-1.24%	72.93%	72.79%	1.94%	2.16%
+ EDA ^[28]	B/D	65.88%	78.87%	0.01%	-0.30%	66.83%	66.41%	-4.16%	-4.22%
+ AEDA ^[29]	B/D	66.58%	79.50%	0.71%	0.33%	72.90%	72.89%	1.91%	2.26%
+ GENIUS ^[95]	B/D	64.27%	78.23%	-1.60%	-0.94%	72.84%	72.46%	1.85%	1.83%
+ DMDA (本文方法)	B/D	66.47%	79.43%	0.60%	0.26%	72.80%	72.57%	1.81%	1.94%
+ BT ^[94]	G/E	65.15%	77.93%	-0.72%	-1.24%	74.40%	74.30%	3.41%	3.67%
+ EDA ^[28]	G/E	50.12%	71.87%	-15.75%	-7.30%	74.15%	73.87%	3.16%	3.24%
+ GPT-2 ^[32]	G/E	65.06%	77.80%	-0.81%	-1.37%	69.55%	69.58%	-1.44%	-1.05%
+ AEDA ^[29]	G/E	65.81%	78.93%	-0.06%	-0.24%	75.49%	75.27%	4.50%	4.64%
+ GENIUS ^[95]	G/E	64.30%	78.07%	-1.57%	-1.10%	74.28%	74.08%	3.29%	3.45%
+ DMDA (本文方法)	G/E	67.98%	80.23%	2.11%	1.06%	74.65%	74.41%	3.66%	3.78%

通用领域英语情感分析基准数据集，用于少样本场景下的性能验证。

基线方法分为三类：经典数据增强方法（Resample、BT、EDA、AEDA）、先进生成式增强方法（GPT-2 SFT、GENIUS）、少样本 SOTA 方法（SSMBA、ALP、SE），所有基线均采用与 DMDA 相同的基础预训练模型，确保对比公平性。

实验设置

本文设置两种实验模式：全量数据模式与少样本模式，采用宏平均 F1 值（Macro-F1）与准确率（Acc）作为核心评价指标。同时对比两种增强策略：平衡生成策略（B/D，生成样本直至类别分布平衡）、固定数量生成策略（G/E，每个原始样本生成 4 个增强样本）。

结果与分析

全量数据模式下，SMP2020-EWECT 与 India-COVID-X 数据集的实验结果如表4-6所示。

实验结果表明：1. DMDA 在所有数据集、所有增强策略下均实现了稳定的性能增益，而多数基线方法在类别失衡的 SMP2020-EWECT 数据集上出现性能下降，充分验证了方法的鲁棒性。2. 在 G/E 固定数量生成策略下，DMDA 在 SMP2020-EWECT 数据集上取得了最优性能，较原始 PLM 基线的 Macro-F1 值提升 2.11 个百分点，显著优于所有基线方法，证明其在失衡场景下的优异适配能力。3. 基于规则的增强方法在分布均衡的数据集上有一定增益，但在失衡场




图 4-8 部分数据模式下 SenWave 数据集的性能表现

表 4-7 少样本设置下 SST-2 数据集的性能表现

数据集	#Shot	数据增强方法									
		N/A	+EDA [†] [28]	+BT [†] [94]	+SSMBA [†] [96]	+ALP [†] [97]	+SE [†] [98]	+GPT-2 [32]	+mixup [99]	+AWD [100]	+DMDA
SST-2	5	54.38	56.22	55.77	56.34	63.40	-	52.18	61.81	58.86	65.30
	10	61.82	53.96	62.05	59.05	69.72	57.56	54.17	61.55	64.62	68.29

注：[†] 表示结果引自原始文献，所有结果均为 5 次随机种子运行的平均值

景下易破坏核心语义，导致性能严重衰减；基于 GPT-2 的生成式增强缺乏标签约束，易出现语义漂移，增益效果不稳定。

部分数据模式下的实验结果如图4-8所示，DMDA 在低资源阿拉伯语、西班牙语、法语数据集上均实现了稳定的性能提升，仅需 50% 的训练数据，即可达到全量数据基线的性能水平，充分验证了方法在低资源场景下的强大适配能力。

少样本模式下，SST-2 数据集的 5-shot、10-shot 实验结果如表4-7所示，DMDA 在 5-shot 设置下取得了最优性能，在 10-shot 设置下取得了极具竞争力的结果，证明其在极端低资源场景下的有效性。

消融实验

为验证 DMDA 各核心模块的有效性，本文在 SMP2020-EWECT 与 India-COVID-X 数据集上开展消融实验，结果如表4-8所示。

结果表明，DMDA 的三个核心模块均对性能有正向贡献，其中数据增强模块是性能提升的核心基础，标签感知嵌入模块有效提升了生成样本的质量，噪声对抗训练模块则降低了低质量样本的负面影响，三个模块协同实现了最优性能。

表 4-8 情感分类任务消融实验结果

数据集	方法	Macro-F	Acc
SMP2020-EWECT	DMDA	0.6798	0.8023
	-w/o 数据增强 (DA)	0.6637	0.7957
	-w/o 标签感知嵌入 (LAP)	0.6671	0.7930
	-w/o 噪声对抗训练 (NRT)	0.6695	0.7963
India-COVID-X	DMDA	0.7465	0.7441
	-w/o 数据增强 (DA)	0.7206	0.7181
	-w/o 标签感知嵌入 (LAP)	0.7298	0.7268
	-w/o 噪声对抗训练 (NRT)	0.7361	0.7354

讨论与可视化

为了分析生成新伪样本的最佳掩码数量，本文在 India-COVID-X 数据集上进行了相关实验。在条件样本生成期间，本文收集了 32 个加噪步骤的掩码序列，并将其每 8 步划分为一组，随后评估不同掩码程度如何影响模型性能。




图 4-9 模型在使用来自不同掩码序列组生成的伪样本时的性能表现。

如图 4-9 所示，本文的观察结果呈现出明显的单峰趋势 (unimodal trend)。模型性能随着掩码程度的增加而提升，在第 4 组达到峰值，此后随着进一步的掩码而性能下降。这同样体现了多样性与一致性的权衡：较多的掩码标记能够创造出更多样化的样本，但过度多样化的样本可能会脱离原始的标签约束或领域知识。

为了探索生成的伪样本与原始样本之间的特征关系，本文进行了 2D t-SNE 可视化分析。图 4-10 显示，随着掩码程度的加深，伪样本逐渐脱离并偏离原始样本区域，表明了样本多样性的增加。




图 4-10 在 India-COVID-X 数据集上的 2D t-SNE 可视化。

4.4 本章小结

本章提出了基于扩散模型的标签感知数据增强框架，核心创新包括：其一，设计了注意力引导的动态噪声调度与标签感知嵌入协同的条件掩码机制，实现标签约束下的可控文本生成，解决了传统生成方法多样性与一致性难以平衡的核心痛点；其二，构建相似性加权筛选与对比学习驱动的噪声对抗训练模块，有效滤除低质量生成样本，提升了模型在长尾分布、少样本场景下的判别鲁棒性。

在汉、英、阿、德、法、西 6 种语言的 6 个基准数据集上的实验结果表明，DMDA 在谣言检测以及低资源情感分析任务上实现了稳定的性能增益，在极端少样本场景下仍具备优异的适配能力。本章的研究成果，为社交媒体场景下样本稀缺、类别失衡的文本分类任务提供了可落地的技术方案，也为同类型场景下的样本级数据增强研究提供了可借鉴的技术范式，与字符级、特征级增强方法共同构成了覆盖社交媒体文本分析全链条核心痛点的多粒度数据增强方法论体系。

第 5 章 基于最优传输与句法图网络的特征级数据增强方法

5.1 研究动机

社交媒体细粒度情感分析中，特征层面的核心质量缺陷表现为**方面词与观点词的深层语义错位、长距离语义依赖捕捉不足以及非规范文本的特征鲁棒性差**。在方面级情感分析（Aspect-based Sentiment Analysis, ABSA）任务中，口语化表达、句式碎片化、隐式情感等问题导致方面术语与其对应的观点词之间常存在非线性、长距离的语义关联，传统方法难以实现精准对齐。针对这一痛点，本章以**特征级数据增强与语义对齐**为技术路径，开展独立的方法研究，旨在从特征分布层面优化语义匹配能力，为细粒度情感挖掘提供鲁棒的语义表示。该研究是全文多粒度数据增强方法论体系中，与字符级、样本级增强方法形成互补闭环的最高层次，共同覆盖社交媒体文本分析从输入规范化、样本分布重构到细粒度语义挖掘的全链条需求。

方面级情感分析旨在识别文本中针对特定方面的情感极性，其核心挑战在于如何建模方面术语与上下文观点词之间的语义依赖关系。如图5-1所示，模型需要精准关联方面术语“performance”与观点词“quite good”、方面术语“cooling”与观点词“not keep up”，才能完成正确的极性判定。在社交媒体非规范文本场景中，口语化表达、长距离嵌套句法、隐式情感等问题极易导致方面与观点的语义错位，直接制约细粒度情感分析的精度。




图 5-1 依存句法树与方面-观点关联示例

现有 ABSA 方法主要分为三类，均在社交媒体复杂场景下面临难以突破的

局限：其一，基于注意力机制的方法通过点积相似度计算语义关联，但易受无关词汇干扰，线性相似度难以捕捉非线性语义依赖^[56,58]；其二，基于图神经网络（GNN）的方法依托依存句法树构建静态图结构，无法适配非规范文本的句法灵活性，易因解析误差引入级联错误^[61,62,101]；其三，结构增强混合模型虽融合句法与语义特征，但缺乏全局分布级的语义对齐机制，在长距离依赖和高噪声场景下性能衰减严重^[60,63]。

针对上述局限，本章引入最优传输（Optimal Transport, OT）理论，提出**最优传输增强句法-语义图网络（Optimal Transport-Enhanced Syntactic-Semantic Graph Network, OTESGN）**，将方面-观点的语义匹配建模为特征分布间的传输代价最小化问题，实现特征层面的全局鲁棒语义增强与对齐。模型核心设计包括：利用 BERT 提取上下文感知词嵌入，依托依存句法构建多粒度掩码矩阵提供结构先验；设计句法-语义协同注意力（Syntactic-Semantic Collaborative Attention, SSCA）机制，融合句法图感知注意力（Syntactic Graph-Aware Attention, SGAA）与语义最优传输注意力（Semantic Optimal Transport Attention, SOTA），同步捕捉显式句法关联与隐式分布级语义匹配；通过自适应注意力融合模块动态平衡双路特征，结合对比正则化提升抗噪声能力。本章在三个 ABSA 基准数据集上完成全面验证，并拓展至突发公共卫生事件舆情中的目标实体负面情感识别场景，充分验证了方法的有效性、鲁棒性与泛化能力。

本章的核心贡献总结如下：

（1）提出面向 ABSA 任务的最优传输增强句法-语义图网络 OTESGN，首次将最优传输理论与句法图网络深度融合，解决了方面-观点语义错位与长距离依赖捕捉不足的核心问题，实现了特征层面的鲁棒语义增强与精准对齐。

（2）设计句法-语义协同注意力机制，通过多粒度句法掩码约束的结构感知注意力与基于 Sinkhorn 求解的最优传输分布对齐注意力双路协同，兼顾了显式句法先验与隐式全局非线性语义关联的建模。

（3）在 Rest14、Laptop14、Twitter 三个基准数据集上完成系统验证，实验结果表明 OTESGN 显著优于 SOTA 基线模型；负面实体情感识别实验进一步验证了方法在突发公共事件舆情细粒度分析中的落地价值，完善了全文方法论体系的真实场景适配能力。

5.2 融合最优传输与图网络的特征级数据增强方法

如图 5-2 所示，本章提出的 OTESGN 以文本-方面对作为输入，通过 BERT 编码层获得上下文语义表示，并进一步从句法结构和语义分布两个角度增强方面级情感特征。具体而言，句法图感知注意力利用依存句法掩码约束无关键词之间的注意力传播，从结构层面降低噪声干扰；语义最优传输注意力则将上下文词与方面术语之间的匹配建模为分布对齐问题，以捕捉传统点积注意力难以刻画的非线性语义关联。随后，模型通过自适应融合机制整合句法分支和语义分支，并在渐进式方面感知学习模块中进行多跳信息传播，最终得到用于情感分类的方面表示。整体框架从特征层面对文本表示进行结构化增强，有助于缓解方面词与观点词之间的语义错位问题。

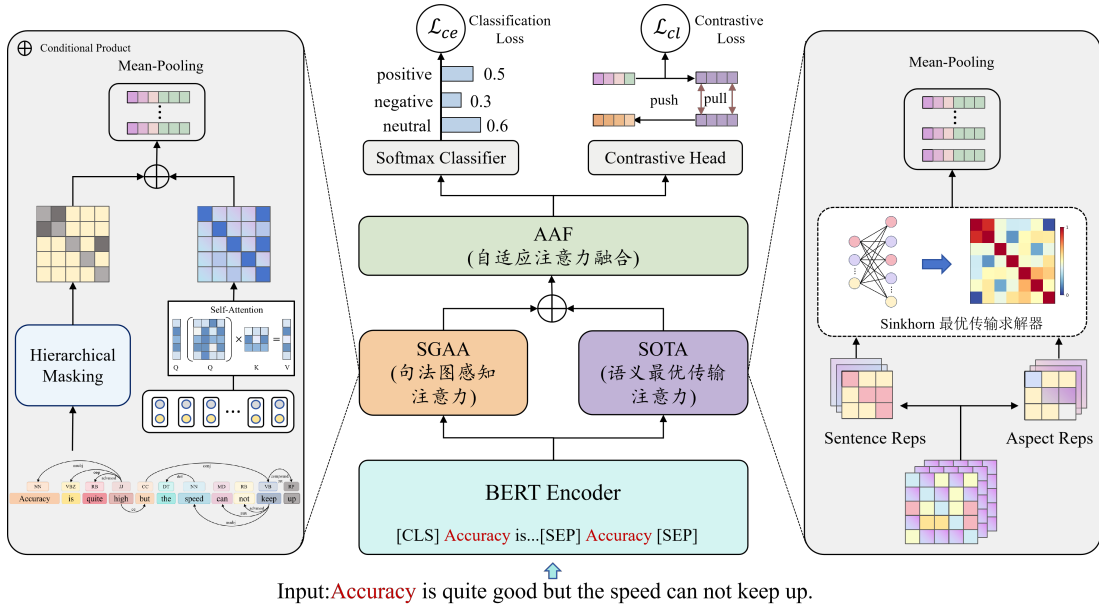


图 5-2 OTESGN 整体架构示意图

5.2.1 输入编码层

给定文本-方面对 (s, a) ，其中文本序列 $s = \{w_1, w_2, \dots, w_n\}$ 包含 n 个 token，方面术语 $a = \{a_1, a_2, \dots, a_m\}$ 是文本 s 的连续子序列 ($1 \leq m \leq n$)。本文采用预训练 BERT 模型作为编码器，输入格式标准化为：[CLS] + Tokenize(s) + [SEP]

+ Tokenize(a) + [SEP]。通过 BERT 编码器得到完整序列的上下文隐藏表示：

$$H = \text{BERT}_{\text{Encoder}} \left([w_{[\text{CLS}]}, w_1, \dots, w_n, w_{[\text{SEP}]}, w_{a_1}, \dots, w_{a_m}, w_{[\text{SEP}]}] \right) \quad (5-1)$$

其中 $H = \{h_0, h_1, \dots, h_{n+1}, h_{n+2}, \dots, h_{n+m+2}\} \in \mathbb{R}^{(n+m+3) \times d}$, d 为隐藏层维度。从中提取文本对应的隐藏表示 $H^s = \{h_1, h_2, \dots, h_n\} \in \mathbb{R}^{n \times d}$, 以及方面术语对应的隐藏表示 $h_a = \{h_{\text{pos}(a_1)}, h_{\text{pos}(a_2)}, \dots, h_{\text{pos}(a_m)}\} \in \mathbb{R}^{m \times d}$, 其中 $\text{pos}(a_j)$ 为方面术语在文本序列中的索引。

5.2.2 句法-语义协同注意力

方面术语的情感极性判定, 同时依赖于句法结构约束与上下文语义依赖。基于此, 本文提出句法-语义协同注意力机制, 融合句法图感知注意力与语义最优传输注意力两个正交分支, 分别捕捉显式句法关联与隐式分布级语义对齐, 通过加权融合实现方面-观点的精准匹配。

(1) 句法图感知注意力

针对传统注意力易受无关词汇噪声干扰的问题, 本文提出句法图感知注意力模块, 将依存句法约束与多头自注意力深度融合, 通过多粒度句法掩码限制无关词之间的注意力传播, 同时自适应加权依存关联强度, 在保留句法先验的同时捕捉细粒度语义关联。

首先, 通过 Stanford CoreNLP 构建文本的依存句法树, 将其转化为无向图计算节点间的最短依存距离, 节点 w_i 与 w_j 之间的距离 $D(i, j)$ 定义为最短路径中的边数。基于最短依存距离, 构建多粒度掩码矩阵集合 $M = \{M^1, M^2, \dots, M^p\}$, 其中 p 为注意力头数量, 第 k 个头的掩码矩阵定义为:

$$M_{ij}^k = \begin{cases} 0, & \text{if } D(i, j) \leq \tau^k \\ -\infty, & \text{otherwise} \end{cases} \quad (5-2)$$

其中 $\tau^k \in [1, p]$ 为第 k 个注意力头的句法距离阈值, 线性设置为 $\tau^k = k$, 实现从局部到全局的多粒度句法约束。掩码值为 0 允许句法相关词之间的注意力计算, $-\infty$ 则抑制无关词对的注意力传播, 从结构层面过滤噪声。

基于多粒度句法掩码，构建句法约束的多头自注意力机制：

$$Q = H^s W_Q, \quad K = H^s W_K, \quad (5-3)$$

$$A_{SG}^k = \text{softmax} \left(\frac{QK^T}{\sqrt{d}} + M^k \right), \quad (5-4)$$

其中 $W_Q, W_K \in \mathbb{R}^{d \times d}$ 为可学习权重矩阵， $k \in [1, p]$ 为注意力头索引。每个注意力头对应不同的句法粒度，实现全局依存建模与句法约束的有机结合。

(2) 语义最优传输注意力

针对传统点积注意力无法捕捉非线性语义关联、易出现语义错位的问题，本文提出 SOTA 模块，将方面-观点的语义对齐建模为最优传输问题，通过最小化语义传输代价，实现上下文词（源分布）到方面术语（目标分布）的全局软对齐，精准捕捉复杂场景下的非线性语义依赖，核心流程如图5-3与图5-4所示。




图 5-3 语义距离建模示意图

语义代价矩阵构建

首先通过平均池化聚合方面术语的隐藏表示，得到方面语义中心：

$$h'_a = \frac{1}{m} \sum_{j=1}^m h_{pos(a_j)}. \quad (5-5)$$

基于余弦距离构建语义传输代价矩阵，量化上下文词与方面语义中心的语义差异：

$$\text{Cost} = 1 - \frac{H^s (h'_a)^T}{\|H^s\| \cdot \|h'_a\|}, \quad (5-6)$$

其中余弦距离越小，代表语义相关性越高，对应的传输代价越低。

源分布与目标分布定义

为满足最优传输的概率分布约束，将上下文词与方面术语分别建模为概率

分布：

$$\begin{aligned}\mu &= \text{softmax}(F_\mu(H^s)), \\ \nu &= [1] \in \Delta^1,\end{aligned}\tag{5-7}$$

其中 F_μ 为线性层，将文本隐藏表示 H^s 投影为一维向量后经 softmax 归一化，确保 $\sum \mu = 1$ ；目标分布 ν 固定为单位向量，对应聚合后的方面语义中心。




图 5-4 语义最优传输求解示意图

基于 Sinkhorn 算法的最优传输求解

本文采用带熵正则化的 Sinkhorn 算法高效求解最优传输方案，为每个注意力头分配专属的正则化系数 ϵ^k ，实现不同粒度的对齐效果：

$$K^k = \exp\left(-\frac{\text{Cost}}{\epsilon^k}\right),\tag{5-8}$$

其中 K^k 为吉布斯核， ϵ^k 控制传输方案的锐度，较小的值强调精准对齐，较大的值促进平滑分布。初始化对偶变量 $u \in \mathbb{R}^n$ 、 $v \in \mathbb{R}^1$ 为全 1 向量，通过迭代更新求解最优对偶变量：

$$u \leftarrow \frac{\mu}{K^k v}, \quad v \leftarrow \frac{\nu}{(K^k)^T u}.\tag{5-9}$$

迭代收敛后得到最优传输方案：

$$\pi^k = \text{diag}(u)K^k v,\tag{5-10}$$

其中 π^k 即为第 k 个注意力头的语义注意力权重，量化了每个上下文词对方面术语的语义贡献度，实现全局级的软对齐。

自适应注意力融合

为整合句法结构信息与语义分布信息，对 SGAA 与 SOTA 的输出进行自适应加权融合。首先将 SOTA 输出的一维注意力权重 π^k 按列广播为矩阵形式 $A_{OT-mat}^k \in \mathbb{R}^{n \times n}$ ，确保与 SGAA 输出的注意力矩阵维度匹配。

每个注意力头的融合公式为：

$$A^k = \beta \cdot A_{SG}^k + (1 - \beta) \cdot A_{OT-mat}^k, \quad (5-11)$$

其中 $\beta \in [0, 1]$ 为可学习参数（初始化为 0.5），动态平衡句法分支与语义分支的贡献。最终的融合注意力矩阵为所有注意力头的平均值：

$$A = \frac{1}{p} \sum_{k=1}^p A^k. \quad (5-12)$$

5.2.3 渐进式方面感知学习

融合后的注意力矩阵 A 整合了句法与语义双路对齐信息，通过多层残差连接实现多跳依赖的渐进式传播，避免多层传播后的特征退化。以 BERT 输出的文本隐藏表示 H^s 作为初始隐藏状态 h^0 ，第 l 层的特征更新规则为：

$$h^l = h^{l-1} + \sigma(Ah^{l-1} + b^l), \quad (5-13)$$

其中 b^l 为偏置项， σ 为 ReLU 激活函数，确保非负特征更新。

提取最后一层输出中方面术语对应的节点表示，经平均池化得到方面的最终聚合表示：

$$h_a^{pool} = \frac{1}{m} \sum_{j=1}^m h_{pos(a_j)}^L, \quad (5-14)$$

其中 L 为网络总层数。最终将聚合表示输入全连接层与 softmax 函数，得到情感极性的预测分布：

$$p(c|a) = \text{softmax}(W_p h_a^{pool} + b_p), \quad (5-15)$$

其中 W_p, b_p 为全连接层的可学习参数， c 为情感极性类别。

5.2.4 多目标训练

为同时优化情感分类精度与特征表示的判别性，本文构建了交叉熵损失与对比学习损失结合的多目标训练框架，整体损失函数为：

$$\mathcal{L}(\theta) = \mathcal{L}_e(\theta) + \lambda \mathcal{L}_c(\theta), \quad (5-16)$$

其中 λ 为超参数，平衡两项损失的权重。

交叉熵损失 $\mathcal{L}_e(\theta)$ 监督情感极性的分类任务：

$$\mathcal{L}_e(\theta) = - \sum_{(s,a) \in \mathcal{D}} \sum_{c \in C} y_c \log p(c|a), \quad (5-17)$$

其中 $\mathcal{D}$ 为训练集的所有文本-方面对， C 为情感极性类别集合， $y_c \in \{0, 1\}$ 为真实标签的 one-hot 编码。

对比学习损失 $\mathcal{L}_c(\theta)$ 对特征空间施加一致性约束，鼓励相同情感标签的样本特征相互靠近，不同标签的样本特征相互远离：

$$\mathcal{L}_c(\theta) = -\frac{1}{K} \sum_{i \in \mathcal{I}} \log \frac{\exp(\text{sim}(h_{a_i}^{pool}, h_{a_i^+}^{pool})/\tau)}{\sum_{j \in \mathcal{I}} \exp(\text{sim}(h_{a_i}^{pool}, h_{a_j}^{pool})/\tau)}, \quad (5-18)$$

其中 K 为批次大小， $\mathcal{I}$ 为批次内样本索引集， $\text{sim}(x, y) = \frac{x^T y}{\|x\| \cdot \|y\|}$ 为余弦相似度函数， $h_{a_i^+}^{pool}$ 为与样本 i 同标签的正样本， $h_{a_j}^{pool}$ 为不同标签的负样本， τ 为温度超参数。

5.3 实验与分析

为全面验证本章提出的 OTESGN 模型的核心创新有效性、复杂场景鲁棒性与真实舆情场景落地价值，本章设计两组递进式实验开展系统验证：第一组为**方面级情感分析主任务实验**，在 3 个 ABSA 领域权威基准数据集上开展对比实验、消融实验与可视化分析，验证模型核心模块的性能优势与作用机制；第二组为**目标实体负面情感识别拓展实验**，将核心方法迁移至突发公共卫生事件舆情的真实场景，验证方法在非规范、强噪声、分布不均衡的真实社交媒体数据中的适配能力与实用价值。

5.3.1 方面级情感分析主任务实验

实验数据集

本文选取 ABSA 领域 3 个权威基准数据集开展核心实验, 包括 SemEval 2014 Task4 发布的餐厅数据集 (Rest14)、笔记本电脑数据集 (Laptop14)^[102], 以及社交媒体推文构建的 Twitter 数据集^[103]。所有数据集均通过 Stanford CoreNLP 构建依存句法树, 数据集的核心统计信息如表5-1所示。

表 5-1 ABSA 基准数据集核心统计信息

数据集	平均依存距离 $\pm$ 标准差	依存距离范围	样本数量
Laptop14	3.21 ± 0.85	[1.00, 8.68]	1863
Rest14	3.17 ± 0.85	[0.00, 8.43]	2579
Twitter	3.41 ± 0.98	[0.50, 11.97]	6728

可以看出, Twitter 数据集的平均依存距离更高、范围更广, 反映出社交媒体口语化文本的句法复杂性更高, 对模型的抗噪声能力与鲁棒性提出了更高要求。

对比基线模型

为全面评估 OTESGN 的性能优势, 本文选取 ABSA 领域 5 大类代表性模型作为基线, 与前序章节的基线分类逻辑保持统一:

- **传统神经网络模型**: RAM^[58]、TNet^[56], 基于循环神经网络与卷积网络建模方面感知注意力, 是 ABSA 任务的经典基线。
- **预训练语言模型基线**: BERT-base^[7], 通过统一框架编码文本与方面术语, 作为预训练模型的基础对照。
- **基于图的句法建模模型**: ASGCN^[61]、SSEGCN^[101]、DGEDT^[60]、CSADGCN^[62]、DualGCN^[70]、KDGN^[63]、RDGCN^[66], 依托依存句法图与图神经网络建模句法关联, 是当前 ABSA 领域的主流技术路线。
- **对比学习增强模型**: SVCCL^[67]、APSCCL^[46]、CADA^[47], 通过对比损失增强特征表示的判别性与鲁棒性。
- **结构增强混合模型**: YORO^[64]、IDGNN^[65]、HPEP-GCN^[104]、LWEDA-ACT^[105], 融合多类型特征与结构先验, 是近年来 ABSA 领域的 SOTA 模型。

训练配置与评价指标

本文采用**准确率 (Accuracy)** 与**宏平均 F1 值 (Macro-F1)** 作为核心评价指标，全面评估模型的整体分类性能与类别不平衡场景下的鲁棒性。采用 BERT-base-uncased 作为预训练编码器，最大输入长度设置为 100，注意力层隐藏维度为 200，多头注意力头数为 5，网络层数为 6；优化器采用 Adam，批次大小为 32，学习率为 $2e-5$ ，dropout 比率为 0.1；SOTA 模块中，Sinkhorn 迭代次数为 50，熵正则化系数为 1。所有实验均独立运行 5 次，取平均值作为最终结果，确保实验的公平性与可复现性。

主要实验结果与分析

OTESGN 与基线模型在 3 个基准数据集上的实验结果如表5-2所示。

表 5-2 OTESGN 与基线模型的实验结果对比 (单位: %)

模型	Rest14		Laptop14		Twitter	
	Acc	F1	Acc	F1	Acc	F1
RAM (2017)	80.23	70.80	74.49	71.35	69.36	67.30
TNet (2018)	80.69	71.27	76.54	71.75	74.90	73.60
BERT (2019)	85.97	80.09	79.91	76.00	75.92	75.18
ASGCN (2019)	80.77	72.02	75.55	71.05	72.15	70.40
DGEDT (2020)	86.30	80.00	79.80	75.60	77.90	75.40
DualGCN (2021)	87.13	81.16	81.80	78.10	77.40	76.02
SSEGCN (2022)	87.31	81.09	81.01	77.96	77.40	76.02
RDGCN (2024)	<u>87.49</u>	81.16	<u>82.12</u>	78.29	<u>78.29</u>	77.14
CSADGCN (2024)	87.40	81.56	<u>82.12</u>	<u>79.22</u>	76.81	75.67
APSCL (2023)	86.86	81.28	81.02	78.47	-	-
SVCCL (2025)	86.34	80.16	81.35	77.76	76.72	75.92
CADA (2025)	87.14	81.26	80.88	77.71	-	-
KDGN (2023)	87.01	<u>81.94</u>	81.32	77.59	77.64	75.55
YORO (2024)	87.14	81.83	81.82	78.32	-	-
IDGNN (2024)	87.25	81.16	81.12	78.46	76.70	75.90
HPEP-GCN (2025)	86.86	80.65	81.96	79.10	-	-
LWEDA-ACT (2025)	88.11	82.12	81.17	78.29	78.17	<u>77.16</u>
OTESGN	87.21	80.47	82.86	80.52	78.75	78.17

从实验结果可得出以下核心结论：

- (1) **整体性能优势**：OTESGN 在 Laptop14 和 Twitter 数据集上均取得了 SOTA 性能，Macro-F1 值较最强基线分别提升 1.30 和 1.01 个百分点，在 Rest14 数据集上也取得了极具竞争力的结果，充分验证了方法的有效性。
- (2) **预训练基线对比**：相较于纯 BERT 基线，OTESGN 在 Laptop14 和 Twitter 数据集上的 Macro-F1 值分别提升 4.52 和 3.00 个百分点，证明句法-语义协同建模与最优传输全局对齐，能显著提升方面-观点的匹配精度，实现有效的特征级增强。
- (3) **图模型基线对比**：相较于传统基于图的模型，OTESGN 在句法最复杂的 Twitter 数据集上提升幅度最大，证明最优传输的全局分布对齐机制，能有效缓解社交媒体非规范文本的句法解析误差带来的级联错误，具备更强的抗噪声能力。
- (4) **对比学习基线对比**：相较于对比学习基线模型，OTESGN 仍保持显著的性能优势，证明最优传输增强的语义对齐，能进一步细化特征空间的判别性，与对比学习形成协同增益，实现更鲁棒的特征表示学习。

模块有效性消融实验

为验证 OTESGN 各核心模块的有效性，本文在 3 个数据集上开展逐一组件消融实验，结果如表5-3所示。

表 5-3 OTESGN 消融实验结果（单位：%）

模型变体	Rest14		Laptop14		Twitter	
	Acc	F1	Acc	F1	Acc	F1
OTESGN (完整)	87.21	80.47	82.86	80.52	78.75	78.17
w/o 句法掩码 (SM)	82.91	76.00	78.81	78.23	71.62	69.20
w/o 句法注意力 (SGAA)	83.94	77.35	<u>81.66</u>	<u>79.41</u>	<u>76.37</u>	<u>74.15</u>
w/o 最优传输注意力 (SOTA)	80.60	71.52	79.93	76.54	73.25	72.01
w/o SGAA+SOTA	81.19	74.45	77.58	75.17	70.15	68.07
w/o 对比学习 (CL)	<u>85.74</u>	<u>79.26</u>	81.27	78.26	75.19	73.52

消融实验结果表明：

- (1) 移除 SOTA 模块后，模型性能出现最显著的跨数据集下降，证明最优传输语义对齐是 OTESGN 的核心创新点，有效解决了传统方法的语义错位核心痛点，是特征级增强的核心支撑。
- (2) 移除句法掩码与 SGAA 模块后，模型性能大幅衰减，尤其在 Twitter 数据集上下降最为明显，证明句法先验能有效过滤噪声，是语义对齐的重要结构支撑。
- (3) 同时移除 SGAA 与 SOTA 模块后，模型性能出现断崖式下降，证明双路协同的注意力机制形成了显著的互补增益，二者缺一不可，共同实现了句法结构与语义分布的协同建模。
- (4) 移除对比学习模块后，模型性能出现稳定下降，在 Twitter 数据集上降幅最大，证明对比正则化能有效提升模型在高噪声场景下的特征判别性与鲁棒性，与核心模块形成协同增益。

可学习融合参数 β 的训练演变过程如图5-5所示，参数最终收敛至 0.10-0.30 区间，进一步验证了 SOTA 模块在模型中的核心贡献，与消融实验结果完全一致。




图 5-5 可学习融合参数 β 的训练演变过程

案例分析与可视化分析

本文对错误分类样本进行案例分析，结果如表5-4所示。模型的主要错误模式为将隐式情感表达误分类为中性，以及嵌套句法结构中的情感反转误判，这也

是当前 ABSA 领域的共性挑战。未来可通过融入常识知识、反讽识别机制进一步优化模型的隐式情感捕捉能力。

表 5-4 错误分类案例分析

真实标签	预测结果	文本
positive	neutral	what is the best harry potter movie for you?
negative	neutral	nicolas cage is selling another castle, maybe he should be a real estate.
negative	positive	i wonder if people like the wiz, taylor swift , and bieber will be popular in 5 years (i hope not)

词级注意力热图可视化结果如图5-6所示，SGAA 模块能有效聚焦与方面术语句法邻近的观点词，而 SOTA 模块能精准捕捉句法距离较远但语义高度相关的情感词，最终融合的注意力整合了二者的优势，实现了方面-观点的精准对齐，直观验证了双路协同机制的有效性。




图 5-6 词级注意力热图

超参数敏感性分析结果如图5-7与图5-8所示，熵正则化系数 ϵ 、dropout 比率、网络层数均存在最优区间，验证了模型超参数设置的合理性，同时表明模型在合理的超参数范围内能保持稳定的性能，具备良好的鲁棒性。




图 5-7 熵正则化系数 ϵ 对 OT 注意力分布的影响




图 5-8 超参数敏感性分析结果

5.3.2 目标实体负面情感识别实验

为进一步验证本章提出的特征级增强与句法-语义感知方法在突发公共事件等真实复杂舆情场景中的落地价值，将 OTESGN 的核心设计拓展至**目标实体负面情感识别任务**（拓展模型记为 TENS-DSA），针对疫情舆情场景下的细粒度实体情感分析开展验证，与全文聚焦的社交媒体舆情分析核心场景形成闭环。

实验数据集与评价指标

本文采用医学专业人员标注的 COVID-19 领域数据集 METS-CoV-TSA^[106]开展实验，该数据集标注了“人”“组织”“药物”“疫苗”四类目标实体，存在显著的情感分布不平衡问题，中性样本占主导，负面情感样本占比低，与真实舆情场景高度契合，数据集标签分布如图5-9所示。




图 5-9 METS-CoV-TSA 数据集的标签分布统计

由于本研究重点关注舆情场景中高价值负面情感的识别性能，且数据集存在显著的分布不平衡问题，实验采用**准确率 (Acc)**、**宏平均 F1 值 (Macro-F1)**、**负面情感 F1 值 (Neg_F1)** 与**负面情感召回率 (Neg_R)** 作为核心评价指标。

对比基线模型与实验设置

本文选取 9 种细粒度情感分析领域的代表性模型作为基线，覆盖了从传统注意力模型、图神经网络模型到领域适配模型的主流技术路线：

- **IAN^[54]**：交互式注意力网络，通过双并行注意力模块实现目标与上下文的双向语义关联建模。
- **TNet-LF^[59]**：通过变换网络与堆叠结构增强目标相关情感信息的捕捉能力，解决长距离依赖问题。
- **ASGCN^[61]**：基于句法依赖树构建图结构，通过图卷积网络实现方面相关语义提取。
- **kumaGCN^[107]**：通过潜在变量自动学习目标特定的图结构，缓解预定义句法树的局限。
- **dotGCN^[108]**：通过离散优化诱导观点树，聚焦目标与观点词的情感关联，减少冗余句法干扰。
- **SSEGCN^[101]**：句法与语义双增强图卷积网络，通过双分支模块实现句法与语义特征的协同建模。

- **MFMCGCN**^[109]: 多特征融合与多通道图卷积网络，整合多类型特征提升模型性能。
- **RDGCN**^[66]: 通过强化学习优化依赖图结构，修正初始句法图偏差，增强容错能力。
- **ASHGCN**^[110]: 面向 COVID-19 领域的细粒度情感分析模型，通过异质图卷积与领域自适应预训练提升适配能力。

实验环境与核心参数设置如下：操作系统为 Ubuntu 20.04.6 LTS，硬件为 NVIDIA GeForce RTX 3090 24G 显卡，开发语言为 Python 3.8，深度学习框架为 PyTorch 2.3.0，搭配 CUDA 11.8 加速计算；核心参数设置如表5-5所示。

表 5-5 TENS-DSA 任务核心参数设置

参数设置	参数值
句法注意力权重 α	0.8
R-Drop 系数 r_{drop_coeff}	0.5
训练迭代次数 epoch	8–15
批次大小 batch_size	16
学习率 learning_rate	2e-5
优化器 optimizer	Adam
预训练模型隐藏层大小 hidden_size	768
非对称损失温度系数 β	0.1

实验结果与分析

(1) 整体性能对比实验

TENS-DSA 与基线模型的整体性能对比结果如表5-6所示。

表 5-6 目标实体情感分类对比实验结果（单位：%）

模型	Person		Organization		Drug		Vaccine		All	
	ACC	F1	ACC	F1	ACC	F1	ACC	F1	ACC	F1
IAN (2017)*	52.81	32.75	67.68	36.70	59.73	25.22	77.22	30.88	62.59	34.62
TNet-LF (2018)*	58.07	51.17	63.16	47.68	60.00	46.30	68.52	41.57	61.71	50.80
ASGCN (2019)*	58.89	42.48	63.89	39.73	58.41	31.12	72.66	38.24	62.69	41.32
kumaGCN (2020)*	66.28	61.84	72.86	58.01	63.61	49.67	76.88	50.17	69.59	59.91
dotGCN (2022)*	67.06	62.56	<u>73.33</u>	58.34	63.35	50.20	77.55	45.98	70.09	<u>60.05</u>
SSEGCN (2022)	68.17	64.74	74.02	64.61	59.91	49.72	75.95	<u>51.98</u>	70.42	57.99
MFMCGCN (2023)	67.74	63.96	72.50	53.57	<u>64.44</u>	51.26	<u>78.78</u>	38.81	71.42	59.86
RDGCN (2024)	63.24	56.74	69.29	42.56	49.34	36.97	74.68	35.77	63.06	46.08
ASHGCN (2025)	64.89	60.39	69.82	53.40	62.56	<u>57.06</u>	80.59	51.83	65.77	55.87
TENS-DSA	<u>68.11</u>	<u>64.04</u>	72.70	<u>59.24</u>	65.64	58.07	77.97	55.08	<u>71.05</u>	62.14

注：* 表示实验数据源自对应数据集的原始发表论文，为原文发布的基准结果

从结果可以看出，TENS-DSA 在整体 Macro-F1 值上较最强基线提升 2.09 个百分点，在所有目标实体类别上的 F1 值均达到最优或次优水平，尤其在“疫苗”类别上的 F1 值较基线提升 3.10 个百分点，展现出在专业领域舆情场景下的优异适配能力。与领域适配模型 ASHGCN 相比，TENS-DSA 在除“药物”实体外的其他三类目标实体上均表现出显著性能提升，F1 值平均提升近 5%，验证了本文方法在真实舆情场景下的泛化能力。

（2）模块有效性消融实验

为验证拓展模型各核心模块的贡献，本文开展逐一组件消融实验，重点关注各模块对负面情感识别性能的影响，结果如表5-7所示。

表 5-7 负面实体情感识别实验消融实验结果（单位：%）

模型变体	Person			Organization			Drug			Vaccine			All		
	F1	Neg _{F1}	Neg _R	F1	Neg _{F1}	Neg _R	F1	Neg _{F1}	Neg _R	F1	Neg _{F1}	Neg _R	F1	Neg _{F1}	Neg _R
TENS-DSA	<u>64.04</u>	71.21	74.60	<u>59.24</u>	55.26	63.64	58.07	42.86	40.53	55.08	41.17	51.85	<u>62.14</u>	62.08	67.06
w/o 数据增强 (DA)	62.56	64.14	61.63	51.78	57.14	52.55	47.75	25.84	19.05	53.39	38.46	29.41	61.29	60.87	59.18
w/o 句法注意力 (SA)	61.02	65.67	59.79	55.15	57.14	50.51	54.71	25.81	19.05	53.88	43.64	35.29	61.56	60.79	58.31
w/o 最优传输注意力 (OA)	58.02	58.54	50.79	51.90	55.10	49.49	43.58	22.22	17.29	50.10	<u>42.15</u>	38.24	56.41	49.57	41.98
w/o 对比学习 (CL)	62.37	67.20	66.14	53.09	54.74	47.37	47.62	28.25	20.81	<u>54.91</u>	37.50	26.47	60.41	58.37	57.43
w/o 非对称损失 (AL)	64.87	<u>69.71</u>	<u>68.78</u>	65.08	54.38	<u>54.55</u>	<u>56.70</u>	<u>41.03</u>	<u>38.10</u>	53.37	41.79	<u>41.18</u>	64.49	<u>60.97</u>	<u>62.39</u>

实验结果表明，各模块对模型性能均具有正向贡献，移除相关组件均会导致评价指标出现不同程度的下降，尤其在负面情感识别任务中表现出一致性衰减。其中，移除最优传输注意力（OA）模块后各项指标降幅最为显著，表明该模块是模型捕捉上下文依赖与隐式负面语义的核心支撑；非对称加权损失（AL）模块在数据不平衡场景下，能显著提升模型对少数类负面情感的捕捉能力；数据增强（DA）、句法注意力（SA）、对比学习（CL）模块均对模型的鲁棒性与负面情感召回率有显著提升，与主实验结论完全一致。

（3）负面情感识别效果分析

为直观展现模型对高价值负面情感的识别效果，本文选取强基线模型 SSEGCN 与 ASHGCN 进行对比，结果如图5-10所示。




图 5-10 TENS-DSA 与强基线模型的负面情感识别效果对比

结果表明，TENS-DSA 在所有实体类别上的负面情感 F1 值与召回率均取得最优表现，整体 Neg_F1 与 Neg_R 较最强基线分别提升 3.38 和 10.50 个百分点。尤其在情感表达隐晦、分布不均衡的“药物”“疫苗”类别上，基线模型性能出现显著衰减，而 TENS-DSA 仍保持稳定的优异表现，充分验证了本文方法在低资源、高噪声、隐式情感表达的真实舆情场景下的鲁棒性，为突发公共事件的舆情细粒度分析提供了可落地的技术方案。

5.4 本章小结

本章针对全文提出的社交媒体文本**深层语义错位**、**方面-观点长距离依赖捕捉不足**核心瓶颈，聚焦细粒度情感分析任务，开展了特征级数据增强与语义对齐

方法的独立平行研究，是全文统一研究主线下，针对特征层语义匹配缺陷的专属解决方案，与第三章字符级、第四章样本级增强方法共同构成了覆盖社交媒体文本分析全链条核心痛点的多粒度数据增强方法论体系。

本章提出了最优传输增强句法-语义图网络 OTESGN，核心创新包括：其一，首次将最优传输理论与句法图网络深度融合，把方面-观点的语义匹配建模为特征分布间的最优传输问题，突破了传统线性对齐方法的局限，实现了特征层面的全局鲁棒语义增强与精准对齐；其二，设计了句法-语义协同注意力机制，通过多粒度句法掩码约束的结构感知注意力，与基于 Sinkhorn 求解的最优传输注意力双路协同，同步捕捉显式句法先验与隐式非线性语义关联；其三，通过对比正则化与多目标训练框架，进一步提升了模型在高噪声、非规范文本场景下的判别鲁棒性。

本章在 3 个 ABSA 基准数据集上完成了系统验证，实验结果表明，OTESGN 在 Laptop14 和 Twitter 数据集上取得了 SOTA 性能，Macro-F1 值较最强基线分别提升 1.30 和 1.01 个百分点，消融实验与可视化分析进一步验证了各核心模块的有效性。面向突发公共卫生事件舆情的拓展实验表明，本文方法在真实场景下的目标实体负面情感识别任务中展现出极强的适配能力，显著提升了隐式负面情感的识别精度，具备良好的落地应用价值。

本章的研究成果，为社交媒体非规范文本的细粒度语义对齐提供了全新的技术思路，完善了全文多粒度数据增强方法论体系在特征层面的理论与实证支撑，与第三、四章的研究成果共同形成了针对社交媒体文本分析三大核心瓶颈的完整解决方案，实现了从输入规范化、样本分布重构到细粒度语义挖掘的全链条技术覆盖。

第6章 总结与展望

6.1 全文总结

本文以**数据增强**为手段，针对社交媒体文本分析中的字符级噪声、样本级失衡和特征级错位三大质量瓶颈，开展了三项平行研究，分别对应低资源语言拼写纠错、突发公共卫生事件谣言检测和低资源情感分析、方面级情感分析三个典型任务场景，形成了覆盖字符—样本—特征三个粒度的递进式研究成果。

在字符级，本文提出融合规则与大语言模型协同的字符级数据增强方法。通过规则构建混淆集覆盖常见错误，利用指令微调的 Qwen 模型生成上下文依赖的伪错样本，并结合多阶段渐进式训练策略，有效解决了低资源语言标注稀缺和错误模式覆盖不足的问题。在 IMLIP 2025 评测中，该方法在印尼语和越南语上的检测 F1 值分别达到 91.17% 和 90.36%，纠错 F1 值达到 80.35% 和 79.75%。

在样本级，本文提出基于扩散模型与对比学习的样本级数据增强方法。引入条件掩码和动态噪声调度，在生成多样化样本的同时约束语义一致性，结合对比学习重构特征空间分布。在多语言谣言检测数据集上，F1 值较最强基线提升 0.2–2.6 个百分点；在低资源情感分析的全量与少样本实验中均取得稳定增益，显著提升了少样本和长尾分布下的模型鲁棒性。

在特征级，本文提出基于最优传输与句法图网络的特征级数据增强方法。将方面-观点语义对齐建模为分布间的传输代价最小化问题，设计协同注意力机制融合句法结构与隐式语义。在通用基准数据集上，本文方法的 F1 值较最优模型最高提升 1.30 个百分点；在高度不平衡的负面实体情感识别任务中，F1 值较最优基线提升 3.38 个百分点；证明了特征级增强对细粒度语义匹配的有效性。

三项研究互为补充，系统揭示了数据增强与文本核心质量瓶颈之间的对应关系，验证了多粒度数据增强策略在破解社交媒体文本质量瓶颈方面的有效性，为低资源、高噪声场景下的自然语言处理提供了可借鉴的技术路径。

6.2 研究展望

尽管本文通过提出针对性的数据增强策略在社交媒体文本的字符去噪、样本扩增与特征对齐方面取得了一定的成果，但在面对更加复杂多变的真实网络环境时仍存在局限性。结合现阶段人工智能技术的发展趋势，未来的研究工作可从以下几个方向进一步深化：

(1) 构建三级数据增强策略协同机制

本文针对字符级、样本级及特征级三类数据增强方法，分别设计了专属优化策略，并在拼写纠错、谣言检测、低资源情感分析、方面级情感分析、负面实体情感识别五个下游任务中独立验证了各自的有效性。在此基础上，**未来可进一步探索三类增强策略的适用边界、性能增益差异及其互补性，并在统一任务框架下研究三者协同增强的可行性。**同时可设计层级化融合增强框架，实现字符去噪、样本扩增与特征对齐的端到端协同优化，从而更充分地释放多粒度数据增强技术的综合潜力。

(2) 向多模态信息融合与跨模态增强拓展

本文当前提出的增强与分析框架均局限于文本模态。然而在真实环境中，信息往往以“图-文-音”交织传播。未来将探索跨模态信息的联合对齐技术，如利用扩散模型生成图文匹配的增强数据，以进一步提升舆情监测的综合性能。

(3) 融合外部知识先验的数据增强策略

通过分析表5-4的结果表明，在面对缺乏显式情感词的隐式表达或复杂嵌套句法时，模型易出现误判。未来的特征级数据增强需超越单纯的数据分布拟合，探索将领域知识图谱或事件先验有机整合到模型中，增强模型对反讽、隐喻等复杂修辞的深度推理能力。

(4) 提升生成式大模型在特定领域的安全与可控性

尽管本文通过指令微调提升了生成质量，但生成式 AI 固有的“幻觉”在对事实性要求极高的敏感领域依然存在隐患。未来可引入基于人类反馈的强化学习与事实核查机制，确保增强样本在提升多样性的同时达到绝对的事实一致性。

参考文献

- [1] 王建明, 陈响育, 杨自忠, 等. 不同数据增强方法对模型识别精度的影响[J]. 计算机科学, 2022, 49(S1):418-423
- [2] 葛轶洲, 许翔, 杨锁荣, 等. 序列数据的数据增强方法综述[J]. 计算机科学与探索, 2021, 15(07):1207-1219
- [3] 许德龙, 林民, 王玉荣, 等. 基于大语言模型的 NLP 数据增强方法综述[J]. 计算机科学与探索, 2025, 19(06):1395-1413
- [4] V. I. Levenshtein. Binary codes capable of correcting deletions, insertions, and reversals[J]. Soviet Physics Doklady, 1966, 10(8):707-710
- [5] E. Brill, R. C. Moore. An improved error model for noisy channel spelling correction[C]//Proceedings of the 38th Annual Meeting on Association for Computational Linguistics (ACL). 2000: 286-293
- [6] S. Gu, F. Lang. A chinese text corrector based on seq2seq model[C]//2017 International Conference on Cyber-Enabled Distributed Computing and Knowledge Discovery (CyberC). 2017: 322-325
- [7] J. Devlin, M. W. Chang, K. Lee, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[C]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL). 2019: 4171-4186
- [8] S. Singh, Singh, et al. Handling real-word errors of hindi language using n-gram and confusion set[C]//Amity International Conference on Artificial Intelligence (AICAI). 2019: 433-438
- [9] A. Jain, M. Jain, et al. “uttam” an efficient spelling correction system for hindi language based on supervised learning[J]. ACM Transactions on Asian and Low Resource Language Information Processing (TALLIP), 2018, 18(1):1-26

- [10] C. J. Lin, W. C. Chu. A study on chinese spelling check using confusion sets and n-gram statistics[J]. International Journal of Computational Linguistics & Chinese Language Processing, 2015, 20(1)
- [11] D. H. Li, D. W. Peng. Spelling correction for chinese language based on pinyin-soundex algorithm[C]//2011 International Conference on Internet Technology and Applications. 2011: 1-3
- [12] 王辰成, 杨麟儿, 王莹莹, 等. 基于 Transformer 增强架构的中文语法纠错方法[J]. 中文信息学报, 2020, 34(06):106-114
- [13] X. Cheng, W. Xu, K. Chen, et al. Spellgen: Incorporating phonological and visual similarities into language models for chinese spelling check[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL). 2020: 871-881
- [14] Y. Hong, X. Yu, N. He, et al. Faspell: A fast, adaptable, simple, powerful chinese spell checker based on dae-decoder paradigm[C]//Proceedings of the 2019 Workshop on Noisy User-generated Text (W-NUT). 2019: 160-169
- [15] B. Ding, L. Yao, B. Kang, et al. Daga: Data augmentation with a generation approach for low-resource tagging tasks[C]//Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP). 2020: 6045-6057
- [16] L. Liu, H. Wu, H. Zhao. Chinese spelling correction as rephrasing language model[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2024: 18662-18670
- [17] Z. Sun, X. Li, X. Sun, et al. Chinesebert: Chinese pretraining enhanced by glyph and pinyin information[C]//Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers). 2021: 2065-2075
- [18] C. Liu, K. Zhang, J. Jiang, et al. Arm: An alignment-and-replacement module for chinese spelling check based on llms[C]//Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. 2024: 10156-10168

- [19] H. Wu, W. Wang, Y. Wan, et al. Chatgpt or grammarly? evaluating chatgpt on grammatical error correction benchmark[J]. arXiv preprint arXiv:2303.13648, 2023
- [20] K. Li, Y. Hu, L. He, et al. C-llm: Learn to check chinese spelling errors character by character[C]//Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. 2024: 5944-5957
- [21] 马灿, 黄瑞章, 任丽娜, 等. 基于大语言模型的多输入中文拼写纠错方法[J]. 计算机应用, 2025, 45(03):849-855
- [22] 王连喜, 林楠铠, 蒋盛益, 等. 印地语自然语言处理研究进展[J]. 中文信息学报, 2023, 37(05):53-69
- [23] H. T. Nguyen, T. B. Dang, L. M. Nguyen. Deep learning approach for vietnamese consonant misspell correction[C]//Computational Linguistics: 16th International Conference of the Pacific Association for Computational Linguistics, PACLING 2019. 2020: 497-504
- [24] K. K. Purnamasari, I. S. Suwardi. Rule-based part of speech tagger for indonesian language[J/OL]. IOP Conference Series: Materials Science and Engineering, 2018, 407(1). DOI: 10.1088/1757-899X/407/1/012151
- [25] L. Jiang, H. Wu, H. Zhao, et al. Chinese spelling corrector is just a language learner[C]//Findings of the Association for Computational Linguistics ACL 2024. 2024: 6933-6943
- [26] N. Luitel, N. Bekoju, A. K. Sah, et al. Contextual spelling correction with language model for low-resource setting[C]//2024 International Conference on Inventive Computation Technologies (ICICT). 2024: 582-589
- [27] 张一珂, 张鹏远, 颜永红. 基于对抗训练策略的语言模型数据增强技术[J/OL]. 自动化学报, 2018, 44(05):891-900. DOI: 10.16383/j.aas.2018.c170464
- [28] J. Wei, K. Zou. Eda: Easy data augmentation techniques for boosting performance on text classification tasks[C]//Proceedings of the 2019 Conference on

- Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing. 2019: 6382-6388
- [29] A. Karimi, L. Rossi, A. Prati. Aeda: An easier data augmentation technique for text classification[C]//Findings of the Association for Computational Linguistics: EMNLP 2021. 2021: 2748-2754
- [30] R. Sennrich, B. Haddow, A. Birch. Neural machine translation of rare words with subword units[C]//Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (ACL). 2016: 1715-1725
- [31] J. Ayoub, X. J. Yang, F. Zhou. Combat covid-19 infodemic using explainable natural language processing models[J]. Information Processing & Management, 2021, 58(4):102569
- [32] A. Anaby-Tavor, B. Carmeli, E. Goldbraich, et al. Do not have enough data? deep learning to the rescue![C]//Proceedings of the AAAI conference on artificial intelligence: volume 34. 2020: 7383-7390
- [33] 刘彤, 刘琛, 倪维健. 多层次数据增强的半监督中文情感分析方法[J]. 数据分析与知识发现, 2021, 5(05):51-58
- [34] 曾子明, 张瑜. 基于数据增强和多任务学习的突发公共卫生事件谣言识别研究[J]. 数据分析与知识发现, 2023, 7(11):56-67
- [35] X. Chen, D. Zhu, D. Lin, et al. Rumor knowledge embedding based data augmentation for imbalanced rumor detection[J]. Information Sciences, 2021, 580: 352-370
- [36] A. S. Karnyoto, C. Sun, B. Liu, et al. Augmentation and heterogeneous graph neural network for aaai2021-covid-19 fake news detection[J]. International journal of machine learning and cybernetics, 2022, 13(7):2033-2043
- [37] M. Askarizade. Enhancing rumor detection with data augmentation and generative pre-trained transformer[J]. Expert Systems with Applications, 2025, 262: 125649

- [38] 蒋超, 朱学芳. 基于 GPT-4 数据增强与对比学习的多模态谣言检测研究[J]. 图书情报工作, 2024(23):76-87
- [39] Z. Chen, L. Wang, Y. Wu, et al. An effective deployment of diffusion lm for data augmentation in low-resource sentiment classification[C]//Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. 2024: 1844-1856
- [40] 王连喜, 廖信峰, 陈宣齐, 等. 基于扩散模型数据增强的突发公共卫生事件谣言检测研究[J]. 情报杂志, 2025, 44(11):188-197
- [41] J. Ma, W. Gao, K.-F. Wong. Detect rumors on twitter by promoting information campaigns with generative adversarial learning[C]//The World Wide Web Conference. 2019: 3049-3055
- [42] Q. Xie, Z. Dai, E. Hovy, et al. Unsupervised data augmentation for consistency training[C]//Advances in Neural Information Processing Systems (NeurIPS): volume 33. 2020: 6256-6268
- [43] 李阳, 王石, 朱俊武, 等. 方面级情感分析综述[J]. 计算机科学, 2023, 50(S1): 34-40
- [44] V. Verma, A. Lamb, C. Beckham, et al. Manifold mixup: Better representations by interpolating hidden states[C]//International Conference on Machine Learning (ICML). : PMLR, 2019: 6438-6447
- [45] J. Chen, Z. Yang, D. Yang. Mixtext: Linguistically-informed interpolation of hidden space for text classification[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL). 2020: 2147-2157
- [46] P. Li, P. Li, X. Xiao. Aspect-pair supervised contrastive learning for aspect-based sentiment analysis[J]. Knowledge-Based Systems, 2023, 274:110648
- [47] L. Xu, H. Xie, S. J. Qin, et al. Exploring chatgpt-based augmentation strategies for contrastive aspect-based sentiment analysis[J]. IEEE Intelligent Systems, 2025, 40(1):69-76

- [48] Y. Rong, W. Huang, T. Xu, et al. Dropedge: Towards deep graph convolutional networks on node classification[J]. International Conference on Learning Representations, 2020, 8:1-18
- [49] K. Ding, Z. Xu, H. Tong, et al. Data augmentation for deep graph learning: A survey[J]. ACM SIGKDD Explorations Newsletter, 2022, 24(2):61-77
- [50] Y. Liu, Y. Jin, et al. Graph augmentation for document classification with graph neural networks[J]. Information Processing & Management, 2022, 59(1):102758
- [51] L. Ribeiro, C. Gardent, I. Gurevych. Investigating data augmentation for amr-to-text generation[J]. Proceedings of the International Conference on Computational Linguistics, 2020, 28:6244-6258
- [52] Z. Wang, J. Zhang, et al. Knowledge graph-augmented language models for complex text classification[J]. Knowledge-Based Systems, 2022, 252:109403
- [53] L. Zhang, Y. Wang, et al. Dynamic graph convolutional networks with attention mechanism for aspect-level sentiment analysis[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2021, 30:260-271
- [54] D. Ma, S. Li, X. Zhang, et al. Interactive attention networks for aspect-level sentiment classification[C]//Proceedings of the 26th International Joint Conference on Artificial Intelligence. 2017: 4068-4074
- [55] J. Wang, J. Li, S. Li, et al. Aspect sentiment classification with both word-level and clause-level attention networks[C]//Proceedings of the 27th International Joint Conference on Artificial Intelligence. 2018: 4439-4445
- [56] F. Fan, Y. Feng, D. Zhao. Multi-grained attention network for aspect-level sentiment classification[C]//Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing. 2018: 3433-3442
- [57] A. Nazir, Y. Rao, L. Wu, et al. Iaf-lg: An interactive attention fusion network with local and global perspective for aspect-based sentiment analysis[J]. IEEE Transactions on Affective Computing, 2022, 13(4):1730-1742

- [58] P. Chen, Z. Sun, L. Bing, et al. Recurrent attention network on memory for aspect sentiment analysis[C]//Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing. 2017: 452-461
- [59] X. Li, L. Bing, W. Lam, et al. Transformation networks for target-oriented sentiment classification[C]//Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2018: 946-956
- [60] H. Tang, D. Ji, C. Li, et al. Dependency graph enhanced dual-transformer structure for aspect-based sentiment classification[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. 2020: 6578-6588
- [61] C. Zhang, Q. Li, D. Song. Aspect-based sentiment classification with aspect-specific graph convolutional networks[C]//Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP). 2019: 4568-4578
- [62] J. Yi, X. Wu, X. Liu. Context-guided and syntactic augmented dual graph convolutional network for aspect-based sentiment analysis[C]//Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2024: 12401-12405
- [63] H. Wu, C. Huang, S. Deng. Improving aspect-based sentiment analysis with knowledge-aware dependency graph network[J]. Information Fusion, 2023, 92: 289-299
- [64] Y. Zheng, X. Li. You only read once: Constituency-oriented relational graph convolutional network for multi-aspect multi-sentiment classification[C]//Proceedings of the AAAI Conference on Artificial Intelligence: volume 38. 2024: 19715-19723
- [65] P. Wang, L. Tao, M. Tang, et al. Incorporating syntax and semantics with dual graph neural networks for aspect-level sentiment analysis[J]. Engineering Applications of Artificial Intelligence, 2024, 133:108101

- [66] X. Zhao, H. Peng, Q. Dai, et al. Rdgcn: Reinforced dependency graph convolutional network for aspect-based sentiment analysis[C]//Proceedings of the 17th ACM International Conference on Web Search and Data Mining (WSDM). 2024: 976-984
- [67] X. Wang, L. Liu, Z. Chen, et al. Graph convolutional network based on self-attention variational autoencoder and capsule contrastive learning for aspect-based sentiment analysis[J]. Expert Systems with Applications, 2025, 279: 127172
- [68] K. Wang, W. Shen, Y. Yang, et al. Relational graph attention network for aspect-based sentiment analysis[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. 2020: 3229-3238
- [69] H. Wu, Z. Zhang, S. Shi, et al. Phrase dependency relational graph attention network for aspect-based sentiment analysis[J]. Knowledge-Based Systems, 2022, 236:107736
- [70] R. Li, H. Chen, F. Feng, et al. Dual graph convolutional networks for aspect-based sentiment analysis[C]//Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers). 2021: 6319-6329
- [71] M. Cuturi. Sinkhorn distances: Lightspeed computation of optimal transport[C]//Advances in Neural Information Processing Systems: volume 26. 2013
- [72] H. Han, M. Luo, H. Liu, et al. A unified optimal transport framework for cross-modal retrieval with noisy labels[J]. IEEE Transactions on Neural Networks and Learning Systems, 2025
- [73] Z. Min, B. Liu, L. Zhang, et al. Exploring optimal transport-based multi-grained alignments for text-molecule retrieval[C]//Proceedings of the IEEE International Conference on Bioinformatics and Biomedicine (BIBM). 2024: 2317-2324

- [74] X. Liao, X. Chen, L. Wang, et al. Otesgn: Optimal transport-enhanced syntactic-semantic graph networks for aspect-based sentiment analysis[C]//arXiv preprint arXiv:2509.08612. 2025
- [75] Y. Wang, N. Yang, D. Miao, et al. Aspect-guided multi-graph convolutional networks for aspect-based sentiment analysis[J]. *Data Intelligence*, 2024, 6(3): 771-791
- [76] 陈壮, 钱铁云, 李万理, 等. 低资源方面级情感分析研究综述[J]. *计算机学报*, 2023, 46(07):1445-1472
- [77] 刘晓明, 李丞正旭, 吴少聪, 等. 文本分类算法及其应用场景研究综述[J]. *计算机学报*, 2024, 47(06):1244-1287
- [78] 桂韬, 奚志恒, 郑锐, 等. 基于深度学习的自然语言处理鲁棒性研究综述[J]. *计算机学报*, 2024, 47(01):90-112
- [79] Z. He, T. Sun, Q. Tang, et al. Diffusionbert: Improving generative masked language models with diffusion models[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistic. 2023: 4521-4534
- [80] M. Mirza, S. Osindero. Conditional generative adversarial nets[J]. arXiv preprint arXiv:1411.1784, 2014
- [81] S. D. Das, A. Basak, S. Dutta. A heuristic-driven ensemble framework for covid-19 fake news detection[C]//Combating Online Hostile Posts in Regional Languages during Emergency Situation: First International Workshop. 2021: 164-176
- [82] A. R. Mahlous, A. Al-Laith. Fake news detection in arabic tweets during the covid-19 pandemic[J]. *International Journal of Advanced Computer Science and Applications*, 2021, 12(6):778-788
- [83] J. Mattern, Y. Qiao, E. Kerz, et al. Fang-covid: A new large-scale benchmark dataset for fake news detection in german[C]//Proceedings of the fourth workshop on fact extraction and Verification. 2021: 78-91

- [84] C. Yang, X. Zhou, R. Zafarani. Checked: Chinese covid-19 fake news dataset [J]. *Social Network Analysis and Mining*, 2021, 11(1):58
- [85] J. Devlin, M. Chang, K. Lee, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[C]//*Proceedings of naacL-HLT*. 2019: 4171-4186
- [86] Y. Liu. Roberta: A robustly optimized bert pretraining approach[J]. *arXiv preprint arXiv:1907.11692*, 2019, 364
- [87] M. Müller, M. Salathé, P. E. Kummervold. Covid-twitter-bert: A natural language processing model to analyse covid-19 content on twitter[J]. *Frontiers in artificial intelligence*, 2023, 6:1023281
- [88] W. Antoun, F. Baly, H. Hajj. Arabert: Transformer-based model for arabic language understanding[C]//*Proceedings of the 4th Workshop on Open-Source Arabic Corpora and Processing Tools, with a Shared Task on Offensive Language Detection*. 2020: 9-15
- [89] M. Abdul-Mageed, A. R. Elmadany. Arbert & marbert: Deep bidirectional transformers for arabic[C]//*Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing*. 2021: 7088-7105
- [90] W. S. Paka, R. Bansal, A. Kaushik, et al. Cross-sean: A cross-stitch semi-supervised neural attention model for covid-19 fake news detection[J]. *Applied Soft Computing*, 2021, 107:107393
- [91] Q. Nan, J. Cao, Y. Zhu, et al. Mdfend: Multi-domain fake news detection[C]//*Proceedings of the 30th ACM International Conference on Information & Knowledge Management*. 2021: 3343-3347
- [92] Q. Yang, H. Alamro, S. Albaradei, et al. Senwave: Monitoring the global sentiments under the covid-19 pandemic[J]. *arXiv preprint arXiv:2006.10842*, 2020
- [93] A. L. Maas, R. E. Daly, P. T. Pham, et al. Learning word vectors for sentiment analysis[C]//*Proceedings of the 49th Annual Meeting of the Association for Computational Linguistics: Human Language Technologies*. 2011: 142-150

- [94] S. Shleifer. Low resource text classification with ulmfit and backtranslation[J]. arXiv preprint arXiv:1903.09244, 2019
- [95] B. Guo, Y. Gong, Y. Shen, et al. Genius: Sketch-based language model pre-training via extreme and selective masking for text generation and augmentation [J]. arXiv preprint arXiv:2211.10330, 2022
- [96] N. Ng, K. Cho, M. Ghassemi. Ssmba: Self-supervised manifold based data augmentation for improving out-of-domain robustness[C]//Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP). 2020: 1268-1283
- [97] H. H. Kim, D. Woo, S. J. Oh, et al. Alp: Data augmentation using lexicalized pcfgs for few-shot text classification[C]//Proceedings of the aaai conference on artificial intelligence: volume 36. 2022: 10894-10902
- [98] H. Zheng, Q. Zhong, L. Ding, et al. Self-evolution learning for mixup: Enhance data augmentation on few-shot text classification tasks[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. 2023: 8964-8974
- [99] H. Zhang, M. Cisse, Y. N. Dauphin, et al. mixup: Beyond empirical risk minimization[J]. arXiv preprint arXiv:1710.09412, 2017
- [100] J. Chen, R. Zhang, Z. Luo, et al. Adversarial word dilution as text data augmentation in low-resource regime[C]//Proceedings of the AAAI Conference on Artificial Intelligence: volume 37. 2023: 12626-12634
- [101] Z. Zhang, Z. Zhou, Y. Wang. Ssegcn: Syntactic and semantic enhanced graph convolutional network for aspect-based sentiment analysis[C]//Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. 2022: 4916-4925
- [102] M. Pontiki, D. Galanis, H. Papageorgiou, et al. Semeval-2016 task 5: Aspect based sentiment analysis[C]//Proceedings of the 10th International Workshop on Semantic Evaluation (SemEval-2016). 2016: 19-30

- [103] L. Dong, F. Wei, C. Tan, et al. Adaptive recursive neural network for target-dependent twitter sentiment classification[C]//Proceedings of the 52nd Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers). 2014: 49-54
- [104] C. Huang, X. Li, X. Zheng, et al. Hierarchical and position-aware graph convolutional network with external knowledge and prompt learning for aspect-based sentiment analysis[J]. Expert Systems with Applications, 2025, 278:127290
- [105] D. Huang, L. Ren, Z. Li. Enhancing aspect-based sentiment analysis with linking words-guided emotional augmentation and hybrid learning[J]. Neurocomputing, 2025, 612:128705
- [106] P. Zhou, Z. Wang, D. Chong, et al. Mets-cov: a dataset of medical entity and targeted sentiment on covid-19 related tweets[C]//Proceedings of the 36th International Conference on Neural Information Processing Systems. 2022: 21916-21932
- [107] C. Chen, Z. Teng, Y. Zhang. Inducing target-specific latent structures for aspect sentiment classification[C]//Proceedings of the 2020 conference on empirical methods in natural language processing. 2020: 5596-5607
- [108] C. Chen, Z. Teng, Z. Wang, et al. Discrete opinion tree induction for aspect-based sentiment analysis[C]//Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics. 2022: 2051-2064
- [109] W. Xi, X. Huang, F. Fukumoto, et al. Multi-feature and multi-channel gens for aspect based sentiment analysis[C]//International Conference on Database and Expert Systems Applications. : Springer Nature Switzerland, 2023: 158-172
- [110] L. Hou, W. Tu, T. Yu, et al. Aspect-based sentiment analysis for covid-19: A heterogeneous graph convolutional network approach[J]. ACM Transactions on Asian and Low-Resource Language Information Processing, 2025, 24(6):1-26

致 谢

岁月不居，时节如流。十九载寒窗，弹指已然收官。此刻静坐窗前，鼠标划过论文定稿的页面，才惊觉青春里的漫漫求学路，即将行至终章。一路走来，风雨兼程，所幸前路有光。我何其有幸，在知识求索与人格修行的路上，遇见了诸多予以指引、伸出援手的良师益友。值此论文付梓之际，谨向生命中照亮我前行之路的每一束光，致以最诚挚的谢意！

自儿时懵懂启蒙，“读书至重”便深深烙印于心。初中勤勉，是为叩响重点高中之门；高中苦读，是为奔赴理想大学之约；考研拼搏，是为追寻更高学术之境。我曾一度将求学的终极意义，简单等同于一份体面的工作、一份安稳的收入。然当这些阶段性目标次第达成，我才恍然醒悟，读书赋予我的，远不止物质层面的回报，更是眼界的开阔、心智的成熟与精神的丰盈。

回望这条路，作为家族首位研究生，我深切体味着农村学子求学之路的坎坷与艰辛。人生每一个关键岔路口，皆无成法可依、无前辈引路，唯有独自摸索、踽踽前行。常言道，人生如棋，落子无悔，而于独自承担所有风险与抉择的行路者而言，每一步落子都格外沉重。困顿迷茫时，常与自我对话；彷徨无措时，唯以坚守自勉。所幸，那些独自跋涉的时光，终沉淀为成长的底气与前行的力量，如今我已顺利录取为博士研究生，即将开启学术之路的全新征程，望向未来，眼底多是坦荡与光明。

落其实者思其树，饮其流者怀其源。特别感谢我的国家。作为从赣南苏区小山村里一步步走出的学子，近二十载求学之路，我的学习与生活离不开国家的扶持与托举。正是国家完备的奖助学政策，让我的家庭得以支撑我从启蒙入学走到硕士收官，更让我有勇气继续奔赴博士阶段的学术求索，心无旁骛地追逐理想。

学贵得师，亦贵得友。首先要向我的硕士生导师王连喜教授，致以崇高的敬意与最诚挚的谢意。您是我的良师，更是我学术道路上的引路人。硕士三年，您不仅在学业上为我传授专业知识，更在生活中教会我诸多为人处世的道理。您所秉持的与人为善、不骄不躁的处世准则，让我在治学与立身两方面都受益匪浅。我定会将这份教诲铭记于心，在科研路上稳步前行。同时，向蒋盛益教授致以诚挚的谢意。先生不仅是我导师的授业恩师，更是我们所有师门后辈的精神榜样，先生深厚的学术积淀与谦和的长者之风，始终为我们树立着治学与为人的标杆。

与此同时，我由衷感谢官全龙教授与饶洋辉副教授。在我硕士生涯收官、申博之路的关键节点，两位老师给予了我悉心的指引、充分的认可与宝贵的支持，助力我顺利录取为博士研究生，得以奔赴更广阔的科研天地。特别感谢我的师兄林楠铠博士，是您在我科研最低谷的时候拉了我一把，让我重拾对科研的信心与希望，在我迷失方向时帮我找回初心，我才得以一步步走到今天。同样由衷感谢黄锡轩师兄，从相识至今，您始终无私地给予我帮助与指引，让我在一次次遇到难题时豁然开朗。

感谢数据挖掘实验室与科研团队全体成员。何其有幸，能与大家一同并肩奋斗、一同成长，在这段奔赴理想时光里，留下了诸多珍贵而美好的回忆。三年来，实验室浓厚的学术氛围与开放的交流环境，为我的科研学习提供了绝佳的成长平台。特别感谢李旭明、徐颂喜等各位同门，以及田宇甲和陈卓玮师弟，每一次组会上的观点碰撞、每一次攻坚时的互帮互助，都让我受益匪浅。感恩这段同心共济的岁月，祝愿各位同窗前路坦荡，未来可期。

少年结意气，白首不相违。由衷感谢我的挚友钟海峰、肖秋香与余平。十余载春秋流转，从青涩相识到如今各赴征程，感谢你们跨越山海的始终相伴，让我深知无论走出多远，总有一份牵挂与支持，永远为我停留。还要致谢我科研路上的知己、学术上的同行伙伴陈宣齐。硕士三载，我们一同在科研的迷雾中摸索，一同为论文定稿并肩攻坚，一同在人生的岔路口彼此鼓劲。感谢一路以来的认可、鼓励与毫无保留的支持，这段并肩同行的时光，我将永远铭记于心。更要致谢朝夕相伴三载的室友游卓凡、雷明琦与周书柏。感谢你们在细碎日常里的包容，在学业上的互助，在生活里的照拂。三年晨昏相伴，一室温暖如常，你们给我的不仅是同窗之谊，更是异乡求学路上，最踏实的归属感。

此外，我要特别感谢我的女友，谢芳同志。自高中相识，大学相恋，至今已相伴十余载。漫漫求学之路，从本科到硕士，从考研备考到论文定稿，再到申博路上的辗转奔波，人生的每一段重要旅程，都有她不离不弃的陪伴与始终如一的理解。感谢她陪我走过风雨，见证我的成长，是她的温暖与坚定，让我能心无旁骛地奔赴学业与理想。

行文至此，最想致以最深切、最由衷谢意的，是生我养我的父母、一路支持我的姐姐，以及所有牵挂我的家人。我最亲爱的父母，特别感谢你们一直以来对我的理解、包容、爱护和支持。我人生的每一步成长，都离不开你们的默默付出与全力托举。还要感谢我的姐姐廖慧敏。如今身为优秀教师的你，在我多次面临人生抉择、徘徊犹豫之时，为我厘清方向，力排众议支持我坚定前行，这份血脉

相连的陪伴与懂得，是我前行路上珍贵的力量。感恩所有家人的牵挂与照拂，你们的期盼与信任，是我穿越所有坎坷、始终勇往直前的底气。

本研究的开展与论文的顺利完成，得到了国家社会科学基金一般项目《突发公共卫生事件舆情中网民负面情绪检测及引导研究》、国家语委科研基金项目《面向“一带一路”经贸合作的紧缺语言资源建设研究》、广东省教育部教育专项项目《协同语言学视角下生成式 AI 可控性评估与优化研究》的资助，在此谨致以诚挚的谢意。

最后，向在百忙之中抽空审阅本论文并提出宝贵意见的评审专家和老师们表示衷心的感谢！

最后的最后，我想感谢我自己。一树树花开，一片片叶落；一段段山路，一次次离别。脚下走过的是滚烫的青春，心底藏着的是绵长的思念。感谢自己，走过一路风雨艰辛，依然保有对生活的热爱；穿行无数漫漫黑夜，依然始终相信前路的曙光；在无人引路的岔路口，敢独自落子、敢奔赴未知，从乡村少年走到硕士收官，更即将开启博士阶段的全新征程。

愿此后，依然坚定初心，步履不息。

廖信峰

2026 年 5 月 22 日

在学期间的科研成果及发表的论文

一、主要学术论文（已录用/发表）

- [1] 王连喜, 廖信峰, 蒋盛益 * 等. 多模态情感分析: 研究全景、技术演进与生成式重构 [J]. 《计算机学报》. (CCF A 类中文期刊录用, 第二作者/导师一作)
- [2] Liao X, Chen X, Wang L*, et al. OTESGN: Optimal Transport Enhanced Syntactic-Semantic Graph Networks for Aspect-Based Sentiment Analysis[C]. *IEEE International Conference on Data Mining (ICDM)*, 2025. (Main Conference Long Paper, CCF B 类, 第一作者)
- [3] Liao X, Xu J, Huang X, et al. A Multistage Framework for Spelling Correction in Low-Resource Languages with Data Augmentation and Prompt Learning[J]. *Data Intelligence*. (中科院二区期刊, 第一作者)
- [4] 王连喜, 廖信峰, 等. 基于扩散模型数据增强的突发公共卫生事件谣言检测研究 [J]. 《情报杂志》, 2025: 1–11. (中文核心期刊发表, 第二作者/导师一作)
- [5] Chen X, Rong Z, Liao X, et al. ModalSyncSum: Synchronizing Image and Text for Reliable Summary Generation[C]. *Association for the Advancement of Artificial Intelligence (AAAI)*, 2025. (Main Conference Long Paper, CCF A 类, 第三作者)
- [6] Chen X, Rong Z, Liao X. TRAC: Token-level Reward Assignment for Coherent Abstractive Summarization.[C]. *Annual Meeting of the Association for Computational Linguistics (ACL)*, 2026. (findings track of ACL, CCF A 类, 第三作者)
- [7] Chen Z, Wang L*, Wu Y, Liao X, et al. An Effective Deployment of Diffusion LM for Data Augmentation in Low-Resource Sentiment Classification[C]. *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2024: 1844–1856. (Main Conference Long Paper, CCF B 类, 第四作者)
- [8] Tian Y, Liao X, Li M, et al. MGTS: An Efficient Method for Constructing Multilingual Entity-Opinion Sentiment Triples[C]. *2025 7th International Conference on Natural Language Processing (ICNLP)*, IEEE, 2025: 150–154. (EI 会议, 第

二作者)

- [9] Chen X, Fu P, **Liao X**, et al. A Framework for Portuguese Multimodal Summarization with Fine-Grained Visual Feature Extraction[C]. *2025 7th International Conference on Natural Language Processing (ICNLP)*, IEEE, 2025: 586–594. (EI 会议, 第三作者)
- [10] 王连喜, 刘宇康, 杨家欢, **廖信峰**. 融合特征图注意力和边界监督的嵌套命名实体识别方法 [C]. *2025 International Conference on Multilingual Intelligent Information Processing (IMLIP)*, 2025. (EI 会议, 第四作者)
- [11] Fu P, Chen X, **Liao X**, et al. HI-MMNet: Enhancing Hindi Multimodal Summarization with Image Segmentation and Cross-modal Interaction[C]. *2026 8th International Conference on Natural Language Processing (ICNLP)*, IEEE. (EI 会议, 第三作者)

二、已投稿/在审学术论文

- [1] **Liao X**, Chen X, Wang L*, et al. Feature-Level Enhanced Syntactic-Semantic Graph Networks via Optimal Transport for Aspect-Based Sentiment Analysis[J]. *Knowledge and Information Systems (KAIS)*. (2026 年 04 月一审意见修回, CCF B 类, 第一作者)
- [2] Lin N, Wang L; **Liao X**, et al. Entropy-guided Graph Structure Optimization for Multimodal Aspect Sentiment Classification.[J]. *Transactions on Knowledge and Data Engineering(TKDE)*. (2026 年 03 月投稿, SCI 一区 top, 第五作者)
- [3] Lin N, Zhou H; **Liao X***. DuOT: Dual Optimal Transport for Multimodal Aspect-Based Sentiment Analysis.[J]. *Information Processing & Management(IPM)*. (2026 年 05 月投稿, SCI 一区 top, 通讯作者)
- [4] Lin N, Wang L; **Liao X**, et al. ECMSA: Entropy-Constrained Dual Alignment for Multimodal Sentiment Analysis.[J]. *ACM MM*. (2026 年 03 月投稿, CCF-A 会议, 第四作者)
- [5] 王连喜, **廖信峰**, 等. 基于数据增强与句法-语义感知注意力的目标实体负面情感检测 [J]. 《智能科学与技术学报》. (2026 年 04 月一审意见修回, 第二作者/导师一作)

三、参与/负责的科研项目

- [1] 突发公共卫生事件舆情中网民负面情绪检测及引导研究. 国家社会科学基金项目 (参与)
- [2] 基于大语言模型与图卷积网络的多模态方面级情感分析研究. 校级科研创新项目 (负责人)
- [3] 面向“一带一路”经贸合作的紧缺语言资源建设研究. 国家语委基金项目 (参与)
- [4] 协同语言学视角下生成式 AI 可控性评估与优化研究. 广东省教育专项项目 (参与)

四、主要竞赛获奖

- [1] 2024 年“华为杯”第二十一届中国研究生数学建模竞赛二等奖, 队长
- [2] 2025 年“华为杯”第二十二届中国研究生数学建模竞赛三等奖, 队长
- [3] 2025 年美国大学生数学建模竞赛 S 奖, 队长
- [4] 2025 年 IMLIP 小语种拼写纠错“印尼语检错”赛道一等奖
- [5] 2025 年 IMLIP 小语种拼写纠错“印尼语纠错”赛道一等奖
- [6] 2025 年 IMLIP 小语种拼写纠错“越南语检错”赛道一等奖
- [7] 2025 年 IMLIP 小语种拼写纠错“越南语纠错”赛道一等奖

五、计算机软件著作权

- [1] 机票价格分析与预测系统. 中华人民共和国国家版权局, 2024SR0670830, 2024 年 5 月 17 日 (第一完成人)
- [2] 自然语言语义分析系统. 中华人民共和国国家版权局, 2024SR0790359, 2024 年 6 月 11 日 (第一完成人)
- [3] 基于特定人物的多语种言论提取及涉华识别系统. 中华人民共和国国家版权局, 2024SR0071548, 2024 年 1 月 10 日 (共同完成人)